

西安电子科技大学

硕士学位论文



基于多模态注意力融合的语音情感识别方法
研究

作者姓名 王媛媛

指导教师姓名、职称 任博 副教授

申请学位类别 工学硕士

学校代码 10701
分类号 TP391

学号 21171213876
密级 公开

西安电子科技大学

硕士学位论文

基于多模态注意力融合的语音情感识别方法 研究

作者姓名：王媛媛

一级学科：计算机科学与技术

二级学科（研究方向）：

学位类别：工学硕士

指导教师姓名、职称：任博 副教授

学 院：人工智能学院

提交日期：2024年6月

Research on Speech Emotion Recognition Method Based on Multimodal Attention Fusion

A Thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Computer Science and Technology

By
Wang Yuanyuan
Supervisor: Ren Bo Title: Associate Professor
June 2024

摘要

语音情感识别是认知计算的一个分支,旨在从语音中鉴别出说话人的情感状态。随着对人机交互和情感交互需求的增加,语音情感识别有着广泛的应用,例如车载系统、医疗行业、客服中心和抑郁症诊断等。虽然语音能够独立地传递情感,但情感的表达是多模态的,人们会通过不同的模态信息进行沟通,例如语音语调、文本语义和面部表情等。而且单模态的信息量不足,很容易受到环境噪声和说话人无关信息等因素的干扰。仅靠单一的语音模态来进行情感识别的结果可能是准确度受限且片面的。因此,基于多种模态融合信息的语音情感识别有望优于仅基于语音的情感识别。而在多模态研究领域,很难对不同模态的信息进行综合表示,并且对于捕捉不同模态之间的内在联系也面临挑战。

因此本论文致力于探讨基于多模态融合的语音情感识别方法,旨在提高情感识别系统的表达能力和鲁棒性。本文使用了语音、语音+文本以及语音+文本+视频的三种组合,分别从特征、多模态信息交互和语境建模的角度提出了三种不同的融合架构。具体地,针对每一种模态组合的特性,提出了相应的注意力机制去进行动态融合,充分利用多模态数据中的信息,实现更精确、更全面的情感识别。

首先,针对单一特征无法充分捕捉到语音信号中丰富的情感信息的问题,本文提出了多级声学信息分层融合架构。其通过结合不同级别声学信息,即梅尔谱图、梅尔频率倒谱系数和自监督特征,获得更全面和多样化的语音特征,从多个角度对情感进行建模。在此基础上,将其转化为多模态融合问题。通过使用本文提出的分层注意力机制,更细致地整合特征,使模型能够同时捕捉高级别的全局特征和低级别的局部特征,从而能够更好地适应不同的语音输入和情感状态以提升模型的表现力和泛化能力。

其次,针对语音信号中环境噪声和语速变化等信息的干扰以及跨模态特征融合问题,本文提出了多模态级联增强融合架构。其以语音模态为主导,引入文本模态作为辅助信息去级联增强语音模态。通过充分利用文本模态的信息,减轻环境噪声等因素对语音情感识别的干扰。其中的模型融合模块,使用多个多头交叉注意力机制的组合实现跨模态特征融合。通过学习不同模态之间的相互关系,动态地调整融合策略,从而更好地捕捉跨模态特征之间的多样性和复杂性,提高了模型对多模态数据的表征能力。

最后,针对忽略了上下文句子之间的依赖关系和模型对个体差异的适应能力较弱问题,本文提出了上下文信息动态融合架构。其旨在对语境关系进行建模,充分利用上下文提供的线索,同时消除个人无关信息对情感识别的影响。本文提出了一

种上下文感知动态注意力机制，能够使模型根据上下文和输入数据的特性进行动态调整。从而有效地关注那些对情感分类具有关键作用的句子，增强模型对整体语义结构的理解能力。同时利用特征解耦模块实现情感特征和说话人特征的分离，提高个体不可知情绪表示的鲁棒性。

通过在公开的语音情感数据库上进行大量的对比实验和消融实验，验证了本文提出的各种架构在情感识别任务中的有效性，同时为多模态领域的发展提供了新的思路和方法。

关键词：语音情感识别， 多模态融合， 注意力机制， 情感表征， 跨模态交互， 上下文信息

ABSTRACT

Speech emotion recognition is a branch of cognitive computing, which aims to identify the emotional state of the speaker from the speech. With the increasing demand for human-computer interaction and emotional interaction, speech emotion recognition has a wide range of applications, such as in-vehicle systems, medical industry, customer service centers, and depression diagnosis. Although speech can transmit emotions independently, the expression of emotions is multimodal, and people will communicate through different modal information, such as speech tone, text semantics and facial expressions. Moreover, the amount of information in the single mode is insufficient, and it is easily disturbed by factors such as environmental noise and speaker irrelevant information. The results of emotion recognition based on a single speech modality may be limited in accuracy and one-sided. Therefore, speech emotion recognition based on multimodal fusion information is expected to be better than speech-only emotion recognition. In the field of multimodal research, it is difficult to comprehensively represent the information of different modalities, and it is also challenging to capture the internal relations between different modalities.

Therefore, this paper is devoted to exploring the speech emotion recognition method based on multimodal fusion, aiming at improving the expression ability and robustness of the emotion recognition system. This paper uses three combinations of speech, speech + text and speech + text + video, and proposes three different fusion architectures from the perspectives of features, multimodal information interaction and context modeling. Specifically, according to the characteristics of each modal combination, a corresponding attention mechanism is proposed to perform dynamic fusion, making full use of the information in multimodal data to achieve more accurate and comprehensive emotion recognition.

Firstly, aiming at the problem that a single feature cannot fully capture the rich emotional information in the speech signal, this paper proposes a multi-level acoustic information hierarchical fusion architecture. By combining different levels of acoustic information, namely Mel spectrogram, Mel-frequency cepstral coefficients and self-supervised features, it obtains more comprehensive and diversified speech features to model emotions from multiple perspectives. On this basis, it is transformed into a multimodal fusion problem. By using the hierarchical attention mechanism proposed in this paper, the features are integrated more

carefully, so that the model can capture high-level global features and low-level local features at the same time, which can better adapt to different voice input and emotional state to improve the performance and generalization ability of the model.

Secondly, aiming at the interference of information such as environmental noise and speech rate changes in speech signals and the problem of cross-modal feature fusion, this paper proposes a multimodal cascade augmented fusion architecture. It is dominated by speech modality, and introduces text modality as auxiliary information to cascade and enhance speech modality. By making full use of the information of text modality, the interference of environmental noise and other factors on speech emotion recognition is reduced. A model fusion module proposed in this paper uses a combination of multiple multi-head cross attention mechanisms to achieve cross-modal feature fusion. By learning the relationship between different modalities, the fusion strategy is dynamically adjusted, so as to better capture the diversity and complexity of cross-modal features and improve the model's ability to represent multimodal data.

Finally, aiming at the problem of ignoring the dependence between context sentences and the weak adaptability of the model to individual differences, this paper proposes a context information dynamic fusion architecture. It aims to model contextual relationships, make full use of the cues provided by the context, and eliminate the influence of personal irrelevant information on emotion recognition. This paper proposes a context-aware dynamic attention mechanism that enables the model to dynamically adjust according to the characteristics of context and input data. So as to effectively focus on those sentences that play a key role in emotion recognition, and enhance the model's ability to understand the overall semantic structure. At the same time, the feature decoupling module is used to realize the separation of emotional features and speaker features, so as to improve the robustness of individual unknowable emotion representation.

Through a large number of comparative experiments and ablation experiments on the public speech emotion databases, the effectiveness of the various architectures proposed in this paper in emotion recognition tasks is verified, and new ideas and methods are provided for the development of multimodal fields.

Keywords: Speech Emotion Recognition, Multimodal Fusion, Attention Mechanism, Emotion Representation, Cross-Modal Interaction, Context Information

插图索引

图 1.1	不同模态信息的互补性	1
图 1.2	特征级融合方式	5
图 1.3	决策级融合方式	6
图 1.4	模型级融合方式	6
图 1.5	论文结构图	7
图 2.1	情感的连续情感类型	11
图 2.2	语音情感识别流程	12
图 2.3	梅尔滤波器组	13
图 2.4	语谱图	14
图 2.5	梅尔谱图	15
图 2.6	RNN	16
图 2.7	LSTM	16
图 2.8	GRU	18
图 2.9	Attention	19
图 2.10	Transformer	20
图 3.1	MAIF架构	25
图 3.2	仅使用MFCC特征的混淆矩阵	33
图 3.3	仅使用自监督特征的混淆矩阵	34
图 3.4	仅使用梅尔谱图特征的混淆矩阵	34
图 3.5	结合三种特征 (MAIF) 的混淆矩阵	35
图 4.1	MTAF架构	37
图 4.2	语音单模态混淆矩阵	44
图 4.3	文本单模态混淆矩阵	44
图 4.4	MTAF混淆矩阵	44
图 5.1	不同的上下文信息所导致的情感识别的结果	46
图 5.2	MCAF架构	47
图 5.3	上下文感知编码器结构	48
图 5.4	特征解耦器结构	49

图 5.5	上下文句子数目为2时的混淆矩阵	55
图 5.6	上下文句子数目为3时的混淆矩阵	55
图 5.7	上下文句子数目为4时的混淆矩阵	55

表格索引

表 2.1	常用语音情感识别数据集	23
表 3.1	实验超参数设置	29
表 3.2	不同SER方法在IEMOCAP (4分类)数据集上的比较	30
表 3.3	不同SER方法在IEMOCAP (6分类)数据集上的比较	31
表 3.4	不同SER方法在Emodb数据集上的比较	31
表 3.5	模型结构的消融实验	32
表 4.1	实验超参数设置	40
表 4.2	不同SER方法在IEMOCAP (4分类)数据集上的比较	41
表 4.3	不同SER方法在IEMOCAP (6分类)数据集上的比较	41
表 4.4	不同SER方法在MELD数据集上的比较	42
表 4.5	模型结构的消融实验	43
表 5.1	实验超参数设置	51
表 5.2	不同SER方法在IEMOCAP (4分类)数据集的比较	51
表 5.3	不同SER方法在IEMOCAP (6分类)数据集的比较	52
表 5.4	不同SER方法在MOSEI (2分类)数据集的比较	53
表 5.5	不同SER方法在MOSEI (6分类)数据集的比较	53
表 5.6	模态种类的消融实验	54
表 5.7	上下文句子数目的消融实验	54
表 5.8	模型结构的消融实验	56

符号对照表

符号	符号名称
x	特征向量
x_a	语音特征向量
x_l	文本特征向量
$Loss$	损失函数
$Concat$	拼接操作
y_i	真实值
$\tilde{y}_i$	预测值
δ	ReLU激活函数
σ	sigmoid 函数
$softmax$	softmax函数
N	训练样本总数

缩略语对照表

缩略语	英文全称	中文对照
BERT	Bidirectional Encoder Representation from Transformers	双向变压器编码表征
CMU-MOSEI	CMU Multimodal Opinion Sentiment and Emotion Intensity	CMU 多模态观点情感和情感强度
CNN	Convolutional Neural Networks	卷积神经网络
CPC	Contrastive Predictive Coding	对比预测编码
DCT	Discrete Cosine Transform	离散余弦变换
DFT	Discrete Fourier Transform	离散傅里叶变换
EmoDB	Berlin Emotional Database	柏林情感数据集
GPT	Generative Pre-Trained Transformer	生成式预训练变压器
GRU	Gated Recurrent Unit	门控循环单元
HuBERT	Hidden unit Bidirectional Encoder Representation from Transformers	隐单元双向变压器编码表征
IEMOCAP	Interactive Emotional Dyadic Motion Capture	交互情感二元动作捕捉
LSTM	Long Short-Term Memory	长短时记忆网络
MAIF	Multi-level acoustic information fusion	多级声学信息分层融合
MELD	Multimodal EmotionLines Dataset	多模态情感线数据集
MTAF	Multimodal transformer augmented fusion	多模态级联增强融合
MCAF	Multimodal context adaptive fusion	多模态上下文感知融合
MFCC	Mel-Frequency Cepstral Coefficients	梅尔频率倒谱系数
NLP	Natural Language Processing	自然语言处理
PE	Positional Encoding	位置编码
ReLU	The Rectified Linear Unit	线性整流函数
RNN	Recurrent Neural Networks	循环神经网络
Seq2Seq	Sequence-to-Sequence	序列到序列
SER	Speech emotion recognition	语音情感识别
SVM	Support Vector Machine	支持向量机

Tanh	Hyperbolic tangent function	双曲正切函数
TFIDF	Term Frequency-Inverse Document Frequency	词频-逆文档频率
UA	Unweighted Accuracy	非加权准确率
VAD	Valence-Arousal-Dominance	效价-唤醒-优势
WA	Weighted Accuracy	加权准确率

目录

摘要	I
ABSTRACT	III
插图索引	V
表格索引	VII
符号对照表	VIII
缩略语对照表.....	IX
第一章 绪论	1
1.1 选题背景及意义	1
1.2 国内外研究现状	2
1.3 本文的研究内容	6
1.4 本文的组织结构	8
第二章 语音情感识别理论基础	10
2.1 情感的定义	10
2.2 情感的分类	10
2.3 语音情感识别的定义和基本流程	11
2.4 语音情感识别的基本特征	12
2.4.1 MFCC.....	12
2.4.2 语谱图	14
2.4.3 自监督特征	14
2.5 语音情感识别的主要模型	15
2.5.1 循环神经网络	15
2.5.2 注意力机制	18
2.5.3 Transformer	19
2.6 语音情感识别的数据集	21
2.7 语音情感识别的评价指标	23
2.8 本章小结	23
第三章 基于多级声学信息分层融合的语音情感识别	24
3.1 引言	24
3.2 模型结构	25
3.2.1 特征提取模块	25
3.2.2 融合模块.....	26

3.2.3	分类模块.....	28
3.3	实验设置	29
3.3.1	特征提取.....	29
3.3.2	实验实现细节	29
3.4	实验结果与分析	30
3.4.1	对比实验.....	30
3.4.2	消融实验与混淆矩阵	32
3.5	本章小结	35
第四章	基于transformer文本增强融合的语音情感识别	36
4.1	引言	36
4.2	模型结构	37
4.2.1	多模态特征提取器	37
4.2.2	模型融合模块	38
4.2.3	分类器	39
4.3	实验设置	39
4.3.1	特征提取.....	39
4.3.2	实验实现细节	39
4.4	实验结果与分析	40
4.4.1	对比实验.....	40
4.4.2	消融实验与混淆矩阵	42
4.5	本章小结	45
第五章	基于上下文信息动态融合的语音情感识别	46
5.1	引言	46
5.2	模型结构	47
5.2.1	上下文感知编码器	48
5.2.2	特征解耦器	49
5.2.3	分类器	50
5.3	实验设置	50
5.3.1	特征提取.....	50
5.3.2	实验实现细节	50
5.4	实验结果与分析	50
5.4.1	对比实验.....	50
5.4.2	消融实验与混淆矩阵	53
5.5	本章小结	56

第六章 总结与展望	57
6.1 论文工作总结	57
6.2 未来研究工作展望	58
参考文献	60
致谢	69
作者简介	70

第一章 绪论

1.1 选题背景及意义

情感是个体对外界刺激或内在感受做出的心理反应，通常表现为多种情绪和情感体验，如喜怒哀乐、焦虑、兴奋等。情感是人类心理活动的重要组成部分，影响着个体的认知、行为和决策，对人们的生活和社会交往具有重要影响^[1]。而对情感的理解和识别对于促进人类的健康、幸福和社会发展具有重要意义。

语音情感识别(Speech Emotion Recognition, SER)是情感识别的一个分支，旨在从说话人的语音中确定说话人的情感状态^[2]。随着对人机交互和情感交互需求的增加，语音情感识别的研究具有重要的现实意义和广泛的应用前景。将语音情感识别系统应用在车载系统中，可以将驾驶员的心理状态信息实时提供给车辆安全运行，确保安全行车^[3]；应用在医院等医疗行业，可以协助医生分析病患的情绪，增进医生和病人的沟通，帮助医生有效地开展病情诊断工作^[4]；应用在车站等客服中心，实时检测客户的情感状态，有助于客服人员提供更高效优质的服务来满足客户的需求^[5]。SER 也被用于帮助自闭症儿童去提高社会情感沟通技能^[6]，因为他们可能在识别和表达情绪方面遇到困难。

虽然语音能够独立地传递情感，但情感本身是一种多通道的表达，人们一般会利用多模态信息如语音、文字、面部表情等来表达情感^[7]。同时，不同模态间的互补信息也能在一个模态出现噪声时增加系统的鲁棒性，如图1.1所示。使用单模态来进行情感识别不仅片面，信息量不足，而且很容易受到环境噪声等其他因素的干扰。因此，基于多种模态融合信息的SER有望优于仅基于语音的SER^[8]。




图 1.1 不同模态信息的互补性

近年来，多模态领域的研究蓬勃发展^[9]。模态间的信息融合是多模态领域探索的重点^[10]。各个模态的形态差异大，既有各自的相对独立性，又存在着同步或异步的信息交互，如何有效的将各个模态的信息融合是研究的难点也是突破点。鉴于特

征级融合和决策级融合方式的局限性，捕获细粒度的模态交互在以往的研究中往往被忽略。与决策级和特征级融合方式相比，模型级融合能更好地利用深度神经网络的优势，更好的融合不同模态的特征，获取情感表示。若再根据实际情况适当的结合以上融合策略，就能很好的扬长避短，捕捉到更为细粒度的模态内和模态间的信息交互，充分利用不同模态的信息。

同时，上下文在确定情感内容时也起到了至关重要的作用。相同的一句话，放置在不同的语境中，可能会传达出截然不同的情感色彩。比如一句简单的“我很高兴”在不同的情境中可能表达出喜悦、惊喜、或者是一种假笑的虚假情感。因此，情感的识别需要考虑到这些上下文因素，才能更准确地理解说话者的情感表达，并且提高情感识别系统的效果和可靠性。

最后，受到注意力机制的启发，Transformer在自然语言处理领域中被提出并取得了优异的成绩^[11]，它能够很好的建模序列中的长时依赖性。尽管原始的Transformer是被提出来解决机器翻译问题的，研究者们正在积极研究其在语音信号处理领域的适应性。多头自注意机制能学习长期时间依赖，多头交叉注意力机制能够从模型级别实现不同模态特征的融合，从共同的语义特征空间产生多模态情感中间表示，从而提高语音情感识别的准确率。

1.2 国内外研究现状

随着语音情感识别研究的深入，研究人员从不同的角度去探索提高识别准确率的方法。而特征的选择，模型的设计以及利用多模态信息是目前研究最为广泛的三个方向。因此，本文通过特征、模型和多模态融合三个方面来介绍当前语音情感识别领域的国内外现状，讨论其最新进展以及存在的缺陷与挑战。

1) 特征的选择

有效的提取和选择特征是提高语音情感识别准确率的关键步骤^[12]。而语谱图，梅尔频率倒谱系数（Mel Frequency Cepstrum Coefficient, MFCC）和自监督特征是日前使用最为广泛的三种特征。它们依次提取了语音信号的时变特征，频谱特征和高级语音表示特征，为情感识别提供了丰富的信息。

MFCC通过模拟人耳特性，将声音从频率分布映射到梅尔尺度上，从而提取出梅尔频率倒谱系数^[13]。这种特征提取方法有助于捕捉语音信号中的频谱特性，能够很好的进行情感表征。研究人员通过将MFCC特征送入到GRU^[14]、LSTM^[15]和Transformer编码器^[16]中捕获时间线索以更好的捕获情感信息。

语谱图是一种将声音信号可视化的方法，显示了语音信号的能量分布，其在情感识别领域有着广泛的应用。Etienne^[17]提出了一种混合CNN-LSTM架构，其中CNN用于从原始语谱图中提取特征序列，LSTM用于聚合长期的特征依赖关系。

Zhao^[18]提出了一种基于1维和2维CNN-LSTM的SER系统。通过从语谱图中捕获局部相关性和全局上下文信息,表明2维CNN-LSTM网络优于1维CNN-LSTM网络。Li^[19]采用自注意力机制关注语谱图中情感的显著时期,提出了一种基于光谱-时间通道注意力^[20]的表示学习方法。该注意力能有效地聚焦于具有判别力的关键特征图,以及关键时间帧和频率点。Muppidi^[21]对梅尔频谱图特征的RGB域进行编码,并使用自定义的四元数卷积层在四元数空间中学习该特征。Liu^[22]研究了语谱图的局部和全局空间表示,提出了一种局部-全局感知的SER深度表示学习方法。

Xu^[23]认为情绪在不同尺度的语谱图中传达出不同的能量信息。因此,使用多尺度区域注意力可以帮助分类器更好地关注不同尺度的情感表征,从而提升情感分类准确率。Jiaxing^[24]提出了一种时频胶囊神经网络对全局信息进行建模,可以直接从语谱图中提取更稳定的全局时频信息。

自监督特征是通过使用在大规模无监督的数据上进行过预训练的模型来进行特征表示,学习到对数据的通用表达能力。在自然语言处理(Natural Language Processing, NLP)领域中,BERT^[25]和GPT^[26]等模型已经证明能够在多种任务上取得显著的效果。

在语音信号处理领域,预训练模型也被广泛应用。Wav2vec^[27]使用自监督学习方式,通过预测被掩蔽的语音来学习语音信息表示。因为不需要人工来标注数据,使得模型能够从大规模的无监督的语音样本中学习信息表征。Wav2vec 2.0^[28]是Wav2vec的升级版本。它使用了自监督对抗训练方法,将语音信号分为无声和有声两个部分,让模型学习自动对这两部分进行区分。Wav2vec2.0在语音识别任务,说话人识别和情感识别等任务上表现出优异的性能。

HuBERT^[29]结合了大规模的文本和音频数据来进行预训练,使得模型能够学习语义和语音的丰富信息。Conformer^[30]结合了Transformer的架构和卷积神经网络模型,在语音识别任务取得了卓越效果,它具有较高的识别准确率和更少的参数数量。Conformer首先使用大量的无标签的语音数据进行预训练,然后在具体任务上进行微调。在语音情感识别领域,许多研究者直接使用上述预训练的模型进行特征表示,取得了较好的效果^[31-33]。

然而先前的研究中仅使用单一语音特征或者单一多尺度特征,并不能完整地捕捉到音频信号中的所有信息。例如,MFCC主要关注的是音频的频谱特性,而忽略了短时频谱变化的信息。这会使得模型可能缺乏一些关键的情感特征,影响情感识别的准确率。同时,每种语音特征都有其缺陷和局限性。例如,MFCC对噪声敏感,语谱图对频谱分辨率有限,自监督特征的泛化能力会受到数据集规模的限制。使用单一特征可能导致模型在特定的情感表达或噪声环境下的性能较差。最后,单一特征可能对特定说话人或语言更为适用,而对于其他说话人或语言的情感识别效果较

差。因此融合多种特征可以提高模型的泛化能力,使其更适用于不同的语音数据和情感表达。综上所述,单一特征在语音情感识别任务中存在信息不足、局限性和泛化能力差等缺陷。

2) 模型的设计

近年来,研究人员发现使用含有卷积神经网络(CNN)和循环神经网络(RNN)的方法比使用传统机器学习的方法进行语音情感识别,效果有显著提升。Trigeorgis^[34]设计了一种基于CNN和LSTM的网络架构,利用CNN从声学特征中学习深度情感特征,利用LSTM学习特征中的上下文关系。Eyben^[35]构造了一个LSTM与RNN结合的SER系统,在二维情感模型基础上引入时间维度,形成了一个新的三维模型以实时评估语音中的情绪。Zhao^[36]使用一维和二维CNN结合LSTM网络进行语音情感识别,一维CNN用于学习语音的局部和全局情绪相关特征,而二维CNN用于学习梅尔频谱图的深度信息。在相似的网络架构下,二维网络的性能优于一维网络。Chen^[37]提出了一种带有注意力机制的3维卷积循环神经网络,他们使用了由静态和一阶与二阶动态特征通道组成的三维梅尔谱图作为网络输入,其中动态特征包含有效的情绪信息,减少了情绪无关因素的影响,提高了识别准确率。

接着出现了注意力机制,注意力机制可以帮助模型在处理长序列时聚焦于关键部分,这在语音情感识别中特别有用。Zhang^[38]提出注意力机制可以使模型意识到语谱图中的哪个时频区域更具有情感相关性,从而提高情感识别的准确性。Kim^[39]提出使用焦点注意力机制检测出分段中幅值最大的部分,校准注意力机制为每个注意力头分配不同的权重来调节信息流,并提高对周围上下文的利用率。Xu^[40]使用注意力机制来学习原始语音和文本之间的对齐关系,并将其用于融合两种模态的特征。

由于Transformer在自然语言处理领域中被提出并取得了优异的成绩,研究人员也将其应用到了语音情感识别领域。Transformer模型被用于学习语音信号中的全局信息和长距离依赖关系,从而提高情感识别的准确率和鲁棒性。Wang^[41]提出了一种新的融合权重共享的深度多模态Transformer网络,学习独立的时间特征并处理模态间的异步情感反映。Wang^[42]提出了一种端到端的语音情感识别架构,利用多个堆叠的transformer层去增强聚合的全局特征。Lian^[43]提出一种基于Transformer的架构来进行不同模态内部和相互之间的动态交互。

综上所述,CNN、RNN、注意力机制和Transformer模型在语音情感识别领域得到了广泛的应用。未来的研究可能会更加注重模型的轻量化和实时性,以满足实际应用的需求^[44]。

3) 多模态信息的融合

多模态融合是指为了获得更准确、更全面和更丰富的表征,而将不同模态(如语

音、文字、视频等)的信息组合在一起^[45]。在人类的感知中,我们经常会同时使用多种感官来理解和解释世界,多模态融合的概念正是受这一观点的启发而产生的。在多模态情感识别领域,研究人员主要关注的是在什么阶段去进行特征的融合。融合方法按照阶段可分为特征级融合(早期融合)、决策级融合(晚期融合)、模型级融合和混合级融合。

特征级融合将多种模态的特征直接通过拼接^[46]和相加^[47]等方式融合成通用的特征向量,利用组合后的特征进行分析,如图1.2所示。然而,这种融合方法得到的特征属于不同的模态,可能存在较大的差异。因此,在融合之前,需要将特征转换为相同的格式。并且,这种融合方式缺乏模态内的动态信息交互,高维特征集很容易受到数据稀疏性问题的影响,使得该方法容易出现模态信息冗余,导致数据过拟合。因此,特征级融合方式的优势受到限制。




图 1.2 特征级融合方式

在决策级融合过程中,如图1.3所示,对每个模态的特征进行独立的建模,最后通过集成学习^[48]、张量融合^[49]或乘法层融合^[50]等方式进行最终融合。这种融合方式的优点在于每个模态都能够使用最适合的分类器来学习其情感表征。但是,由于不同模态使用了各自的分类器,这导致了融合阶段的繁琐耗时。而且,这种融合方式没有考虑不同模态之间的相互作用和相关性,必须解决其无法捕捉细粒度模态间动态交互的问题。

模型级融合通过使用深度学习的各种模型,基于模型的中间层进行融合,如GRU^[51]、LSTM^[52]、Attention^[53]和Transformer^[54]等,来融合不同模态的特征产生情感中间表示,如图1.4所示。然而,模型级融合方法的效果主要取决于所使用的融合模型,并不能细致考虑到每种模态特征的特性。

混合级融合^[10]是前三种融合方法的结合,因此最为复杂。Sebastian^[55]提出了早期和晚期融合技术的组合,利用语音和文本模态的互补信息进行情感识别。Kumar^[56]提出了基于混合融合的新型系统ParallelNet,它将来自语音和图像模态的信




图 1.3 决策级融合方式

息结合起来，采用中间融合和后期融合的混合方式。混合融合方法根据不同融合方法的组合而不同，是目前融合效果最好，最全面的融合方法。然而，混合级融合方法虽然结合了不同融合方法的优点，使得不同模态之间能够很好地交互，但是增加了复杂度和训练难度。





图 1.4 模型级融合方式

综上所述，每种融合方式都有其优劣和适用性，如何权衡以达到扬长避短的效果，需要研究者们不断的去探索新的方法，并进一步提升多模态融合技术的性能和应用范围。

1.3 本文的研究内容

本论文深入研究了语音情感识别问题的相关方法，同时考虑到情感表达的多模态性，特征选择的局限性以及上下文信息的辅助性等问题。因此本论文旨在研究多模态融合的语音情感识别方法，分别研究了语音单模态、语音+文本双模态和语音+文本+视频三模态的情感识别。针对每种模态组合的特性，本文分别从特征、多模态信息交互和语境建模的角度提出了三种不同的融合架构。通过依次将语音和各

种模态进行融合，充分利用不同模态的信息去增强语音模态的表达能力和鲁棒性，减轻环境噪声和说话人信息等因素对情感识别的干扰。本文研究内容如图1.5所示：



1. 针对单一特征表示无法充分捕捉到语音信号中丰富的情感信息的问题，提出了多级声学信息分层融合架构MAIF。通过结合不同级别声学信息进行分层融合，获得更全面和多样化的语音特征，从而更好地描述语音信号的情感内容。梅尔谱图表示语音的能量分布，MFCC表示语音的频率特征，而自监督特征可以捕捉语音中更高层次的语义和上下文信息。不同级别的特征表示具有不同的优点和局限性，通过将其转化为多模态融合问题，利用分层注意力机制去捕获局部和全局特征，可以弥补彼此的不足，从多个角度对情感进行建模，使得模型能够更好地适应不同的语音输入和情感状态，更具有表现力和泛化能力。

2. 针对语音信号中环境噪声和语速变化等因素的干扰以及跨模态特征融合问题，提出了多模态级联增强融合架构MTAF。其使用语音模态作为主导，引入文本模态作为辅助信息，去级联增强语音模态。充分利用文本信息来增强语音信号的表达能力和鲁棒性，提升语音情感识别的准确率。具体地，使用早期融合使模型从开始就学习到丰富的跨模态特征，有助于捕捉更复杂的模态间关系；使用多头交叉注意力机制通过级联增强的方式进行跨模态特征融合，允许模型不仅在单一模态内部学习特征之间的关系，而且还能学习不同模态之间的相互关系。

3. 针对上下文句子之间的依赖关系和模型对个体差异的适应能力较弱问题，提出了一个上下文信息动态融合架构MCAF。不仅对语境关系进行建模，同时对情感特征和说话人特征进行分离。具体地，将早期融合后的多模态特征送入上下文感知编码器中生成情感表征，由于不同的句子对情感识别的重要程度不同，因此我们提出了基于上下文感知的动态注意力进行特征加权和，凸显不同句子的重要程度，更好的捕获情感信息。接着将深度情感特征向量送入由注意力层组成的特征解耦模块，

用来实现情感信息和个人信息的分离，从而提高个体不可知情绪表示的鲁棒性。

首先，多级声学信息分层融合架构为语音情感识别提供了丰富的特征表示，包括梅尔谱图、MFCC和自监督特征，增强了语音信号情感内容的描述能力。其次，多模态级联增强融合架构结合了语音和文本模态，专注于研究跨模态信息的交互学习，提高了模型对多模态数据的表征能力。最后，上下文信息加权融合架构对语境进行建模，充分利用了上下文信息，通过使用动态注意力机制突出关键信息，为情感识别提供了更准确的线索。运用这些架构能够使得模型更好地适应不同语音输入和情感状态，提高情感识别的准确率和鲁棒性。

1.4 本文的组织结构

本文章节安排如下：

第一章，绪论。首先介绍了本文基于多模态融合的语音情感识别的选题背景和意义。接着从特征、模型和多模态融合三个方面介绍了国内外研究现状，并指出了现有研究存在的缺陷和挑战。最后，明确了本研究的目标和意义，为后续章节的内容奠定了坚实基础。

第二章，语音情感识别理论基础。首先介绍了情感的定义和两种分类方式，接着详细阐述了语音情感识别的定义和基本流程，包括预处理、特征提取和构建分类器。其次介绍了语音情感识别常用的特征（语谱图，MFCC和自监督特征）和深度学习模型，如循环神经网络、注意力机制和Transformer编码器。最后，列举了常用的多模态情感识别数据集和语音情感识别常用的评价指标。

第三章为多级声学信息分层融合架构。首先针对单一特征无法充分捕捉语音信号中丰富的情感信息问题，详细阐述了基于多级声学信息分层融合架构的工作原理，并对其中涉及的模块进行详细说明。在IEMOCAP和Emodb数据集上设置对比试验验证了本架构的有效性并进行了原因分析。随后通过混淆矩阵具体讨论了每种特征对不同情感类别的识别效果并给出了可能性的原因。最后设置多组消融实验验证了特征种类和融合模块对语音情感识别的影响。

第四章为多模态级联增强融合架构。针对语音信号中的环境噪声、语速变化等因素干扰和跨模态特征融合的挑战，详细阐述了基于多模态级联增强融合架构的工作原理和具体结构。随后在IEMOCAP和MELD数据集上进行了对比试验，虽然相比其他方法的结果取得了很大的提升，但是在MELD数据集上的整体效果并不理想，本文对原因进行了具体的分析。最后通过观察消融实验和混淆矩阵的结果，证实了本文使用多模态进行情感识别的有效性和必要性，同时证明了本文所提架构的有效性。

第五章为上下文信息动态融合架构。针对忽略了上下文句子之间的依赖关系和模型适应个体差异能力较弱的问题，详细阐述了基于上下文信息动态融合架构的研究动机和工作原理，并详细介绍了其具体的组成模块。通过在IEMOCAP和CMU-MOSEI数据集上进行对比试验，证实了本文所提架构的有效性。接着通过混淆矩阵，探讨了本实验中最合适的上下文句子数目并给出了具体分析。最后设置多组消融实验验证了模态种类，上下文句子数目以及模型结构的有效性。

第六章，总结和展望。对本文的三个研究工作进行总结，并指出了创新和贡献。同时，也提出了本研究存在的缺陷和不足，并给出未来改进的目标和方向，希望能够为该领域的发展提供借鉴和思路。

第二章 语音情感识别理论基础

2.1 情感的定义

情感是机体对特定的刺激，如人、情境或事件而表现出的一种反应。它是一种强烈的、短暂的体验，并且通常是能被感知到的^[57]。

情感通常包括以下几个要素：

1. 生理反应：情感通常伴随着生理的变化，如心率的增加、呼吸的改变和肌肉的收缩等^[58]。这些生理反应表征了相应的情感状态。

2. 认知成分：情感是与认知密切相关的，个体会按照以往的经验 and 经历做出对环境和事物的理解和反应。认知成分涉及对感觉、思维和记忆的加工。

3. 表达行为：情感通常会通过声音、面部表情、肢体动作和语言等方式表达出来，这些表达行为是情感状态的外在表现^[59]。

4. 主观体验：情感是个体的主观性的体验，即个体对其情感状态的理解和感受^[60]。这是情感最核心的部分，因为不同的个体可能对相同的刺激产生不同的反应和情感体验。这导致无法完全通过定性和定量的方法进行分析，因此通过人表达的情感本身就具有一种模糊性。

情感可以影响决策的执行、认知加工和社交行为等各个方面，对于个体的心理和生理健康有着重大的影响^[61]。同时情感也是人类文化、创造性表达和艺术传承的重要组成部分，通过情感，人们能够理解和领悟彼此的经验^[62]。研究情感有助于深入了解和挖掘人类的心理和行为，也对计算机科学和人工智能等领域的认知计算和情感识别的研究提出了挑战。

2.2 情感的分类

情感可以根据不同的维度进行分类。以下是两种常见的情感分类方式：

1. 离散维度分类

在离散维度分类中，情感被认为是一组离散的、互相独立的状态。常见的离散情感分类包括：基本情感分类、复杂情感分类和社会情感分类。

基本情感是指一组基本的、原始的情感状态，如喜悦、悲伤、愤怒、恐惧、厌恶和惊奇^[63]；复杂情感分类包括爱、羡慕、羞耻、嫉妒、同情、孤独等情感状态，它们由多种基本情感组合而成，或者包含更复杂的情感体验；社会情感分类涉及与他人进行交往和互动相关的情感，如同情、羞耻、感激、宽恕、道歉等。

2. 连续维度分类

维度情绪不是将情绪划分为若干类别，而是将情绪视为效价-唤醒空间或效价-唤醒-优势空间中属性的连续值/度^[64]。效价是积极或消极情绪的程度，唤醒度是指从嗜睡（低）到清醒（高）的激活水平，优势度是对情绪的控制程度。

Russell认为先前的情绪类别可以映射到二维效价-唤醒度空间中^[65]，如图2.1所示。为维度情感寻找更高的维度是一个需要深入研究的问题。Mehrabian和Russell开发了三个数值维度（Valence-Arousal-Dominance, VAD）^[66]，用于评估环境感知、体验和心理反应。然而，Fontaine等的研究发现，维度情绪的世界不是两个或三个维度，而是四个维度，第四个维度是不可预测性^[67]。




图 2.1 情感的连续情感类型

综合来看，离散维度和连续维度两种分类方式从不同的视角提供了不同的理解方式，有助于我们更好地理解和领悟情感的多样性和复杂性。

2.3 语音情感识别的定义和基本流程

语音情感识别是情感计算的一个分支，旨在通过对语音信号所传达的内容进行分析，来推断说话者的情感状态^[68]。它涉及从语音信号中提取特征，并将这些特征与情感类别进行关联，以识别和判定说话人此刻的情感状态。

如图2.2所示，语音情感识别具体包含以下步骤：

1. 预处理：降噪，平滑语音信号，消除环境噪声以确保数据采集质量。
2. 特征提取：从预处理后的语音信号中进行特征提取，如梅尔频率倒谱系数（MFCC）、音调、音高、能量和基频等。
3. 构建分类器：使用机器学习分类算法或深度学习模型，如隐马尔可夫模型、支持向量机（SVM）、循环神经网络（RNN）等，对提取的特征进行情感识别。




图 2.2 语音情感识别流程

以上步骤构成了基本的语音情感识别分类算法，其中预处理和特征提取阶段为模型提供了可靠的输入数据，而分类器则对情感进行分类。

2.4 语音情感识别的基本特征

特征提取对语音情感识别至关重要。通过将语音信号转换成具有代表性的特征，能够捕获语音中蕴含的情感信息，为后续分类器提供有效的输入，从而提高情感识别的准确性和鲁棒性。因此，精确而有效的特征提取是构建可靠的语音情感识别系统的关键步骤^[69]。其中，MFCC、语谱图和自监督特征是最常用的三种特征。

2.4.1 MFCC

MFCC是一种基于梅尔频率刻度的语音特征提取方法，它模拟了人类听觉系统对声音的感知方式^[70]。MFCC 的计算过程包括如下步骤，

1. 预加重：将语音信号通过高通滤波器， $H(z) = 1 - \mu z^{-1}$ ，式中的 μz 的值通常取0.97。预加重的目的是通过增强高频部分的能量，减少低频部分的能量，去提高信号的清晰度、信噪比和抗干扰能力。这是因为在语音信号中，高频成分往往携带着更多的信息，而低频成分则包含了较多的背景噪音和冗余信息。

2. 分帧：先将N个采样点组合成一个观测单位，即帧。N为语音数据一毫秒的采样点数，通常为320 或480。接下来引入了一段重叠区域，该区域包含了M个采样点，M的值约为N的1/2 或1/3。引入重叠区域的目的是为了避免相邻帧之间的突变过大，平滑地过渡信号，以提高频谱分析的准确性，为后续的语音信号处理提供更合理、

准确的输入。

3. 加窗：应用汉明窗对每一帧进行加权，有助于提高帧左右端的连续性，减少突变，平滑过渡相邻帧之间的信号，以及降低频谱泄露。这种处理方式有助于提高语音信号分析的准确性和连续性。假设分帧后的信号为 $S(n), n = 0, 1, \dots, N-1$, N 是帧的大小，那么乘上汉明窗后 $S'(n) = S(n) \times W(n)$, $W(n)$ 的形式如下，

$$W(n, a) = (1 - a) - a \times \cos \left[\frac{2\pi n}{N-1} \right], 0 \leq n \leq N-1 \quad (2-1)$$

通常情况下， a 取0.46，不同的 a 值会产生不同的汉明窗。

4. 快速傅立叶变换：为了观察信号的特性就需要将信号从时域转换到频域。分帧加窗后，对每帧信号进行快速傅里叶变换获得各帧的频谱分布。进一步，通过对语音信号的频谱取模平方得到语音信号的功率谱，用于分析信号的频域特性。频域分析的结果能够反映不同语音的特性。设语音信号的离散傅里叶变换（DFT）为，

$$X_a(k) = \sum_{n=0}^{N-1} x(n)e^{-j2\pi kn/N}, 0 \leq k \leq N \quad (2-2)$$

式中， $x(n)$ 是语音信号， N 是傅里叶变换的点数。

5. 梅尔滤波器组：利用梅尔尺度的三角形滤波器组对能量谱进行滤波，将能量分布映射到梅尔频率上，以更好地模拟人类听觉系统的特性。使用一个包含 M 个滤波器的滤波器组， M 通常取22-26，与临界带的个数相近。滤波器组中的各个滤波器的中心频率 $f(m)$ 的间隔会随着 m 值的变化，相应缩小或增大，如图2.3所示。




图 2.3 梅尔滤波器组

6. 对数操作：人类的发声系统是由基因信息和声道信息卷积而成的。当进行语谱图傅里叶变换时，卷积操作转变为乘法操作。为了将乘法转换为加法信号，使得频谱表示更加直观，可以对乘法信号进行对数运算。计算每个滤波器组输出的对数能量为，

$$s(m) = \ln \left(\sum_{k=0}^{N-1} |X_a(k)|^2 H_m(k) \right), 0 \leq m \leq M \quad (2-3)$$

7. 离散余弦变换 (DCT): DCT可以分离基音和声道信息。在频域内,基音信息呈现出快速变化,而声道信息则表现为缓慢变化。再次进行DCT变换能够将它们分离,形成倒谱域。在倒谱域中,低频部分主要反映了声道信息,而高频部分主要反映了基音信息。因此,从倒谱域的低频部分获取声道信息的表示,从高频部分获取基音信息的表示。得到 $H[k]$ 就是梅尔频率倒谱系数。梅尔频率倒谱系数是MFCC特征的一部分。通过对DCT变换后的输出进行降维,可以得到最终的MFCC特征。

2.4.2 语谱图




图 2.4 语谱图

语谱图是一种将语音信号转换为时间-频率图的方法,它显示了语音信号随时间变化的频谱内容,如图2.4所示。在语谱图中,水平轴表示时间,垂直轴表示频率,颜色或亮度表示的是每个时间点和频率上的能量或功率。语谱图可以直观地展示语音信号在时间和频率上的详细信息,有助于理解和分析语音信号特征。语谱图的提取和MFCC类似,但是只包含预加重、分帧、加窗和傅里叶变换操作,通过傅里叶变换处理后的语音信号,再经过转化后就可以得到语谱图。

语谱图往往是较大的图像,时间和频率都有很高的分辨率,但是这种详细的细节对某些任务来说没有必要或者过于冗余。为了获得合适的语音特征,通常使用梅尔滤波器组将语谱图转换为梅尔谱图,如图2.5所示。梅尔谱图相比于语谱图在横轴上保留时间信息,在纵轴上使用梅尔频率,并保留了适当的分辨率,更加符合人类的听觉系统对声音的感知方式。

2.4.3 自监督特征

自监督特征就是利用预训练模型在大规模无标注数据上学习到的通用表示能力,对语音信号进行情感表示。有以下两种使用方式:

1. 直接用于特征提取:通过直接将语音信号输入到训练好的模型当中,使用模




图 2.5 梅尔谱图

型中间层的输出作为语音情感表征。中间层可以是卷积层，循环神经网络层或者线性层中的一种。

2. 微调或迁移学习：将预训练模型引入到语音情感识别任务中，可以对其进行微调或迁移学习。微调是指冻结特定层的参数，调整部分层的参数，以适应特定的语音情感识别任务；或者可以利用迁移学习，将模型在其他任务上学到的知识引入到情感识别任务上，丰富特征表示。

通过使用预训练模型进行情感表征，可以充分使用大规模语音数据中蕴含的丰富情感信息，提取出更具普遍性和泛化性的情感特征，从而提高语音情感识别系统的准确率和鲁棒性。

2.5 语音情感识别的主要模型

在实现语音情感识别的过程中，各种深度学习模型被提出并应用于该任务。其中，循环神经网络、注意力机制、以及Transformer模型是备受关注的模型。这些模型不仅在自然语言处理领域取得了显著成果，而且在语音情感识别任务中也展现出了强大的表现。

2.5.1 循环神经网络

循环神经网络（Recurrent Neural Network, RNN）^[71]是一类特殊的神经网络，如图2.6所示。RNN 具备记忆功能，主要应用于处理序列数据。与传统的前馈神经网络相比，它可以接受任意长度的序列输入，并且信息可以在网络内部进行传递。这使得RNN 在处理序列数据时具有很强的表征能力。

RNN的基本结构是循环连接，其核心思想是将当前时间步的输入和前一个时间步的隐藏状态作为输入，输出当前时间步的隐藏状态和预测结果。这使得RNN 能够




图 2.6 RNN

对序列中的上下文信息进行建模。

RNN的基本表达式如下：

$$h_t = \sigma(W_{ih}x_t + W_{hh}h_{t-1} + b_h) \quad (2-4)$$

$$y_t = \text{softmax}(W_{hy}h_t + b_y) \quad (2-5)$$

其中： x_t 是当前时刻的输入， h_t 是当前时刻的隐藏状态， h_{t-1} 是上一时刻的隐藏状态， y_t 是当前时刻的输出， W_{ih} ， W_{hh} 和 W_{hy} 是权重矩阵， b_h 和 b_y 是偏置项， σ 是激活函数，通常是tanh 或者ReLU， softmax 用于输出层的分类。




图 2.7 LSTM

长短期记忆网络（Long Short-Term Memory Network，LSTM）^[72]是一种特殊的RNN，如图2.7所示，用来解决RNN中的梯度消失和爆炸问题，并更好捕获长期时间依赖关系。它引入了一个“细胞状态”的变量来存储网络的记忆，并通过设置一系列的门结构来控制信息的流动。LSTM 的组成主要包括细胞状态、遗忘门、输入门和输出门。

细胞状态是LSTM 的核心部分，它类似于传送带，沿着整个序列在网络中进行信息的流动，它允许长期依赖信息在模型中传递；遗忘门的作用是筛选出细胞状态

中需要保留的信息，并丢弃掉无用信息，其输出在0到1之间；输入门通过sigmoid层确定哪些信息需要更新，通过tanh层生成新的候选值向量，从而影响当前时刻和上一时刻的细胞状态的更新；输出门决定了当前时刻细胞状态在输出占据的重要程度，以调节细胞状态流向输出的比例。

假设当前时刻为 t ，输入为 x_t ，隐藏状态为 h_{t-1} ，细胞状态为 C_{t-1} ，输出为 y_t 。以下是具体的计算公式：

1. 计算遗忘门：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2-6)$$

2. 计算输入门：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2-7)$$

3. 细胞状态的更新：

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2-8)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (2-9)$$

4. 计算输出门：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2-10)$$

$$h_t = o_t \odot \tanh(C_t) \quad (2-11)$$

其中： $\odot$ 表示逐元素相乘， $[h_{t-1}, x_t]$ 表示将隐藏状态 h_{t-1} 和输入 x_t 进行拼接， W_f ， W_i ， W_C ， W_o 分别是遗忘门、输入门、更新细胞状态和输出门的权重， b_f ， b_i ， b_C ， b_o 分别是遗忘门、输入门、更新细胞状态和输出门的偏置， $\tilde{C}_t$ 是新的候选细胞状态。

LSTM通过这些门结构来控制信息的流动和记忆的更新，有效的解决了RNN中的梯度问题，并且能更好的捕获长期时间依赖关系。因此，LSTM在许多任务中被广泛应用，如语音识别、机器翻译和情感识别等。

LSTM虽然在解决长期依赖问题上表现出色，但其结构较为复杂，训练和计算成本较高。因此出现了GRU，如图2.8所示，它是LSTM的一个变体，全称为门控循环单元（Gated Recurrent Unit）。相较于LSTM，GRU具有更简单的结构，参数较少，更易于训练和实现。GRU引入了更新门和重置门来控制信息的流动和记忆的更新，以提高模型的性能和训练效率。更新门决定了前一时间步的记忆信息是否更新到当前时间步的候选记忆中。重置门决定了如何融合当前输入和前一时间步的记忆信息，以生成候选记忆。




图 2.8 GRU

GRU的计算公式如下所述:

1. 更新门的计算:

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (2-12)$$

2. 重置门的计算:

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad (2-13)$$

3. 候选记忆的计算:

$$\tilde{h}_t = \tanh(W \cdot [r_t \odot h_{t-1}, x_t] + b) \quad (2-14)$$

4. 更新记忆的计算:

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (2-15)$$

其中, W_z , W_r 和 W 是权重矩阵, b_z , b_r 和 b 是偏置向量, σ 是sigmoid 函数, $\odot$ 表示逐元素乘法操作。 h_t 是当前时间步的隐藏状态, x_t 是当前时间步的输入。

2.5.2 注意力机制

注意力机制 (Attention Mechanism) 是一种模仿人类认知行为的深度学习模型中的关键部分, 如图2.9所示, 它使模型能够在处理输入数据时重点关注与当前任务最相关的部分, 而不是公平的对待整个序列。注意力机制最初在自然语言处理领域中被提出并广泛应用, 随后由于它的优越性能也逐渐被其他领域所引入。

在序列到序列 (Seq2Seq) 模型中, 注意力机制允许模型在生成输出序列时, 动态的计算输入序列中不同位置的重要程度, 使模型能够更多地关注输入序列中的重要位置。重要程度是根据输出序列和输入序列中所有时间步的隐藏状态计算得出的。以下是三种最常见的计算注意力权重的方式:




图 2.9 Attention

1. 点积注意力：使用点乘操作计算查询向量 q 和键向量 k 的相似度，并通过softmax 函数将相似度转换为概率分布。计算公式如下所示：

$$Attention(q, k) = q \cdot k \quad (2-16)$$

2. 缩放点积注意力：类似于点积注意力，但在计算相似度时还要除以特征维度的平方根来进行缩放，防止梯度爆炸。计算公式如下所示：

$$Attention(q, k) = \frac{q \cdot k}{\sqrt{d_k}} \quad (2-17)$$

其中： d_k 是键向量 k 的维度。

3. 加性注意力：使用全连接层来自动计算 q 和 k 之间的相似度，然后通过softmax 函数转换为概率分布。计算公式如下所示：

$$Attention(q, k) = softmax(W_q q + W_k k + b) \quad (2-18)$$

其中： W_q 和 W_k 是用于 q 和 k 的权重， b 是偏置项。

2.5.3 Transformer

Transformer^[11]最初是为了解决自然语言处理任务问题而提出的一种新模型。Transformer 的设计抛弃了传统的神经网络，并引入了完全基于注意力机制的新结构，使其在处理长距离依赖关系时具有更好的效果。Transformer 模型主要由以下几个核心组件构成，结构如图2.10所示，




图 2.10 Transformer

1. 多头注意力机制 (Multi-Head Attention): Transformer 的核心组件, 计算输入序列中每个位置的重要程度, 以便模型能够更好的在编码和解码阶段将注意力集中在最相关的部分。多头注意力机制能够同时从多个表示空间中获取信息, 从而更好地捕获序列中的各种依赖关系。

假设给定查询向量 Q , 键向量 K , 值向量 V , 以及注意力的头数 h , 每个头的维度为 d_{model}/h 。对于每个注意力头 i (其中 $i = 1, 2, \dots, h$), 注意力分数 $score_i$ 的计算如下:

$$score_i = \text{Attention}(QW_{Qi}, KW_{Ki}, VW_{Vi}) \quad (2-19)$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-20)$$

其中 QW_{Qi} , KW_{Ki} , VW_{Vi} 分别是 Q , K , V 分别乘以该注意力头 i 对应的权重, d_k 是 k 的维度。

对于每个注意力头 i 的注意力分数 $score_i$, 使用 softmax 操作, 产生注意力权

重 α_i :

$$\alpha_i = \text{softmax}(\text{score}_i) \quad (2-21)$$

对于每个注意力头 i ，将注意力权重 α_i 与 V 相乘，并将结果进行拼接，得到最终的输出 $\text{MultiHead}(Q, K, V)$ ：

$$\text{MultiHead}(Q, K, V) = \text{concat}(\alpha_1 V, \alpha_2 V, \dots, \alpha_h V) W_O \quad (2-22)$$

其中 W_O 是输出层的权重矩阵。

2. 编码器（Encoder）：由多个相同的层组成，每层都包含多头自注意力机制和前馈神经网络层。编码器将输入序列转换为固定长度的向量表示。

3. 解码器（Decoder）：也由多个相同的层组成，每个层包含多头自注意力机制、编码器-解码器注意力机制（Encoder-Decoder Attention）和前馈神经网络层。解码器根据编码器的输出和上一时刻的输出，得到目标序列。

4. 位置编码（Positional Encoding, PE）：由于Transformer不包含顺序信息，所以引入位置编码为不同位置提供不同的向量表示。将序列的位置信息添加到模型中，使模型能够捕捉到输入序列中不同位置的顺序信息。

假设输入序列的长度为 L ，位置编码的维度为 d_{model} ，那么第 pos 位置的位置编码 PE_{pos} 计算如下：

$$PE_{pos,2i} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2-23)$$

$$PE_{pos,2i+1} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2-24)$$

其中： pos 是序列中的位置索引， i 是位置编码向量的索引，表示位置编码向量的维度的一半。

5. 残差连接（Residual Connection）和层归一化（Layer Normalization）：通过在每个子层的输入和输出之间应用残差连接，并在每个子层的输出后使用层归一化，以便更好地训练深层网络。

2.6 语音情感识别的数据集

语音情感识别数据集是研究语音信号情感表达的重要资源。现有的数据集主要包括表演型和自发型两种。表演型情感数据集主要是在实验室环境下录制职业演员模拟不同的情感状态，职业演员的过度夸张的表情，使得易于情感识别^[73]。随着对

自然场景下情感识别的需求增加，人们开始更加重视自发型语音情感数据集。这类数据集包含了在真实环境中的说话人的情感表达，这使得情感识别更贴近实际场景，但也增加了任务的难度。以下总结了最常用的四种情感识别数据集：

1. EmoDB^[74]：德国柏林工业大学录制的包含10位演员的语音情感识别数据集。其中，5男5女分别对10个德语语音进行表演，涵盖七种情感：生气、悲伤、高兴、害怕、中性、厌恶和无聊。经过大量筛选后最终只留下了500句语料。语料的采样率是48kHz，采用16位进行量化并最终压缩至16kHz。在语料文本的选择上，遵循无情感倾向和中性原则，采用口语化的表达方式，避免过多的书面语去进行修饰。数据集是在专门的录音室中进行录制的，通过让演员回忆真实经历或过往体验来酝酿情绪，从而增强情感表达的真实性和可信性。

2. IEMOCAP^[75]：由南加利福尼亚大学录制，是包含语音、视频、人脸变动捕捉和文本的多模态数据集。总共10个演员（5男5女），每组演员（1男1女）演绎一段对话，总共5段对话，共录制了近12小时。数据集包括剧本和即兴自发两种方式的对话。每个句子至少由三人进行评估和标注。对话涵盖了9种离散情感标签（生气、高兴、激动、伤心、沮丧、恐惧、惊讶、中性和其他）以及三个连续维度标签（愉悦度、唤醒度和优势度）。在语音情感识别研究中，研究人员通常将激动添加到开心类别中，使用四分类数据集（中性、生气、开心和伤心）或六分类数据集（中性、生气、开心、伤心、沮丧和惊讶）。为了方便与先前的研究方法进行比较，本文同时使用了四分类和六分类数据集。

3. MELD^[76]：在EmotionLines数据集的基础上进行增强和扩展的。它不仅包含EmotionLines中的对话实例，还包括其他模态的数据，如音频、视频和文本。MELD数据集总共包含来自电视节目《老友记》的超过1,400个对话和1,3000个句子。这些对话涉及多个说话人。MELD共包含7种情感类别，分别是愤怒、厌恶、悲伤、快乐、中立、惊讶和恐惧。此外，该数据集还为每个句子提供了连续维度的情感标注，包括正面、负面和中性。

4. CMU-MOSEI^[77]：用于情感识别和情感强度预测的大规模多模态数据集。该数据集在句子级别进行了标注，总共有23259句样本。数据样本共包括三种模态：以44.1 kHz采样的语音、文本和从视频中以30 Hz采样的图像帧。样本中的句子是从不同主题和独白视频中随机选择的，视频片段来自于TED演讲和其他在线视频资源。CMU-MOSEI数据集的离散情感类别包括愤怒、厌恶、恐惧、快乐、悲伤和惊讶，而连续情感类别则包括积极和消极两种。为了方便与先前的研究方法进行比较，本文同时使用了离散（2分类，积极和消极）和连续情感标签（6分类）。

四个数据集的详细情况总结在如下表2.1。

表 2.1 常用语音情感识别数据集

数据集	语言	话语数量	说话人数量	情感激发类型	情感类别
EmoDB	德语	500	10	表演型	7
IEMOCAP	英语	7433	10	表演型	9
MELD	英语	13000	—	表演型	7
CMU-MOSEI	英语	23259	—	自发型	6

2.7 语音情感识别的评价指标

在语音情感识别领域，加权准确率（Weighted Accuracy, WA）和UA（Unweighted Accuracy, UA）是两个常用的评价指标，它们用于评估模型在准确识别情感类别方面的性能。

1. WA：考虑了每个情感类别在数据集中的分布情况。具体计算公式如下：

$$WA = \sum_{i=1}^N \frac{TP_i}{P_i} \times \frac{P_i}{T} = \sum_{i=1}^N \frac{TP_i}{T} \quad (2-25)$$

其中， N 是情感类别的总数， TP_i 是模型正确预测为第 i 类情感的样本数， P_i 是第 i 类情感的总样本数， T 是总样本数。WA通过计算每个情感类别的准确率，并使用类别的分布权重对这些准确率进行加权求和而得到。这种加权方式能够更好地反映情感识别系统在处理不平衡数据集时的性能。

2. UA：简单地计算所有情感类别的准确率的平均值。具体计算公式如下：

$$UA = \frac{1}{N} \sum_{i=1}^N \frac{TP_i}{P_i} \quad (2-26)$$

其中， N 是情感类别的总数， TP_i 是模型正确预测为第 i 类情感的样本数， P_i 是第 i 类情感的总样本数。UA忽略了不同情感类别在数据集中的分布情况，因此对于平衡数据集和不平衡数据集都能够提供公平的评估。

这两个指标通常用于评估语音情感识别系统在识别准确度方面的性能。WA能够更好地反映在不平衡数据集上的性能表现，而UA则提供了对整体性能的简单评估。

2.8 本章小结

本章首先给出了情感的定义，并概述了两种常见的分类方式。接着详细描述了语音情感识别的流程，包括预处理、特征提取和分类器构建。其次介绍了常用的语音情感识别特征，即语谱图、MFCC和自监督特征，以及深度学习模型，例如循环神经网络、注意力机制和Transformer编码器。最后，列举了流行的多模态情感识别数据集和常见的评价指标。

第三章 基于多级声学信息分层融合的语音情感识别

语音情感识别在当今科技发展中扮演着重要的角色，不仅对于改善人机交互、提升情感智能系统的智能化水平具有重要意义，也在医疗领域和社会服务中发挥着积极作用。然而，由于语音信号的复杂性和多样性，选择合适的特征来表示情感是一个挑战。同时，特征的选择也受到数据集、语音质量、说话人的差异等因素的影响。因此需要综合考虑语音信号的特点、任务需求和模型复杂度，采用合适的方法来提取和选择特征，以提高情感识别系统的性能和泛化能力。

3.1 引言

特征提取是进行语音情感识别的非常重要的一个环节，有效的提取和选择特征是提高语音情感识别准确率的关键步骤。而梅尔谱图、MFCC和自监督特征是最常用的三种特征，梅尔谱图表示语音的能量分布，MFCC表示语音的频率特征，自监督特征可以捕捉语音中更高层次的语义和上下文信息。先前的研究中仅仅关注到了单一的语音特征或者多尺度的单一特征，无法充分捕捉到语音信号中丰富的情感信息。例如，MFCC主要关注音频的频谱特性，而忽略了短时频谱的变化。这使得模型可能缺乏一些关键的情感特征，影响情感识别的准确率。同时，每种特征都有其局限性。例如，梅尔谱图对频谱分辨率有限，MFCC对噪声敏感，自监督特征的泛化能力会受到数据集规模的限制。使用单一特征可能导致模型在特定情感表达或噪声环境下的性能较差。最后，单一特征可能对特定说话人或语言更为适用，而对于其他说话人或语言的情感识别效果较差。

考虑到融合不同级别的特征可以获得更全面和多样化的语音特征，从多个角度对情感进行建模，达到扬长避短的效果。而且还可以提高模型的泛化能力，使模型能够更好地适应不同的语音输入和情感状态，具有更佳的表现力。

因此本文提出了一个多级声学信息分层融合架构（Multi-level acoustic information fusion, MAIF），结合不同级别的特征，即梅尔谱图，MFCC和自监督特征，来捕捉语音信号中丰富的情感信息，从多个角度对情感进行建模。同时将单模态的语音情感识别转化为多模态融合问题。通过使用本文提出的LSTM融合模块和分层注意力机制，更细致地整合特征，使模型能够同时捕捉高级别的全局特征和低级别的局部特征，从而能够更好地适应不同的语音输入和情感状态以提升模型的表现力和泛化能力。

3.2 模型结构

如图3.1所示是本文提出的架构MAIF，MAIF主要包括3部分，分别是特征提取模块、融合模块和分类模块。接下来详细介绍各个模块的组成和结构。




图 3.1 MAIF架构

3.2.1 特征提取模块

首先，将原始语音拆分为若干段，得到梅尔谱图特征 x_1 、MFCC特征 x_2 和音频段特征 x_3 。接着根据每种特征的特性选择相应的编码器进行情感表征，捕获情感信息。

AlexNet^[78]是一个经典的卷积神经网络架构，它是深度学习在计算机视觉领域取得重大突破的关键之一。AlexNet包含5个卷积层，每个卷积层后跟着一个ReLU激活函数以增加非线性，这些卷积层用于提取图像的特征。在每个卷积层之后都有一个最大池化层，用于降低特征图的维度并提取最显著的特征。在卷积层之后有3个全连接层，用于将提取的特征映射到输出类别。为了防止过拟合，AlexNet在全连接层之间使用了Dropout层，以在训练过程中随机丢弃部分神经元。在预训练阶段，模型会在ImageNet数据集上进行训练，学习到通用的图像特征。然后，预训练的模型可以在特定任务的数据集上进行微调，以适应新的任务。这种预训练的策略有助于提高模型的泛化能力和性能，并且使得在小样本数据集上也能取得良好的表现。

因此本文将梅尔谱图特征 x_1 送入预训练的AlexNet模型提取有用的深层表征，这些表征能够更好地捕捉语音信号在频域的信息，得到 y_1 ：

$$y_1 = AlexNet(x_1) \quad (3-1)$$

Transformer 在处理序列数据方面非常适用，因为它能够有效捕捉序列中的长期依赖关系，这对于理解语音信号的情感内容尤为关键。因此将MFCC特征 x_2 送入Transformer编码器捕获时间依赖，得到 y_2 ：

$$y_2 = Transformer(x_2) \quad (3-2)$$

Wav2vec2^[28]是Facebook在2020年提出的一种自监督学习方法，用于学习音频信号的表示，在语音处理领域取得了显著的进展。Wav2vec2通过自监督学习的方式，将音频信号转换为表示向量，这些向量可以被用于各种语音处理任务，如语音识别、语音情感分析等。Wav2vec2的关键创新在于使用了一种称为Contrastive Predictive Coding (CPC) 的自监督学习目标。其基本思想是通过预测音频信号中某些时间步长上的未来信息来学习音频的表示。通过将原始音频信号分成固定大小的时间片段，然后利用自编码器架构预测未来的音频片段，从而学习到音频的高级表示。这种方法使得模型能够学习到丰富的音频特征，而不需要人工标注的标签。Wav2vec2的结构包括四个主要组件：卷积特征提取器、上下文聚合器、量化模块和预测网络。首先，卷积特征提取器是一个卷积神经网络，用于从原始音频信号中提取特征。该网络通常由多个卷积层和池化层组成，可以有效地捕获音频信号的局部和全局特征。上下文聚合器负责聚合音频片段之间的上下文信息，以便更好地理解音频信号的连续性和长期依赖关系，通常使用Transformer架构来实现上下文聚合。其次，量化模块将连续的特征向量映射到离散的码本，以进行后续的预测任务。最后，预测网络是一个用于预测未来音频片段的神经网络，通常使用自编码器结构。它负责生成量化码本的预测，以用于学习音频信号的表示。

因此将音频段特征 x_3 直接输入到经过预训练的wav2vec2模型，以生成嵌入向量 y_3 。wav2vec2的深度情感提取模块能够提供丰富的原始音频信号信息，这种方法不仅不依赖于传统的声学特征，而且还能充分利用wav2vec2模型对语音数据的有效编码。

$$y_3 = Wav2vec2(x_3) \quad (3-3)$$

在编码器之后通过使用线性层进行维度的变换，使得 y_1 、 y_2 和 y_3 的维度相等。

3.2.2 融合模块

在融合模块中，本文首先将不同特征进行特征级融合，目的是为了得到多模态特征，使模型从开始就学习到丰富的跨模态特征，有助于捕捉更复杂的模态间关系，方便进行后续的特征融合和特征交互；接着利用LSTM网络进行模型级融合，充分发挥深度学习模型的优势，模拟人类认知和感知的过程，依次将不同级别的特征进行融合，捕获更丰富和抽象的信息表示，减少信息丢失，提高模型稳健性；最后，

使用分层注意力机制，更细致地整合特征，模型能够同时捕捉高级别的全局特征和低级别的局部特征。总之，融合模块结合了特征级，模型级和决策级融合方式，充分发挥不同融合方式的优势，最大限度的进行模态交互，提高模型对多模态数据的表征能力。

具体地，首先通过以下公式进行不同级别特征的特征级融合，得到多模态特征 a_1 ：

$$a_1 = [y_1; y_2; y_3] \quad (3-4)$$

[:]是指拼接操作。

接着是LSTM模型融合模块，其由四个LSTM网络组成，其中，上一个LSTM网络的隐藏层和细胞单元的输出作为下一个LSTM网络的隐藏层和细胞单元的初始值，以连接四个独立的LSTM进行特征的深度融合。本文首先将早期融合后得到的特征 a_1 送入第一个LSTM网络进行模态交互，捕获模态的相互关系，得到输出 a_2 ：

$$a_2 = LSTM1(a_1) \quad (3-5)$$

为了捕获更细致的模态间的动态交互，将 a_2 和梅尔谱图特征 y_1 相加得到 a_3 ：

$$a_3 = a_2 + y_1 \quad (3-6)$$

将 a_3 送入第二个LSTM网络捕获长时依赖：

$$a_4 = LSTM2(a_3) \quad (3-7)$$

继续将第二个LSTM网络的输出 a_4 和MFCC特征 y_2 相加得到 a_5 ，并将其送入第三个LSTM网络。将得到的网络输出 a_6 和自监督特征 y_3 相加得到 a_7 ，将其送入第四个LSTM网络，得到最终输出 a_8 。依此类推，此处的公式不再赘述， a_5 、 a_6 、 a_7 和 a_8 可以依次得到。

由于LSTM网络的短时记忆特性，越早的信息遗忘的速度越快。为了改善这一问题，本文提出了分层注意力机制，通过在不同的网络层次计算注意力，使模型能够同时捕捉高级别的全局特征和低级别的局部特征，从而提高特征融合的效果和准确性。具体地，本文对四个LSTM网络的输出计算注意力，进行决策层融合。

其中 m_1 权重计算如下：

$$m_1 = \sigma(w1(a_2; a_4; a_6; a_8) + b_1) \quad (3-8)$$

m_2 权重计算如下：

$$m_2 = \sigma(w2(a_2; a_4; a_6; a_8) + b_2) \quad (3-9)$$

w_1 、 w_2 、 b_1 和 b_2 是可训练的参数。同样地， m_3 和 m_4 可以被计算出。

最后，最终输出 H 的计算公式如下所述：

$$H = m_1 * a_2 + m_2 * a_4 + m_3 * a_6 + m_4 * a_8 \quad (3-10)$$

其中关于不同特征的融合步骤是按照特征的级别，由低到高，依次进行深度融合。按照特征的级别进行深度融合具有多重优势：首先，这种方法能够逐步提升信息层次，特征的级别由低到高代表了信息的抽象程度逐渐增加，通过逐步融合不同层次的特征，模型可以逐步获得更丰富和抽象的信息表示。其次是能够提取不同抽象程度的特征，低级特征通常包含原始数据的基本特性，而高级特征则可能是对低级特征的抽象和高层次表示，按照特征级别由低到高的顺序进行深度融合可以充分利用不同抽象程度的特征，提高模型的性能。此外，逐步融合还有助于减少信息丢失，提高模型的稳健性；最后，这种方法还能更好地模拟人类感知和认知过程，提高模型的可解释性和理解能力。

就不同级别来说，梅尔谱图是将音频信号转换为时频图像的表示方法，可以展示音频信号的频谱变化，属于比较基础的声学特征表示方法。MFCC是在语谱图的基础上进行进一步处理得到的声学特征表示方法，通过傅里叶变换和梅尔滤波器处理得到，用于描述音频信号的频谱特性。自监督特征是基于深度学习方法得到的高级特征表示，通过神经网络训练学习得到音频信号的更高级别的特征表示，是相对于传统信号处理方法而言的高级声学特征表示。因此，融合过程中，本文先将多模态特征和语谱图进行融合，接着是MFCC特征，最后是自监督特征融合。

3.2.3 分类模块

经过融合模块后得到的最终特征 H ，被送入线性层和softmax函数转换为概率分布。使用交叉熵损失函数来进行约束。

$$\tilde{y}_i = \text{softmax}(wH + b) \quad (3-11)$$

$$Loss = -\frac{1}{N} \sum_{i=1}^N y_i \log(\tilde{y}_i) \quad (3-12)$$

其中， y_i 是真实的标签， $\tilde{y}_i$ 是来自softmax层的预测概率分布， w 和 b 是可学习的参数， N 是训练过程中使用的样本数目。

3.3 实验设置

3.3.1 特征提取

所用原始音频信号的采样频率为16kHz。将每个音频段划分为若干长度为3秒的片段，当小于3秒时，施加填充操作，保持长度不变。通过librosa^[79]库，提取得到40维的MFCC特征。对于语谱图，采用跳变长度10ms，汉明窗大小为40ms，将每个加窗的块视为一帧。对每一帧进行离散傅里叶变换，长度为800，从时域变换到频域。取前200个点作为谱图特征，最终得到大小为300 * 200的梅尔谱图特征。自监督特征使用预训练的wav2vec2^[28]模型进行特征提取得到，它是语音的深层特征在时域上的反映。

3.3.2 实验实现细节

训练过程在GTX3090上使用PyTorch实现。实验超参数如表3.1所示，每个LSTM的层数为2，隐层神经元个数设置为256，共使用4个LSTM。Transformer编码器有2层，多头注意力的头数设置为4。本实验使用了Adam优化器，将学习率设置为0.001。批处理大小设置为64，早停策略设置为8轮，在性能不再改善时停止训练。实验最多迭代训练100次。本实验采用WA和UA作为评价指标。

表 3.1 实验超参数设置

参数名	参数值
LSTM个数	4
LSTM层数	2
LSTM隐层神经元个数	256
Transformer层数	2
多头注意力头数	4
优化器	Adam
学习率	0.001
批处理大小	64
早停策略轮数	8
迭代次数	100

为了与之前的研究工作保持一致，本实验采用了留一说话人交叉验证方法，以确保训练集和测试集没有说话人重叠。首先，将数据集按照说话人进行划分，确保每个说话人的数据不会同时出现在训练集和验证集中。然后，对于每个说话人，将其数据作为验证集，其余所有说话人的数据作为训练集。接着，使用训练集来训练模型，并使用对应说话人的验证集来评估模型的性能。这个过程重复进行，直到所

有说话人的数据都被用作验证集为止。

3.4 实验结果与分析

3.4.1 对比实验

为了评估本文所提出的多级声学信息分层融合架构MAIF的有效性, 本节分别在IEMOCAP (4分类), IEMOCAP (6分类) 和EmoDB 数据集上与其他最先进的架构进行了比较。

1. 在IEMOCAP (4分类)数据集上比较的架构有: 1) HNSD^[80] 是一种新的层次化网络, 该网络能够有效地集成SER的静态和动态特征。2) Dual-Attention+BiLSTM^[81] 是一种新颖的双层结构, 称为基于双注意力的双向长短时记忆网络, 用于语音情感识别。3) LSTM-Coattention^[82] 提出了一种利用多级声学信息的端到端语音情感识别系统, 并设计了新的协同注意力模块。4) DAAE+CNN+Attention^[83] 是一种领域对抗自编码器来提取SER的判别性表示。5) AMSNet^[84] 是一种基于连接注意力机制的多尺度SER并行网络, 融合了细粒度的帧级手工特征和粗粒度的语句级深度特征。

2. 在IEMOCAP (6分类)数据集上比较的架构有: 1) CAN^[85] 以交叉的方式将每个模态的注意力权重应用于另一个模态, 从而收集基于每个模态的相同时间步的音频和文本信息。2) MSCAN^[86] 的核心是使用并行的交叉和自注意力模块来显式地建模音频和文本的模态间和模态内交互。3) AMH^[87] 是一种跳跃注意力机制, 通过迭代跳跃过程在其他模态上进行条件化, 计算显著部分并聚合来自另一个模态的顺序信息。

表 3.2 不同SER方法在IEMOCAP (4分类)数据集上的比较

模型	WA(%)	UA(%)
HNSD ^[80]	70.50	72.50
Dual-Attention+BiLSTM ^[81]	68.73	70.29
LSTM-Coattention ^[82]	71.64	72.70
DAAE+CNN+Attention ^[83]	70.07	70.67
AMSNet ^[84]	69.22	70.51
MAIF	71.99	72.91

如表3.2所示, 在IEMOCAP (4分类) 数据集上, 本文提出的多级声学信息分层融合架构MAIF取得了最高的71.99%的WA 和72.91%的UA。与其他架构相比, MAIF的WA 提升了0.35% 到3.26%, UA提高了0.21%到2.62%。这证明了MAIF 架构对情感识别的有效性。如表3.3 所示, MAIF架构在IEMOCAP (6分类) 数据集上达

到了65.29%的WA和60.90%的UA。WA相比其他的架构得到了2.89%到7.39%的提升，UA得到了1.20%到12.20%的提升。在IEMOCAP数据集上，不管是使用了四分类或六分类情感类别，MAIF均取得了不错的识别效果。这证明了MAIF架构在情感识别任务上表现出良好的泛化能力，并取得了令人满意的情感识别效果。

表 3.3 不同SER方法在IEMOCAP (6分类)数据集上的比较

模型	WA(%)	UA(%)
CAN ^[85]	57.90	48.70
MSCAN ^[86]	61.20	56.00
AMH ^[87]	62.40	59.70
MAIF	65.29	60.90

3. 在Emodb数据集上比较的架构有：1) LSTM^[88]在MTL框架中引入语言ID作为另一个辅助任务，探究尚未被研究的口语在情绪识别中的作用。2) CNN+LSTM^[89]利用6种不同的语音情感语料，采用跨语料库训练的方法，对深度学习模型的泛化能力进行分析。3) Badshah et al.^[90]使用基于深度卷积神经网络的特征学习方案来解决SER问题。

如表3.4所示，在EmoDB数据集上，MAIF架构取得61.11%的WA和55.56%的UA。相比其他的架构，WA提升了2.97%，UA提升了3.56%到13.57%。虽然在Emodb数据集上相比其他的架构取得了很大的提升，但是情感识别的效果远不如在IEMOCAP数据集上的理想。这是因为Emodb数据集非常的小，总共只有500句语料，不同情感类别的样本分布不均衡，无法充分覆盖各种语音情感的变化和表达方式，导致数据集的代表性不足。这样的数据集可能无法很好地反映真实世界中的语音情感样本，从而使模型难以从中学习到丰富的特征和模式，从而影响了情感识别的效果。

表 3.4 不同SER方法在Emodb数据集上的比较

模型	WA(%)	UA(%)
LSTM ^[88]	58.14	—
CNN+LSTM ^[89]	—	41.99
Badshah et al. ^[90]	—	52.00
MAIF	61.11	55.56

在这三个数据集上的实验结果均证明了本文所提架构的有效性。多级声学信息分层融合架构MAIF通过结合不同级别声学信息，即梅尔谱图、MFCC和自监督特征，获得更全面和多样化的语音特征，从多个角度对情感进行建模。在此基础上，将其转化为多模态融合问题。通过使用本文提出的分层注意力机制，更细致地整合特征，使模型能够同时捕捉高级别的全局特征和低级别的局部特征，从而能够更好地

地适应不同的语音输入和情感状态以提升模型的表现力和泛化能力。

3.4.2 消融实验与混淆矩阵

本节在IEMOCAP (4分类)数据集上进行了若干消融实验,以评估本文提出的架构MAIF的有效性。结果见表3.5。MFCC、Self - Supervised 和Spectrogram模型都是只使用了一种特征,分别将MFCC特征、自监督特征和梅尔谱图特征特征送入2层LSTM网络进行分类。MFCC + Self - Supervised、MFCC + Spectrogram和Spectrogram + Self - Supervised模型只使用了2种对应的声学特征,融合模块只使用了3个LSTM网络。Without-fusion去除了融合模块,直接将拼接后的特征送入线性层进行分类。

表 3.5 模型结构的消融实验

模型	WA(%)	UA(%)
MFCC	56.09	56.47
Self-Supervised	64.39	65.54
Spectrogram	61.29	62.27
MFCC+Self-Supervised	67.24	68.63
MFCC+Spectrogram	64.55	65.34
Spectrogram+Self-Supervised	69.89	70.45
Without-fusion	69.02	69.20
MAIF	71.99	72.91

单独看这三种特征,自监督特征取得了最高的64.39%的WA和65.54%的UA。语谱图特征的识别准确率次之,MFCC特征的识别准确率较差。这是因为MFCC是手工提取的特征,而自监督和语谱图特征都使用了预训练模型来进行情感表征。本文分析了可能的原因:首先,基于特征表示的丰富性来看,手工提取的特征通常是基于领域知识或经验设计的,可能无法充分表达语音信号中的复杂信息。相比之下,预训练模型提取的特征是通过大规模数据进行无监督学习而得到的,能够学习到更加丰富和高层次的特征表示。其次,从适应性和泛化能力来看,预训练模型能够从数据中学习到更多有效的特征表示,具有较强的适应性和泛化能力,能够适应不同样本和任务的特征表示需求。而手工提取的特征通常受限于特征选择、参数设置等因素的影响,难以达到最优性能。最后,从超参数调优和优化策略来看,预训练模型通常采用了更加复杂和有效的模型结构、优化策略和超参数调优方法,能够更好地优化模型性能。相比之下,手工提取的特征可能无法达到预训练模型的识别性能。

在使用一种特征的基础上,增加一种特征或者两种特征后,模型的性能有了很大的提升。这证明了融合多种特征进行情感识别的有效性。不同级别的特征表示具

有不同的优点和局限性，通过这些特征表示进行分层融合，转化为多模态融合问题，可以弥补彼此的不足，从多个角度对情感进行建模。

去除融合模块后，WA较MAIF降低了2.97%，UA降低了3.71%。这证明了本文提出的融合模块的有效性。本文使用LSTM网络和分层注意力机制，对不同级别的特征进行分层融合。融合模块更细致地整合特征，使模型能够同时捕捉高级别的全局特征和低级别的局部特征，从而能够更好地适应不同的语音输入和情感状态以提升模型的表现力和泛化能力，从而提高了语音情感识别的准确率。

最后，为了探究不同的特征对具体情感类别的识别效果，本文还在IEMOCAP（4分类）数据集上绘制了仅使用MFCC特征、仅使用自监督特征、仅使用梅尔谱图特征以及本文提出的架构MAIF的混淆矩阵（Ang：生气，Sad：伤心，Hap：高兴，Neu：中性）。单个特征的使用是去除了融合模块，直接将其送入2层LSTM网络进行情感识别。




图 3.2 仅使用MFCC特征的混淆矩阵

如图3.2所示，MFCC对伤心和开心类别的识别效果较好，分别达到了80%和65%；而生气类别的识别准确率只有40%，中性类别的准确率最低，只有37%。针对这些实验结果，本文分析这可能是由于声音特征差异导致的。伤心和高兴情感往往会引起声音频率、音调、语速等方面的明显变化，这些变化可以很好地被MFCC捕捉到。相比之下，生气和中性情感的声音特征可能相对稳定，不太容易通过MFCC进行有效区分。此外，生气类别有57%的概率被错分为开心类别，中性类别有43%的概率也被错分为开心类别。本文推测这是因为生气情感和开心情感在声音特征上可能存在一定的相似性，例如，生气和开心都可能伴随着较高的声音能量、较快的语速等特征。这种相似性可能导致模型难以准确区分生气和开心类别，从而导致生气类别被误分类为开心类别。而中性情感可能在声音特征上表现较为平淡，模型难以从中获得有效的情感特征区分，因此容易被错分，造成识别准确率低。




图 3.3 仅使用自监督特征的混淆矩阵

观察图3.3可以看出，自监督特征对伤心类别的识别效果最好，高达92%；其次是生气和开心类别的识别准确率也较高，而中性类别的准确率相对来说表现比较差，只有31%。这可能是由于预训练模型在大规模数据上进行训练时偏向于伤心情感类别的特征表示，导致其在识别这些类别时表现较好，而在其他类别上表现较差。




图 3.4 仅使用梅尔谱图特征的混淆矩阵

如图3.4所示，梅尔谱图特征对伤心类别的识别效果最好，达到了84%，对中性，生气和开心类别的识别准确率较为接近，分别是59%、59%和53%。综合来看，梅尔谱图特征对每种情感类别的识别效果比较均衡。这可能是因为梅尔谱图使用了预训练的Alexnet模型进行深层表征，这些表征能够更好地捕捉语音信号在频域的信息，更全面地表征语音信号中的情感信息。

综合来看这三种特征，MFCC对开心类别的识别效果最好，达到了最高的65%；自监督特征对生气和伤心类别的识别效果最好，分别达到了71%和92%；梅尔谱图特征对中性类别的识别效果最好，达到了59%。本文推测这应该是和每种特征的特

性有关，梅尔谱图表示语音的能量分布，MFCC表示语音的频率特征，自监督特征可以捕捉语音中更高层次的语义和上下文信息。因此不同的特征对相同的情感类别的识别效果是不同的。




图 3.5 结合三种特征（MAIF）的混淆矩阵

当结合3种特征进行情感识别时，如图3.5所示，情感识别的整体准确率有了很大的提高。尤其是中性类别，准确率提高了18%-46%。这个实验结果再一次证明了每种特征都有其优势和适用场景。通过结合不同级别的特征，可以达到扬长避短的效果，从多个角度对情感进行建模，使模型具有更强的表达能力和泛化能力，提升情感识别准确率。

3.5 本章小结

本文提出了一种多级声学信息分层融合架构MAIF，通过多模态融合方式将梅尔谱图、MFCC和自监督特征进行融合，并且使用分层注意力机制去同时捕提高级别的全局特征和低级别的局部特征。这促使模型学会灵活地融合多种特征以更有效地传递情感信息，同时提高模型的自适应性，使其能够在多样化的场景中实现准确的情感分类。通过在IEMOCAP和EmoDB数据集上对提出的方法进行了评估，并取得了优异的结果，证明了本文提出方法的有效性。在未来的工作中，本文将进一步探索更多的语音特征对情感识别的影响以及不同特征的融合方法，旨在最大限度地利用不同级别的特征，获得丰富的情感表示，进一步提高语音情感识别的准确率。

第四章 基于transformer文本增强融合的语音情感识别

语音信号往往仅提供了情感表达的一部分信息，而且受环境噪声和说话人个体差异的影响较大，这会使得情感识别模型在不同环境和不同说话人之间的泛化能力较弱。为了解决这一问题，研究人员进行了大量的实验和探索，提出了一系列创新性的方法和技术，为语音情感识别领域的发展做出了重要贡献。

4.1 引言

在第三章中，本文使用了传统的语音情感识别方法，即仅使用语音信号来进行分析，将语音单模态情感识别问题转化为多模态融合问题。虽然能够获得更全面和多样化的语音特征，从多个角度对情感进行建模。然而，仅使用语音信号进行情感识别不仅信息量不足，准确度受限，而且容易受到环境噪声，语速变化和说话人信息等因素的干扰，导致识别性能下降。考虑到情感的表达是多模态的，因此本章结合多模态信息来进行情感识别，充分利用多模态间的互补信息。

本文使用语音模态作为主导，选择了文本模态作为辅助信息去增强语音模态的表达能力和鲁棒性。首先，语音模态可以提供声音的声学特征，如语调、语速和音量等信息。而文本模态提供了语义信息。通过结合两者，可以获得更全面的情感表达，涵盖了声音和语义层面的信息。其次，语音模态提供了声音的时间序列信息，文本模态提供了更多的上下文信息。通过结合两者，可以获得更准确和完整的上下文信息，帮助解析情感表达的背景和情感转变的过程。对于某些情感，语音模态可能在声音特征上更加突出，能够传达出说话人的情感状态。而对于某些情感，文本模态可能提供了更丰富的情感词汇和语义信息，能够更准确地表达情感的细节。最后，语音模态容易受到环境噪声，语速变化等因素的影响，而文本模态很容易受到语音识别任务的影响，从而包含歧义。语音和文本模态间的互补信息能在任何一种模态出现噪声时增加系统的鲁棒性。

因此，文本和语音模态可以很好地进行互补。而传统的多模态方法在语音情感识别领域容易忽略语音信号，主要依靠文本信息对情感进行分类。并且只是简单地将不同模态的特征连接在一起或者通过一些基本的方法进行融合，而缺乏对模态之间关系的深入挖掘。

本文提出了一种多模态级联增强融合架构（Multimodal transformer augmented fusion, MTAF），使用语音模态作为主导，引入文本模态作为辅助信息，充分利用文本信息去增强语音信号的表达能力和鲁棒性，减轻环境噪声等因素对情感识别的干

扰。通过使用本文提出的模型融合模块，即多个多头交叉注意力机制的组合去级联增强语音模态，学习两种模态之间的相互关系和相互依赖性，动态地调整融合策略，提高模型对多模态数据的表征能力。

4.2 模型结构




图 4.1 MTAF架构

图4.1所示的是本文提出的架构MTAF。MTAF由三部分组成：多模态特征提取器、模型融合模块和分类器。

4.2.1 多模态特征提取器

输入语音特征序列表示为 x_a ，文本特征序列表示为 x_l 。

多模态特征序列是通过特征级融合方式得到，特征级融合能够使模型从开始就

学习到丰富的跨模态特征，有助于捕捉更复杂的模态间关系。多模态特征 x_e 计算公式如下所述：

$$x_e = [x_a; x_l] \quad (4-1)$$

[;] 是拼接操作符。

接着将语音 x_a 、文本 x_l 和多模态特征 x_e 通过线性层映射到同一维度，并将特征送入各自的transformer自编码器捕获时间依赖并进行情感表征。自编码器的核心部件是多头自注意力机制，每个自编码器都有 m 层和 n 个注意力头。

多头自注意力机制的查询向量 Q ，键向量 K 和值向量 V 来自同一模态。具体计算公式如下所述：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4-2)$$

其中 d_k 是 Q 的维度。

$$Multihead(Q, K, V) = Concat(head_1, \dots, head_n)W^O \quad (4-3)$$

$$where head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (4-4)$$

其中 n 是注意力头的个数； W^O 、 W_i^Q 、 W_i^K 和 W_i^V 是可学习的参数。

4.2.2 模型融合模块

模型融合模块由三个交叉编码器的组合形成，用于模态融合并生成多模态情感中间表示。通过学习不同模态之间的相互关系，动态地调整融合策略，从而更好地捕捉跨模态特征之间的多样性和复杂性，提高了模型对多模态数据的表征能力。

交叉编码器的核心部件是多头交叉注意力机制。使用多头交叉注意力机制通过级联增强的方式进行跨模态特征融合，允许模型不仅在单一模态内部学习特征之间的关系，而且还能学习不同模态之间的相互关系。

每个交叉编码器都有 m 层和 n 个注意力头。多头交叉注意力的计算公式和多头自注意力类似，区别就是对于多头交叉注意力机制，源模态特征被转换为 K 和 V ，而目标模态特征被转换为 Q 。

模型融合模块的做法就是使用特征级融合后的多模态特征通过多头交叉注意力机制分别去增强语音和文本特征，再使用加强后的文本特征去进一步增强语音特征。充分利用文本信息来增强语音信号的表达能力和鲁棒性，减轻环境噪声等因素对情感识别的干扰。具体地，在经过自编码器后分别对语音，文本和多模态特征进行情感表征后，将其送入两个并行的交叉编码器进行模态交互。其中，多模态特征

作为 Q ，一个交叉编码器的 K 和 V 是语音特征，另一个交叉编码器则是使用了文本特征。接着，继续将交叉编码器增强过的文本特征作为 Q ，语音特征作为 K 和 V 送入第三个交叉编码器，得到最终增强后的语音特征。

4.2.3 分类器

经过模型融合模块，将得到的最终情感表示 H 送入一个全连接层和一个softmax层，以交叉熵损失为代价函数来预测情感类别：

$$\tilde{y} = \text{softmax}(wH + b) \quad (4-5)$$

$$\text{Loss} = -\frac{1}{N} \sum_{i=1}^N y_i \log(\tilde{y}_i) \quad (4-6)$$

y_i 是真实标签， $\tilde{y}_i$ 是来自softmax层的预测概率分布， w 和 b 是可学习的参数， N 是训练时使用的样本总数。

4.3 实验设置

4.3.1 特征提取

使用Python程序包Librosa提取句子级语音特征。共提取199维特征，包括梅尔频率倒谱系数（MFCC）、色度、音高、过零率、光谱及其均值、标准差、最小值、最大值等统计量。

使用IEMOCAP和MELD数据集中的转录文本提取1890维的词频-逆文档频率特征向量（Term Frequency-Inverse Document Frequency, TFIDF）。TFIDF是一种数值统计量，表示一个词与一个文档在一个集合或语料库中的相关性。

4.3.2 实验实现细节

实验超参数如表4.1所示。通过一个线性层获得256维的语音、文本和多模态特征。将其输入到自编码器中，自编码器有2个Transformer编码层和4个多头注意力头。接下来，将新生成的3个256维向量送入模型融合模块，该模块由3个交叉编码器组成。 Q 是交叉编码器的残差部分，用于执行模态之间的深度交互。交叉编码器和自编码器具有相同的层数和注意力头。经过模型融合模块，最终得到256维的情感特征向量用于情感分类。

训练过程在GTX3090上使用PyTorch实现。本实验使用了Adam优化器，将学习率设置为0.0001。批处理大小设置为200。为了缓解过拟合采用了0.4的dropout方法。

实验最多进行了100次迭代，直到精度不发生改变。本实验使用WA 和UA 作为评价指标。

表 4.1 实验超参数设置

参数名	参数值
特征维度	256
Transformer层数	2
多头注意力头数	4
优化器	Adam
学习率	0.0001
批处理大小	200
dropout	0.4
迭代次数	100

4.4 实验结果与分析

4.4.1 对比实验

为了验证本文所提出的多模态级联增强融合架构MTAF有效性，本节分别在IEMOCAP（4分类），IEMOCAP（6分类）和EmoDB数据集上，将MTAF与下述目前比较先进的架构进行了对比。

1. 在IEMOCAP (4分类)数据集上比较的架构有：1) DST^[91]是一个用于SER任务的可变形语音Transformer，通过一个轻量级的决策网络来确定输入语音的窗口大小。2) Dual-Attention+BiLSTM^[81]、3) LSTM-Coattention^[82]、4) DAAE+CNN+Attention^[83]、5) HNSD^[80]、6) AMSNet^[84]在上一章中已经介绍过，此处不再赘述。

2. 在IEMOCAP (6分类)数据集上比较的架构有：1) COGMEN^[47]是一种利用局部信息（说话人之间的语内或语际依赖关系）和全局信息（上下文）的基于情境化的图神经网络。2) CTNet^[54]使用Transformer的结构来建模多模态特征的模态内和跨模态交互。3) MultiEMO^[92]提出了一种新颖的基于注意力机制的相关感知多模态融合框架MultiEMO。4) DF-ERC^[93]介绍了一种新颖的MM-ERC系统，该系统强调特征纠缠和融合，同时兼顾多模态和会话语境。5) MSCAN^[86]和AMH^[87]也已经在上一章节中介绍过了。

如表4.2所示，在IEMOCAP 数据集（4分类）上，本文提出的多模态级联增强融合架构MTAF取得了最高的75.32%的WA 和72.86%的UA，这证实了本文所提出的架构MTAF的有效性。MTAF相较于其他方法，WA和UA均取得了较大的提升。WA提高了1.72%-6.59%，UA提高了1.06%-2.57%。在IEMOCAP 数据集（6分类）上，实

表 4.2 不同SER方法在IEMOCAP (4分类)数据集上的比较

模型	WA(%)	UA(%)
Dual-Attention+BiLSTM ^[81]	68.73	70.29
LSTM-Coattention ^[82]	71.64	72.70
HNSD ^[80]	70.50	72.50
DAAE+CNN+Attention ^[83]	70.07	70.67
AMSNet ^[84]	69.22	70.51
DST ^[91]	73.60	71.80
MTAF	75.32	72.86

验结果如表4.3所示。同样地，MTAF取得了最高的72.31%的WA和75.08%的UA。与其他方法相比，MTAF架构的WA得到了0.47%-11.11%的提升，UA得到了2.33%-19.08%的提升。在IEMOCAP数据集上，不管是使用了四种情感类别，还是六种情感类别，MTAF均取得了不错的效果。这证实了本文所提出的架构MTAF具有很强的泛化能力，能够在情感识别任务上取得很好的效果。

表 4.3 不同SER方法在IEMOCAP (6分类)数据集上的比较

模型	WA(%)	UA(%)
MSCAN ^[86]	61.20	56.00
AMH ^[87]	62.40	59.70
COGMEN ^[47]	68.20	—
CTNet ^[54]	68.00	67.60
MultiEMO ^[92]	—	72.75
DF-ERC ^[93]	71.84	70.78
MTAF	72.31	75.08

3. 在MELD数据集上比较的架构有：1) RNN^[94]是一种使用了不同的RNN结构的方法，用于语音情感识别中的特征学习。2) MDNN^[95]是一种通过在局部分类器中分组训练原始特征，以避免高维度灾难的架构。其将每个局部分类器的高层特征串联起来作为一个全局分类器的输入。3) bcLSTM^[96]是一种LSTM网络，将视频中的话语序列作为输入，通过对依赖关系建模，提取上下文单模态和多模态特征。4) DialogueRNN^[97]是一种基于循环神经网络的新方法，该方法在整个会话过程中追踪个人特征，并利用这些信息进行情感分类。5) HGFM^[14]在之前已经介绍过。

通过观察表4.4，可以看出在MELD数据集上，本文提出的架构MTAF达到了48.12%的WA和39.50%的UA，比其他架构的WA提高了5.82%-14.12%，UA提高了16.80%-22.60%。虽然MTAF的结果优于其他架构，但在MELD数据集上的整体表现并不理想。此处推测是因为，与IEMOCAP数据集相比，MELD数据集是情感识

别领域中一个比较大的数据集。其数据来源于电视节目老友记，与IEMOCAP中的数据相比，并不贴近现实生活。此外，数据收集条件也不像IEMOCAP那样标准化，存在质量问题，如噪音、录音不清晰等。因此，对MELD数据集的情感识别精度不如IEMOCAP。但本文认为MELD是一个适合的数据集来比较和验证本文的方法，因为与其他方法相比，实验结果有很大的提升，尽管总体结果偏低。

表 4.4 不同SER方法在MELD数据集上的比较

模型	WA(%)	UA(%)
RNN ^[94]	38.40	20.60
MDNN ^[95]	34.00	16.90
bcLSTM ^[96]	39.10	17.20
DialogueRNN ^[97]	41.80	22.70
HGFM ^[14]	42.30	20.30
MTAF	48.12	39.50

基于以上三个数据集的对比实验结果，此处对模型的性能提升进行了分析。本文提出的MTAF架构使用语音模态作为主导，引入文本模态作为辅助信息。通过使用多头交叉注意力机制去级联增强语音模态，充分利用文本信息来增强语音信号的表达能力和鲁棒性，减轻环境噪声等因素对情感识别的干扰。其中的模型融合模块，使用多个多头交叉注意力机制的组合实现跨模态特征融合。通过学习不同模态之间的相互关系，动态地调整融合策略，从而更好地捕捉跨模态特征之间的多样性和复杂性，提高了模型对多模态数据的表征能力。

4.4.2 消融实验与混淆矩阵

本节在IEMOCAP数据集（6分类）上进行了多个消融实验，以评估本方法中采用的融合方式，transformer编码器和融合模块的有效性。

表4.5分别给出了Audio-only、Text-only、Feature Fusion、Model Fusion、Without Self-Transformer Encoder 和Without Model-fusion module的消融研究结果。Audio-only和Text-only模型只使用单种模态来进行情感识别，分别只有一个语音模块和文本模块，但没有模型融合模块。Feature Fusion模型包含图4.1中间的Feature-fusion模块，但不包含Model-fusion模块。Model Fusion模型不包含Feature-fusion模块分支，仅使用一个交叉Transformer编码器进行多模态融合。Without Self-Transformer Encoder去除了自编码器，直接将提取的低级语音、文本和拼接的多模态特征送入Model-fusion模块。最后，Without Model-fusion module模型去掉了Model-fusion模块也即交叉编码器组合后，将三个分支的输出直接串联送入全连接层。

观察实验结果可以看出，在IEMOCAP数据集（6分类）上，使用语音单模态进

表 4.5 模型结构的消融实验

模型	WA(%)	UA(%)
Audio-only	58.58	61.73
Text-only	61.86	63.42
Feature Fusion	67.15	68.30
Model Fusion	63.66	64.95
Without Self-Transformer Encoder	70.09	73.48
Without Model-fusion module	69.65	72.24
MTAF	72.31	75.08

行情感识别时只取得了58.58%的WA和61.73%的UA，文本模态的结果略高于语音模态，WA为61.86%，UA为63.42%。而当结合语音和文本两种模态进行情感识别时，WA提高了10.45%-13.73%，UA提高了11.66%-13.35%。这证实了语音和文本模态的互补性，以及本文结合这两种模态进行情感识别的有效性。

与Feature Fusion和Model Fusion模型相比，MTAF的WA和UA分别提高了5.16%-8.65%和6.78%-10.13%。实验结果证实了本文提出的混合融合策略的有效性。它结合了特征级和模型级融合方法的优点，捕获更细粒度的模态内和模型间交互，充分利用语音和文本模态的互补信息，获得更丰富的情感表示。

当去掉自编码器后，模型的WA下降了2.22%，UA下降了1.60%。这一结果突出了使用多头自注意力机制进行模态内交互以捕获上下文时间依赖性的重要性。进一步地，当去除融合模块后，模型的性能也有所下降，这表明使用多头交叉注意力机制进行跨模态特征融合的重要性。其能够动态地学习不同模态之间的相互关系，并灵活调整融合策略，以更好地捕捉跨模态特征的多样性和复杂性。

最后，为了探究不同模态对具体情感类别的识别效果，本文还绘制了仅使用语音和仅使用文本模态的混淆矩阵以及本文提出的MTAF的混淆矩阵（Ang：生气，Sad：伤心，Hap：高兴，Fru：沮丧，Sur：惊讶，Neu：中性），如图4.2、4.3和4.4所示。纯语音模型和纯文本模型分别有一个语音模块和文本模块，但没有模型融合模块。

对于沮丧和中性两种情绪类别，多模态模型的识别准确率与单模态模型接近。对于其他情感类别，多模态模型的识别准确率远高于单模态模型。此外还观察到，将语音和文本结合起来进行情绪识别后，快乐类别的识别正确率有10%到27%的显著提高，愤怒类别的正确率显著提高了15%-18%，悲伤类别的正确率显著提高了9%-14%。这些实验结果再一次证实了结合语音和文本模态进行情感识别的有效性。多模态方法结合了不同模态的优点，可以获得更丰富的情感表示。此外，当一种模态出现噪声时，不同模态的互补信息也可以增加系统的鲁棒性。




图 4.2 语音单模态混淆矩阵




图 4.3 文本单模态混淆矩阵




图 4.4 MTAF混淆矩阵

此外，结合三张图片一起来看，可以明显发现沮丧和惊讶类别的识别准确率明显偏高，这是因为数据样本分布不均衡所导致的。沮丧类别样本数目是最多的，有1849条样本。这使得模型能够充分学习到沮丧情感的特征表示，从而在识别时取得较高的准确率。而惊讶类别样本数目是最少的，只有107条样本。由于样本数目很少，这会导致准确率很容易出现偏低或者偏高的现象，在本例中结果是偏高。为了解决这种样本不平衡的问题，可以考虑一些方法，例如过采样（增加样本数量）、欠采样（减少样本数量）、生成对抗网络（GAN）生成合成样本等，以平衡不同类别之间的样本分布，从而提高模型在少样本类别上的识别准确率。

值得注意的是，愤怒、快乐和中性类别被错误分类为悲伤的概率相对较大。此外，快乐和悲伤的类别也经常归类为中性。先前的研究已经证明55%的人际关系依赖于面部表情或肢体动作，38%依赖于言语，仅有7%依赖于文本^[98]。面部表情给出了人类情感非常重要的线索^[99]。在语音和文本模态的基础上，增加面部表情可以提高识别准确率^[87]。因此，本文推断人类更多地面部表情中表达这些被划分错误

的情感。这些有趣的发现需要更多的研究，并可能导致识别精度的进一步提高。

4.5 本章小结

本文提出了一种多模态级联增强融合架构MTAF，使用语音和文本两种模态来进行情感识别。语音模态作为主导，文本模态作为辅助信息去级联增强语音模态，提高模型对多模态数据的表征能力。并且同时结合了特征级融合和模型级融合两种融合方式，有效地整合了不同的模态信息。此外，本文提出的模型融合模块，由多个多头交叉注意力机制组成，用于执行细粒度的模态内和模态间交互，最终生成多模态情感表示。在IEMOCAP和MELD数据集上的实验结果证明了所提方法的有效性。在未来的工作中，本文将尝试加入面部表情进行多模态情感识别，进一步提高语音情感识别的准确率。

第五章 基于上下文信息动态融合的语音情感识别

情感属于人主观性的产生和感知，导致无法完全通过定性和定量的方法进行分析，因此通过人表达的情感本身就具有一种模糊性。同时由于人说话的表达方式，一句语音中可能包含多种不同概率的情感。由于情感的模糊性和复杂性，语音情感识别的性能会受到限制，因为语音信号本身可能不足以提供充分的信息以准确识别说话者的情感状态。而上下文信息，如说话者的语言内容、语境和环境条件等，可以提供额外的线索和语境，有助于更准确地理解说话者的情感。

5.1 引言

第四章中提出的多模态级联增强融合架构，仅仅考虑到了多模态数据的信息交互作用，提高了模型对多模态数据的表征能力。但其却忽略了上下文句子之间的依赖关系，未利用上下文信息为情感识别提供的线索。同时还未考虑到模型对个体差异的适应能力较弱的问题，这会使得特征的代表性不足，影响到语音情感识别的泛化能力和识别效果。




图 5.1 不同的上下文信息所导致的情感识别的结果

图5.1 说明了上下文在确定情感内容时的重要性。相同的一句话，把它放在不同的语境中会传达出截然不同的情感。因此情感的识别是需要语境的。当说话者说“嗯嗯”时，我们可能无法确定说话者的真实情感状态。但是，如果考虑到上下文信息，比如说话者所讨论的话题、说话者的语气、以及之前的交流历史等，就能够更好地理解说话者的情感，并作出更准确的情感分类。

之前的研究中都将每个句子看作一个独立的实体，而忽略了上下文句子之间的依赖关系。根据情绪产生理论，人类不仅通过当前的话语来感知情绪，还通过周围的话语来感知情绪^[100]。因此，对语境关系进行建模是很有必要的。并且，编码后的特征向量不仅包含情感信息，而且包含了个人无关信息。如每个个体都有独特的音色和表达习惯，这会给人带来误导性的信息从而影响对情感表达的解读。考虑个体

差异的特征可以处理跨个体泛化问题，从而打破模型性能的上限。

同时考虑到在第四章的实验部分，即混淆矩阵分析那里，本文指出面部表情给出了人类情感非常重要的线索，在语音和文本模态的基础上，增加面部表情可以提高识别准确率。因此，本节在使用语音和文本模态的基础上，增加了视频模态，利用不同模态间的互补信息去进一步提升情感识别的准确率。

本文提出了一个上下文信息动态融合架构（Multimodal context adaptive fusion, MCAF），结合语音，文本和视频模态，不仅对语境关系进行建模，同时对情感特征和说话人特征进行分离。具体的，将早期融合后的包含上下文信息的语音、文本和视频特征送入上下文感知编码器中捕获时间依赖。由于不同的句子对情感识别的重要程度不同，因此本文提出了基于上下文感知的动态注意力机制。使模型能够根据上下文和输入数据的特性进行动态调整，从而有效地关注那些对情感分类具有关键作用的句子，增强模型对整体语义结构的理解能力。接着将深度情感特征向量送入由注意力层组成的特征解耦模块，用来实现实现情感信息和个人信息的分离，从而提高个体不可知情绪表示的鲁棒性。

5.2 模型结构

如图5.2所示，MCAF架构主要由三部分组成：上下文感知编码器，特征解耦器和分类器。




图 5.2 MCAF架构

将提取得到的三种模态，即语音（a）+ 文本（t）+ 视频（v）的特征通过拼接

的方式进行特征级融合得到多模态特征 (atv)。特征级融合能够使模型从开始就学习到丰富的跨模态特征，便于捕获模态的动态交互关系。

接着将每个句子的多模态特征进行连接， $S(i)$ 是指第 i 个句子， $S(i-1)$ 是指第 i 个句子的前一个句子，其他以此类推。最终得到上下文特征 X ：

$$X = x^{(atv)} = \left[x_1^{(atv)}, x_2^{(atv)}, \dots, x_n^{(atv)} \right]^T \quad (5-1)$$

其中 n 是句子数目。

5.2.1 上下文感知编码器

特征级融合后，包含上下文信息的多模态特征 $X \in R^{n \times d_1}$ 被送入上下文感知编码器中捕获时间信息，其中 n 是句子数目， d_1 是特征维度。

上下文感知编码器由多头注意力层和基于上下文感知的动态注意力构成，如图5.3所示。多头注意力结构和第四章相同，此处不再赘述。经过多头注意力层后，最终得到上下文特征 $z_\alpha \in R^{n \times d_2}$ ，其中 d_2 是特征维度。




图 5.3 上下文感知编码器结构

由于不同的句子对情感识别的重要程度不同，因此本文提出了基于上下文感知的动态注意力机制去使模型根据上下文和输入数据的特性进行动态调整。通过计算不同句子的重要性来进行加权和，从而有效地关注那些对情感分类具有关键作用的句子，增强模型对整体语义结构的理解能力。

权重 α_{fuse} 的计算公式如下所述：

$$\alpha_{fuse} = softmax(z_\alpha W_z + b_z) \quad (5-2)$$

经过加权求和得到最终的上下文情感表征 z :

$$z = \alpha_{fuse}^T z_{\alpha} \quad (5-3)$$

$W_z \in R^{d_2 \times 1}$, $b_z \in R^{n \times 1}$ 。因此 $\alpha_{fuse} \in R^{n \times 1}$, $z \in R^{d_2}$ 。

5.2.2 特征解耦器




图 5.4 特征解耦器结构

通过上下文感知编码器后，语音特征被嵌入为深度情感特征向量 z 。在语音情感识别中，个人无关信息如音色和表达习惯可能会对识别结果产生负面影响。这可能包括刻板印象导致的过度概括，误导性信息带来的错误理解，个人偏好的影响导致的偏见，以及声音干扰导致的识别困难。因此，在进行情感识别时，需要谨慎处理个人无关信息，以避免对识别结果造成不良影响。考虑个体差异的特征可以处理跨个体泛化问题，从而打破模型性能的上限。因此本文提出了一个由提取器和解耦器组成的特征解耦模块，如图5.4所示，用来实现实现情感信息和个人信息的分离，从而提高个体不可知情绪表示的鲁棒性。

首先将上一步得到的上下文情感表征 z 送入提取器，去计算说话人特征 x 。提取器由注意力层组成，计算公式如下所述：

$$a = \sigma(W_2 \delta(W_1 z + b_1) + b_2) \quad (5-4)$$

$$s = a * z + z \quad (5-5)$$

$$x = \delta(W_3 s + b_3) \quad (5-6)$$

接着，将深度特征向量 z 和说话人特征 x 送入解耦器，得到最终情感表征 H ，计算公式如下所述：

$$H = z - x \quad (5-7)$$

其中 W_1 、 W_2 、 W_3 、 b_1 、 b_2 和 b_3 是可学习的参数， δ 是ReLU激活函数， σ 是sigmoid函数。

5.2.3 分类器

通过特征解耦模块后，将最终的情感表示 H 通过全连接层和softmax层，使用交叉熵损失函数预测情感类别：

$$\tilde{y} = \text{softmax}(wH + b) \quad (5-8)$$

$$Loss = -\frac{1}{N} \sum_{i=1}^N y_i \log(\tilde{y}_i) \quad (5-9)$$

y_i 是真实标签， $\tilde{y}_i$ 是通过softmax层的预测概率分布， w 和 b 是可学习的参数， N 是用于训练的样本总数。

5.3 实验设置

5.3.1 特征提取

本文根据不同模态数据的特性，选择相应的特征提取方法。IEMOCAP数据集，语音特征(100维)使用OpenSmile^[101]提取，视频特征(512维)取自Openface 2.0^[102]，文本特征(768维)使用sBERT^[103]提取。MOSEI数据集的语音特征使用librosa^[79]提取80维特征向量，视频特征(35维)取自ZADEH^[104]，文本特征(768维)使用sBERT获取。

5.3.2 实验实现细节

本实验分别使用IEMOCAP（4分类），IEMOCAP（6分类）和MOSEI数据集的离散标签（6分类）和连续标签（2分类，积极和消极）进行情感识别。实验超参数设置如表5.1所示，Transformer编码器有2层，多头注意力的头数设置为10。训练过程在GTX3090上使用PyTorch实现。本实验使用Adam优化器，学习率设置为0.0001，批处理大小设置为256。为了缓解过拟合，采用了0.4的dropout方法。模型最多训练了55轮，直到精度不再变化。所采用的评价指标为加权精度（WA）和非加权精度（UA）。

5.4 实验结果与分析

5.4.1 对比实验

为了验证本文所提出的上下文信息动态融合架构MCAF的有效性，分别在IEMOCAP（4分类），IEMOCAP（6分类），MOSEI（2分类）和MOSEI（6分

表 5.1 实验超参数设置

参数名	参数值
Transformer层数	2
多头注意力头数	10
优化器	Adam
学习率	0.0001
批处理大小	256
dropout	0.4
迭代次数	55

类)数据集上与其他最先进的架构进行了比较。

1. 在IEMOCAP (4分类)数据集上比较的架构有: 1) LOSO^[105]是一种基于多级多头融合注意力机制和循环神经网络的语音情感识别方法。2) KS-Transformer^[106]是一种稀疏Transformer, 通过更多地关注与情感相关的信息来实现高效的情感识别。3) Wu et al.^[107]是一种用于多模态情感识别的新型双分支神经网络模型结构, 该结构由时间同步分支和时间异步分支组成。4) Dutta et al.^[108]是一种用于对话式多模态情感识别的分层信息融合架构。其通过联合学习表示在信息融合的每个阶段改进了语句级语音和文本的表示。5) MSCNN-SPU-ATT^[109]是一种简单有效的架构, 其使用了CNN和注意力机制来解决语音情感识别任务。6) GRU-SA^[110]设计了一个跨模态Transformer模块用于多模态学习, 使用自注意力(SA)网络从融合的多模态特征中选择更重要的情感信息。

2. 在IEMOCAP (6分类)数据集上比较的架构有: 1) MSCAN^[86], 2) AMH^[87], 3) COGMEN^[47], 4) CTNet^[54], 5) MultiEMO^[92]和6) DF-ERC^[93], 以上架构也已经介绍过, 此处不再重复。

表 5.2 不同SER方法在IEMOCAP (4分类)数据集的比较

模型	WA(%)	UA(%)
LOSO ^[105]	73.23	—
KS-Transformer ^[106]	74.30	75.30
Wu et al. ^[107]	77.57	78.41
GRU-SA ^[110]	78.82	79.95
Dutta et al. ^[108]	78.90	—
MSCNN-SPU-ATT ^[109]	80.30	70.51
MCAF	80.81	80.63

如表5.2所示, 在IEMOCAP (4分类)数据集上, 本文提出的上下文信息动态融合架构MCAF取得了不错的结果, WA高达80.81%, UA高达80.63%。与选择的其

他架构相比较，MCAF的WA 提升了0.51% 到7.58%，UA提高了0.68%到10.12%。如表5.3所示，MCAF架构在IEMOCAP（6分类）数据集上的效果也很不错，达到了75.95%的WA和74.48%的UA。相比其他架构，WA得到了4.11%到14.75%的提升，UA得到了1.73%到18.48%的提升。这证实了本文所提出的MCAF架构的有效性。

表 5.3 不同SER方法在IEMOCAP (6分类)数据集的比较

模型	WA(%)	UA(%)
MSCAN ^[86]	61.20	56.00
AMH ^[87]	62.40	59.70
COGMEN ^[47]	68.20	—
CTNet ^[54]	68.00	67.60
MultiEMO ^[92]	—	72.75
DF-ERC ^[93]	71.84	70.78
MCAF	75.95	74.48

3. 在MOSEI（2分类）数据集上比较的架构有：1）MMMUBA^[111]是一种基于循环神经网络的多模态注意力框架，利用上下文信息进行语句级情感预测。2）LMR-CBT^[112]是一种高效的神经网络，通过CBTransformer学习模态融合表示，从未对齐的多模态序列中进行多模态情感识别。3）LGCCT^[113]是一种使用了轻量级门控交叉互补Transformer的架构。4）TCM-LSTM^[114]通过声学 and 视觉LSTM学习多模态嵌入，从不同的角度增强语言表示，其中语言特征起主导作用。5）M3^[115]是一种使用乘性融合层的多模态情感识别模型，其使用乘性融合来决定在每个样本的基础上，应该更多地依赖哪种模态来进行预测。6）MUIT^[116]的核心是跨模态注意力机制，它提供了一种潜在的跨模态适应，通过直接关注其他模态中的低级特征来融合多模态信息。

4. 在MOSEI（6分类）数据集上比较的架构有：1）Graph-MFN^[117]是一种与带有记忆融合网络的图进行了动态融合的架构。2）CIM-Att-STL^[118]是一种上下文级别的模态间注意力框架，用于同时预测话语的情感和表达的情感。3）M-ELMo+NN(A+T)^[119]通过在双向语言模型中加入平行流，将声学信息融入到语境化的词汇嵌入中。4）TF^[120]使用多任务训练的Transformer模型的编码器来提取人物身份和自动语音识别嵌入。

此外，本节还同时使用了MOSEI数据集的离散和连续的情感标签，即分别在MOSEI（2分类）和MOSEI（6分类）数据集上进行了对比实验，以评估本文提出的MCAF架构。如表5.4所示，在MOSEI（2分类）数据集上，MCAF取得了82.92%的WA，WA相比其他的架构提升了0.42%-3.12%。如表5.5所示，MCAF在MOSEI（6分类）数据集上取得了67.10%的WA。相比其他的架构，WA提升

表 5.4 不同SER方法在MOSEI（2分类）数据集的比较

模型	WA(%)
MMMU-BA ^[111]	79.80
LMR-CBT ^[112]	80.50
LGCCT ^[113]	81.10
TCM-LSTM ^[114]	81.40
M3 ^[115]	82.50
MUIT ^[116]	82.50
MCAF	82.92

了0.70%到4.80%。不管使用的是离散情感标签，还是连续情感标签，MCAF均取得了不错的识别效果。这个实验结果进一步证实本文所提的上下文信息动态融合架构MCAF的有效性。

表 5.5 不同SER方法在MOSEI（6分类）数据集的比较

模型	WA(%)
Graph-MFN ^[117]	62.30
CIM-Att-STL ^[118]	62.80
M-ELMo+NN(A+T) ^[119]	66.20
TF ^[120]	66.40
MCAF	67.10

在这四种类别的数据集上的实验结果均证明了本文所提架构MCAF的有效性。本文提出的上下文信息加权融合架构MCAF，对语境关系进行建模，充分利用上下文提供的线索，同时消除个人无关信息对情感识别的影响。利用上下文感知动态注意力机制使模型根据上下文和输入数据的特性进行动态调整，从而有效地关注那些对情感分类具有关键作用的句子，增强模型对整体语义结构的理解能力。同时利用特征解耦模块实现情感特征和说话人特征的分离，从而提高个体不可知情绪表示的鲁棒性。

5.4.2 消融实验与混淆矩阵

本节在IEMOCAP数据集（4分类）上进行了多种消融实验，以评估本文所提出方法中的模态种类，上下文句子数目以及模型结构的有效性。

表5.6展示的是不同模态对情感识别结果的影响。a是指语音单模态，at是指语音+文本双模态，atv是指语音+文本+视频三模态，其他以此类推。通过观察可以看出，单模态时，文本对情感识别的准确率最高，WA达到了65.04%，UA达到了70.80%。语音模态的情感识别结果次之，视频模态的最差。猜测这是因为虽然视

表 5.6 模态种类的消融实验

模态	WA(%)	UA(%)
a	61.15	65.06
t	65.04	70.80
v	44.71	50.71
at	71.36	77.18
av	61.62	66.76
tv	65.98	72.83
atv	80.81	80.63

频模态包含了较多信息，但同时引入了很多噪声，影响了情感识别的准确率。而当依次增加模态时，情感识别准确率较单模态都有提升。最后，当使用三种模态进行情感识别时的结果最好，不同模态间的互补信息提升了情感识别的准确率。同时这证实了本文在上一章混淆矩阵部分给出的猜想，引入视频模态能够进一步提升情感识别的准确率。

表 5.7 上下文句子数目的消融实验

上下文句子数	WA(%)	UA(%)
[0]	75.36	75.50
[-1,1]	77.54	77.33
[-2,2]	78.58	78.02
[-3,3]	80.81	80.63
[-4,4]	78.39	78.88
[-5,5]	75.30	74.21
[-6,6]	75.15	73.84

表5.7展示的是上下文句子数目对情感识别结果的影响。通过观察表格可以看出，当句子数目设置为1-4时，增加上下文信息后相较于单个句子的情感识别准确率均提高了，这证明了引入上下文信息对情感识别的有效性。通过融合上下文信息，为情感识别提供了额外的线索，提升了情感识别的准确率。其中，句子数目为3时准确率最高，WA达到了80.81%，UA达到了80.63%。最后，当句子数目设置为5和6时，融合上下文信息后相较于单个句子的WA和UA都下降了，这证明了句子数目不是越多越好，否则会适得其反。

对于这一发现，本文进一步在IEMOCAP（4分类）数据集上绘制了上下文句子数目分别为2、3和4时的混淆矩阵（Hap：高兴，Sad：伤心，Neu：中性，Ang：生气），观察句子数目对具体情感类别的识别影响。混淆矩阵如图5.3、5.4和5.5所示。

通过观察实验结果可知，上下文句子数目为3时情感识别的整体准确率最高，相

较句子数目为2时，伤心的识别准确率提升了21%。当句子数目增加为4时，开心和伤心的识别准确率分别下降了2%和18%。

因此，对于融合上下文信息进行情感识别来说，不是说使用的句子数目越多越好，当句子数目增加时同样也会引入无关线索，对情感识别起到迷惑作用。在本实验中句子数目为3时识别结果最好，但是最适宜的句子数目不是确定的，要根据实际情况进行大量的实验去探究合适的句子数目，才能提高情感识别的准确率。




图 5.5 上下文句子数目为2时的混淆矩阵




图 5.6 上下文句子数目为3时的混淆矩阵




图 5.7 上下文句子数目为4时的混淆矩阵

表5.8展示的是模型结构对情感识别结果的影响。**without-Encoder**模型是去除了上下文感知编码器，**without-decoupling**模型是去掉了特征解耦器。观察实验结果，当去掉上下文感知编码器后，模型的WA下降了5.53%，UA下降了4.10%。这证明了使用上下文感知编码器来对上下文信息进行编码的重要性。其中的上下文感知动态注意力机制能够根据不同句子的重要程度进行特征加权和，使模型有效地关注对情感分类具有关键作用的句子，从而更好的捕获情感信息。当去除特征解耦器后，模型的性能也有所下降，这表明进行情感信息和个人信息的分离的重要性，特征解耦

能够提高个体不可知情绪表示的鲁棒性。

表 5.8 模型结构的消融实验

模型	WA(%)	UA(%)
without-Encoder	75.28	76.53
without-decoupling	78.30	78.76
MCAF	80.81	80.63

5.5 本章小结

本文在上一章使用语音和文本模态的基础上增加了视频模态，进一步探索多模态情感识别。同时考虑到情感识别是依赖于语境的，而且编码后的特征向量不仅包含情感信息，还包含了个人无关信息，会影响情感识别的准确率。因此，本文提出了一种上下文信息动态融合架构（MCAF）。不仅对语境关系进行建模，同时对情感特征和说话人特征进行分离。具体地，使用基于上下文感知的动态注意力机制进行上下文特征加权和，关注那些对情感分类具有关键作用的句子，更好的捕获情感信息。同时将深度情感特征向量送入由注意力层组成的特征解耦模块，用来实现情感信息和个人信息的分离，从而提高个体不可知情绪表示的鲁棒性。通过在IEMOCAP和MOSEI数据集上对提出的方法进行了评估，证明了本文所提方法的有效性。

第六章 总结与展望

6.1 论文工作总结

语音情感识别作为人工智能领域的重要研究方向,在改善人机交互、情感智能系统和健康医疗等领域具有广泛的应用前景。该技术通过分析语音信号中的特征,可以准确地捕获说话者的情感状态,从而实现智能系统对用户情绪的感知和响应。未来,随着深度学习技术的发展,语音情感识别的性能和应用范围将进一步拓展,为人们带来更智能、更个性化的交互体验和服务。

然而,在实践中,语音情感识别面临着特征提取和选择的挑战,需要从复杂的语音信号中提取具有代表性的特征,并构建适当的分类器来进行情感分类。由于语音信号的复杂性和多样性,选择合适的特征来表示情感是一个挑战。同时,特征的选择也受到数据集、语音质量、说话人的差异等因素的影响。因此需要综合考虑语音信号的特点、任务需求和模型复杂度,采用合适的方法来提取和选择特征,以提高情感识别系统的性能和泛化能力。

同时,尽管语音能够独立的传达情感,但情感的表达是多模态的。人们通过语音语调、文本语义和面部表情等不同模态信息进行沟通。单一模态信息量不足,易受环境噪声和无关信息干扰。仅依靠语音模态进行情感识别可能准确度有限,且片面。

最后,结合上下文信息对情感识别具有重要的辅助性。在语音情感识别中,仅仅依靠语音信号进行情感分类可能会受到限制,因为语音信号本身可能不足以提供充分的信息以准确识别说话者的情感状态。而加入上下文信息,如说话者的语言内容、语境和环境条件等,可以提供额外的线索和语境,有助于更准确地理解说话者的情感。

因此本文整体基于多模态融合的思想,分别从语音单模态、语音+文本双模态以及语音+文本+视频三模态入手,提出了三种不同的融合架构,以增强语音情感识别系统的表达能力和鲁棒性。这些架构分别从特征、多模态信息交互和语境建模的角度提升了情感识别的准确率。

1. 针对无法充分捕捉语音信号中丰富情感信息的特征表示问题,本文提出了多级声学信息分层融合架构MAIF。通过结合不同级别的声学信息,包括梅尔谱图, MFCC和自监督特征,获取到丰富和多样化的语音特征,从多个角度对情感进行建模。并将其转化为多模态融合问题,利用分层注意力机制进行融合,捕获局部和全局特征,提高模型对情感的建模能力和泛化能力。

2. 针对语音信号中的环境噪声、说话人信息干扰和跨模态特征融合的挑战, 本文提出了多模态级联增强融合架构MTAF。其以语音模态为主导, 引入文本模态作为辅助信息, 通过级联增强的方式去增强语音模态, 减轻环境噪声和说话人信息等因素对语音情感识别的干扰, 同时提高模型对多模态数据的表征能力。具体地, 特征级融合使模型从开始就学习到丰富的跨模态特征, 而多头交叉注意力机制允许模型不仅在单一模态内部学习特征之间的关系, 而且还能学习不同模态之间的相互关系。

3. 针对未充分利用上下文信息和模型适应个体差异能力较弱的问题, 本文提出了上下文信息动态融合架构MCAF。具体地, 利用上下文感知编码器去进行语境建模, 并使用动态注意力机制进行特征加权, 突出对情感识别具有关键作用的句子, 更好地捕获情感信息。而特征解耦模块则进一步从情感信息中分离出个人信息, 提高了个体不可知情绪表示的鲁棒性。

多级声学信息分层融合架构提供了丰富的特征表示, 能够更好地适应不同的语音输入和情感状态, 提高模型对情感的建模能力和泛化能力; 但其识别效果会受到数据集泛化能力的限制, 在实际应用中需要更多的数据来训练提取有效的情感特征。多模态级联增强融合架构强调跨模态信息的交互学习, 利用文本信息来增强语音信号的表达能力和鲁棒性; 但其性能会受到语音识别任务的影响, 当文本模态不够准确或完整时会导致其辅助效果不佳。而上下文信息加权融合架构则充分利用上下文信息为情感识别提供额外线索, 并且增强了模型对个体差异的适应能力; 但是由于视频模态涉及隐私会导致其应用受到限制, 在实际应用中的很多领域, 如: 呼叫中心等, 无法获取视频模态数据。因此, 这三种架构各有利弊, 需要根据实际情况选择最优的架构使用。

6.2 未来研究工作展望

本文提出的三种融合架构充分利用了多模态数据中的信息, 减轻环境噪声和说话人信息等因素对语音情感识别的干扰, 实现了更精确、更全面的情感识别。不仅结合不同级别的声学信息去从多个角度对情感进行建模, 还学习了不同模态之间的相互关系从而更好地捕捉跨模态特征之间的多样性和复杂性, 而且对语境关系进行建模去增强模型对整体语义结构的理解能力。尽管本文提出的语音情感识别架构在性能上有显著提升, 但仍存在一些不足, 需要进一步研究和分析。具体来说, 有以下方面需要深入探讨和改进。

1. 在特征选择方面, 虽然梅尔谱图、MFCC和自监督特征是常用的语音特征, 但仍存在其他可能更具信息量的特征未被考虑。特征选择的局限性可能导致模型无法捕捉到一些重要的情感信息, 从而影响情感识别的准确率和鲁棒性。因此可以尝

试探索更多的语音特征，并且对不同特征之间的融合方式进行更加深入的研究，使模型能更好地适应不同的语音输入和情感状态，以提高模型的表现力和泛化能力。

2. 在模态选择方面，当前多模态情感分析主要集中在文本、语音和视频等数据模态上，而脑电信号、生理信号（心率的变化，呼吸的改变和肌肉的收缩等）等其他模态的数据集较为匮乏。考虑扩展数据集以涵盖这些额外模态将有助于丰富情感识别的视角，为多模态情感识别领域带来更广阔的发展空间和可能性。

3. 在模型选择方面，语音信号在情感分析方面具有独特挑战，因为其中包含的情感特征难以清晰区分。举例来说，在语谱图中，生气和高兴的情感类别可能呈现相似的特征，导致传统分类方法难以应对。因此，为了更好地理解语音信号并提取相关特征，需要选择适用于语音特点的网络结构，这需要进一步的实验和研究。

4. 说话人的个人无关信息，如音色和表达习惯，可能会给语音情感识别带来负面影响。这包括刻板印象导致的过度概括，误导性信息带来的错误理解，个人偏好的影响导致的偏见，以及声音干扰导致的识别困难。因此在进行情感识别时，需要注意个人无关信息可能带来的误导性影响。可以考虑进一步优化说话人特征和情感特征的特征解耦方式，如多任务学习，加入说话人分类等任务，能够更好的进行说话人无关的情感表征，消除说话人相关信息对情感识别的干扰。

参考文献

- [1] 张琪, 熊馨, 周建华, et al. 注意力残差网络结合LSTM的EEG情绪识别研究[J]. 华东理工大学学报(自然科学版), 2024: 1–11.
- [2] EL AYADI M, KAMEL M S, KARRAY F. Survey on speech emotion recognition: Features, classification schemes, and databases[J]. Pattern Recognition, 2011, 44(3): 572–587.
- [3] WANI T M, GUNAWAN T S, QADRI S A A, et al. A Comprehensive Review of Speech Emotion Recognition Systems[J]. IEEE Access, 2021, PP(99): 1–1.
- [4] TAO J, TAN T. Affective computing: A review[C] // Affective Computing and Intelligent Interaction: First International Conference, ACII 2005, Beijing, China, October 22-24, 2005. Proceedings 1. 2005: 981–995.
- [5] SCHULLER B W. Speech Emotion Recognition Two Decades in a Nutshell, Benchmarks, and Ongoing Trends[J]. Communications of the ACM, 2018, 61(5): 90–99.
- [6] MARCHI E, SCHULLER B, BATLINER A, et al. Emotion in the Speech of Children with Autism Spectrum Conditions: Prosody and Everything Else[C] // Proceedings 3rd Workshop on Child, Computer and Interaction (WOCCI 2012). 2012.
- [7] 陈国伟, 张鹏洲, 王婷, et al. 多模态情感分析综述[J]. 中国传媒大学学报(自然科学版), 2022, 29(70-78).
- [8] WANG C, REN Y, ZHANG N, et al. Speech emotion recognition based on multi-feature and multi-lingual fusion[J]. Multimedia tools and applications, 2022(4): 81.
- [9] SEBE N, COHEN I, GEVERS T, et al. Multimodal approaches for emotion recognition: a survey[J]. International Society for Optics and Photonics, 2005.
- [10] PORIA S, CAMBRIA E, BAJPAI R, et al. A review of affective computing: From unimodal analysis to multimodal fusion[J]. Information Fusion, 2017, 37: 98–125.
- [11] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[J]. arXiv, 2017.
- [12] 张晓莉. 改进MFCC特征和MLA模型的语音情感识别[J]. 福建电脑, 2024, 40: 52–56.
- [13] 应娜, 吴顺鹏, 杨萌, et al. 基于小波散射变换和MFCC的双特征语音情感识别融合算法[J]. 电信科学, 2024: 1–14.
- [14] XU Y, XU H, ZOU J. Hgfm: A hierarchical grained and feature model for acoustic emotion recognition[C] // ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2020: 6499–6503.
- [15] WANG J, XUE M, CULHANE R, et al. Speech Emotion Recognition with Dual-Sequence LSTM Architecture[C] // IEEE International Conference on Acoustics, Speech and Signal Processing

- (ICASSP). 2020 : 6474–6478.
- [16] WANG Y, GU Y, YIN Y, et al. Multimodal transformer augmented fusion for speech emotion recognition[J]. *Frontiers in Neurorobotics*, 2023, 17.
- [17] ETIENNE C, FIDANZA G, PETROVSKII A, et al. CNN+LSTM Architecture for Speech Emotion Recognition with Data Augmentation[J]. *arXiv preprint arXiv:1802.05630*, 2018.
- [18] ZHAO J, MAO X, CHEN L. Speech emotion recognition using deep 1D and 2D CNN LSTM networks[J]. *Biomedical signal processing and control*, 2019, 47 : 312–323.
- [19] LI Y, ZHAO T, KAWAHARA T, et al. Improved end-to-end speech emotion recognition using self attention mechanism and multitask learning[C] // *Interspeech*. 2019 : 2803–2807.
- [20] GUO L, WANG L, XU C, et al. Representation Learning with Spectro-Temporal-Channel Attention for Speech Emotion Recognition[C] // *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2021.
- [21] MUPPIDI A, RADFAR M. Speech Emotion Recognition Using Quaternion Convolutional Neural Networks[C] // *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2021 : 6309–6313.
- [22] LIU J, LIU Z, WANG L, et al. Speech Emotion Recognition with Local-Global Aware Deep Representation Learning[C] // *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2020 : 7174–7178.
- [23] XU M, ZHANG F, CUI X, et al. Speech Emotion Recognition with Multiscale Area Attention and Data Augmentation[C] // *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2021 : 6319–6323.
- [24] LIU J, SONG Y, WANG L, et al. Time-Frequency Representation Learning with Graph Convolutional Network for Dialogue-Level Speech Emotion Recognition[C] // *Interspeech*. 2021 : 4523–4527.
- [25] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[J]. *Proceedings of naacL-HLT*, 2018, 1.
- [26] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[J]. *OpenAI*, 2018.
- [27] SCHNEIDER S, BAEVSKI A, COLLOBERT R, et al. wav2vec: Unsupervised Pre-training for Speech Recognition[J]. *arXiv preprint arXiv:1904.05862*, 2019.
- [28] BAEVSKI A, ZHOU Y, MOHAMED A, et al. wav2vec 2.0: A framework for self-supervised learning of speech representations[J]. *Advances in neural information processing systems*, 2020, 33 : 12449–12460.
- [29] HSU W-N, BOLTE B, TSAI Y-H H, et al. Hubert: Self-supervised speech representation learning

- p by masked prediction of hidden units[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29 : 3451 – 3460.
- [30] PENG Z, HUANG W, GU S, et al. Conformer: Local Features Coupling Global Representations for Visual Recognition[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021 : 367 – 376.
- [31] GRÓSZ T, PORJAZOVSKI D, GETMAN Y, et al. Wav2vec2-Based Paralinguistic Systems to Recognise Vocalised Emotions and Stuttering[C] //Proceedings of the 30th ACM International Conference on Multimedia. 2022 : 7026 – 7029.
- [32] XIA Y, CHEN L-W, RUDNICKY A, et al. Temporal Context in Speech Emotion Recognition.[C] //Interspeech. 2021 : 3370 – 3374.
- [33] PEPINO L, RIERA P, FERRER L. Emotion recognition from speech using wav2vec 2.0 embeddings[J]. arXiv preprint arXiv:2104.03502, 2021.
- [34] TRIGEORGIS G, RINGEVAL F, BRUECKNER R, et al. Adieu features? end-to-end speech emotion recognition using a deep convolutional recurrent network[C] //2016 IEEE international conference on acoustics, speech and signal processing (ICASSP). 2016 : 5200 – 5204.
- [35] EYBEN F, WÖLLMER M, GRAVES A, et al. On-line emotion recognition in a 3-D activation-valence-time continuum using acoustic and linguistic cues[J]. Journal on Multimodal User Interfaces, 2010, 3 : 7 – 19.
- [36] ZHAO J, MAO X, CHEN L. Speech emotion recognition using deep 1D & 2D CNN LSTM networks[J]. Biomedical signal processing and control, 2019, 47 : 312 – 323.
- [37] CHEN M, HE X, YANG J, et al. 3-D convolutional recurrent neural networks with attention model for speech emotion recognition[J]. IEEE Signal Processing Letters, 2018, 25(10): 1440 – 1444.
- [38] GUO L, WANG L, XU C, et al. Representation learning with spectro-temporal-channel attention for speech emotion recognition[C] //IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021 : 6304 – 6308.
- [39] KIM J, AN Y, KIM J. Improving speech emotion recognition through focus and calibration attention mechanisms[J]. arXiv preprint arXiv:2208.10491, 2022.
- [40] XU H, ZHANG H, HAN K, et al. Learning Alignment for Multimodal Emotion Recognition from Speech[C] //Interspeech. 2019.
- [41] WANG Y, SHEN G, XU Y, et al. Learning Mutual Correlation in Multimodal Transformer for Speech Emotion Recognition[C] //Interspeech. 2021 : 4518 – 4522.
- [42] WANG X, WANG M, QI W, et al. A novel end-to-end speech emotion recognition network with stacked transformer layers[C] //IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021 : 6289 – 6293.

- [43] LIAN Z, LIU B, TAO J. CTNet: Conversational transformer network for emotion recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 985–1000.
- [44] 王颖, 高胜. 轻量型胶囊网络语音情感识别方法[J]. 电子科技大学学报, 2023, 52: 423–429.
- [45] LIU Z, SHEN Y, LAKSHMINARASIMHAN V B, et al. Efficient low-rank multimodal fusion with modality-specific factors[J]. arXiv preprint arXiv:1806.00064, 2018.
- [46] PORIA S, CAMBRIA E, HAZARIKA D, et al. Multi-level Multiple Attentions for Contextual Multimodal Sentiment Analysis[C] // 2017 IEEE International Conference on Data Mining (ICD-M). 2017: 1033–1038.
- [47] JOSHI A, BHAT A, JAIN A, et al. COntextualized GNN based Multimodal Emotion recognition[C] // Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2022: 4148–4164.
- [48] CHEN M, ZHAO X. A Multi-Scale Fusion Framework for Bimodal Speech Emotion Recognition[C] // Interspeech. 2020: 374–378.
- [49] ZADEH A, CHEN M, PORIA S, et al. Tensor Fusion Network for Multimodal Sentiment Analysis[C] // Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 1103–1114.
- [50] MITTAL T, BHATTACHARYA U, CHANDRA R, et al. M3ER: Multiplicative Multimodal Emotion Recognition using Facial, Textual, and Speech Cues[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(2): 1359–1367.
- [51] MAJUMDER N, HAZARIKA D, GELBUKH A, et al. Multimodal sentiment analysis using hierarchical fusion with context modeling[J]. Knowledge-based systems, 2018, 161: 124–133.
- [52] ZADEH A, LIANG P P, MAJUMDER N, et al. Memory fusion network for multi-view sequential learning[J]. Proceedings of the AAAI conference on artificial intelligence, 2018, 32(1).
- [53] SUN L, LIU B, TAO J, et al. Multimodal cross-and self-attention network for speech emotion recognition[C] // IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021: 4275–4279.
- [54] LIAN Z, LIU B, TAO J. CTNet: Conversational Transformer Network for Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, PP(99): 1–1.
- [55] SEBASTIAN J, PIERUCCI P, OTHERS. Fusion Techniques for Utterance-Level Emotion Recognition Combining Speech and Transcripts[C] // Interspeech. 2019: 51–55.
- [56] KUMAR P, MALIK S, RAMAN B. Interpretable multimodal emotion recognition using hybrid fusion of speech and image data[J]. Multimedia Tools and Applications, 2023: 1–22.
- [57] DZEDZICKIS A, KAKLAUSKAS A, BUCINSKAS V. Human emotion recognition: Review of sensors and methods[J]. Sensors, 2020, 20(3): 592.

- [58] 温万惠. 基于生理信号的情感识别方法研究[D]. [S.l.]: 西南大学, 2010.
- [59] KO B C. A brief review of facial emotion recognition based on visual information[J]. *sensors*, 2018, 18(2): 401.
- [60] 周菊香, 刘金生, 甘健侯, et al. 基于多尺度时序感知网络的课堂语音情感识别方法[J]. *计算机应用*, 2024: 1–10.
- [61] BAGOZZI R P, GOPINATH M, NYER P U. The role of emotions in marketing[J]. *Journal of the academy of marketing science*, 1999, 27(2): 184–206.
- [62] SOLOMON R C. Thinking about feeling: Contemporary philosophers on emotions[M]. 2004.
- [63] EKMAN P. An argument for basic emotions[J]. *Cognition & emotion*, 1992, 6(3-4): 169–200.
- [64] ATMAJA B T, SASOU A, AKAGI M. Survey on bimodal speech emotion recognition from acoustic and linguistic information fusion[J]. *Speech Communication*, 2022, 140: 11–28.
- [65] RUSSELL J A. A circumplex model of affect.[J]. *Journal of personality and social psychology*, 1980, 39(6): 1161.
- [66] MEHRABIAN A, RUSSELL J A. An approach to environmental psychology.[M]. 1974.
- [67] FONTAINE J R, SCHERER K R, ROESCH E B, et al. The world of emotions is not two-dimensional[J]. *Psychological science*, 2007, 18(12): 1050–1057.
- [68] 高鹏淇, 黄鹤鸣, 樊永红. 融合坐标与多头注意力机制的交互语音情感识别[J]. *计算机应用*, 2023: 1–7.
- [69] 裴晓敏, 刘诗琦. 基于双通道多特征融合网络语音情感识别[J]. *微电子学与计算机*, 2024: 1–10.
- [70] DAVIS S, MERMELSTEIN P. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences[J]. *IEEE transactions on acoustics, speech, and signal processing*, 1980, 28(4): 357–366.
- [71] ELMAN J L. Finding structure in time[J]. *Cognitive science*, 1990, 14(2): 179–211.
- [72] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural computation*, 1997, 9(8): 1735–1780.
- [73] 陶建华, 陈俊杰, 李永伟. 语音情感识别综述[J]. *信号处理*, 2023, 39: 571–587.
- [74] BURKHARDT F, PAESCHKE A, ROLFES M, et al. A database of German emotional speech[C] //9th European Conference on Speech Communication and Technology: Vol 5. 2005: 1517–1520.
- [75] BUSSO C, BULUT M, LEE C-C, et al. IEMOCAP: Interactive emotional dyadic motion capture database[J]. *Language resources and evaluation*, 2008, 42: 335–359.
- [76] PORIA S, HAZARIKA D, MAJUMDER N, et al. Meld: A multimodal multi-party dataset for emotion recognition in conversations[J]. *arXiv preprint arXiv:1810.02508*, 2018.

- [77] ZADEH A B, LIANG P P, PORIA S, et al. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph[C] // Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics : Vol 5. 2018 : 2236–2246.
- [78] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [79] MCFEE B, RAFFEL C, LIANG D, et al. librosa: Audio and music signal analysis in python[C] // Proceedings of the 14th python in science conference : Vol 8. 2015 : 18–25.
- [80] CAO Q, HOU M, CHEN B, et al. Hierarchical Network Based on the Fusion of Static and Dynamic Features for Speech Emotion Recognition[C] // ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021 : 6334–6338.
- [81] CHEN Q, HUANG G. A novel dual attention-based BLSTM with hybrid features in speech emotion recognition[J]. Engineering Applications of Artificial Intelligence, 2021, 102 : 104277.
- [82] ZOU H, SI Y, CHEN C, et al. Speech emotion recognition with co-attention based multi-level acoustic information[C] // ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2022 : 7367–7371.
- [83] GAO Y, LIU J, WANG L, et al. Domain-Adversarial Autoencoder with Attention Based Feature Level Fusion for Speech Emotion Recognition[C] // 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021 : 6314–6318.
- [84] CHEN Z, LI J, LIU H, et al. Learning multi-scale features for speech emotion recognition with connection attention mechanism[J]. Expert Systems with Applications, 2023, 214 : 118943.
- [85] YOONHYUNG L, SEUNGHYUN Y, KYOMIN J. Multimodal Speech Emotion Recognition Using Cross Attention with Aligned Audio and Text[C] // Interspeech. 2020 : 2717–2721.
- [86] SUN L, LIU B, TAO J, et al. Multimodal cross-and self-attention network for speech emotion recognition[C] // 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021 : 4275–4279.
- [87] YOON S, DEY S, LEE H, et al. Attentive Modality Hopping Mechanism for Speech Emotion Recognition[C] // IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2020 : 3362–3366.
- [88] GOEL S, BEIGI H. Cross lingual cross corpus speech emotion recognition[J]. arXiv preprint arXiv:2003.07996, 2020.
- [89] PARRY J, PALAZ D, CLARKE G, et al. Analysis of Deep Learning Architectures for Cross-Corpus Speech Emotion Recognition[C] // Interspeech 2019. 2019 : 1656–1660.
- [90] BADSHAH A M, AHMAD J, RAHIM N, et al. Speech emotion recognition from spectrograms with deep convolutional neural network[C] // 2017 international conference on platform technolo-

- p>gy and service (PlatCon).. 2017 : 1 – 5.
- [91] CHEN W, XING X, XU X, et al. DST: Deformable speech transformer for emotion recognition[C] //ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2023 : 1 – 5.
- [92] SHI T, HUANG S-L. MultiEMO: An attention-based correlation-aware multimodal fusion framework for emotion recognition in conversations[C] //Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023 : 14752 – 14766.
- [93] LI B, FEI H, LIAO L, et al. Revisiting disentanglement and fusion on modality and context in conversational multimodal emotion recognition[C] //Proceedings of the 31st ACM International Conference on Multimedia. 2023 : 5923 – 5934.
- [94] MIRSAMADI S, BARSOUM E, ZHANG C. Automatic speech emotion recognition using recurrent neural networks with local attention[C] //IEEE International conference on acoustics, speech and signal processing (ICASSP). 2017 : 2227 – 2231.
- [95] ZHOU S, JIA J, WANG Q, et al. Inferring emotion from conversational voice data: A semi-supervised multi-path generative neural network approach[C] //Proceedings of the AAAI Conference on Artificial Intelligence : Vol 32. 2018.
- [96] PORIA S, CAMBRIA E, HAZARIKA D, et al. Context-dependent sentiment analysis in user-generated videos[C] //Proceedings of the 55th annual meeting of the association for computational linguistics (volume 1: Long papers). 2017 : 873 – 883.
- [97] MAJUMDER N, PORIA S, HAZARIKA D, et al. Dialoguernn: An attentive rnn for emotion detection in conversations[C] //Proceedings of the AAAI conference on artificial intelligence : Vol 33. 2019 : 6818 – 6825.
- [98] MEHRABIAN A, OTHERS. Silent messages[J]. Wadsworth Publishing Company, Inc., Belmont, Calif., 1971, 8(152).
- [99] KIM H-R, KIM Y-S, KIM S J, et al. Building Emotional Machines: Recognizing Image Emotions through Deep Neural Networks[J]. IEEE Transactions on Multimedia, 2018, 20(11) : 2980 – 2992.
- [100] GROSS J J, FELDMAN BARRETT L. Emotion generation and emotion regulation: One or two depends on your point of view[J]. Emotion review, 2011, 3(1) : 8 – 16.
- [101] EYBEN F, WÖLLMER M, SCHULLER B. Opensmile: the munich versatile and fast open-source audio feature extractor[C] //Proceedings of the 18th ACM international conference on Multimedia. 2010 : 1459 – 1462.
- [102] BALTRUSAITIS T, ZADEH A, LIM Y C, et al. Openface 2.0: Facial behavior analysis toolkit[C] //2018 13th IEEE international conference on automatic face & gesture recognition (FG 2018). 2018 : 59 – 66.

- [103] REIMERS N, GUREVYCH I. Sentence-bert: Sentence embeddings using siamese bert-networks[J]. arXiv preprint arXiv:1908.10084, 2019.
- [104] ZADEH A B, LIANG P P, PORIA S, et al. Multimodal language analysis in the wild: Cmu-mosei dataset and interpretable dynamic fusion graph[C] //Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018 : 2236–2246.
- [105] HO N-H, YANG H-J, KIM S-H, et al. Multimodal approach of speech emotion recognition using multi-level multi-head fusion attention-based recurrent neural network[J]. IEEE Access, 2020, 8 : 61672–61686.
- [106] CHEN W, XING X, XU X, et al. Key-sparse transformer for multimodal speech emotion recognition[C] //IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2022 : 6897–6901.
- [107] WU W, ZHANG C, WOODLAND P C. Emotion recognition by fusing time synchronous and time asynchronous representations[C] //IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021 : 6269–6273.
- [108] DDUTTA S, GANAPATHY S. Multimodal transformer with learnable frontend and self attention for emotion recognition[C] //IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2022 : 6917–6921.
- [109] PENG Z, LU Y, PAN S, et al. Efficient speech emotion recognition using multi-scale cnn and attention[C] //IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2021 : 3020–3024.
- [110] MAJI B, SWAIN M, GUHA R, et al. Multimodal emotion recognition based on deep temporal features using cross-modal transformer and self-attention[C] //ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2023 : 1–5.
- [111] GHOSAL D, AKHTAR M S, CHAUHAN D, et al. Contextual inter-modal attention for multimodal sentiment analysis[C] //proceedings of the 2018 conference on empirical methods in natural language processing. 2018 : 3454–3466.
- [112] FU Z, LIU F, XU Q, et al. LMR-CBT: Learning modality-fused representations with CB-transformer for multimodal emotion recognition from unaligned multimodal sequences[J]. Frontiers of Computer Science, 2024, 18(4) : 184314.
- [113] LIU F, SHEN S-Y, FU Z-W, et al. Lgcct: A light gated and crossed complementation transformer for multimodal speech emotion recognition[J]. Entropy, 2022, 24(7) : 1010.
- [114] MAI S, XING S, HU H. Analyzing multimodal sentiment via acoustic-and visual-LSTM with channel-aware temporal convolution network[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29 : 1424–1437.

- [115] GEORGIOU E, PARASKEVOPOULOS G, POTAMIANOS A. M3: MultiModal Masking Applied to Sentiment Analysis[C] //Interspeech. 2021 : 2876–2880.
- [116] TSAI Y-H H, BAI S, LIANG P P, et al. Multimodal transformer for unaligned multimodal language sequences[C] //Proceedings of the conference. Association for Computational Linguistics. Meeting. NIH Public Access,. 2019 : 6558.
- [117] LIANG P P, SALAKHUTDINOV R, MORENCY L-P. Computational modeling of human multimodal language: The mosei dataset and interpretable dynamic fusion[C] //First Workshop and Grand Challenge on Computational Modeling of Human Multimodal Language : Vol 113. 2018 : 116–125.
- [118] AKHTAR M S, CHAUHAN D S, GHOSAL D, et al. Multi-task learning for multi-modal emotion recognition and sentiment analysis[J]. arXiv preprint arXiv:1905.05812, 2019.
- [119] TSENG S-Y, NARAYANAN S, GEORGIOU P. Multimodal embeddings from language models for emotion recognition in the wild[J]. IEEE Signal Processing Letters, 2021, 28 : 608–612.
- [120] KHARE A, PARTHASARATHY S, SUNDARAM S. Multi-modal embeddings using multi-task learning for emotion recognition[J]. arXiv preprint arXiv:2009.05019, 2020.