

分类号: _____

密级: _____

U D C: _____

编号: _____

工学博士学位论文

基于深度学习的语音情感识别技术研究

博 士 研 究 生 : 闫天昊

指 导 教 师 : 孟浩

学 科 、 专 业 : 控制科学与工程

2023 年 4 月

分类号：_____

密级：_____

U D C：_____

编号：_____

工学博士学位论文

基于深度学习的语音情感识别技术研究

博 士 研 究 生：闫天昊

指 导 教 师：孟浩

学 位 级 别：工学博士

学 科、专 业：控制科学与工程

所 在 单 位：哈尔滨工程大学

论文提交日期：2023 年 4 月

论文答辩日期：2023 年 5 月

学位授予单位：哈尔滨工程大学

Classified Index:

U.D.C:

A Dissertation for the degree of D. Eng

Research on Speech Emotion Recognition Technology based on Deep Learning

Candidate: Yan Tianhao

Supervisor: Meng Hao

Academic Degree Applied for: Doctor of Engineering

Specialty: Control Science and Engineering

Date of Submission: April, 2023

Date of Oral Examination: May, 2023

University: Harbin Engineering University

摘 要

语音情感识别是利用计算机算法策略针对人们所说出的话语来完成情感预测与识别,是实现智能化人机交互不可或缺的组成部分,涉及语音信号处理、心理学、计算机科学、模式识别等在内的多项学科,在交互式人工智能领域有广泛的应用前景和研究意义,是该领域最重要的研究热点之一。近年来,深度学习已经被引入到语音情感识别研究中,提升了识别性能,因此研究能有效提升识别精度的深度学习算法对促进语音情感识别的发展有重要意义。

目前,与传统机器学习算法相比,基于深度学习的语音情感识别技术已经取得了较大的成功,然而仍然存在一些问题制约着情感识别精度的提升,主要包括:1)语音信号通过短时傅里叶分析得到的声学特征,在时频域内表征信号局部特征能力较弱;传统注意力模型无法从声学特征中生成有效的显著性特征分布;2)卷积神经网络因单一感受野导致语谱图特征中全局信息提取不够充分;注意力机制在提取高维特征时忽视了时域维度上相关情感特征的获取;3)注意力机制往往是以先后顺序在时域和频域单一维度上提取显著性特征以加强情感分布,忽视了对高维特征中时频二维局部空间信息的提取;4)情感语音数据因模型并行训练需要截取语音片段,存在所截取片段标签与句子标签不匹配的问题;注意力机制忽略了显著性特征位置信息,且较为依赖时间序列而无法对特征并行处理。

针对上述问题,本文从语音情感信号处理、特征提取以及注意力机制结构设计等角度给出了有效的解决方法,提升了语音情感识别精度及其模型的泛化能力,主要研究的具体内容如下:

1)针对声学信号在时频域内提取到的显著性特征表征情感能力较弱的问题,提出了基于小波包重构特征自适应注意力网络的语音情感识别算法。该算法利用小波包重构方式对语音信号进行分析,然后从重构后的信号中提取帧级声学特征,使其包含更多的时频分辨率信息,加强了对时频域局部情感特征的捕捉能力。提出了自适应注意力网络用于提取有效的显著性特征以生成帧级特征分布,与从原始信号中提取的句子级声学特征分布相联合,增强了语音情感信息表征能力,最后利用交叉熵损失函数实现语音情感识别。实验结果表明所提出的基于声学特征的语音情感识别算法有效提高了情感识别结果。

2) 针对语谱图在利用卷积神经网络提取过程中获取全局特征能力不足而导致部分情感信息缺失, 以及在时域维度中存在获取显著性情感特征较少的问题, 提出了基于自适应时频注意力残差网络的语音情感识别算法。该算法提出在卷积模块中融入空洞卷积与残差结构, 扩大情感特征感受野范围并增强表征能力, 然后使用循环模块获取与时序相关的特征。提出的自适应时频注意力模块利用其内部结构分别加强对时频域内显著性特征的捕捉能力, 生成更有利于情感识别的特征分布。最后利用可兼顾类内聚合和类间分离的中心损失函数, 联合交叉熵损失函数实现语音情感识别。实验结果表明所提出的算法有效提升了识别性能。

3) 针对语谱图在特征提取过程中高维特征内时频二维局部空间情感相关信息遗漏问题, 提出了基于动态空间自适应注意力网络的语音情感识别算法。该算法主要包含两个模块: 时频注意力循环模块和空间注意力循环模块, 前者用于从高维特征中捕获与时序相关特征, 并生成包含全局信息的显著性特征分布; 后者则用于提取高维特征中时频二维局部空间的情感特征, 生成包含局部空间信息的显著性特征分布, 然后将两个特征分布联合以丰富情感表达。最后利用可改善类别数量不平衡问题的焦点损失函数完成语音情感识别。实验结果表明所提出的算法可进一步提升情感识别精度, 同时基于新冠咳嗽声检测的扩展研究结果也证明了所提出算法的实用性与泛化性。

4) 针对语音信号处理过程中因样本时长不等导致所截取语音片段标签与句子标签不匹配, 以及在特征提取过程中模型对于情感显著性特征提取不够充分的问题, 提出了基于残差多尺度卷积 Transformer 神经网络的语音情感识别算法。该算法提出动态帧移算法使不同长时的句子级样本生成相同数量的块级片段并提取语谱图, 通过重塑模型输入使块级片段与句子标签相匹配, 实现模型并行训练; 提出带残差结构的多尺度卷积模块, 设计自适应特征位置编码结构, 并通过将位置信息融入到高维特征中, 使 Transformer 结构能够更好地获取块级片段情感显著性特征, 利用均值池化时间聚合策略生成句子级情感特征分布, 最后利用均方误差损失函数完成语音情感识别。实验结果表明所提出的算法可有效提升识别精度, 同时基于新冠咳嗽声的扩展研究进一步验证了该算法的实用性和泛化性。

关键词: 语音情感识别; 语音信号处理; 深度学习; 注意力机制; 特征位置编码

Abstract

Speech emotion recognition is the process of identifying and predicting emotions from spoken speech using computer algorithm methodologies. It involves speech signal processing, psychology, computer science, pattern recognition, other fields and is a crucial component of achieving intelligent human-computer interaction. It is one of the most significant research hotspots in the field of interactive artificial intelligence and has a wide range of application opportunities. Deep learning has been included into speech emotion recognition studies recently, which has increased recognition performance. To advance the development of speech emotion recognition, it is crucial to research deep learning algorithms that can effectively increase recognition accuracy.

Deep learning-based speech emotion recognition technology has currently outperformed more conventional machine learning algorithms, but there are still significant issues that limit the accuracy of emotion recognition from getting much better, most notably: 1) The acoustic features obtained by short-time Fourier analysis of the speech signal have a weak ability to represent the local features of the signal in the time-frequency domain. The traditional attention model cannot generate effective salient feature distributions from the acoustic features. 2) The attention mechanism ignores the acquisition of related emotional features in the time domain dimension when extracting high-dimensional features due to the convolutional neural network's single receptive field, which prevents the global information extraction in the spectrogram features from being sufficient. 3) In order to bolster emotional distribution, the attention mechanism frequently harvests salient characteristics in the time domain and the frequency domain, but ignores the extraction of time-frequency two-dimensional local spatial information in high-dimensional features. 4) Due to the need to intercept speech segments for parallel training of emotional speech data models, there is a problem of mismatch between the captured segment labels and utterance labels. The attention mechanism ignores the location information of salient features and is more dependent on time series, making it impossible to process features in parallel.

Taking into account the aforementioned issues, this study offers efficient solutions from the angles of speech emotion signal processing, feature extraction and attention mechanism

structure design, which enhances the model's generalizability and the precision that it can recognize emotions in a speaker's speech. The primary findings of the study are as follows:

1) A speech emotion recognition algorithm based on the Adaptive Attentive Wavelet Packet Reconstruction Recurrent Neural Network is proposed as a solution to the issue that saliency features collected from the acoustic data in the time-frequency domain are insufficient for describing emotion. In order to better capture local emotional features in the time-frequency domain, this algorithm uses wavelet packet reconstruction to analyze speech signals before extracting frame-level acoustic features from the reconstructed signals. An adaptive attention network is proposed to extract effective salient features to generate frame level feature distribution, which is combined with the utterance level acoustic feature distribution extracted from the original signal to enhance the ability of speech emotion information representation. Finally, speech emotion recognition is realized using cross entropy loss function. The experimental results show that the proposed speech emotion recognition algorithm based on acoustic features effectively improves emotion recognition results.

2) A speech emotion recognition algorithm based on the Residual Convolutional Recurrent Neural Network Model with Adaptive Time-Frequency Attention is proposed to address the issues of limited significant emotional features in the time domain dimension and the inability of spectrograms to obtain global features during the convolutional neural network extraction process, both of which result in the loss of emotional information. To improve the algorithm's representational ability and broaden the algorithm's receptive field for emotional variables, it recommends adding a dilated convolution and residual structure to the convolution module. The proposed adaptive time-frequency attention module utilizes its internal structure to enhance the ability of capturing significant features in the time-frequency domain and generating feature distributions, which are more conducive to emotion recognition. Finally, speech emotion recognition is realized by combining cross entropy loss function with the center loss function that can give attention to both intra class aggregation and inter class separation. The experimental results show that the proposed algorithm effectively improves recognition performance.

3) A speech emotion recognition algorithm based on Dynamic Adaptive Spatial Attentive ConvLSTM Recurrent Neural Networks is proposed to address the issue of missing emotion

related information in high-dimensional features, time-frequency and two-dimensional local space in the feature extraction process of spectrograms. This algorithm mainly consists of two modules: a time-frequency attention recurrent module and a spatial attention recurrent module. The former is used to capture temporal related features from high-dimensional features and generate saliency feature distributions containing global information; The latter is used to extract emotional features from high-dimensional features in time-frequency two-dimensional local space, generates saliency feature distributions containing local spatial information, and then combines the two feature distributions to enrich emotional expression. When it comes time to finish up speech emotion recognition, the focus loss function is utilized to help even out the amount of categories. The experimental findings demonstrate the efficacy of the suggested algorithm in enhancing the precision of emotion recognition. The practicality and generalizability of the suggested approach is further demonstrated by the extensive study results based on COVID-19 cough sound detection.

4) A speech emotion recognition algorithm based on a Multi-Scale Convolutional Transformer Neural Network is proposed to address the issue of mismatched captured speech segment labels and utterance labels due to different sample durations during speech signal processing, as well as insufficient extraction of emotional saliency features by the model during feature extraction. This algorithm proposes a dynamic frame shift algorithm to generate the same number of chunk level segments from utterance level samples of different lengths and extract spectrograms. By reshaping the model input to match chunk level segments with utterance labels, the model is trained in parallel. An adaptive feature position encoding structure and a multi-scale convolution module with residual structure are proposed. To better get the chunk level segment emotional salient aspects, the Transformer structure incorporates the location information into the high-dimensional features. The distribution of emotional features at the utterance level is generated using a mean pooling temporal aggregation technique. A mean squared error loss function is used in the last step. The experimental results demonstrate the efficacy of the suggested method in enhancing recognition precision. The algorithm's usability and scalability have also been confirmed by additional study based on the COVID-19 cough detection.

Keywords: Speech Emotion Recognition; Speech Signal Processing; Deep Learning;
Attention Mechanism; Feature Position Encoding

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 语音情感识别.....	3
1.2.2 语音情感研究常用数据集.....	4
1.2.3 基于声学特征的语音情感识别研究.....	6
1.2.4 基于语谱图特征的语音情感识别研究	9
1.3 本文的主要研究内容和组织结构	12
第 2 章 基于小波包重构特征自适应注意力网络的语音情感识别	15
2.1 引言.....	15
2.2 基于小波包重构特征自适应注意力网络的语音情感识别模型框 架	16
2.3 基于小波包重构特征的自适应注意力神经网络	18
2.3.1 语音信号的端点检测预处理.....	18
2.3.2 小波包重构算法的帧级特征提取.....	19
2.3.3 自适应特征采样注意力模块.....	23
2.3.4 损失函数.....	29
2.4 实验描述及结果分析.....	30
2.4.1 实验准备	30
2.4.2 实验结果与分析.....	34
2.4.3 消融实验.....	38
2.5 本章小结.....	40
第 3 章 基于自适应时频注意力残差网络的语音情感识别	41
3.1 引言.....	41
3.2 基于自适应时频注意力残差网络的语音情感识别模型框架	42
3.3 基于自适应时频注意力残差卷积循环神经网络	44
3.3.1 三通道语谱图的特征提取.....	44
3.3.2 残差卷积神经网络模块.....	47
3.3.3 自适应时频注意力机制模块.....	51
3.3.4 损失函数.....	55
3.4 实验描述及结果分析.....	56
3.4.1 实验准备	57
3.4.2 实验结果与分析.....	57
3.4.3 消融实验.....	62

3.5 本章小结.....	65
第 4 章 基于动态自适应空间注意力网络的语音情感识别	67
4.1 引言.....	67
4.2 基于动态自适应空间注意力网络的语音情感识别整体框架 ...	68
4.3 基于动态自适应空间注意力神经网络	69
4.3.1 时频注意力循环模块.....	69
4.3.2 空间注意力循环模块.....	72
4.3.3 损失函数.....	74
4.4 实验描述及结果分析.....	75
4.4.1 实验准备	75
4.4.2 实验结果与分析.....	76
4.4.3 消融实验.....	80
4.4.4 基于空间注意力循环模块的扩展研究	83
4.5 本章小结.....	87
第 5 章 基于残差多尺度卷积 Transformer 网络的语音情感识别 ...	89
5.1 引言.....	89
5.2 基于残差多尺度卷积 Transformer 网络的语音情感识别框架	90
5.3 基于残差多尺度卷积 Transformer 神经网络	92
5.3.1 块级片段的语音信号预处理.....	92
5.3.2 残差多尺度卷积模块.....	94
5.3.3 自适应位置编码 Transformer 网络模块.....	96
5.3.4 句子级特征分布的生成.....	100
5.3.5 损失函数.....	101
5.4 实验描述及结果分析.....	101
5.4.1 实验准备	102
5.4.2 实验结果与分析.....	103
5.4.3 消融实验.....	106
5.4.4 基于自适应位置编码算法的扩展研究	110
5.5 本章小结.....	113
结论.....	115
参考文献.....	119

第1章 绪论

1.1 研究背景及意义

随着人工智能技术的发展，人们越来越需要使人机交互（HCI）更加自然，希望机器能够富有情感地与人们进行深入交流，情感是由大脑神经物理变化所引发的精神状态，与思想、感觉、行为反应等有关，通常与心情、个性、性格交织在一起，情感识别是使用基于人工智能的算法检测人类表现出的情感，以评估非语言反应的过程。而语音是人类彼此之间交流的必不可少的重要桥梁，同时也是表达情绪的主要窗口，是听觉上可以反映人类情绪状态的非视觉交流信号，这源于说话者口腔中声门的变化，以及大脑听觉神经对声音的感知，是传递和理解情感的关键机制。与其他信号相比，语音在情感识别中有高效、直观等优点，包含更多的情感信息，情感专家 Ambady 通过研究分析发现，语音信息相比于语言信息在预测和分析人类情感行为中扮演了更为重要的角色。对于识别人的心理状态，人类情感语音的识别一直是人们关注的一个焦点问题。在计算机科学技术兴起之前，对情感语音的识别分辨一直是信号学和心理学的一个重要研究方向^[1, 2]，然而随着计算机技术的发展，语音信号处理、模式识别、机器学习等学科均取得了突破性进展，使得语音情感识别（Speech Emotion Recognition, SER）成为一个多学科交叉融合的重要课题。

近几年来，随着科技的不断进步，人工智能领域的重要性愈发凸显。国家高度重视人工智能的发展，尤其在人机交互领域，在这种大环境背景下人工智能的大力发展是必然趋势，其中语音情感识别在该领域的地位不言自明，是人机交互的一个最关键技术之一，也是机器人能感知并理解人类情感表达的基础性技术^[3]。语音情感识别是指利用计算机通过机器学习算法来分析人类语音信号中情感区域的变化，进而判定人内心的情感状态，从而实现人机情感交流，是人机交互走向智能化不可或缺的重要组成部分^[4]。随着人工智能领域的蓬勃发展，语音情感识别已成为本世纪的一个新兴领域，也因此吸引了大量的科研人员致力于此项研究^[5, 6]。在多个子领域都有重要的研究意义，其中包括但不限于：

1) 教育领域，情感识别在教育领域有着深远的研究价值与意义，在教学活动中，学生在教室中会体验到积极和消极的感受，教育者应该了解每个学生的情感状态，并提供一个积极的学习环境，以帮助他们克服压力以及挑战、减少恐惧等，激励学生从

而确保他们获得新的知识和技能,进行更有效的学习,因此情感监测很有必要,带着积极的情绪集中注意力、解决问题和思考往往会取得事半功倍的效果^[7-10];

2) 智能驾驶领域,情感在驾驶过程中起着至关重要的作用,因为它影响着驾驶的安全性与舒适性。在国家每年发生的交通事故中,驾驶员因无法控制自己的情绪被认为是影响驾驶安全的关键因素之一,因此驾驶员的情感识别与干预是汽车人机交互系统中的重要研究,既往研究表明,驾驶员认为车载情感识别系统有助于了解和改善其情感状态,从而提高驾驶的安全性和舒适性^[11-14];

3) 健康领域,有效且高效的抑郁症自动诊断是情感识别领域一个非常具有挑战且重要的应用,抑郁症是世界上第四大最常见的精神障碍,通常与持续的悲伤情绪有关,并给经济、司法和社会制度带来了较重的负担。研究表明,抑郁症会导致神经生理和神经认知的变化,这些变化会通过发声、对话内容的选择反映在个人的交流中。基于这一特点,可以从患者的音频模式中检测抑郁症,以便可以及早的发现抑郁症并着手治疗,给饱受病痛折磨的患者带去福音^[15-18]。

综上所述,现在乃至在未来,人工智能将是国家的战略级发展方向,同时更是全世界科研人员的挑战,其中语音情感识别是人工智能领域的基础性技术之一,具有重要的理论研究意义和广泛的应用前景,因此对语音情感识别研究刻不容缓。

1.2 国内外研究现状

自 21 世纪之初,科研人员在不同种类的模态下进行情感识别的研究,模态包括情感语音、面部表情以及语言文本。基于这些模态可以通过算法使机器加深对情感的理解、增强特征提取并准确识别出人类的情感,这在人机交互中具有重要的研究意义。面部表情是人类表达情绪的主要窗口,是视觉上可观察到的对人类情感做出反应的非语言交流信号,以面目表情为主导的基于深度学习的人脸表情识别(FER)研究取得了一定进展^[19, 20],但是表情在记录过程中需要面对摄像头,应用在多人交互场景中,采集数据的成本会增高。因此,在实际应用中仅仅通过表情来识别情感还有待商榷。文本情感识别(TER)通过结合语音识别来自动识别文本中所表达的情感状态,在自然语言处理领域同样取得了一些进展^[21, 22],但是口语文本可能有几种解释,这取决于它是如何说的。例如,“OKAY”这个词在英语中被用来表达钦佩、怀疑、同意、不感兴趣或断言等多种情感。因此,仅仅理解文本同样是不足以解释口语话语的情感状态。

与面目表情和文本不同在于,人们相信使用语音信号进行通信是交流思想的最快手段,从语音识别延伸出来的新研究领域是语音情感识别。最早意义上的语音情感识

别相关研究出现在上世纪 80 年代中期，它们开创了使用传统声学特征进行情感识别的先河。直到 1985 年，Minsky 教授提出了“让计算机具有情感能力”的观点之后，人工智能领域的研究者们逐渐认识到情感智能对于人机交互的重要性。然而系统和机器之间的互动不是一个顺利的过程，系统根据检测到的情感对用户做出反应，其中语音情感识别在这个过程中起着十分重要的作用^[23]。真正引起领域轰动且具有里程碑式意义的研究是美国麻省理工学院媒体实验室的 Picard 教授在 1997 年首次提出“情感计算”的概念^[24]，其定义是对情感影响因素、相关因素、产生因素的计算。情感识别与检测一直是热门的研究课题，其中语音是人类交流最重要的一环，它通过明确的（语言学）和隐含的（副语言学）特点来传达有关情感表达的信息。近十多年来，先后有包括语音情感识别在内以情感计算为主题的期刊和会议被创立，并得到了世界范围内研究人员的青睐，其中较为著名的有始于 2009 年的 INTERSPEECH Emotion Challenge 年度竞赛，创刊于 2010 年的《IEEE Transactions on Affective Computing》期刊等，得益于研究者们共同努力，研究工作在情感数据库的建立、情感特征分析、模型分类等领域的各个方面都取得了长远的发展，为构建语音情感识别标准化平台做出巨大贡献。

1.2.1 语音情感识别

语音情感识别领域发展至今，科学家们仍然致力于实现更自然的人机交互，如何有效提升语音情感识别精度成为了该领域亟需研究的问题，在语音情感识别研究中，为了成功地实现一个语音情感识别系统，需要仔细地定义和建立情感模型。然而，关于情感的定义并没有共识，它仍然是心理学中一个开放的问题。Plutchik^[25]在二十世纪初提出了九十多个关于情感的定义，指出情绪是一种错综复杂的心理状态，由个人经历、生理、行为和社会反应等几个部分组成。基于这些定义，语音情感识别总共分为两大类：离散语音情感识别和维度语音情感识别^[26]。离散情感理论是基于六类基本情感：悲伤、高兴、恐惧、愤怒、厌恶和惊讶，这些情感属于与生俱来的、独立的情感并且能在短时间内被感知到的^[27]，这些情感类别的标签方案是可直观观测的，因此一部分语音情感识别模型是基于离散标签实现分类，然而离散语音情感识别模型虽然简洁但对情感的描述能力有限，很难准确地描述日常交流中一些自发情感状态。连续语音情感识别，也称维度情感识别，它使用少量的潜在维度来描述并衡量情感及有关情感的状态，维度主要包含以下三类：激活度（Arousal）、愉悦度（Valence）、支配度（Dominance）^[28, 29]，其中针对激活度的定义为情感从平静（Calm）到活跃（Active）的状态程度，针对愉悦度的定义为情感从消极（Negative）到积极（Positive）的状态

程度，针对支配度的定义是情感从弱（Weak）到强（Strong）的状态程度^[30]，这些维度是根据情感的描述和自身特性等方面定义的，在维度情感识别任务中，情绪不是相互独立的，而是按自身特性分布在多维度中，利用欧氏空间描述情感，坐标轴的不同取值组合表示一种特定的情感状态，如图 1.1 所示。




图1.1 二维维度情感识别示意图

Figure 1.1 Schematic Diagram of 2D Dimensional Emotion Recognition

尽管离散情感识别与维度情感识别分别利用不同的方法描述情感，但是两者之间并不是对立的，而是可以相互转换的，离散情感可以通过一定方式映射到维度空间中，两者在语音情感识别过程中，对语音信号处理，特征提取模型结构都是相同的，因为维度情感是被精确地量化的情感，减小情感标签的模糊性，更有利于自发情感的描述。

目前语音情感识别研究主要分为基于声学特征的语音情感识别与基于语谱图特征的语音情感识别^[31-33]，主要分为三个步骤：语音信号处理、情感特征提取以及情感识别，研究人员往往依据上述三个步骤来提升语音情感识别精度，其中语音信号处理是指通过麦克风采集语音波形后生成电信号，之后将电信号转换为情感识别声学特征的过程；情感特征提取是指从处理好的信号中获取到具有情感判别力的特征；情感识别是指利用分类器（传统机器学习算法）或通过损失函数反向传播迭代更新所提取特征的权重（深度学习算法）实现识别过程。

1.2.2 语音情感研究常用数据集

数据集是语音情感识别的一个重要部分，在分类以及预测过程中依赖于标记的数据，因此数据的质量影响着识别过程的成功。不完整的且质量较差的数据极有可能导致模型对数据产生错误的判断而造成结果失准，因此，精心设计并收集到的良好数据

能够在语音情感识别过程中起到事半功倍的作用。语音情感数据集可分为三种类型：模拟的（表演）、诱发的（环境）和自然的（真情流露），其中模拟情感语料库是从有经验的和受过训练的演员或艺术家那里收集到的语音数据，例如录音。诱发式情感语料库是让说话者参与情感对话或处在对话环境之中人为的产生一种情感语境而收集得到的，此外说话者处在情感环境中做出的反应会在他们不知情的情况下被记录下来。自然情感数据集是通过记录真情实感对话而收集的样本，如急救中心或者服务中心等^[34]。本文使用在语音情感识别研究中最具权威且应用最为广泛的情感数据集来进行实验研究，下面将详细介绍数据集的内容及其组成部分：

（1）IEMOCAP

IEMOCAP（Interactive Emotional Dyadic Motion Capture Database）是交互式情感动态捕捉数据集的缩写，它记录了在人体面部、头部和手部均有标记的双人对话数据。因此，这些记录提供了关于演员在演绎交流场景和即兴表演交流场景中面部表情和手部动作的详细信息^[35]。每个对话（Session）中的语音数据都是可用的，且同时提供了分类和维度预测的标签。对于情感分类研究，有九个独立的类别：中性、快乐、愤怒、惊讶、恐惧、厌恶、沮丧、兴奋和其他情感。对于维度情感识别研究，有三个维度的独立标签：激活度、愉悦度、支配度，值的范围为1~5。IEMOCAP数据集的总长度约为12个小时，包含10039个语音数据（49%为女性/51%为男性），其长度在0.58秒和34.14秒之间变化，每个wav文件都有至少三个评委注释的句子级情感类别标签，包含由10个演员演绎的5组对话，每组对话包含两个演员（一男一女），采样频率为16kHz。

（2）MSP-IMPROV

MSP-IMPROV^[36]由德克萨斯大学达拉斯分校多模态信号处理（MSP）实验室开发，是一个多模态情感数据集，通过录音过程中应用词汇和控制自身感情获得，同时也保留了自发情感的状态。该数据集提供了音频和视频的记录，同时也提供了由语音识别模型获得的文本记录，录音方法与IEMOCAP相同，至少包含5个评价者对音频样本进行打分。MSP-IMPROV数据集包含8438个语音数据样本，涵盖四大场景，分别为“Target-improvised”、“Target-read”、“Other-improvised”、“Natural-interaction”。对于双模态语音和语言的融合样本，做语音情感识别任务中可能在场景中删除一部分由词汇语音主导的数据样本，提升语音与目标样本的相关性。对于情感分类研究，共分为5个标签：愤怒、快乐、中性、悲伤和其他情感。对于维度情感识别，也分为三个标签：

激活度、愉悦度和支配度。MSP-IMPROV 数据集中的语音数据收录为 wav 文件，原始采样频率为 44.1kHz，单声道录音，音频的比特率为 705kbps。

（3）MSP-Podcast

MSP-Podcast 数据集^[37]是来自各种在线音频共享网站的富于情感内容的自发语音数据组成，并且这些数据被授权了知识共享许可。语音数据中包括对各种主题的自发讨论，包括政治、体育、娱乐、艺术、技术和经济等领域，提供了广泛、丰富和自然的情感样本。该语料库还对数据进行了预处理，包括去除背景音乐、噪音、重叠音或背景中多个扬声器中与情感语音无关的声音，最终收录干净音频^[38]。该数据集提供了离散识别和维度识别的情感注释，这些注释是由至少五个注释者利用众包方法为每段语音进行标记^[39]。MSP-Podcast 数据集每过一段时间就会更新，目前最新版本为 1.9 版本，同时也是本文所使用的版本，其中包括用于训练、验证、测试的独立数据集。测试集分两个部分组成，第一部分包含来自 60 个说话人（30 位男性和 30 位女性）的语音片段，共 16570 个片段，第二部分从 100 个视频中随机选择 4990 个片段，这些片段不包括在任何其他数据集中。验证集包含了 44 位说话人（22 位女性和 22 男性）的语音数据共计 9546 个，而训练集利用的语音情感样本为 55283 个。值得注意的是，数据库中各个语音数据均为说话人无关（Speaker-independent）的样本。

（4）EMODB

柏林情感语音数据集（Berlin Database of Emotional Speech）^[40]是最广泛用于语音情感识别的数据集之一，它是一个模拟性质的数据集，由 10 个德语句子组成，包括 5 个短句和 5 个长句，其中分别由 10 个说话人（5 男 5 女）进行不同的情感表达。在记录音频信号的同时，为了能够更精确地提取韵律特征和音质特征，在录音的同时还记录声门图。整个数据集包含 535 个样本数据，包含 7 种情感，分别为中性、愤怒、恐惧、快乐、悲伤、厌恶以及无聊。语音信号的采样频率为 16kHz，且每个采样点为 18 bits。

1.2.3 基于声学特征的语音情感识别研究

在基于声学特征的语音情感识别过程中，声学特征提取扮演了非常关键的角色，它是一个将原始信号信息大幅度压缩的过程，依赖声学知识通过一系列数学公式在原始信号中的时域以及频域上进行分析并计算得到的，主要分为以下四类特征：韵律特征（Prosodic）、音质特征（Quality）、频谱特征（Spectral）以及 TEO（Teager Energy Administrator）依赖特征，如图 1.2 所示。



图1.2 语音信号特征分类

Figure1.2 Speech Signal Feature Classifications

这些声学特征在情感识别中包含了大量关键信息，可辨别出情感句子中的变化、不同的说话人、说话风格以及说话速度等差异^[41]。图 1.2 所描述声学特征被统称之为局部特征（Low-level Descriptions, LLDs），而为了描述各帧之间关系以反映出全局信息，往往利用一些统计学方法对局部特征做相应变换得到衍生值，比如均值、一阶差分、二阶差分等，衍生出的特征也被称为全局特征（High-level Functional Statistic, HSFs）。近年来，基于声学特征的语音情感识别被广泛研究，Lee 等人^[42]和 Schuller 等人^[43]利用基于能量和基频等局部特征和全局特征构成的特征集在语音情感识别任务中

表1.1 基于声学特征模型的语音情感识别相关研究

Table 1.1 Related Researches on SER based on One Dimension Acoustic Features Model

研究	年份	特征	算法	数据集	结果
Lee et.al ^[44]	2011	LLDs/HSFs	DT	IEMOCAP ^[35]	UAR:58.46%
Rahul et.al ^[45]	2015	47 LLDs	GMM/KNN	EMODB ^[40]	Accuracy:66%
Tzinis et.al ^[46]	2017	47 LLDs	LSTM	IEMOCAP	UAR:60.02%
Mirsamadi et.al ^[47]	2017	36 LLDs	CNN-LSTM	IEMOCAP	UAR:58.8%
Chernykh et.al ^[48]	2017	34 LLDs	LSTM	EMODB	Accuracy:70.5%
Sarama et.al ^[49]	2018	23 MFCCs	TDNN-LSTM	IEMOCAP	UAR:60.3%
Xie et.al ^[50]	2019	LLDs	LSTM	IEMOCAP	UAR:54.0%
Atmaja et.al ^[51]	2020	57 LLDs	CNN/LSTM	IEMOCAP	Aro(CCC):0.571 Val(CCC):0.418 Dom(CCC):0.500
Fahad et.al ^[52]	2021	MFCCs	DNN-HMM	IEMOCAP	UAR:60.86%
Lin et.al ^[53]	2021	130 LLDs	CNN/LSTM	MSP-Podcast 1.4	Aro(CCC):0.7025 Val(CCC):0.2683 Dom(CCC):0.6268

取得较好结果，并证实了基于音高与基频的特征比基于能量的特征在语音情感识别研究中拥有更大相关性。Rao 等人比较了局部特征和全局特征，包括其组合^[54]，其中全局特征是在韵律特征中利用统计学方法计算出来的，局部特征是从音节的持续时间，帧级基频和能量值收集的，证明了当局部特征和全局特征结合在一起时，情感识别性能获得提升。Lugger 等人使用韵律特征和音质特征，包括声门梯度、偏度梯度、闭合率梯度等^[55]构成的特征集采用两级分类法进行语音情感识别并得到 74.5% 的识别率。Li 等人在全局特征中添加声音抖动和颤动等音质特征实现了更高的识别率^[56]。Zhang 等人使用韵律特征以及音质特征组合，包括前三个共振峰，与单独使用韵律特征相比，识别率提升了 10%。Sato 等人^[57]利用聚类对每一帧进行标记并使用分段式 MFCC 特征构成特征集，与基于韵律特征的 K 近邻算法（KNN）以及基于传统 MFCC 的隐马尔可夫模型（HMM）算法进行了比较，证明了所使用特征集效果更好。Bitouk 等人^[58]引入了一系列新的频谱特征，包括对重元音，非重元音以及辅音分别计算 MFCC 的值，得出了语音信号中辅音相比元音包含的情感信息更多的结论。Zhou 等人^[59]提出三种 TEO 特征的变体，尤其是 TEO 自相关包络的标准带，并基于这些特征研究了人在压力下表达时声道中气流特征的能量变化，其结果优于局部特征中的音高与 MFCC 的特征组合。在完成上述声学特征提取后，需要对特征集筛选并完成最终情感分类，一部分研究在提取声学特征集后使用机器学习算法进行分类^[60-62]，例如使用高斯混合模型（GMM）、支持向量机（SVM）、决策树（DT）等分类方法；另一部分研究，例如使用一维卷积神经网络以及循环神经网络，是基于深度学习技术从声学特征中获取有效的情感特征分布并利用损失函数实现情感识别，这里列举了几个典型研究如表 1.1 所示。

表 1.1 研究表明人类语音中的情感信息包含了大量的声学特征，且这些声学特征已经被证实是可靠指标，可表征说话者的情感状态，基于深度学习算法利用声学特征进行语音情感识别的优势主要在于两点：1) 利用声学特征的模型具备一定的可解释性，深度学习算法可针对不同的声学特征分配可学习权重，即分配给有情感判别力的特征权重高，反之则低，与机器学习算法相比有利于提升识别精度；2) 模型整体复杂度低，声学特征集是通过对语音信号进行一系列数学运算获取，可学习参数较少，并且深度学习方法又提升了模型的适应性和灵活性，使模型避免过拟合的同时，可以将训练好的深度学习网络部分迁移并应用在其他有关情感识别研究中，增加了模型的可移植性。尽管基于声学特征的语音情感识别算法取得了一定进展，但仍然存在着一一些问题，具体而言：

(1) 大部分声学特征需要对语音信号进行短时傅里叶变换计算得到, 该变换是一种全局变换, 无法表述信号中对于情感这类非平稳信号最根本且关键的时频局部性质, 导致在时频域内对信号的局部特征表征能力较弱;

(2) 基于声学特征的注意力模型较难从特征集中获取有利于情感识别的显著性分布, 导致丢失部分相关情感信息。

1.2.4 基于语谱图特征的语音情感识别研究

在基于语谱图特征的语音情感识别研究过程中, 如何从语谱图中提取到具有情感判别力的特征是实现情感识别最重要的环节之一。语谱图特征提取主要是指利用深度学习模型从语谱图中提取到涵盖更多全局信息的深层特征的过程, 语谱图 (Mel-Spectrogram), 是区别于上述共振峰、抖动、MFCC 等特征的另一种声学特征, 语谱图能够综合时域和频域两种信息, 以一种二维形式表达三维信息的方法给出, 维度分别表示信号的时域和频域, 值代表能量, 语谱图的好处是将进一步的特征提取交给后续的深度学习网络模型来实现从低维特征到高维特征的提取^[63], 神经网络可以在训练过程中, 自动学习到类似梅尔滤波器提取的特征, 包含了更多声学特征集涵盖不到的情感信息, 所以利用语谱图进行基于深度学习技术的语音情感识别研究已被广泛运用。

自 2012 年, Hinton 领导的小组在著名的 ImageNet 图像识别大赛上一骑绝尘, 开启了现代深度学习领域的先河, 随着深度学习技术的不断进步以及数据处理能力的不断提升, 许多算法在语音情感识别中取得傲人的成绩。与机器学习方法相比, 用于语音情感识别的深度学习技术^[32], 具有内部复杂结构和提取情感特征的能力, 而不需要手动提取或筛选声学特征。深度神经网络 (DNNs) 基于前馈结构, 是由输入和输出之间的一层或多层带有一定数量神经元的隐藏层组成, 其结构核心运用的是梯度下降算法, 通过计算模型输出与真实标签之间的损失利用反向传播算法迭代更新隐藏层中各个神经元的权重与偏置值, 进而获得最优模型以实现情感分类。卷积神经网络 (Convolutional Neural Networks, CNNs) 在语音情感识别中是最重要的模型结构之一^[64], 由于语谱图在时间维度和频率维度上存在较强的局部相关性, 拥有局部连接特征的卷积神经网络能够更好地对其建模, 是处理二维语谱图以提取高维特征的有效手段^[65]。循环神经网络 (Recurrent Neural Networks, RNNs)^[66]及其变体长短时记忆网络 (Long Short-Term Memory, LSTM)^[67]可从由卷积神经网络输出的高维特征中捕获受时间序列影响的特征, 同时也可以处理帧级声学特征进而获取高维情感特征^[68]。注意力机制 (Attention Mechanism)^[47], 本质上也属于特征提取, 该结构可进一步从卷积

神经网络输出的高维特征中提取有利于情感识别的显著性特征，以获得有价值的情感特征分布实现语音情感识别。

表1.2基于语谱图特征模型的语音情感识别相关研究

Table 1.2 Related Researches on SER based on Spectrograms Feature Model

研究	年份	算法	数据集	结果
Zou et.al ^[69]	2014	DBN	ABC Corpus ^[70]	Accuracy:52.2%
Kim et.al ^[71]	2019	DNN	IEMOCAP	UAR:61.4%
Aldeneh et.al ^[72]	2017	CNN	IEMOCAP MSP-IMPROV ^[36]	UAR:61.8% UAR:52.6%
Lee et.al ^[73]	2015	BiLSTM	IEMOCAP	UAR:63.89%
Latif et.al ^[74]	2019	CNN-LSTM	IEMOCAP MSP-IMPROV	UAR:60.23% UAR:52.43%
Bhosale et.al ^[75]	2020	ACNN	IEMOCAP	UAR:63.15%
Mustaqeem et.al ^[76]	2020	CNN-LSTM	EMODB	Accuracy:85.57%

近几年基于深度学习网络的语音情感识别取得飞速进展^[77]，Trigeorgis 等人^[78]和 Lim 等人^[79]提出了一个将卷积神经网络（CNN）与长短时记忆网络（LSTM）相结合的结构，其中 CNN 被用来直接从语谱图中提取高维特征^[80]，LSTM 被用来补充高维特征中与时序相关的情感特征，与机器学习算法相比，所得出的情感识别结果更好，这种 CNN-LSTM 结构被其他多项研究使用^[49, 78, 81]。为了学习频谱中的空间关系，文献^[82]中使用了基于 CNN 的胶囊网络，设计了一个连续结构来获得句子级情感特征分布并取得了良好的实验结果。表 1.2 详细介绍了近些年一些典型的基于深度学习技术的语谱图特征模型的语音情感识别研究。

包含上述研究在内的基于深度学习网络模型从语谱图中提取了包含大量时频情感信息的高维特征之后，为进一步提升识别精度，从而获取到有利于情感识别的特征非常有必要，因此注意力机制结构被广泛应用在后续特征提取当中^[83]，其中包括自注意力^[84, 85]，局部注意力^[47]，跳动注意力^[86]以及其他许多变体^[87-89]在提升语音情感识别精度上均取得一定成果，该结构能够从卷积网络或循环网络输出的高维特征内增强有效特征权重同时减弱无效特征权重，以此将网络关注点聚焦于有利于情感识别的显著性特征区域以生成特征分布，表 1.3 详细介绍了近几年利用注意力机制提升语音情感识别精度的研究。

表1.3 基于注意力机制结构的语音情感识别研究

Table 1.3 Related Researches on SER based on Attention Mechanism Structure

研究	年份	算法	数据集	结果
Mirsamadi et.al ^[47]	2017	Local Attention	IEMOCAP	UAR:58.8%
Li et.al ^[90]	2019	Self Attention	IEMOCAP	UAR:51.1%
Yoon et.al ^[86]	2019	Multi-Hop Attention	IEMOCAP	UAR:65.2%
Xie et.al ^[91]	2019	TF Attention	CASIA ^[92] eNTERFACE	UAR:63.89% UAR:89.6%
Tarantino et.al ^[93]	2019	Self Attention	IEMOCAP	UAR:63.8%
Xu et.al ^[94]	2020	Alignment Attention	IEMOCAP	UAR:57.4%
Li et.al ^[95]	2021	Self BiAttention	IEMOCAP EMODB	UAR:61.2% Accuracy:85.95%

此外，在得到经过模型训练之后的情感特征分布之后，需要对其进行情感分类，在语音情感识别的分类（离散语音情感识别）和回归（维度语音情感识别）过程中，是利用损失函数来计算预测值与真实值的偏差，通过反向传播算法来更新深度学习神经网络模型中的权重数值，以获取最优模型。在损失函数的选择上，对于离散任务，交叉熵损失函数应用最为广泛，对于回归任务，则使用均方误差作为损失函数。此外，评价指标被用来衡量深度学习算法的有效性，对于离散语音情感识别研究，在 21 世纪初通常使用准确率作为衡量标准，然而随着数据集的不断扩展，样本容量在各个类别之间往往是不平衡的，在语音情感识别领域的第一个挑战--InterSpeech 2009 情感挑战赛^[96]引入之后，研究者们通常使用非加权平均召回率（UAR），针对每类样本进行未加权计算得到并代表各个情感类别的平均召回率，此后该评价指标逐渐应用在数据类别不等且样本较多的情感数据集中。对于维度语音情感识别，则使用自相关系数（CCC）作为评价指标^[97]来衡量识别效果。表 1.4 详细介绍了一些近年来基于深度学习网络的维度情感识别研究。

从表 1.3 和表 1.4 可以看出，近年来有关高维特征提取模型以及注意力机制模型在语音情感识别领域取得了不错的进展，然而目前该领域在特征提取过程仍然存在部分问题亟需解决：

（1）特征提取过程中卷积神经网络采用固定的卷积核尺度，导致有效的显著性情感特征区域感受野变小，卷积神经网络获取的全局情感信息不足；

(2) 注意力机制结构往往过于依赖全连接层与 Softmax 损失函数来加强特征分布，缺乏对情感特征丰富区域的局部信息，全局信息以及时频位置信息的获取，导致卷积神经网络提取的显著性特征分布对情感判别力较弱，限制了情感识别精度的提升；

(3) 交叉熵损失函数比较依赖数据集的样本分布，往往因不同情感的特征分布较为近似而导致分类困难；

(4) 数据集中包含的各个语音样本时长不等，导致并行训练过程中所截取片段标签与句子标签不匹配，限制了语音情感识别精度的提升。

表1.4 基于维度语音情感识别的相关研究

Table 1.4 Related Researches on Dimensional SER based on Deep Learning Networks

研究	年份	算法	数据集	结果
Parthasarathy et.al ^[98]	2020	CNN	MSP-Podcast 1.2 ^[37]	Arousal(CCC):0.803 Valence(CCC):0.458 Dominance(CCC):0.746
Atmaja et.al ^[99]	2020	LSTM	IEMOCAP	Arousal(CCC):0.590 Valence(CCC):0.421 Dominance(CCC):0.484
Sridhar et.al ^[100]	2020	DNN	IEMOCAP	Arousal(CCC):0.448 Valence(CCC):0.316 Dominance(CCC):0.473
Li et.al ^[101]	2021	CNN-LSTM	MSP-Podcast 1.6	Arousal(CCC):0.706 Valence(CCC):0.377 Dominance(CCC):0.639
Wagner et.al ^[102]	2022	CNN-Transformer	MSP-Podcast 1.7	Arousal(CCC):0.739 Valence(CCC):0.636 Dominance(CCC):0.655
Seo et.al ^[103]	2022	CNN-Attention	IEMOCAP	Arousal(CCC):0.700 Valence(CCC):0.608

1.3 本文的主要研究内容和组织结构

针对语音情感识别领域亟需解决识别率较低的问题，本文基于深度学习算法重点围绕语音信号处理、特征提取、注意力机制结构设计等角度进行创新，旨在从语音信号中学习到更具有情感判别力的特征分布，进而提升语音情感识别模型的准确性、有效性和泛化性。本文在第二章主要是针对声学特征设计了深度学习网络完成语音情感识别，第三章是针对声学特征无法反映出在相邻时刻时频域之间的空间关系，利用语

谱图特征设计特定的网络完成识别研究，第四章针对前两章注意力结构忽略了高维特征中时频域内局部特征空间的关系问题，提出了空间局部注意力机制网络以加强情感特征分布，第五章从维度语音情感角度出发，采用并行处理高维特征的方式，设计了自适应位置编码 Transformer 网络结构，同时也解决了训练过程中样本片段标签与句子标签不匹配问题。本文的主要研究内容与组织结构如图 1.3 所示。




图1.3 本文的主要研究内容与组织结构

Figure 1.3 Research Contents and Organization of Thesis

本文的研究内容和组织结构如下：

第 1 章绪论。首先详细介绍研究课题的背景与意义，指出目前语音情感识别领域亟需解决的问题，从语音信号处理、特征提取、注意力机制结构设计、情感识别类型四个方面详细介绍了国内外重要发展现状，并阐述了其不完善之处，同时介绍了目前领域内应用最广泛的语音情感数据集，最后简要概括本文的研究内容和组织结构。

第 2 章基于小波包重构特征自适应注意力网络的语音情感识别。首先分析并总结了声学信号在时频域内提取显著性情感特征时存在的问题。然后详细阐述了所提出算法如何解决存在的问题，涵盖算法模型的整体框架结构及模型中各个模块细节。最后通过实验在三个语音数据集上对所提出算法进行评估验证，并对语音情感识别模型中各个模块进行消融分析，验证了所提出算法的有效性和泛化性。

第 3 章基于自适应时频注意力残差网络的语音情感识别。首先分析并总结了在前

一章中基于声学特征模型以及注意力机制在提取显著性特征时存在的问题。然后详细阐述了所提出的算法如何解决存在的问题，涵盖算法模型的整体框架结构及模型各个模块细节。最后通过实验在三个语音数据集上对所提出模型进行评估验证，并通过消融实验细致分析所提出模型内各个模块对情感识别的影响，验证了所提出模型的有效性和泛化性。

第 4 章基于动态自适应空间注意力网络的语音情感识别。首先分析并总结了在前一章中注意力机制结构在时域和频域内捕捉时频空间信息时存在的问题。然后详细阐述了所提出的算法如何解决存在的问题，涵盖算法模型的整体框架结构及模型各个模块细节。最后通过实验在三个语音数据集上对所提出模型进行评估验证，并应用于新冠咳嗽声检测的扩展研究，证明所提出算法其实用性、泛化性和有效性。

第 5 章基于残差多尺度卷积 Transformer 网络的语音情感识别。首先分析并总结了在前三章离散语音情感识别中，语音信号处理和特征提取过程中在提取显著性情感特征空间信息时存在的问题。然后详细阐述了所提出的算法如何解决存在的问题，涵盖算法模型的整体框架结构及模型各个模块细节，为了加强显著性特征表征情感能力，应用在维度语音情感识别中。最后通过实验在三个语音数据集上对所提出算法进行评估验证，并应用于新冠咳嗽声检测的扩展研究，证明所提出算法其实用性、泛化性和有效性。

最后是本文的结论，对基于深度学习的语音情感识别技术及应用研究的一个全面总结，并对未来该领域研究道路指明了方向。

第2章 基于小波包重构特征自适应注意力网络的语音情感识别

短时傅里叶变换由于无法根据信号高、低频率变化自适应调整窗口宽度，导致表征信号局部特征能力较弱；在语音情感识别的特征提取过程中，传统注意力机制提取显著性情感特征较少。为解决上述问题，有效提升语音情感识别精度，本章提出了基于小波包重构特征自适应注意力神经网络的语音情感识别算法，提出了小波包重构帧级特征方法并基于帧级特征设计了自适应注意力网络，丰富时频域内的显著性情感特征信息，增强时频域内重要语音情感信息表征能力，提升语音情感识别精度。所提出算法在三个数据集中分别进行实验，并增加模块消融实验，全面验证模型性能。

本章研究内容的结构安排如下：2.1 节是引言；2.2 节是基于小波包重构特征自适应注意力网络的语音情感识别模型框架；2.3 节对所提出方法的具体细节进行详细介绍；2.4 节是实验以及结果分析；2.5 节是本章小结。

2.1 引言

特征提取在语音情感识别过程中扮演了十分重要的角色，情感语音当中可以提取多种声学特征，用以反映说话人的情感行为的特点，有效且高价值的特征将对识别结果准确性产生重大影响，如何提取和选择能有效反映情感变化的语音特征，是目前语音情感识别领域最重要的问题之一。研究人员已经提出了各种短时（short-term）和长时（long-term）的情感声学特征，主要分为两类：局部特征（LLDs）和全局特征（HSFs），局部特征是指在语音信号处理过程中，从 20 至 50 毫秒的短帧中提取出来的声学特征，主要分为四类：

1. 包括音高、振幅、强度等在内的韵律特征；
2. 包括短时能量、过零率等在内的激励特征；
3. 共振峰特征等；
4. 频谱特征 MFCC 等；

全局特征是指在话语的持续时间内，对局部特征采用各类统计函数方法，如最大值、最小值、方差、一阶差分等，并将统计计算后的结果串联成句子层面的长特征向量。而在提取上述声学特征的过程中，大部分特征如基频、共振峰、MFCC 等，是通过对原始语音信号进行短时傅里叶分析获得的，然而这是一种单分辨率的信号分析方法，也是一种全局变换，要么完全在时域，要么完全在频域，无法表述信号的时频

局部性质，而这种性质是情感语音信号最根本和最关键的性质，导致它在时频局部化的精细方面和灵活性方面表现欠佳，因此基于短时傅里叶分析所提取的帧级局部特征对时频域的特征能力相对减弱，损失了特征中所包含的相应时间分辨率和频率分辨率情感信息。

循环神经网络（RNN）因其具有对序列特性数据处理的能力以及能够挖掘情感语音中的时序高度关联信息和语义信息的优势，在语音情感识别领域取得了巨大成功，许多基于 RNN 进行 SER 的研究被不断提出^[78, 84]，已被证实 RNN 及其变体有能力来处理情感语音信号中与时序相关的特征。在情感识别过程中，语音内受时序影响较多的帧级声学特征发挥了关键作用^[104]，由于帧与帧之间存在时序高度关联性，因此 RNN 网络可以增加相邻帧之间的信息，使帧级特征能够更好地映射到可有效识别情感类别的特征分布之中。然而，如何有效从循环神经网络输出的情感特征分布中获取更有价值的信息也同样值得探究，注意力机制结构的提出在一定程度上改善了这个问题^[50]，其本质就是要从时间序列中学习到每一帧级特征的重要程度，然后按重要程度将特征合并，进而获得有助于情感分类的显著性特征分布。在这个过程中如何使 RNN 输出的高维特征中，有利于情感识别的特征区域获取的权重增多，而与情感无关的特征区域获取的权重减少，以获取更好的显著性情感特征分布，进而提升模型识别性能。

针对以上问题，本章提出了一种基于小波包重构特征的自适应注意力网络（Adaptive Attentive Wavelet Packet Reconstruction Recurrent Neural Network, AWPRNN）。首先将具有时频局域化特性的小波函数作为基底，利用小波包重构算法对情感语音信号进行处理，使重构后的信号包含较高的时间分辨率和频率分辨率信息，进而加强信号表征局部特征的能力，再对重构信号提取帧级声学特征，然后使用循环神经网络进一步提取与时间序列紧密相关的情感特征，提出了自适应特征采样注意力模块将更大的权重分配给更有利于情感识别的特征区域，用于提取有效的显著性特征以生成帧级特征分布，最后将得到的帧级特征分布与从原始信号中提取的句子级特征分布相联合以丰富情感特征分布，使用交叉熵损失函数实现语音情感识别。

2.2 基于小波包重构特征自适应注意力网络的语音情感识别模型框架

图 2.1 是本章提出的基于小波包重构特征自适应注意力网络的语音情感识别模型框架图，该框架图以语音信号作为输入，首先利用自相关端点检测技术消除信号中与情感无联系的静态帧区域，然后利用小波包重构算法对信号进行 3 层分解并重构，得到 8 个新的信号，并对得到的每个信号提取 36 维帧级声学特征，并进行特征归一化，在联

合 8 个信号提取的帧级特征后，输入到双向长短时记忆网络（BiLSTM）中提取与时序相关的情感特征，接着自适应特征采样注意力模块进一步提取显著性特征，以生成帧级特征分布，最后与从语音信号所提取的句子级声学特征分布联合，利用交叉熵损失函数实现语音情感识别。




图2.1 基于小波包重构特征自适应注意力网络的语音情感识别框架图

Figure 2.1 Framework of Speech Emotion Recognition Based on Wavelet Packet

Reconstructed Frame Level Features Adaptive Attention Model

基于小波包重构特征自适应注意力网络的语音情感识别的整体步骤如下：

- (1) 对原始情感语音信号利用自相关函数端点检测法进行预处理，通过设置 T_1 和 T_2 两个阈值来检测语音信号的端点，移除静态帧部分以防止对时序信号产生影响；
- (2) 利用小波包重构算法对预处理后的语音信号进行 3 层的小波包分解，并重构生成 8 个新信号；
- (3) 对每个新信号提取 36 维帧级声学特征并进行归一化，联合后组成数量为 288 维的帧级声学特征集；
- (4) 利用双向长短时记忆网络中进一步提取与时序相关的高维特征，接着输入到提出的自适应特征采样注意力模块中提取显著性特征，进而获取帧级情感特征分布；
- (5) 从预处理的语音信号中提取句子级声学特征集并通过包含单隐藏层的深度神经网络生成句子级情感特征分布，与第 (4) 步获得的帧级声学特征联合，以丰富情感特征分布，最后利用交叉熵损失函数实现语音情感识别。

2.3 基于小波包重构特征的自适应注意力神经网络

2.3.1 语音信号的端点检测预处理

在对语音信号进行处理之前，事实上可能会遇到一个严重的问题，那就是语音信号中那些静态帧（Silent Frame）和噪声在特征提取过程中产生的负面影响，同时也是导致后续分类精度降低的原因之一。因此在语音预处理过程中，为了消除上述原因所带来的影响，进而保留有效的语音序列信号在语音信号处理中属于是至关重要的步骤之一。语音信号的端点检测技术（Voice Activity Detector, VAD）的出现缓解了这一问题，目的是检测语音信号的起始点和终止点，因为语音信号在录制过程中不免在开始前和结束后有一系列的停顿，以及在说话过程中的诸如清音“si”等与任务本身无关的发音，都会对识别结果产生影响，端点检测是将这些无关的语音信号从样本信号中剥离出来。语音信号有自带周期性的特点，在通常情况下信号的周期性不会被静态帧和噪声所影响，从中就能衍生出一个周期性的信号其自相关函数也同样具有周期性的性质，并且两者的周期相同。利用这一特性，基于自相关函数的端点检测应运而生，本章采用该方法进行情感语音信号的端点检测。




图2.2 基于自相关函数端点检测算法的信号

Figure 2.2 Signal based on Autocorrelation Function VAD

给定一个语音信号，进行分帧加窗，其中采样频率为 16kHz，窗函数选择对平滑细节保留最好的汉明窗，窗长和帧移分别设置为 25ms 和 10ms，自相关函数公式如 (2-1)所示。

$$R_n(k) = \frac{\sum_{m=1}^{N-k} x_n(m)x_n(m+k)}{\sum_{m=1}^N x_n^2(m)} \quad (0 \leq k \leq K) \quad (2-1)$$

其中 $x_n(m)$ 表示原始情感语音信号， N 和 K 分别代表帧的数量和延迟值，并且在其中进行了正则化处理，因为这样可以避免在端点检测中受到能量的影响。然后为自相关函数算法设定双阈值，包括下限“T1”和上限“T2”，当相关函数的最大值大于“T2”时，便判定是语音；当相关函数最大值大于或小于“T1”时，则判定为语音信号的端点，如图 2.2 所示。

从图 2.2 可以看出，其中两条红色虚线之间的信号为端点检测之后的信号，因此，在对原始语音信号进行端点检测预处理之后，对其进行基于小波基的变换并分解，然后重构为新的信号。

2.3.2 小波包重构算法的帧级特征提取

在利用 2.3.1 节的自相关函数端点检测法消除语音信号中与情感无关的静态帧之后，本节提出了一种基于 Daubechies 小波基的小波包重构算法，对重构后的新信号提取帧级特征（Frame-level），作为后续所提出的神经网络模型的输入。研究人员在提取声学特征的过程中，选择短时傅里叶变换对信号进行分析，然后提取一维声学特征，然而缺点在于无法表述情感这类非平稳语音信号的时频局部性质，导致在时频域内对局部特征表征能力弱，同时傅里叶变换后的信号中时间分辨率以及频率分辨率相对较低，容易在特征提取过程中丢失有价值的情感信息，原始信号频谱如图 2.3 所示。




图2.3 原始语音信号频谱

Figure 2.3 Raw Speech Signal Spectrogram

从图 2.3 中可以看出在频域内，信息随着频率的增多而减少，导致在获取中高频情感信息的过程中处于劣势，相比于傅里叶变换使用一组无限长的三角函数进行信号拟合，小波变换使用的则是一组正交的、迅速衰减的小波函数基进行信号拟合（卷积），这种小波基函数通过设置尺度变量和平移变量，获得不同区域的频域和时域位置，在

利用小波基对信号进行分解时，即使是突变信号，用较少的小波基就能拟合出来。因此，基于小波变化的小波包重构算法在处理语音信号的过程中，重新构建可同时保留时域信息和频域信息的多组语音序列信号，弥补了这一劣势^[105]。在小波变换中，一个位于希尔伯特空间中的函数，可以分解成一个尺度函数和一个小波函数，其中尺度函数对应原始函数中的低频部分，小波函数对应原始函数中的高频部分。通过尺度函数可以构建对原始信号的低通滤波器，通过小波函数可以构建对原始信号的高通滤波器，在这个过程中，首先使用预处理后的语音信号作为初始输入信号，接着使用小波基将输入信号通过上述滤波器分解为近似分量（子带） O 和细节分量 Y （子带）。值得注意的是选择合适的小波基函数是非常重要的，必须保证拥有足够能力分别在时域和频域来匹配输入信号。其中紧支撑小波基是性质较好的一类小波基，紧支撑（Compact Support）函数是指这样一类函数：其自变量仅在 0 附近的取值范围内能得到非零函数值，而在其他区间取值，则得到的函数值全为零。非零函数值的自变量取值区间被称为该函数的支撑区间。一个函数的支撑区间长度主要由其尺度参数决定，支撑区间越大，计算复杂度越高，边界拖尾效应越明显，因此在选择小波基时，以支撑长度较短的小波基为宜。

本节选择由 Inrid Danbechies 提出的 Daubechies (dbN) 小波基函数，其中 N 为小波分解的级数，该小波的尺度函数和小波函数的支撑区间长度为 $2N-1$ ，小波函数的消失矩为 N 。dbN 小波基有一些优势包括：具有更好的正则性、紧支撑性和随分解层数加深时所产生更合适的消失矩，以保证在频域中获取位置信息的能力更强，并且拟合出的信号也较为光滑。然而小波变化仍存在不足之处，由于小波变换在每级信号分解时仅仅对低频子带进行分解，因此无法对高频子带的信息进行同样高分辨率的提取，而小波包分解完美解决了这个问题，其整个过程如图 2.4 所示。




图2.4 基于三层小波包分解流程图

Figure 2.4 Flow Chart based on Three-layers Wavelet Packet Decomposition

其中 h 代表低频区域, g 代表高频区域, 将第一层的近似分量 $\Phi(t)$ 定义为 $d_1^0(t)$, 细节分类 $\Psi(t)$ 定义为 $d_1^1(t)$, 其中下标指的是小波包分解级数的编号, 上标指的是分解时产生的小波包序列在该级的位置, 小波包分解, 又称为最优子带树结构 (Optimal Sub-band Tree Structuring) 是对小波变换的进一步优化。在小波变换的基础上, 在每一层信号分解时, 除了对低频子带进行进一步分解, 也对高频子带进行进一步分解。最后通过最小化一个代价函数, 计算出最优的信号分解路径, 并对原始信号进行分解。本节采用 3 层小波包分解, 因此在重构过程中将获得 8 个基于小波基函数的重构信号。首先, 利用公式(2-2)计算出小波函数基的值。

$$\begin{cases} d_{L-1}^{2n}(t) = \sum_k h_k d_L^n(t-k) & d_L^n(t-k) = d_{L-1}^n(2t-k) \\ d_{L-1}^{2n+1}(t) = \sum_k g_k d_L^n(t-k) & d_L^n(t-k) = d_{L-1}^n(2t-k) \end{cases} \quad (2-2)$$

公式(2-2)也表示为(2-3)。

$$\begin{cases} d^{2n}(t) = \sum_k h_k d^n(2t-k) \\ d^{2n+1}(t) = \sum_k g_k d^n(2t-k) \end{cases} \quad (2-3)$$

其中 h_k 和 g_k 分别代表半带低通滤波器和半带高通滤波器, 本章采用的是幂级数离散尺度的二元小波变换, 规模参数为 2^i , 其中 i 表示层数; d 和 k 分别表示小波包系数和平移变量。然后, 利用公式(2-3)计算出用于匹配输入语音信号的小波包变换值, 作为小波包函数基的系数, 如公式(2-4)所示。

$$\begin{cases} D_{\Phi}^{2n}(2^i, k) = (f(t), d^{2n}(t)) = \frac{1}{\sqrt{2^i}} \sum_t \Phi^*\left(\frac{2t-k}{2^i}\right) \\ D_{\Psi}^{2n+1}(2^i, k) = (f(t), d^{2n+1}(t)) = \frac{1}{\sqrt{2^i}} \sum_t \Psi^*\left(\frac{2t+1-k}{2^i}\right) \end{cases} \quad (2-4)$$

其系数是通过计算输入语音信号与各小波函数基的内积得到的。这表示输入信号在各个小波函数上的投影值, 投影值越大, 说明对应的小波信号所携带输入信号的特征信息的比例越大。其中 $f(t)$ 表示输入语音信号, 最后在利用小波包反变换如公式(2-5)的帮助下得到了 8 个新的基于 3 层小波包分解的重构语音信号。

$$\begin{cases} f_{new}^{*2n} = \sum (D_{\Phi}^{2n} \cdot d^{2n}(t)) \\ f_{new}^{*2n+1} = \sum (D_{\Psi}^{2n+1} \cdot d^{2n+1}(t)) \end{cases} \quad (2-5)$$

其中 f_{new} 是本节最终得到的重构信号, 被用来作为后续神经网络的输入信息来进一步从中提取高维特征。值得注意的是, 当所选择的小波包分解层数减少时, 会出现对局部特征表征能力下降从而导致一些有效的频域信息被忽略; 而当所选择的小波包

分解层数增多时，由于信号在高频区域信息相对较少，导致参数冗余及浪费计算资源。通过 2.4 节的消融实验得知，给出了不同层数下模型对性能结果的影响，结果证明利用 3 层小波包分解构建 8 个新的语音信号较为合适，3 层小波包重构信号频谱图如图 2.5 所示。




图2.5 3层小波包重构信号频谱图

Figure 2.5 3-Layer wavelet packet reconstructed signal spectrogram

由图 2.5 可得，与原始语音信号生成的频谱相比，小波包重构信号包含更多的时间分辨率和频域分辨率信息，这意味着该信号在时频域内可提取到更多的局部特征。

在利用小波包重构算法从原始信号中获取 8 个新信号之后，在采样频率设置为 16kHz、帧长设置为 400 (25ms) 以及帧移设置为 160 (10ms) 的条件下，对每个新信号进行帧级声学特征提取^[47]，分别提取能够表征信号的帧级声学局部特征，它们分别是短时能量、短时过零率、短时能量熵、频谱中心及范围、频谱熵、频谱波动值、频谱滚降值、13 维的梅尔倒谱系数 (MFCCs) 及其一阶差分、谐波比 (Harmonic Ratio) 和音高 (Pitch)，共计 36 个特征，并分别对每个重构信号所提取到的特征进行归一化；为了后续网络的并行训练，需要对时间序列不等长的样本统一长度，本节将每个语音信号的时间序列 (时间步长, Time_step) 统一为 1024 帧，不足 1024 帧的情感语音信号样本采用前后补零的方式进行对齐，若超过统一值，则通过截取的方式进行，其中截取的规则为：将样本序列的总帧数与 1024 帧做差，从差值中随机取值作为序列的开始端，截取长度到 1024 为止，这么做的目的是根据其随机性在训练过程中可以充分训

练序列较长的样本数据，加强模型的有效性；在统一特征形状之后，将重构后 8 个信号提取到的帧级特征进行联合，组成 288 个帧级声学特征输入到后续的网络模型中。

2.3.3 自适应特征采样注意力模块

在上一小节获得重构后的帧级声学特征之后，本小节将介绍用于进一步提取的显著性特征的自适应特征采样注意力模块，在提取之前，先使用双向长短时记忆网络构成的循环网络模块从帧级特征中提取与时序相关的情感特征，下面对两个模块逐一进行介绍。

(1) 循环网络模块

循环神经网络是一种使用序列数据或时序数据的人工智能网络，通过在层内添加递归链接部分，来实现跨时间序列的参数共享，使得循环神经网络比隐马尔可夫模型具有更强的表征能力^[67]。在处理较长的时序信号时，需要增加循环层数，但是同时会产生两个问题，一个是随着层数的增多，网络模型容易产生梯度消失；而另一个则是存在长期依赖问题，处理语音信号的过程与处理隐马尔可夫问题相似，即当前时刻帧所表现的特征较为依赖前段时刻帧的状态，但是并不是当前帧都能与之前所有帧的状态存在联系，随着当前帧与过去某一时刻的时间步长较远时，那一时刻的状态很难影响到当前帧的状态。普通循环神经网络的隐藏层只有一个状态 (h)，该状态对当前帧相邻时刻的帧十分敏感，但却使得普通循环神经网络处理长期这个过程往往就造成信息的损失与计算资源的浪费，那么如果再添加一个状态 (c)，来保存长期的状态，就能很好的解决上述问题^[106]，长短时记忆网络 (LSTM) 应运而生，如图 2.6 所示。




图2.6 长短时记忆网络模型结构图

Figure 2.6 The Framework of LSTM Model

从图中看到，在某一时刻 t (帧)，LSTM 的输入有三个分别是：时间序列中当前时刻的输入 x_t 、上一时刻 LSTM 的输出值 h_{t-1} 、上一时刻的单元状态 C_{t-1} ；而 LSTM 的输出有两个，分别是 LSTM 的输出 h_t 和当前时刻的单元状态 C_t 。LSTM 网络主要是由三个门构成，门实际上是一层全连接层，它的输入是一个向量或多个向量，输出是一个 0 到 1 之间的数字。当门输出为 0 时，任何向量与之相乘都会得到 0 向量，相当于

信息无法传递过去；当输出为 1 时，任何向量与之相乘都不会有改变，信息可以通过。LSTM 用两个门来控制单元状态 C 的内容，一个是遗忘门（Forget gate），它决定了上一时刻的单元状态 C_{t-1} 有多少保留至当前时刻 C_t ；另一个是输入门（Input gate），它决定了当前时刻网络的输入 x_t 有多少保存到单元状态 C_t 。最后 LSTM 用输出门（Output gate）来控制单元状态 C_t 有多少输出到当前输出值 h_t 。其中遗忘门如公式(2-6)所示。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2-6)$$

其中 W_f 是遗忘门的权重矩阵； $[h_{t-1}, x_t]$ 表示把两个向量连接成更长的向量； b_f 是遗忘门的偏置项； σ 是 Sigmoid 函数，如果输入的维度是 d_x ，隐藏层的维度是 d_h ，单元状态的维度是 d_c （通常 $d_c = d_h$ ），则遗忘门的权重矩阵 W_f 维度是 $d_c \times (d_h + d_x)$ 。事实上，权重矩阵 W_f 都是两个矩阵拼接而成的：一个是 W_{fh} ，它对应着输入项 h_{t-1} ，其维度为 $d_c \times d_h$ ；一个是 W_{fx} ，它对应着输入项 x_t ，其维度为 $d_c \times d_x$ 。 W_f 可以写为公式(2-7)。

$$[W_f] \begin{bmatrix} h_{t-1} \\ x_t \end{bmatrix} = [W_{fh} \ W_{fx}] \begin{bmatrix} h_{t-1} \\ x_t \end{bmatrix} = W_{fh} h_{t-1} + W_{fx} x_t \quad (2-7)$$

然后输入门如公式(2-8)所示。

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2-8)$$

其中 W_i 是输入门的权重矩阵， b_i 是输入门的偏置项。接着利用公式(2-9)计算当前输入的单元状态 $\tilde{C}_t$ ，它是根据上一时刻输出和当前输入来计算的。

$$\tilde{C}_t = \text{Tanh}(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2-9)$$

在得到 $\tilde{C}_t$ 之后，计算当前时刻的单元状态 C_t 。它是由公式(2-10)得到的，即上一时刻的单元状态 C_{t-1} 按元素乘以遗忘门 f_t ，再用当前输入的单元状态 $\tilde{C}_t$ 按元素乘以输入门 i_t ，再将两个积加和产生的。

$$C_t = f_t \circ C_{t-1} + i_t \circ \tilde{C}_t \quad (2-10)$$

其中符号‘ $\circ$ ’表示点乘。

这样，LSTM 网络就把当前记忆 $\tilde{C}_t$ 和长期的记忆 C_{t-1} 组合在一起，形成了新的单元状态 C_t 。由于遗忘门的控制，它可以对距当前时刻较远的过去时序信息进行保存，又由于输入门的控制，它又可以避免当前无关紧要的时刻信息进入记忆状态中。通过公式(2-11)，可以看出输出门 o_t 通过控制长短时记忆来对当前输出所造成的影响。

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2-11)$$

LSTM 最终输出，是由输出门和单元状态共同确定的，如公式(2-12)所示。

$$h_t = o_t \circ \text{Tanh}(C_t) \quad (2-12)$$

然而 LSTM 仍然存在一个问题：无法编码从后到前的情感信息。在情感复杂交错的语音信号中，需要时刻注意情感的变化，LSTM 网络只能把控当前时刻之前的信息特征分布，而后续时刻的情感信息易被忽视。举一个例子，真实标签为高兴的语音样本“我今天心情真好”，这个样本的情感倾向集中在“真好”，但是“我今天”的这段时序主要体现为中性标签，所以导致如果当前时序为“心”，那么需要接收来自后续时刻的情感信息，以达到把控完整句子的情感信息的目的。因此，为了解决这一问题，双向长短时记忆网络（BiLSTM）被提出用来可以更好的捕捉双向的语音依赖，如图 2.7 所示。




图2.7 双向长短时记忆网络流程图

Figure 2.7 Flow Chart of BiLSTM

与 LSTM 网络不同，BiLSTM 网络在其基础上使用双向流动，能够利用当前时刻的前后双方的信息，在序列的两个方向上对情感信息和信号之间的顺序依赖关系进行建模。这有助于模型不仅仅可以从句子正向序列中学习情感相关的特征，也会从逆向序列中学习，这同时也意味着要以正向语音序列的末端作为起始点进行上述 LSTM 网络的一系列操作，并在最后将前向和后向的结果拼接在一起得到最终结果，如公式 (2-13) 所示。

$$h_t^* = [\vec{h}_t, \overleftarrow{h}_t] \quad (2-13)$$

其中 h_t^* 是 BiLSTM 的最终输出；网络中各个门的激活函数 σ 为 Sigmoid 函数；输出的激活函数为双曲正切函数（Tanh），如公式(2-14)、(2-15)所示。

$$\sigma(z) = y = \frac{1}{1 + e^{-z}} \quad (2-14)$$

$$\text{Tanh}(z) = y = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (2-15)$$

在经 BiLSTM 对重构后小波包帧级特征集进行提取与时序相关的特征之后，利用自适应特征采样注意力模块从获取的特征中提取到更有利于情感分类的显著性帧级特征，以生成帧级情感特征分布。

(2) 自适应特征采样注意力模块

自适应特征采样注意力模块主要由两部分构成：一维卷积自适应特征采样结构和注意力机制结构，其中一维卷积自适应特征采样结构的流程图如图 2.8 所示。




图2.8 一维卷积自适应特征采样结构流程图

Figure 2.8 Flow Chart of One-dimensional Convolutional Adaptive Feature Sampling

该结构目的是在提取后的特征中对情感分类有利的特征区域进行加强，对于情感分类不利的特征区域进行弱化，由于原始输入信号进行 3 层小波包分解并重构为 8 个语音信号后，情感特征分布并不是在每个重构后的信号中都有体现，比如在中性、悲伤等消极情感在高频区域内的特征要弱于低频区域，而愤怒、高兴等强烈情感在高频区域的信息又明显增多，所以设计这样一个模块来帮助模型筛选对它更有利的情感区域，整个结构的流程如表 2.1 所示。

表2.1 基于一维卷积自适应特征采样算法流程

Table 2.1 Algorithm of One-dimensional Convolutional Adaptive Feature Sampling

算法：基于一维卷积自适应特征采样结构

输入：样本特征表征 h_t^* ，形状[Batch_size, Time_steps, Feature_dim]

输出：采样之后的特征表征分布，形状与输入保持一致。

1.将初始输入 h_t^* 在时间步长维度上进行一维自适应平均池化：

$$h_t^*_{mean} = AdaptiveMeanPool1d(1)[h_t^*]$$

2.将 $h_t^*_{mean}$ 送入到卷积核为 3 的一维卷积层中生成自适应分布特征：

$$h_t^*_{conv} = Conv1D[h_t^*_{mean}]$$

3.利用 Sigmoid 损失函数处理 $h_t^*_{conv}$ ，给予信息多的区域相对较大的值：

$$h_t^*_{\sigma} = Sigmoid()[h_t^*_{conv}]$$

4.将 $h_t^*_{\sigma}$ 扩展到与 h_t^* 一样的形状后进行逐元素相乘。

5.最终得到自适应采样特征分布 $h_t^*_{Adap}$ 。

该结构利用一维卷积来实现重构后信号特征间的信息交互，相对于直接使用全连接层所实现的全局通道信息交互所带来的计算开销，可以显著降低模型复杂度的同时保持性能。其中一维自适应平均池化是对输入特征中的时间维度进行一维平均池化的操作，它的作用是在减少参数量的同时，将更多信息蕴含在特征的时间维度中，并且有效降低因 BiLSTM 网络对输出结果造成一些估计值方差增大的影响，使特征分布更加平滑；一维卷积层作用在特征维度中，通过内在的一维卷积核使特征集中的相邻局部特征之间的联系更为紧密，并通过学习被赋予其不同的权重，权重较大的区域包含情感信息更多，反之亦然，这样就实现了自适应特征采样的目的；在学习到特征权重分布之后，利用激活函数 Sigmoid 的输出在 (0, 1) 之间优化稳定、便于求导等优势，对其进行 Sigmoid 函数运算使权重分布更加稳定，再通过广播操作将该分布生成循环神经网络输出特征的形状之后，与输出特征进行点对点相乘，最终获得自适应采样的显著性特征。

采用注意力机制结构代替一维平均池化层和一维最大值池化层，用以消除自适应采样输出中的时间维度，以生成帧级情感特征分布便于利用损失函数实现情感分类。与单纯的对时间维度求均值和最大值操作不一样，注意力机制结构可对自适应采样后的特征中施加不同的权重，从而关注更有利于给定样本标签区域的具体位置，由于情感在整个语音中分布是不均匀的，因此注意力机制可用来关注给定样本中情感突出的部分^[107, 108]，与上述自适应采样结构针对时间序列维度不同的是，注意力机制直接针对特征维度来获取更具判别力的特征分布，如图 2.9 所示。




图2.9 注意力机制结构图

Figure 2.9 Structure Diagram of Attention Mechanism

该结构计算的是一个加权总和，而不是随时间变化的平均数，其中权重是根据注意力机制结构中一组额外的参数决定的。使用一个单逻辑回归结构作为注意力机制模

型，即在每个时间帧 t 中，计算注意力参数向量 u （超参数，设置为“1/特征维数”）和自适应采样结构的输出 h_t^* 之间的内积，一个 Softmax 函数被应用在其中，以获得一组基于时间帧的权重，其总和为 1，然后将获得的权重与输出 h_t^* 再做一次内积，最终得到情感语音信号的显著性帧级特征分布。

（3）语音信号的句子级特征提取

为了用于情感分类的特征分布更加趋于完善，使其包含更多的情感信息，由于小波包重构帧级注意力网络输出的是帧级情感特征分布，该分布更加关注对语音信号的局部特征信息，因此本小节针对原始输入信号设计了一个包含 140 个特征的句子级声学特征集，利用单隐藏层的深度神经网络对句子级声学特征集进一步提取，以生成句子级情感特征分布，加强对全局特征信息的关注，其中隐藏层节点设置为 64，输出层为 32。特征提取过程使用 OpenSmile^[109]程序，所使用的全局特征如表 2.2 所示。

表2.2 140 个句子级语音情感全局特征组成的特征集合

Table 2.2 Feature Set composed of 140 Utterance-level SER Global Features

类别	局部特征	全局特征
韵律特征	短时能量	最大值/最小值/均值/方差
	-	短时能量抖动
	短时线性回归系数	均方误差
	-	250Hz 以下短时能量占比
浊音特征	基音频率	最大值/最小值/均值/方差
	-	一阶、二阶基频抖动
	-	基频分段方差
	基频一阶差分	最大值/最小值/均值/方差
共振峰特征	1~3 共振峰频率	最大值/最小值/均值/方差/一阶抖动
	第 2 共振峰频率比率	最大值/最小值/均值
谱特征	0~12 阶 MFCC	最大值/最小值/均值/方差
	0~12 阶 MFCC 一阶差分	最大值/最小值/均值/方差

从表 2.2 中得到，由 140 个特征组成的句子级声学特征集包括能量特征、浊音特征、共振峰特征以及谱特征的相关衍生值，该特征集包含大量能体现情感状态的全局特征

信息,情感的变化能够通过句子级特征间的差异体现,这对情感分类有重要意义,该声学特征集不仅涵盖了大量的时域与频域的全局信息,同时也能够反应出人们在表达过程中情感的整体变化。本小节利用前馈神经网络将由 140 个特征构成的样本空间映射为低维空间,在降维缩减的同时,也让模型学习并筛选出更适合于情感分类的特征分布,在前馈神经网络结构中,在隐藏层分别使用 Dropout 结构和批归一化结构来加强前馈神经网络模型结构对于声学特征的提取能力。

Dropout 结构可以作为训练深度学习网络的一种技巧(trick)供选择,属于超参数的一种。在每个训练批次中,通过忽略神经元结点(即使该隐藏神经元的结点权重置为零),可以明显地减少过拟合现象,即神经网络在前向传播的时候,让某个神经元的激活值以一定的概率停止工作,可以使模型泛化性更强,因为它不会太依赖某些局部特征。在实验过程中,只在模型训练阶段以一定概率丢弃神经元,而在验证和测试阶段则保留全部神经元以保证模型的稳定输出。使用 Dropout 的意义在于减少神经元之间复杂的共适应关系,以达到防止过拟合的目的。

批归一化结构(Batch Normalization, BN),是将分散的数据统一的一种做法,也是优化神经网络的一种方法,让深度学习网络更容易学习到数据之中的规律。在深度学习网络的训练过程中,随着逐层学习,上层网络需要不停调整(即权重更新)来适应输入数据分布的变化,每层权重的方差通过反向传播不断累积,容易陷入梯度饱和区,减缓网络收敛速度,批归一化层的出现完美解决了这一问题,有效防止梯度弥散,加快训练速度并提高模型精度。本章将在 2.4.3 小节对使用两种结构进行消融实验。

2.3.4 损失函数

最终将基于小波包重构特征自适应注意力网络模型得到帧级特征分布与从原始信号中得到的句子级特征分布相融合,构成可包含局部特征信息与全局特征信息的情感分布,在损失函数的帮助下实现情感分类。模型整体参数配置如表 2.3 所示。

表 2.3 中的 T 为序列长度,属于超参数,如上述设置为 1024 帧;K 为情感最终分类的类别数,是由具体情感任务决定。将所提出模型的输出和真实标签一同输入到损失函数中,得到最终的识别结果。训练损失函数选择交叉熵损失函数,如公式(2-16)所示。

$$CE_Loss = \frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(p_{ic}) \quad (2-16)$$

其中 M 代表类别的数量； y_{ic} 表示真实标签，在多分类实验任务中，需要对真实标签进行 one hot 编码，即样本 i 的真实标签位 c 取 1，否则取 0； p_{ic} 为观测样本 i 属于类别 c 的预测概率。实验环境以及超参数的设置将在下一节详细介绍。

表2.3 基于小波包重构特征的自适应注意力网络模型整体参数配置

Table 2.3 Overall Parameter Configuration of AWPRNN Model

层以及特征	输入维度	输出维度	内部参数
小波重构帧级特征	$8 \times T \times 36$	$T \times 288$	-
BiLSTM	$T \times 288$	$T \times 128$	Hidden_state = 64
自适应采样层	$T \times 128$	$T \times 128$	Kernel_size: 3
注意力机制层	$T \times 128$	128	-
全连接层	128	32	Dropout = 0.2
句子级特征集	140	140	-
深度神经网络	$140 \rightarrow 64 \rightarrow 32$	32	-
联合分布	$32 + 32$	64	-
全连接层	64	$K(=4/7)$	-

2.4 实验描述及结果分析

本章从语音信号处理、声学特征提取及注意力机制设计等角度，提出了基于小波包重构特征自适应注意力网络（AWPRNN）的语音情感识别算法，在两个公开可用的数据集以及自设计数据集共三个数据集上进行实验，以验证所提出算法结构的泛化性和有效性，实验结果均通过双尾 T 检验证明其真实性。

2.4.1 实验准备

（1）数据集

本章在实验中使用两个公共数据集 IEMOCAP 和 EMODB，这两个数据集已经在 1.2 节中进行了详细介绍，而本文自设计的 CID 数据集将在本小节进行介绍，下面对三个数据集的具体使用细节进行描述。

IEMOCAP 数据集是基于戏剧理论基础上收集，以模拟演员之间的自然对话，总共包括 5 组对话（Session），每个 Session 包含两个说话人（Speaker），分别为 1 男 1 女，共 10 人；对话由两种情感激发方法组成，包括按戏剧剧本的表演方式以及在情感场景中的即兴表演。每个波形文件都有至少由三个人类注释者提供的情感类别标签，在原始数据中，总共有 10039 个的情感样本，平均时间为 4.5 秒，包含 7 种情绪状态愤怒、兴奋、沮丧、高兴、中性、悲伤和惊讶，采样频率为 16kHz。鉴于数据库中类别标签

样本不均衡,因此,从所有情感样本中取出生气,悲伤,高兴以及中性的情感样本进行四分类实验,其中由于兴奋和高兴在情感表达上十分相近并且可以弥补高兴样本的数据量,故将兴奋和高兴情感样本合并在一起,总共为包含四种类别在内的 5531 个语料级样本(愤怒:1103;悲伤:1084;高兴:1636;中性:1708)进行实验。

EMODB 数据集是通过演员们在进行自发式表演时收集的,数据集同样包括 10 名演员(5 男 5 女),包括 7 种情感分别是中性、恐惧、高兴、愤怒、悲伤、厌恶和无聊,每种情绪由几乎相同数量的语料组成,总共包括 535 个样本,采样频率为 44.1kHz,在预处理时降为 16kHz。本章将利用全部的 535 个情感语料级样本进行七分类实验。

CID 数据集是由本文所设计新的中文数据集,将其命名为中文模仿数据集(Chinese Imitation Dataset, CID),和 CASIA 中文数据集和 EMODB 德语数据集的采集过程类似,该数据集是一个模仿性质的数据集,录音设备为索尼降噪蓝牙耳机 WH-1000XM4,数据集总共由 30 个句子组成,由 24 位人员录制(18 男 6 女),每个人从 30 个句子中随机挑 10 句话,分别用 4 种情感在 3 秒内进行表述录制,情感包括中性、高兴、愤怒以及悲伤,共组成 960 个样本,其中各个情感样本数量均衡,采样频率 16kHz。与 IEMOCAP 和 EMODB 数据集不同,该数据集录制环境为自然条件下录制,为了进一步验证所提出模型的有效性和鲁棒性,被动的引入音量不均以及如呼吸声、背景声等噪声的干扰因素到样本中,以下是句子样本例如:

1. 天空真晴朗呀。
2. 晚上一起吃饭。
3. 你以为我不敢吗?
4. 我真的好伤心。
-
30. 认清生活的真相,并仍然热爱它。

以上样本总共为 30 句,从中可以看出一些句子带有明显的情感倾向,比如第 3 句从语音角度上看倾向于愤怒情感,以及第 4 句更倾向于悲伤情感。但是,数据录制仍然要求演员们分 4 种情感录制,这样做的目的是使语言对于情感状态的影响降到最低,着重研究语音对于情感的影响。

(2) 实验设置

由于三个数据集并没有明确给出训练集,验证集和测试集,因此本章采用留一十折交叉验证(Leave-one-speaker-out Cross Validation)的方式进行实验,以验证所提出算法的有效性和泛化性。具体而言,就是重复的使用数据,把得到的样本数据进行切

分,组合为不同的训练集、验证集和测试集,用训练集来训练模型,用验证集来调整参数以及用测试集来评估模型情感识别精度,在此基础上可以得到多组不同的训练集、验证集和测试集。某次训练集中的某样本在下次可能成为测试集或验证集中的样本,即所谓“交叉”,其意义在于对数据集进行多次划分,对多次评估的结果取平均,从而消除单次划分时数据划分得不平衡而造成的不良影响,因为这种不良影响在小规模数据集上更容易出现,所以交叉验证方法在小规模数据集上更能体现出优势;当用交叉验证进行模型选择时,可以从多种模型中选择泛化能力最好(非过拟合)的模型,从这个角度看,交叉验证是防止过拟合的有效手段。此外,由于数据集中样本标签分布不一,所以选择十折而非五折交叉验证可以增强模型的稳定性,降低泛化误差,使结果更加可靠。

每个人在发声过程中,由于其生理结构的不同比如嘴型,咽喉结构等,所表达出的情感信息也不尽相同,所以在情感识别过程中会掺杂一些有关说话人信息帮助识别情感,对模型的泛化性产生影响。试想在实际应用中,一个成熟的已经训练好的模型是不知道未来将会在哪个数据样本(哪个人所说的话语)上进行识别的,独立说话人实验是指将单个人分别单独作为验证集和测试集进行实验,即某个说话人的情感语音样本完全仅在训练集中或测试集中。具体而言,10个人的 IEMOCAP 数据集中,将其中 8 个说话人作为训练集,1 个说话人作为验证集,剩下的 1 个人作为测试集,进行 10 次实验并取其平均结果作为最终结果;与独立说话人实验对立则是依赖说话人实验,顾名思义,即说话人的情感语音样本在训练集和测试集中都存在,在 EMODB 和 CID 数据集中应用留一十折交叉验证的情况下,采用 10 次不同随机数种子对数据集的随机打乱,每次取其中的 80%作为训练集,10%作为验证集,剩余 10%作为测试集,取 10 次实验结果的平均值作为最终结果。本章在 IEMOCAP 数据集和 EMODB 数据集分别做了独立说话人实验(Speaker-independent)和依赖说话人实验(Speaker-dependent),在自设计 CID 数据集上做了依赖说话人实验以验证所提出算法的有效性和泛化性。

本章分别在三个数据集中使用的基于小波包重构特征的自适应注意力神经网络模型都是从零开始训练的,使用 Adam 算法作为优化器,学习率设置为 $1e-4$,用于计算梯度及其平方的平均值系数 betas 设置为 (0.9, 0.999),权重衰减设置为 0,数值稳定性参数设置为 $1e-8$,batch_size 大小设置为 32,在训练阶段 Epoch 设置为 150。

本章的模型使用 Pytorch 开源深度学习框架实现,所有实验均在 NVIDIA GTX 3090 GPU 单卡上运行。

(3) 评价指标

语音情感识别研究中最重要的是两个评价指标是未加权平均召回率（UAR）以及混淆矩阵，在介绍它们之前，基于两个评价指标给出描述模型性能的四个最基本的评估术语，分别为：真阳性（True Positives, TP）、假阳性（False Positives, FP）、假阴性（False Negatives, FN）及真阴性（True Negatives, TN），其中 TP 表示正样本识别被正确识别为正样本；TN 表示负样本被正确识别为负样本；FP 表示假的正样本即负样本被错误识别为正样本；而 FN 则表示假的负样本即正样本被错误识别为负样本，以高兴情感为例，如表 2.4 所示。

表2.4 类别为二分类时的混淆矩阵

Table 2.4 Confusion matrix when the category is binary

		预测类别		
		高兴	不高兴	总计
实际类别	高兴	TP	FN	P（实际为高兴）
	不高兴	FP	TN	N（实际为不高兴）
	总计	P'（被分为高兴）	N'（被分为不高兴）	P + N

（1）未加权平均召回率（Unweighted Accuracy Recall, UAR）

未加权平均召回率，即正类召回率和负类召回率的平均值，如公式(2-17)所示。

$$UAR = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{FP + TN} \right) \quad (2-17)$$

当测试集样本类别均衡，准确率（Accuracy）如公式(2-18)所示。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-18)$$

平均召回率和准确率在样本类别数量平衡的任务中会给出相同的结果，但是由于每个情感类别的样本并不是均衡的，模型对不同情感的感知也是不一样的，可能存在这样一种情况，即当有少量来自正类的样本和大量来自负类的样本时，如果模型对正类的预测较少，而对负类正确预测较多时，平均召回率则远低于准确率，这是由于负类样本占比多的同时预测也多，表明了模型在正类上表现不佳，平均召回率则给出了更为真实的结果，所以在进行情感识别时，使用平均召回率作为评价指标之一是具备科学意义的。

（2）混淆矩阵

混淆矩阵也称误差矩阵，是表示精度评价的一种标准格式，用 n 行 n 列的矩阵形式来表示，特别用于有监督学习，如表 2.4 所示，其主要表达两层含义：1.混淆矩阵的每一列代表了预测类别，每一列的总数表示预测为该类别数据的数目；2.每一行代表了

数据的真实归属类别，每一行的数据总数表示该类别的数据实例的数目，每一列中的数值表示真实数据被预测为该类的数目。混淆矩阵主要用于比较分类结果和实际测得值，可以把分类结果的精度显示在一个混淆矩阵里面。通过混淆矩阵可以方便快捷的分析出哪个类别容易被误识别，从而系统地有针对性找到问题出现的原因，并且在语音情感识别中被当作可视化工具来使用。

2.4.2 实验结果与分析

为了方便所提出的网络模型并行训练，如上一节所述，在帧级特征集提取过程中，将从原始信号中采用截取补零的方式将信号设置为相同长度，将每个语音信号的时间序列（时间步长，Time_step）统一为 1024 帧以并行训练。为了与其他研究作比较以验证所提出算法的有效性，本章在 IEMOCAP 数据集中选择平均召回率作为评价指标，而在数据量较少的 EMODB 中选择准确率作为评价指标。由于 CID 数据集在设计过程中各个情感样本分布一致，在做依赖说话人实验中准确率与平均召回率相等，因此本文选择将平均召回率作为该数据集的评价指标，各个数据集的实验结果如下所示。

（1）IEMOCAP 数据集的实验结果

如上所述，本章使用留一十折交叉验证的策略在 IEMOCAP 数据集上进行独立说话人以获得平均召回率，在 IEMOCAP 数据集上应用本章所提出的算法与其他算法研究进行比较，结果如表 2.5 所示。

表2.5 小波包重构特征自适应注意力网络模型在 IEMOCAP 数据集上与其它方法的比较

Table 2.5 Comparison of the AWPRNN Model with Other Methods on the IEMOCAP

研究	特征	算法	平均召回率
Han et.al ^[110]	MFCC、音高等	DNN and ELM	54.3%
Lee et.al ^[44]	ZCR、音高、MFCC 等	决策树	58.46%
Mirsamadi et.al ^[47]	LLDs 和自学习特征	Deep RNN	58.8%
Sebastian et.al ^[111]	ComParE2013 特征集	融合模型	60.3%
Kim et.al ^[71]	LLDs 特征	DNN	61.8%
本章	小波包重构帧级特征	AWPRNN 模型	62.15%

从表 2.5 可以看出，在独立说话人实验中，本章所提出的模型结构在 IEMOCAP 数据集上的平均召回率达到了 62.15%，超过了其他利用声学特征模型的识别精度，证明了所提出算法的有效性。图 2.10 分别显示了独立说话人实验类型的混淆矩阵，描述了四种语音情感分类结果的细节。




图2.10 IEMOCAP 数据集独立说话人实验混淆矩阵

Figure 2.10 Confusion Matrix of Speaker-independent Experiment on IEMOCAP

此外由图 2.10 的混淆矩阵验证了上述论述，可以看出在愤怒情感和悲伤情感相对而言取得了良好结果，分别是 64.28%和 71.40%，与基线研究相比^[112]，中性和高兴的平均召回率分别为 60.66%和 52.26%，表明本章模型结构从小波包重构信号中提取到的特征在该数据集上表现更好。然而在高兴情感的预测上依然有 24.08%被预测到了中性，预测错误的原因主要是高兴与中性情感的特征分布较为接近，在实验中相比愤怒和悲伤情感更难分辨出来。此外在数据集实际录制中，人们在彼此正常交流中表达中性情感时，受心理层面的影响，往往产生趋向于高兴情感的表达的想法，这可能也是导致平均召回率较低的原因。

(2) EMODB 数据集的实验结果

本章同样在 EMODB 数据集上使用留一十折交叉验证策略进行七分类语音情感识别，由于 EMODB 数据集上的数据较少为 535 个（愤怒：127；无聊：81；厌恶：46；恐惧：69；高兴：71；悲伤 62；中性：79），目前主流的研究都是以依赖说话人实验作为主要研究，评价指标选择准确率，并在此基础上与其他算法进行比较，结果如表 2.6 所示。

表2.6 小波包重构特征自适应注意力网络模型在 EMODB 数据集上与其它方法的比较

Table 2.6 Comparison of the AWPRNN Model with Other Methods on the EMODB

研究	特征	算法	准确率
Bitouk et.al ^[58]	谱特征	SVM	81.3%
Albornoz et.al ^[113]	MFCC、韵律特征等	Hierarchical 分类器	71.5%
Deng et.al ^[114]	LLDs 特征	Denoising AE	57.9%
Mao et.al ^[115]	自学习特征	CNN	79.9%
本章	小波包帧级特征	AWPRNN 模型	82.63%

图 2.11 显示依赖说话人实验类型下以混淆矩阵的形式呈现的情感分类结果。通过观察混淆矩阵，本章提出的算法在 EMODB 数据集中依然表现良好，验证了模型算法的泛化性与有效性，实验中愤怒、悲伤、中性情感分别达到 88.98%、88.71%以及 89.74%准确率，但在高兴情感上依然表现不佳，有 25.35%错误预测在愤怒情感中，出现误判的原因主要在于所使用的数据集的样本主要由演员表演录制，而非自发，这就导致演员在录制过程中，突出了高兴的情感表达，导致愤怒和高兴的情感特征分布近似，并从支配维度角度观察，两种情感都属于强情感，而从激活维度视角看，则都属于活跃情感。




图2.11 EMODB 数据集依赖说话人实验混淆矩阵

Figure 2.11 Confusion Matrix of Speaker-dependent Experiment on EMODB

(3) CID 数据集的实验结果

受 CID 数据集中样本数量的限制以及多人录制条件，因此本章将重点关注该数据集下依赖说话人实验，已验证所提出方法的泛化性，将平均召回率作为评价指标用以评估模型有效性，所提出的模型在依赖说话人实验中与其他方法在 CID 数据集上的比较结果如表 2.7 所示。图 2.12 为相应的依赖说话人实验混淆矩阵。

表2.7 小波包重构特征自适应注意力网络模型在 CID 数据集上与其它方法的比较

Table 2.7 Comparison of the AWPRNN Model with Other Methods on the CID

研究	特征	算法	平均召回率
前馈神经网络	原始句子特征	DNN	58.28%
Mirsamadi et.al ^[47]	原始帧级特征	ARNN	59.46%
本章	小波包帧级特征	AWPRNN 模型	61.30%

由表 2.7 所示的结果, 相比与其他基线研究, 本章所提出算法在 CID 上获得了更高的 61.30% 平均召回率, 分析原因在于小波包重构特征自适应注意力网络能够提取到较为全面的情感特征分布, 包含局部情感特征信息和全局情感特征信息, 比基于原始信号帧级特征的神经网络以及单独使用语音信号句子级声学特征模型要好, 证明所提出模型结构的有效性, 同时从混淆矩阵上也能看出, 本章算法在四种情感上取得了良好结果, 如图 2.12 所示。




图2.12 CID 数据集依赖说话人实验混淆矩阵

Figure 2.12 Confusion Matrix of Speaker-dependent Experiment on CID Dataset

由图 2.12 中所示, 在 CID 数据集依赖说话人实验结果中显示了各个情感的平均召回率, 和 IEMOCAP 数据集的整体识别趋势类似, 其中愤怒和悲伤情感取得一定程度的实验结果, 分别达到了 69.58% 和 71.67% 的平均召回率, 由于数据集中的样本量较少且样本为自然条件下录制, 如存在呼吸声、背景杂音以及样本之间音量不等问题, 高兴情感以及中性情感也达到了 44.77% 和 59.17% 平均召回率, 说明所提出的模型在复杂的环境下对情感识别仍然取得一定效果, 进一步验证了所提出的网络模型的鲁棒性和有效性。但是高兴和愤怒情感之间, 中性和悲伤情感之间, 仍然存在容易弄混的问题, 分析原因可能在于高兴和愤怒情感之间的激活度类似, 导致模型在区分激活度方面出现误判, 而中性和悲伤则在愉悦度上容易产生混淆, 这可能是导致精度没有进一步提升的主要原因, 其次数据集的样本量和语音样本的表演痕迹也同样会对识别结果产生重要影响。

(4) 性能分析

受可学习参数的影响, 在实际应用中, 需要权衡算法的资源占用与性能之间的关系, 表 2.8 展示了使用不同小波包分解层数所利用的可学习参数数量以及注意力机制的使用所占用的参数数量。

表2.8 不同模型结构的可学习参数数量

Table 2.8 Number of Learnable Parameters for Different Model Structures

小波包分解层数	模型结构	可学习参数量
三层	WPRNN (无注意力)	196740
一层	AWPRNN (有注意力)	40649
二层		123145
三层		196873
四层		344329

从表 2.8 可以看出, 在各个小波包分解层数下, 展示了使用本章所提出注意力机制的可学习参数量以及不使用情况。各个模型结构产生的实验结果在下一章节 2.4.3 消融实验中给出并进行详细讨论。值得注意的是, 随着小波包层数分解的增多, 可学习参数不断增加, 这符合递增规律, 从效果上看使用三层小波包分解产生的结果更好, 可学习参数在应用中可以被接受, 而随着分解层数增加到 4 层, 这导致重构后的信号中的情感信息会被稀释, 导致性能下降并对可学习参数造成资源浪费。此外, 通过添加注意力机制, 可有效提升模型对识别情感任务的精度, 并且所占用的可学习参数较少 (仅增加了 133 个参数), 实际应用中在小型存储设备上可以采用此算法进行语音情感识别。

2.4.3 消融实验

本节将从以下三个角度逐一做出消融分析实验 (Ablation Analysis), 包括声学特征集网络模型参数、基于小波包分解层数、一维卷积自适应特征采样结构, 以进一步验证所提出模型结构的有效性, 所有消融分析均在公共数据集 IEMOCAP 上做了独立说话人实验 (SI) 和依赖说话人实验 (SD), 实验结果如下所示。

(1) 句子级声学特征集模型参数的影响

本小节主要针对所提出算法中关于句子级声学特征集的模型参数进行消融分析, 分别进行了不同超参数的深度神经网络模型实验, 包括隐藏神经元的数量、Dropout 结构和批归一化层 (BN) 结构的选择搭配, 结果的评价指标为平均召回率, 如表 2.8 所示, 其中单隐藏层的神经元个数为 “64”; 双隐藏层的神经元个数分别为 “128” 和 “64”。

。

表2.9 基于句子级特征的网络模型参数配置的消融实验

Table 2.9 Ablation Experiment of Utterance-level Feature Model Parameter Configuration

特征	算法	参数配置	IEMOCAP(SI)	IEMOCAP(SD)
句子级声学特征	DNN	单隐藏层 + Dropout (0.5)	57.16%	59.63%
		单隐藏层 (64) + BN	58.04%	60.56%
		双隐藏层 (128, 64) + BN	57.93%	60.34%

从表 2.9 可以看出, 在单独使用句子级特征集进行语音情感识别时, 利用添加 BN 层的单隐藏层和双隐藏层, 在两类实验中均取得了不错的实验结果, 证明了在深度神经网络中批归一化技术可帮助模型提升分类效果, 其中使用单隐藏层 (64) 的效果更好, 但提升非常有限, 没有达到预期目标, 说明单独使用句子级声学特征集在进行 SER 任务中仍有其局限性。

(2) 基于小波包分解层数的影响

本小节主要针对小波分解层数对深度学习神经网络产生结果的影响, 分别针对小波包在不同层数分解下产生的结果进行消融分析, 包括直接对原始输入进行 36 维帧级特征提取, 以及 1、2、4 层小波包分解对实验结果的最终影响, 如表 2.9 所示。值得注意的是, 为了与下一小节进行对比分析, 本小节产生结果均不包含一维卷积自适应特征采样结构和 140 个句子级特征的前馈神经网络结构。

从表 2.10 可以看出, 当采用三层小波包分解并从重构后的信号提取到 288 维帧级特征并联合组成特征集, 产生的实验结果表现最好, 在两类实验中均有一定提升, 分别为 58.82% 和 61.23%。当分解层数少时, 特征集中包含情感信息也会随之减少; 当分解层数多时, 特征虽然包含较多的信息, 但主要集中在低频区域, 而高频区域信息很少, 造成特征参数冗余而易产生过拟合, 在浪费计算资源的同时, 影响模型分类效果。

表2.10 小波包分解层数对模型整体影响

Table 2.10 The Overall Effect of Wavelet Packet Decomposition Layers

小波分解层数	算法模型	IEMOCAP(SI)	IEMOCAP(SD)
无小波分解	AWPRNN (无自适应采样)	55.38%	57.47%
一层		56.16%	58.03%
二层		57.43%	59.65%
三层		58.82%	61.23%
四层		56.95%	60.14%

(3) 基于一维卷积自适应特征采样结构的影响

本小节主要针对基于一维卷积自适应特征采样结构对模型结果产生的影响做出消

融分析，包括使用和不使用该特征采样结构，如表 2.11 所示。

表2.11 基于一维卷积自适应特征采样结构对实验结果的影响

Table 2.11 The Influence of One-dimensional Convolution-based Adaptive Feature Sampling

特征	算法模型	IEMOCAP(SI)	IEMOCAP(SD)
联合特征	AWPRNN（无自适应采样结构）	60.56%	64.48%
	AWPRNN（整体）	62.15%	65.87%

其中联合特征是指基于重构后的小波信号所提取的帧级特征与从语音信号中直接提取句子级特征联合后的特征，从表 2.10 可以看出，当采用本章所设计的一维卷积自适应特征采样结构时，从各项实验结果上看，平均召回率稳定提升在 1%~2%之间，这是因为该模块可拉开有效情感特征和非有效情感特征在分布中的间隔距离，帮助注意力机制将关注点集中在那些可有效区分情感的显著性特征区域内，达到提升识别精度的目的，进一步证明了所提出的一维卷积自适应特征采样结构的有效性和泛化性。

2.5 本章小结

本章针对情感语音信号利用短时傅里叶变换提取声学特征过程中，在时频域内对局部特征表征能力弱的问题，以及注意力机制结构无法获取更有效的有利于情感分类的显著性特征分布问题，提出了基于小波包重构特征自适应注意力网络的语音情感识别算法。首先利用小波包重构算法生成了包含更多时间分辨率和频率分辨率相关情感信息的新信号，加强了在时频域内对局部特征表征能力，并提取帧级声学特征。然后使用循环模块从中进一步提取与时序相关的特征，并通过所设计的自适应特征采样注意力网络模块增强有利于情感分类特征区域的权重，生成更加具有情感判别力的显著性特征分布，进而提升语音情感识别精度。实验在情感语音公共数据集 IEMOCAP 和 EMODB 进行多次验证，证明了所提出算法的有效性和泛化性，并分别在独立人说话人实验和依赖说话人实验中获得 62.15%平均召回率以及 82.63%准确率，在情感类别样本均衡的自设计数据集 CID 中，平均召回率和准确率均在依赖说话人实验获得 61.30%的语音情感识别结果。

第3章 基于自适应时频注意力残差网络的语音情感识别

上一章通过在时频域内重构小波包帧级特征，并将其输入到自适应特征采样注意力模块中，提升了语音情感识别结果。然而上述方法采用的声学特征集无法反映出在相邻时刻时频域之间的空间联系；提取特征过程中获取全局信息能力不足而导致在语音情感识别过程中情感特征遗漏；在时域维度中相关特征表征情感能力较弱。为了解决上述问题，进一步提升识别精度，本章提出基于自适应时频注意力残差神经网络的语音情感识别算法，从原始信号中提取三通道语谱图作为模型输入，然后设计了卷积模块进行特征提取以获取高维特征，利用循环模块进一步提取与时序相关的情感特征，输入到自适应时频注意力机制模块，生成在时频域内有利于情感识别的显著性特征分布，最后联合中心损失函数和交叉熵损失函数实现语音情感识别。所提出算法在三个数据集中分别进行实验，并增加模块消融实验，全面验证模型性能。

本章研究内容的结构安排如下：3.1 节是引言；3.2 节是基于自适应时频注意力残差网络的语音情感识别模型框架；3.3 节是所提出算法的具体细节进行详细介绍；3.4 节是实验以及结果分析；3.5 节是本章小结。

3.1 引言

目前，针对语音情感识别领域内的特征工程研究，科学家仍然没有找到可完全判别情感类别的最佳特征集，尽管从语音信号中直接提取手工声学特征集并利用深度学习模型进行情感识别，以其低模型复杂度的优势在数据集样本容量相对较少的情感识别中尤为显著，并取得了一定成果，但是声学特征集在时频域内所包含的情感信息并不充分，同时也无法发挥深度学习中卷积神经网络处理二维特征的优势，限制了相应深度网络模型结构的运用导致灵活性降低。因此，从原始信号中提取二维语谱图可以同时时在时频域建立局部空间关系，处理这种二维特征公认主流的算法是利用卷积神经网络（Convolutional Neural Networks, CNN）进行特征提取^[116-119]。通常情况下，在语音信号处理过程中，信号通过短时傅里叶分析以及梅尔滤波器得到二维语谱图，它与其他声学特征最为明显的不同就是具备结构特点，在局部空间中可同时具备时域和频域信息，在特征提取过程中，卷积神经网络可以同时时在时域和频域上进行特征提取，使时频特征联系更为紧密且具备可学习性，并且可以利用卷积的不变性来克服语音信号本身的多样性，CNN 相比 DNN 在参数数量上大大减少，提高准确度的同时不占用计算资源，并且也比较容易实现大规模并行化运算，最大限度地保留情感语音特征表

征的全局信息。卷积神经网络是一个信息提取的过程，从浅层的语谱图逐渐提取到高度抽象的特征，即高维特征，由于情感语音信号属于时序相关信号，高维特征中包含受时序影响的信息，因此循环神经网络可以对高维特征进一步提取使其能够捕捉到时序相关的情感信息。注意力机制结构则帮助提取后的高维特征生成更有利于情感识别的显著性特征分布，有助于提升模型性能，最后在损失函数的帮助下通过反向迭代更新模型参数实现语音情感识别。然而上述结构仍存在一些不足：1) 单通道的语谱图在时域上无法表现其相邻时刻间动态变化信息；2) 卷积模块中固定的卷积核以及简单堆叠的结构限制了模型对特征的感受野范围，降低了高维特征对全局信息的获取能力；3) 注意力机制结构在处理高维特征时忽视了对时序相关特征区域的加强；4) 考虑到各类情感在特征空间中分布紧密，而类别内样本分布较大，交叉熵损失函数在识别过程中对不同类别情感容易造成混淆，导致情感分类错误。

针对上述问题，本章提出了一种基于自适应时频注意力残差网络模型 (Residual Convolutional Recurrent Neural Network Model Based on Adaptive Time-Frequency Attention, ARCRNN)。首先对情感语音信号提取对数梅尔倒谱图特征，也称为语谱图，是同时包含时频域的二维特征向量，并与可描述各帧之间的相邻时刻动态关联性的 δ 和 $\delta\delta$ 谱图联合构建三通道语谱图，再使用 SpecAugment 算法进行数据增强后作为深度学习网络模型的输入特征，在卷积模块浅层使用空洞卷积和普通卷积相结合方式来扩大感受野以生成高维特征，然后使用由门控神经单元网络构成的循环模块进一步提取与时序相关的情感特征，接着输入到自适应时频注意力机制模块中，提取有利于情感识别的显著性特征并获取特征分布，最后联合中心损失与交叉熵损失函数之后实现语音情感识别。

3.2 基于自适应时频注意力残差网络的语音情感识别模型框架

图 3.1 是本章提出的基于自适应时频注意力残差网络的语音情感识别模型框架图，采用能够反映信号在时域上的动态变化的三通道语谱图，作为整个模型的输入，模型包括三个部分：卷积模块、循环模块以及注意力机制模块，其中卷积模块首先联合空洞卷积层和普通卷积层作为浅层结构来处理语谱图，保证不丢失时频分辨率的情况下扩大感受野，同时捕捉更多的局部时频信息。然后输入到带残差结构的两个卷积层区域中，每个卷积层区域包括带批归一化层的两层普通卷积层，在卷积区域之间穿插二维最大池化层，目的是在降低特征维度的同时减少计算量，扩大特征感受野以更好的提取全局信息；将卷积模块的输出改变结构以适应循环神经网络，用双向门控神经单

元网络结构代替普通循环神经网络从高维特征中进一步提取与时序相关的特征。最后利用自适应时频注意力机制（Temporal-Frequency Domain Attention, TFDA）模块在时频域内获取有利于情感识别的显著性特征分布，联合交叉熵损失函数与中心损失函数实现语音情感识别。




图3.1 基于自适应时频注意力残差网络的语音情感识别模型框架图

Figure 3.1 Framework of SER Model based on Adaptive Time-Frequency Domain Attention Residual Network

基于自适应时频注意力残差网络的语音情感识别的整体步骤如下：

（1）对原始语音情感信号利用快速傅里叶变换进行时频转换之后，生成对数梅尔倒谱特征，通过截取补零的方式保持样本时长的一致性，时域长度为 300 帧（时长约 3s），在语谱图提取的过程使用梅尔滤波器的数量为 40，然后计算 δ 和 $\delta\delta$ 谱图共同组成形如 “[3, 300, 40]” 的三通道特征输入，并对其进行数据增强；

（2）将增强后的三通道语谱图输入到带有残差结构和空洞卷积结构的卷积模块获得高维特征；

（3）将步骤（2）获得的高维特征在改变形状后，输入到双向门控神经网络中进一步提取与时序相关的特征；

（4）利用自适应时频注意力机制模块在时频域内提取有利于情感分类的特征以生成显著性情感特征分布；

（5）联合交叉熵损失函数与中心损失函数反向传播迭代更新所提出模型的参数，完成语音情感识别研究。

3.3 基于自适应时频注意力残差卷积循环神经网络

3.3.1 三通道语谱图的特征提取

“短时傅里叶分析”是利用语音信号提取语谱图过程中重要的一环。由于语音信号在时间上为连续信号，所以其特征参数会随时间不断变化，因此无法对其使用平稳连续信号的方式进行处理，由于声音是通过声门的细小震动所产生的，其振荡频率对原始语音频率而言十分缓慢，所以可以认为语音信号在短时间内是平稳的。因此首先需要对语音信号进行短时分析，主要手段为分帧、加窗，使用滑动窗口有效避免了信号两端信息突变为 0 的情况，同时采用重叠的方法，即窗函数每次滑动帧长的 1/2 或 1/3，实际帧长减去重叠部分称为帧移，通常情况下选择汉明窗作为窗函数进行短时分析，如公式(3-1)所示。

$$h(n) = \begin{cases} 0.54 - 0.46 \cos\left[\frac{2\pi n}{N-1}\right] & 0 \leq n \leq N-1 \\ 0 & \text{其他} \end{cases} \quad (3-1)$$

其中窗口大小为 N ，作用于帧 $h(n)$ ，受卷积神经网络及其不同变体在图像分类方面取得巨大成就等启发，本小节从图像领域中获得一些成功的经验应用在语音情感识别中，大量研究表明 Mel-scale 更适合人类的听觉特性，在 1000Hz 以下呈现线性分布，在 1000Hz 以上则呈现对数增长，并且在低频条件更具备辨别能力，在高频中辨别能力则有所减弱，利用这一特性将对数梅尔倒谱图最为模型的输入之一，梅尔倒谱与频率之间的关系如公式(3-2)所示。

$$f_{mel} = 2595 \cdot \lg\left(1 + \frac{f}{700}\right) \quad (3-2)$$

在 16kHz 采样率的状态下，本小节采用 40 个滤波器来处理原始情感语音信号；FFT 参数被设置为 512；窗函数使用汉明窗；窗长为 25 毫秒；帧移为 10 毫秒，在信号进入滤波器组之前，为了消除杂音等与情感信息无关的信号，过滤掉频率小于 300Hz 以及频率大于 8000Hz 的帧，将信号处理完之后，利用公式(3-3)得到滤波器组 $H_m(k)$ 。

$$H_m(k) = \begin{cases} \frac{k - f(m-1)}{f(m) - f(m-1)} & f(m-1) \leq k \leq f(m) \\ \frac{f(m+1) - k}{f(m+1) - f(m)} & f(m) \leq k \leq f(m+1) \\ 0 & \text{其他} \end{cases} \quad (3-3)$$

然后将滤波器组应用于信号的能量谱之后如公式(3-4)所示, 得到对数梅尔倒谱, 即语谱图。

$$\text{Log_MelSpec}(m) = \sum_{k=f(m-1)}^{f(m+1)} \log(H_m(k) * |X(k)|^2) \quad (3-4)$$

其中 $|X(k)|^2$ 表示第 k 个采样点的能量; m 代表滤波器的数量; k 是FFT参数的值。为了充分体现语音信号中相邻帧之间的动态联系, 通过对数语谱图来计算其 δ 和 $\delta\delta$ 的值, 即原始对数语谱图作为其中一维输入, 与所计算的 δ 和 $\delta\delta$ 对数语谱图共同组成三维输入, 称之为三通道语谱图(3D语谱图), 在输入数据预处理阶段就被赋予相比于单个语谱图更多的时域信息, 后续模型在此基础上就能提取到更多的情感信息, 如公式(3-5)和公式(3-6)所示。

$$L_M(m)^d = \frac{\sum_{n=1}^N n(L_M(m)_{t+n} - L_M(m)_{t-n})}{2 \sum_{n=1}^N n^2} \quad (3-5)$$

$$L_M(m)^{dd} = \frac{\sum_{n=1}^N n(L_M(m)^d_{t+n} - L_M(m)^d_{t-n})}{2 \sum_{n=1}^N n^2} \quad (3-6)$$

其中 t 表示语音信号帧的数量; N 通常情况下被设置为2; L_M 是对数频谱图的缩写, 最终得到了带 δ 和 $\delta\delta$ 对数语谱图的三个通道的特征(初始特征的通道数即为3), 即 $X \in R^{c,t,f}$, 作为后续卷积神经网络的输入。此外, 在一般情况下, 3秒的语音信号已经能够完整描述情感状态, 利用FFT生成的对数语谱图中时序长度设置为300, 因此最终模型输入为“[3, 300, 40]”。为了统一网络模型的输入, 本小节采用截取补零的方式在模型训练过程中统一输入特征形状, 其中当时序长度超过300时, 将当前长度与300作差, 然后随机在0到差值之间取一个值作为样本的开始时间, 往后延300即为一个情感样本语谱图; 当时序长度小于300时, 则在样本的前后进行零填充, 通过以上方式得到了统一形状的输出特征图, 方便于模型进行并行训练, 三通道语谱图如图3.2所示。

在将语谱图输入到深度神经网络之前, 对语谱图中频域维度(即滤波器组维度)进行归一化是必不可少的, 这是因为情绪在不同频域下的分布不一致, 归一化使得网络学习的参数权重更平滑可靠, 同时也避免了因特征分布差异过大在卷积层中累积过大方差导致梯度爆炸, 得到归一化后的特征后, 对其进行特征增强也是对模型整体的又一大帮助, 在提升模型识别精度的同时, 也增强了模型自身的鲁棒性和泛化性。




图3.2 在四种情感信号下的波形图以及三通道语谱图表示

Figure 3.2 Waveform Diagram and 3-channel Spectrogram Representation under Four Emotional Signals

在以前 SER 的工作中已经显示了使用数据增强的益处^[120-122], 因此, 为了提升模型对数据的敏感度, 在准备输入特征的最后阶段应用 SpecAugment 算法来对语谱图进行数据增强。SpecAugment^[123]通过以在频域和时域进行掩蔽 (Mask) 的方式进行数据增强, 直接作用于对数语谱图。具体来说, 在频域中, 从连续的 f 个梅尔 (Mel) 频段中随机选择并掩蔽 $[f_b, f_b + f]$, 其中 f 是从 0 到所设定的频率掩蔽参数的均匀分布, 而 f_b 是从 $[0, F - f]$ 中选择的, F 是梅尔频段的数量。时域掩蔽与频域掩蔽类似, 它是在时域中进行应用, 目的是提高模型对情感语音片段时频域失真的鲁棒性。值得注意的是, 为了提高模型的稳定性及对样本的适应性, SpecAugment 算法作用在语谱图的不同位置, 最终得到了受数据增强并归一化的 3D 语谱图并将其输入到后续模型当中, 数据增强如图 3.3 所示。



图3.3 对数语谱图 Log_Melspectrogram 的 SpecAugment 数据增强

Figure3.3 SpecAugment Data Augmentation for Log_Melspectrogram

3.3.2 残差卷积神经网络模块

利用前馈神经网络（DNNs）来处理语谱图有以下几点不足：1）会丢失相邻时域与频域之间的联系，造成信息损失；2）参数过多浪费计算资源；3）容易造成过拟合导致识别精度降低。针对上述问题，在对原始语音信号应用 3.3.1 小节所提出的特征工程而得到三通道语谱图后，将其输入到本小节所设计的卷积模块中。在此之前，首先来简单介绍以下卷积神经网络（CNN），CNN 是一种前馈神经网络，它是由一个或多个卷积层和顶端的全连接层组成，同时也包括池化层^[124]，这一结构能够利用输入数据的二维结构，例如可有效从二维语谱图中提取到与时频域相关特征。相比于前馈神经网络，CNNs 需要考虑的参数更少，且能利用自身卷积核通过滑动将其与对应的语谱图执行乘积并求和运算，以将感受野内的信息投影到特征图中的一个元素，最终使情感信息集中在通道维度上。有研究表明由卷积神经网络提取到的高维特征更具有概括性、判别性和语境性^[72, 74]。特征在输入到卷积层后可以产生一组特征图（feature map），它通过在输入特征上滑动不同的卷积核并执行一定的运算而组成。此外，在每个滑动位置上，卷积核与输入语谱图之间会执行一个元素对应乘积并求和的运算以将感受野内的信息投影到语谱图中的一个元素，滑动的过程称为步长（Stride），也是卷积层控制输出特征尺寸的影响因素之一。值得注意的是，卷积核的尺寸要比语谱图小的多，通常状态下，卷积核在语谱图中平行滑动，并通过卷积计算得到输出特征图，在卷积的过程中实现了权重（Weight）和偏置项（Bias）共享。

卷积层的意义在于可以起到滤波器的作用，网络会使滤波器学习到当它看到某些类型的符合人耳听觉特征时就激活，并能捕捉到信号的强弱、波动等，在处理语谱图时，让每个神经元只与输入特征的一个局部区域相连接，其连接的空间大小就叫做神经元的感受野，由卷积核的尺寸决定，并在深度方向上，这个连接的大小总是和输入特征的深度（三通道语谱图深度为 3）相等，不同的感受野感受到的时频特征区域是不同的，感受野的值越大表示其能接触到的特征范围就越大，也意味着它可能蕴含更为全局、语义层次更高的特征；而值越小则表示其所包含的特征越趋向于局部和细节，因此为了在特征提取过程中捕获充足的情感特征信息，本小节在卷积模块浅层，利用感受野大小不同的空洞卷积网络和普通卷积网络共同提取语谱图，并将二者输出在深度维度上进行拼接，在相对减少计算量的同时，以此获得大量有价值的信息，空洞卷积层如图 3.4 所示。




图3.4 空洞卷积方式示意图

Figure 3.4 Schematic Diagram of the Dilated Convolutional Layer

空洞卷积层，也叫膨胀卷积或者扩张卷积，通过引入扩展率（Dilation Rate），使得同样尺寸的卷积核获得更大的感受野，同时也使得在相同感受野大小的前提下，空洞卷积比普通卷积的参数量更少。在特征提取过程中，通常增大感受野的方式是使用卷积或者池化操作减小时频特征尺寸，但这种下采样的操作会导致特征细节被丢失，而空洞卷积在一定程度上解决了这一问题。空洞卷积是通过在其卷积核中的尺寸之间填充 0，实现在扩大感受野的同时从语谱图中捕捉多尺度范围内的特征信息；普通卷积层是从语谱图中捕捉相邻时间与频率之间的局部特征信息，将两者提取到的特征在深度维度上进行拼接得到新特征，再输入到后续卷积层中。虽然空洞卷积有上述优点，但在实际使用过程中对模型结构不好优化，且影响收敛速度，所以本小节只在卷积模块的浅层阶段使用空洞卷积，整个模型结构参数设置如表 3.1 所示。

表3.1 整个卷积神经网络模块的参数配置

Table 3.1 Parameter Configuration of the Entire Convolutional Neural Network Module

CNN 模块					
模块	输入通道	输出通道	卷积核	步幅	填充
Conv1	3	16	(3,3)	(1,1)	(1,1)
Dilated Conv1	3	16	(3,3)	(1,1)	(2,2)
Conv2	32	32	(3,3)	(1,1)	(1,1)
Pool1	32	32	-	(2,2)	-
Conv3_1	32	64	(3,3)	(1,1)	(1,1)
Conv3_2	64	64	(3,3)	(1,1)	(1,1)
Pool2	64	64	-	(1,2)	-
Conv4_1	64	128	(3,3)	(1,1)	(1,1)
Conv4_2	128	128	(3,3)	(1,1)	(1,1)
Skip_Conv5	32	128	(3,3)	(1,1)	(1,1)
Skip_Pool3	128	128	(1,4)	(1,1)	(0,0)

在获得由空洞卷积和普通卷积沿通道维度拼接的特征后，输入到一个输入和输出深度相同的卷积层中，目的是整合两类卷积层的输出以映射成更好的特征分布。然后再输入到本小节所设计的卷积区域当中，该区域包含两层卷积层、一个激活函数层、一个批归一化层以及二维最大池化层，整个区域结构如图 3.5 所示。



图3.5 卷积区域流程图

Figure 3.5 Convolution Module Area Flow Chart

其中卷积层中常用参数包含卷积核的尺寸（kernel_size）、步幅（stride）、以及填充范围（padding），激活函数层在整个结构中必不可少，这是因为数据的分布绝大多数是非线性的，而一般神经网络的计算是线性的，引入激活函数，是在网络中注入非线性，达到强化网络学习能力的目的。通常情况下，ReLU 函数是针对 Sigmoid 和 Tanh 的饱和性提出的新激活函数，如图 3-6（a）所示，当 $x > 0$ 的时候，不存在饱和问题，所以 ReLU 能够在 $x > 0$ 的时候保持梯度不衰减，从而缓解梯度消失问题，然而随着训练的推进，部分输入会落入硬饱和区（即 $x < 0$ 的区域），导致权重无法更新，这种现象称为“神经元死亡”，会影响网络的收敛性。因此，针对 $x < 0$ 的硬饱和问题，本小节使用 Leaky_ReLU 激活函数来代替普通 ReLU，即在 $x < 0$ 部分添加一个参数 α ，如 3-6（b）所示。




图3.6 两种不同激活函数示意图

Figure 3.6 Schematic Diagram of Two Different Activation Functions

然后将激活后的特征输入到批归一化层中，如公式(3-7)所示。

$$Z_i = BN(z_i) = \gamma \left(\frac{z_i - \mu}{\sqrt{\sigma^2 + \varepsilon}} \right) + \beta \quad (3-7)$$

其中 z_i 表示特征图中第 i 个特征, μ 和 σ 分别表示均值和方差, γ 和 β 是可学习参数, ε 为一个极小的数以防止分母为零, 批归一化层的添加作用是防止在训练过程中出现梯度弥散, 同时加快收敛速度。

随着网络层数的增加, 网络会发生退化现象, 越来越容易陷入局部最优, 甚至会产生梯度消失问题, 利用残差网络, 也称为跳步连接可有效解决上述问题, 该结构可有效简化特征学习过程, 增强了梯度传播以及网络模型的泛化能力, 值得注意的是, 在深层卷积区域的最后一个激活函数层, 应将其放在跳步连接输出之后, 即将跳步连接的输出与主干卷积神经网络的输出相加后再送入激活函数层, 整个残差网络结构如图 3.7 所示。




图3.7 残差网络结构示意图

Figure 3.7 Schematic Diagram of Residual Network Structure

此外, 在训练本章提出的网络之前还需要注意的是, 参数初始化问题, 合理的权重初始化将决定模型是否收敛, 如果权重过小, 那么输入层的信息将随着网络的深入而逐渐消失, 同样如果输入层的权重过大, 导致到激活层这里的输入值过大, 梯度接近饱和, 模型同样学习不到有价值的信息。因此需要一种权重初始化手段, 使得输入、输出的方差保持不变, Xavier 正态分布初始化方法应运而生, 参数由均值为 0 和标准差的正态分布产生, 标准差如公式(3-8)所示。

$$W^{[l]} \sim N(\mu=0, \sigma^2 = \frac{1}{n^{[l-1]}}) \quad (3-8)$$

$$b^{[l]} = 0 \quad (3-9)$$

其中 $n^{[l-1]}$ 是第 $l-1$ 层的神经元的个数。初始权值 W 可以从均值 $\mu=0$, 方差为 $\sigma^2 = \frac{1}{n^{[l-1]}}$ 的正态分布中随机选取, 此外, Xavier 初始化方法可帮助模型提升训练速度和分类性能。

3.3.3 自适应时频注意力机制模块

在得到卷积模块所输出的高维特征之后，为了从中提取与时序相关特征，将频域维度与深度维度相乘重塑构成特征维度，形状如 “[Batch_size, Time_steps, Feature_dim]” 的三维张量（保留时域维度），输入到由双向门控循环单元神经网络（BiGRUs）结构构成循环模块中，之后将提取到高维特征再输入到自适应时频注意力机制模块中进一步提取显著性特征，以生成情感特征分布。以下将详细介绍这两个模块。

（1）双向门控循环单元神经网络

门控循环单元（GRU）是循环神经网络的变体^[125]，引入门控机制有选择地记住或遗忘信息来完成与时序相关的情感特征提取，目的与长短时记忆网络（LSTM）一样，在保留长期序列信息的同时，减少梯度消失问题，而与 LSTM 网络不同的是，在其结构中每个隐层减少了几何矩阵相乘，从而相对加快了训练速度。GRU 包括两个输入和两个输出，并且只有两个门分别是更新门（Update Gate）与重置门（Reset Gate），引入门控机制的特殊之处在于，所保存的长序列中的信息不会随时间而清除，或因与预测不相关而移除，整体结构如图 3.8 所示。




图3.8 门控循环单元结构图

Figure 3.8 Structure diagram of GRUs

假定当前的情感特征表征为 x_t ，上一个时间结点传递下来的隐藏状态（hidden state） h_{t-1} ，该状态包含了之前时间步的相关信息，结合 x_t 和 h_{t-1} ，GRU 会得到当前隐藏结点的输出和传递给下一个结点的隐藏状态 h_t 。与 LSTM 网络结构不同，GRU 将输入门、遗忘门、输出门变为两个门，分别是更新门（Update Gate） z_t 和重置门（Reset Gate） r_t ，其中更新门如公式(3-10)所示。

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t]) \quad (3-10)$$

其中 x_t 为第 t 个时间步的输入向量， W_z 为更新门的权重，其中包括 x_t 和 h_{t-1} 的权重，更新门将当前输入 x_t 和上一个时间步的隐藏状态信息相加并投入到 Sigmoid 激活函数

中使结果保持在 0 到 1 之间，重置门主要决定了到底有多少过去的信息需要遗忘，如公式(3-11)所示。

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t]) \quad (3-11)$$

其中 W_r 为重置门的权重包括 x_t 和 h_{t-1} 的权重，和更新门的运算方法一致，在经过一个线性变换后，再相加投入 Sigmoid 激活函数以得到激活值，然后利用重置门存储与过去时间步相关的情感信息，如公式(3-12)所示。

$$\tilde{h}_t = \text{Tanh}(W \cdot [r_t \circ h_{t-1}, x_t]) \quad (3-12)$$

‘ $\circ$ ’为 Hadamard 乘积，即重置门的输入 r_t 与上一时间点传递下来的隐藏状态 h_{t-1} 进行附带相应权重的对应元素乘积，因为前面计算的重置门是一个由 0 到 1 组成的向量，它会衡量门控开启的大小，如果某个元素的门控值为 0，即表示该元素上的信息完全被遗忘掉；Hadamard 乘积（点积）将确定所要保留与遗忘的之前时间步信息，将这两部分的计算结果相加之后投入到双曲正切激活函数中（Tanh 激活函数），最后由更新门接收当前的记忆内容以及上一个时间结点 h_{t-1} 中需要收集的信息是什么，如公式(3-13)所示。

$$h = (1 - z_t) \circ h_{t-1} + z_t \circ \tilde{h}_t \quad (3-13)$$

其中 z_t 为更新门的输出激活结果，它同样以门控的形式控制了信息的流入； z_t 与 h_{t-1} 的点积结果表示前一时间步保留到最终记忆的情感信息，该信息加上当前记忆保留至最终记忆的信息就等于 GRU 网络的最终输出结果。从以上 GRU 网络处理情感特征的公式可以总结出，GRUs 不会随时间而隐藏以前的信息，它会对之前时间步产生的有价值的信息传递到下一个单元，在避免梯度消失的同时，效率也比 LSTM 网络要高。

与 BiLSTM 结构类似，GRUs 对当前时间结点的未来时间步敏感性不强，因此本小节在此基础上应用 BiGRUs，能够利用当前时间结点的前后两个方向的信息，针对情感信息和信号之间的顺序依赖关系进行建模，将正向时间序列的在 GRUs 网络的输出与反向 GRUs 网络的输出相连接得到 BiGRUs 的最终输出进而提取到与时序紧密相关的情感特征，并将其作为后续自适应时频注意力机制模块的输入。

（2）自适应时频域注意力机制模块

从上一小节 BiGRUs 模型结构获得了输出特征 $h_t = [\vec{h}_t, \overleftarrow{h}_t]$ 之后，接下来的目标是使用注意力机制来关注重要的特征并抑制无关的特征，来获取高维特征中显著性特征分布实现语音情感识别。本小节提出了一个自适应时频注意力机制模块实现这一目标，自适应时频域注意力机制（Temporal-Frequency Domain Attention, TFDA）是一种分别在时间维度和频域维度上的注意力机制，其中利用卷积运算将时频域信息融合在一起，

该结构从 h_t 的两个主要维度时间维度（Time_steps，时域）和特征维度（Feature_dim，频域）上生成更有利于情感识别的情感显著性特征分布，如图 3.9 所示。




图3.9 自适应时频注意力机制模块 TFDA 全方位框架示意图

Figure 3.9 Schematic Diagram of the Overall Framework of the TFDA Block

整个结构过程的详细描述如表 3.2 所示:

表3.2 自适应时频注意力机制模块算法图

Table 3.2 Algorithm of Time-Frequency Domain Attention Mechanism

自适应时频注意力机制模块

输入：样本特征表征 h_t ，形状 “[Batch_size, Time_steps, Feature_dim]”

输出：样本情感类别特征分布，形状 “[Batch_size, c]”。

1.将初始输入 h_t 分别通过自适应一维最大池化层和一维平均池化层（注：“（）”里为层内参数，“[]”参与层间运算）

$$h_{t_max} = \text{AdaptiveMaxPool1d}(1)[h_t]$$

$$h_{t_mean} = \text{AdaptiveMeanPool1d}(1)[h_t]$$

2.将 h_{t_max} 送入到两层一维卷积中（Conv1D），其中Reduction为减少率

$$\text{max_out_c} = \text{ReLU}(\text{Conv1D}(\text{Feature_dim}, \text{Feature_dim} // \text{Reduction})[h_{t_max}])$$

$$\text{max_out_c} = \text{Conv1D}(\text{Feature_dim} // \text{Reduction}, \text{Feature_dim})[\text{max_out_c}]$$

3.将 h_{t_mean} 送入到两层一维卷积中，过程与步骤2保持一致，最终得到 mean_out_c

4.将 max_out_c 与 mean_out_c 相加后，送入到Sigmoid激活函数中

$$f_output = \text{Sigmoid}(\text{max_out_c} + \text{mean_out_c})$$

5.将原始输入 h_t 与 f_output 相乘得到 Fre_output ，两者形状一致

$$\text{Fre_output} = h_t * f_output$$

6.分别将 Fre_output 在 Feature_dim 维度上求最大值和均值，并保留 Feature_dim 维度

$$\text{max_Fre} = \text{Max}(\text{Fre_output})$$

$$\text{mean_Fre} = \text{Mean}(\text{Fre_output})$$

7.将 max_Fre 与 mean_Fre 在 Feature_dim 维度合并传入一个一维卷积层

$$t_output = \text{Conv1D}(2, 1)[\text{Cat}(\text{max_Fre}, \text{mean_Fre})]$$

8.将 t_output 送入到Sigmoid激活函数中

$$\text{Tem_output} = \text{Sigmoid}(t_output)$$

9.将 Fre_output 与 Tem_output 相乘

$$h_{t_TFDA} = \text{Fre_output} * \text{Tem_output}$$

10.利用下式注意力结构对 h_{t_TFDA} 消除时间维度，得到最优 Feature_dim ，即 c ：

$$\alpha_t = \frac{\exp(W \cdot h_{t_TFDA})}{\sum_{t=1}^T \exp(W \cdot h_{t_TFDA})}$$

$$c = \sum_{t=1}^T \alpha_t \cdot h_{t_TFDA}$$

通过步骤 1-5 实现对频域注意力的获取，其中步骤 2 中的两层一维卷积层参数是共享的，将其中卷积层的输出特征进行基于逐个元素的（element-wise）加和操作，经过 Sigmoid 激活函数后，使 f_output 和 h_t 做点乘操作，生成带有频域注意力的高维特征。然后将其输入到时域维度注意力机制部分，并通过步骤 6-9 以捕获时域维度注意力。最终生成带有自适应时频注意力的高维特征，该轻量级结构具有较强的通用性和可解释性，针对 BiGRUs 网络的输出中时频两个维度分别做注意力机制，先频域再时域，有效帮助高维特征将注意力集中在那些有利于情感识别的特征区域中，为提高模型精度及分类效果做出巨大贡献，最后通过步骤 10 将时间维度信息融合到特征维度中，以生成显著性情感特征分布实现语音情感识别，模型参数如表 3.3 所示。

表3.3 模型参数配置以及输入输出形状表示

Table 3.3 Model Parameter Configuration and Input and Output Shape Representation

模块（层）	参数	输入	输出
卷积模块	128 通道数	[b_s,3,300,40]	[b_s,128,150,5]
重塑（Reshape）	—	[b_s,128,150,5]	[b_s,150,640]
循环模块	128	[b_s,150,640]	[b_s,150,256]
自适应时频注意力模块	Reduction:8	[b_s,150,256]	[b_s,256]
全连接层	(256, 64)=>(64, 4)	[b_s,256]	[b_s,4]

表中“4”表示最终情感分类类别数量。

3.3.4 损失函数

与上一章模型对输出的处理一样，将模型输出与经过 one hot 编码之后的真实标签共同送入到损失函数中，得到最终的情感识别结果，损失函数是衡量计算预测与实际值的偏差程度的数学方程，较高的损失值表明模型出现了重大错误，相反较低损失值意味着预测相当准确。目标是尽可能减少损失函数产生的偏差，模型利用损失函数学习参数，包括权重和偏差，由于参数的权重更新方程具有损失函数关于权重或偏差的一阶导数，因此该函数的行为将对梯度下降过程中产生重大影响。常用的损失函数为交叉熵损失函数（Cross Entropy, CE），交叉熵损失函数的优势在于当误差大的时候，权重更新快；而当误差小的时候，权重更新慢，然而劣势在于随着分类数目的增多，分类层的线性变换矩阵参数也随之增大，另外它采用了类间竞争机制，只关心对于正确标签预测概率的准确性，忽略了其他非正确标签的差异，导致学习到的特征比较散。针对上述交叉熵损失函数的劣势，本小节在此基础上做出改进，引入中心损失函数（Center Loss）^[126]，以与交叉熵损失函数相结合的方式对偏差进行优化，中心损失函

数最早开发应用在非封闭训练集人脸识别中，这与语音情感识别独立说话人实验很相似，都是在训练过程中见不到测试集中说话人的任何情感样本，利用两者损失函数所带来的优势提出了以相结合方式来解决语音情感识别问题，中心损失的意思为每一个类别提供一个类别中心，以达到缩小类内距离的目的，如公式(3-14)所示。

$$L_c = \frac{1}{2} \sum_{i=1}^m \|x_i - c_{y_i}\|_2^2 \quad (3-14)$$

c_{y_i} 就是每个 batch 中每个样本对应的类别中心，它和模型输出最终的特征 x_i 的维度一样。训练过程是交叉熵损失结合中心损失进行联合训练的，其中中心损失函数的权重为 λ ，如公式(3-15)所示。

$$L = L_{CE} + \lambda L_c = - \sum_{i=1}^m \log \frac{e^{w_{y_i}^T x_i + b_{y_i}}}{\sum_{j=1}^n e^{w_j^T x_i + b_j}} + \frac{\lambda}{2} \sum_{i=1}^m \|x_i - c_{y_i}\|_2^2 \quad (3-15)$$

中心损失帮助交叉熵损失对训练集的每个类别在特征空间分别维护了一个类中心，增加样本经过网络映射特征空间与类中心的距离约束，从而兼顾了类内聚合与类间分离， λ 在设置上值越大，类内间距就越小，中心损失函数占的比重就越大，但并不是值越大识别结果越好，因为在训练过程中有可能将预测错误的样本（在高兴和中性情感的识别上）分给其他类别，根据混合损失的特征，反而较难将该样本拉回到正确类别上，因此选择一个合适 λ 的值，在分类任务效果才会有所提升。虽然增加了模型的计算量，以在计算资源允许的情况下，以空间换时间，提升模型的收敛速度与分类精度，此外，不同的 λ 值对与模型的影响较大，通常在语音情感识别任务中， λ 的值为 0.1 时，模型准确率获得较大提升，随着 λ 值的增大，模型的平均召回率反而不如交叉熵损失函数，这是因为情感的分布错综复杂，比如在上一章已经分析过高兴情感与中性情感分布比较接近，在模型训练的初期，一些样本已经被判断为负样本，而含较大比重的中心损失只会将负样本在特征分布中与正样本中心的距离愈拉愈远，反而造成较低的识别率，因此本章采用的损失函数以交叉熵损失函数为主，中心损失函数为辅的设计。

3.4 实验描述及结果分析

本章从语音信号处理、特征提取及注意力机制设计等角度，提出了基于自适应时频注意力残差卷积循环神经网络（ARCRNN）的语音情感识别算法，使用两个公共数据集 IEMOCAP 和 EMODB，以及在第二章提出的 CID 数据上进行综合实验，以验证所提出模型结构的有效性和泛化性，包括一系列消融实验，以证明模型结构中每个组

成模块的有效性,实验结果均通过双尾 T 检验证明其准确性,本章的模型依然使用 Pytorch 开源深度学习框架实现,所有实验均在 NVIDIA GTX 3090 GPU 单卡上运行。

3.4.1 实验准备

本章实验使用 IEMOCAP 交互式数据集、EMODB 表演式数据集以及第二章设计的 CID 数据集来对所提出算法的有效性进行详细验证,三个数据集分别利用留一十折交叉验证来进行独立说话人实验(Leave-one-speaker-out)和依赖说话人实验(Leave-10%Data-out),评价指标选择未加权平均召回率(UAR)、准确率和混淆矩阵。值得注意的是实验实施细则有很大不同,本章在 IEMOCAP 数据集中使用的基于自适应时频注意力残差卷积循环神经网络是从零开始训练的,使用 Adam 算法作为优化器,学习率设置为 $3e-5$,用于计算梯度及其平方的平均值系数 betas 设置为 $(0.9, 0.999)$,权重衰减设置为 0,数值稳定性参数设置为 $1e-8$,batch_size 大小设置为 32,在训练阶段 Epoch 设置为 200。由于本章提出的模型相比上一章利用声学特征进行情感分类的模型,模型复杂度更高,而 EMODB 数据集和 CID 数据集上分别仅有 535 个样本和 960 个样本,当利用小数据集从零训练开始训练本章所提出的较大模型时,非常容易造成过拟合,造成识别结果偏低,甚至导致模型不收敛,所以针对上述问题,本小节利用预训练模型学习算法将在 IEMOCAP 数据集上训练出的最优模型在 EMODB 和 CID 数据集上进行全局微调(Global Finetune),实验 Epoch 设置为 100,微调学习率设置为 $1e-5$ 。

迁移学习(Transfer Learning)的一个分支就是把已训练好的模型参数迁移到新的数据集上来,基于预训练模型以适应新数据集的研究任务^[127, 128],考虑到情感任务存在相关性,所以通过迁移学习可以将大数据集下的预训练模型应用在数据量较小的数据集任务中,以获取初始情感特征分布,不需要从零开始训练而避免陷入局部最优,并且使得训练成本大大下降,由于 EMODB 和 CID 数据集样本量较少且和 IEMOCAP 数据集同为情感类别数据集^[129],因此在训练 EMODB 和 CID 数据时使用预训练模型以及全局微调技术可有效提升模型在低样本量数据集上的准确率。

3.4.2 实验结果与分析

本章将从原始信号中采用截取补零的方式将信号长度设置为 3 秒,在模型训练阶段,每个 3 秒长的子段均参与训练并预测一个情感,子段标签与句子标签共享,而在测试阶段,则针对每个子段的后验概率应用最大池化来评估整个句子样本,当后验概

率最高的那个标签与整句标签一致时，则认为所提出的模型对该句子样本预测成功，各个数据集所选择的评价指标与第二章保持一致。

(1) IEMOCAP 数据集的实验结果

本章所提出的自适应时频注意力残差网络模型在独立说话人实验中与其他方法在 IEMOCAP 数据集上的比较结果如表 3.4 所示。

表3.4 自适应时频注意力残差网络模型在 IEMOCAP 数据集上与其它方法的比较

Table 3.4 Comparison of the ARCRNN Model with Other Methods on the IEMOCAP

研究	特征	算法	平均召回率
Ghosh et.al ^[130]	语谱图	DAE+BiLSTM	51.86%
Latif et.al ^[74]		CNN+LSTM	60.23%
Bhosale et.al ^[75]		ACNN	63.15%
Yao et.al ^[131]		DNN	61.8%
Neumann et.al ^[132]		ACNN	59.54%
AWPRNN (第 2 章)	小波包帧级特征	AWPRNN	62.15%
本章	3D 语谱图	ARCRNN	64.36%

从表 3.4 可以看出，本章所提出算法取得的实验结果最优，未加权平均召回率为 64.36%，与第二章提出的基于小波包重构特征自适应注意力网络模型相比较，平均召回率提升了约 2.2%，证明了本章提出算法模型的优越性和有效性，ARCRNN 模型利用在时频域建立空间联系的三通道语谱图完成语音情感识别，这比声学特征更加稳定，此外模型中利用所设计的卷积模块、循环模块以及注意力模块相比于其他研究的模型结构，可以提取到更有利于情感识别的显著性特征分布，所以识别精度要比其他研究要好，整个结构也更加灵活可控，其中独立说话人实验混淆矩阵如图 3.10 所示。




图3.10 IEMOCAP 数据集独立说话人实验混淆矩阵

Figure 3.10 Confusion Matrix of Speaker-independent Experiment on IEMOCAP

从图 3.10 的混淆矩阵中可以看出,提升主要体现在对中性情感的分类中,利用 ARCRNN 模型处理 3D 语谱图可有效减少愤怒、悲伤和高兴被误分类成中性,这是因为本章算法能够学习到可区别于中性情感的特征分布,从而导致平均召回率的提升,并且在高兴情感状态下也获得了明显的优势,获得了 55.62%的平均召回率,相对比与其他研究在高兴情感识别平均召回率要好很多^[75],而在愤怒、悲伤和中性情感上分别取得 66.73%、72.32%和 62.76%的实验表现,与 Chen^[108]等人的研究对比,在高兴情感识别中有较大的平均召回率提升。为了进一步验证模型的有效性,本章同时也在 IEMOCAP 数据上做了依赖说话人实验。

IEMOCAP 数据集中依赖说话人实验在上述实验条件下获得了 68.23%平均召回率的情感识别结果,其中愤怒情感的识别结果为 73.26%,与其他研究^[133]对比,有较大提升,然后悲伤、高兴和中性情感分别获得 75.81%、58.72%和 65.14%的识别平均召回率。综上,无论是独立说话人实验还是依赖说话人实验,其中高兴情感的平均召回率依然较低,归其原因主要是因为高兴情感的特征分布与中性情感的特征分布近似,此外数据量的不足也可能导致网络无法通过足够的数据来学习两者情感之间的差异性,从实际应用上看,高兴情感的特征如果在不依靠语言的帮助下很容易被误认为成其他情绪。

(2) EMODB 数据集的实验结果

由于受 EMODB 数据集中样本数量的限制,大多数研究往往更关注该数据集下依赖说话人实验,已验证自身所提出方法的有效性,且往往选择准确率作为评判模型有效性的标准,因此所提出的算法模型与其他研究在 EMODB 数据集上的比较结果如表 3.5 所示。

表3.5 自适应时频注意力残差网络模型在 EMODB 数据集上与其它方法的比较

Table 3.5 Comparison of the ARCRNN Model with Other Methods on the EMODB

研究	特征	算法	准确率
Kerkeni et.al ^[60]	谱特征和 MFCC	RNN	83%
Tiwari et.al ^[134]	HLDs 特征和 LLDs 特征	DNN	82.73%
Badshah et.al ^[124]	语谱图	CNN	85.5%
Chauhan et.al ^[135]	语谱图	CNN	84.61%
本章	3D 语谱图	ARCRNN	85.42%

从表 3.5 可以看出,本章在 EMODB 上的准确率评价指标依然为最优,为 85.42%,与上一章相比有一定程度的提升,这是因为 EMODB 所用的模型是从已经训练好的预训练最佳模型中的全局微调过来的,其中 EMODB 数据集有 80%样本参与训练,在

EMODB 训练网络之前，模型各个模块已经获得更适合于情感分类的特征分布，而上一章的算法仅仅使用帧级声学特征从零开始训练的（初始参数分布为正态分布），这是造成部分差距的主要原因，相应的依赖说话人实验混淆矩阵，如图 3.11 所示。




图3.11 EMOB 数据集依赖说话人实验混淆矩阵

Figure 3.11 Confusion Matrix of Speaker-dependent Experiment on EMOB

从图 3.11 的混淆矩阵中可以看出，在依赖说话人实验中各个情感均具备很高的准确率，主要是因为数据集中的样本量较少，且无背景噪声（即无情景交互），而且表演者在录制过程中刻意模仿该情绪，所有情感均取得 70%以上的准确率，高兴情感的准确率提升了约 27%^[108]。相比于其他研究^[136]，在每个情感分类上的准确率都得到了改善，悲伤情感、中性情感、无聊情感等分别达到了 87.10%、91.14%、86.42%的准确率，与其他情感相比，高兴情感的准确率为 74.65%，依然是比较低的，有 19.72%被误分成愤怒情感，这和 IEMOCAP 数据集在高兴情感的预测趋势保持一致。分析主要原因，是由于 EMOB 库数据量较小，模型对于两种情感没有充分学习，导致二者的在特征空间的分布较为接近，从而对识别结果造成消极影响。

（3）CID 数据集的实验结果

受 CID 数据集中样本数量的限制以及多人录制条件，因此本章将重点关注该数据集下依赖说话人实验，已验证自身所提出方法的泛化性，并将平均召回率作为评价指标用以评估模型有效性，所提出的方法 ARCRNN 模型与其他方法在 CID 数据集上的比较结果如表 3.6 所示。

表3.6 自适应时频注意力残差网络模型在 CID 数据集上与其它方法的比较

Table 3.6 Comparison of the ARCRNN Model with Other Methods on the CID

研究	特征	算法	平均召回率
Badshah et.al ^[124]	语谱图	CNN	59.36%
Chen et.al ^[108]	3D 语谱图	ACRNN	61.08%
AWPRNN (第2章)	声学特征	AWPRNN	61.30%
本章	3D 语谱图	ARCRNN	66.56%

从表 3.6 可以看出, 本章在 CID 上的平均召回率评价指标依然为最优, 为 66.56%, 与上一章相比有一定程度的提升, 由于在 CID 数据上使用 IEMOCAP 数据集预训练好的模型, 因此在训练 CID 数据之前已经获得了初始情感特征分布, 进而在后续微调时, 获得较好的实验结果, 通过实验结果对比, 所提出的模型算法在情感识别任务上相对要更好, 同时从混淆矩阵上也能看出, 本章算法在高兴情感上与上一章相比有一定程度提升, 相应的依赖说话人实验混淆矩阵, 如图 3.12 所示。




图3.12 CID 数据集依赖说话人实验混淆矩阵

Figure 3.12 Confusion Matrix of Speaker-dependent Experiment on CID

从图 3.12 的混淆矩阵中可以看出, 在 CID 数据集依赖说话人实验中各个情感均显示出较高平均召回率, 和 EMODB 数据集的整体识别趋势类似, 这是由于数据集中的样本量较少且为四分类情感识别, 分析主要原因还是在于所提出算法可以有效提取到有利于情感分类的显著性特征区域, 提升了识别精度, 其中愤怒情感、悲伤情感、高兴情感以及中性情感分别达到了 75.42%、78.33%、46.67%、65.83%的平均召回率, 高兴情感的识别仍然不理想, 主要原因在于在激活度维度上高兴与愤怒情感易存在混淆, 造成识别精度降低的原因还可能情感语音样本的音频录制环境问题, 人员在表演过程中情绪控制不佳以及中英文语言差异对于情感识别产生一定的影响。

（4）性能分析

目前主流的研究大多数都使用语谱图特征作为语音情感识别模型的输入，由于移动设备的推陈出新，提供了较强的架载能力，但在实际应用同样也需要权衡内存空间与性能之间的关系，较多的可学习参数可以增强模型的学习能力，表 3.6 结合第 2 章展示了使用不同模型时所包含的可学习参数，值得注意的是，有关表 3.6 的详细实验结果与分析见下一章节 3.4.3 消融实验。

表3.7 不同模型结构的可学习参数数量

Table 3.7 Number of Learnable Parameters for Different Model Structures

模型结构	可学习参数量
AWPRNN 模型（第 2 章）	196873
ARCRNN 模型（普通卷积）	1403519
RCRNN 模型（不带注意力）	1571956
ARCRNN 模型（本章）	1588351

从表 3.7 可以看出，相比于第 2 章利用声学特征进行语音情感识别任务，使用语谱图特征的模型可学习参数增加了 7 倍，这是因为声学特征的提取依赖声学知识而不依赖于神经网络的迭代学习，所以参数较少。尽管如此，如上述结果可知，在实验识别精度的提升是可观的，以 IEMOCAP 数据集为例，提升了 2.2%识别精度。相比于普通卷积层（详见 3.4.3），本章所设计的卷积结构在牺牲小部分资源的前提下，提升了约 0.5%平均召回率，可以认为这是值得的，同理当使用本章所设计的注意力机制时，参数仅增加 16395，性能提升了 1.2%，从侧面证明所提出的自适应时频注意力机制的有效性。在实际应用中，可在中小型存储设备上采用此算法进行语音情感识别。

3.4.3 消融实验

本小节将利用消融分析进一步阐明所提出算法的有效，依然采用控制变量法的方式，基线（Baseline）为本章提出的 ARCRNN 模型，模型性能主要由以下五点决定：特征选择、空洞卷积的使用、残差网络、双向门控单元网络、自适应时频注意力机制的应用，依次替换当中的模块，然后做出分析对比，所有实验均在 IEMOCAP 数据集上进行：独立说话人实验（SI: Speaker-independent）；依赖说话人实验（SD: Speaker-dependent）。

(1) 三通道语谱图的影响

本章采用的是三通道（3D）语谱图，是由对数语谱图通过计算其 Δ 和 $\Delta\Delta$ 而得到相应的语谱图，三个语谱图通过叠加的方式共同组成了三通道的输入特征，本小节分别对单独使用原始语谱图，以及依次添加 Δ 的相应语谱图分别做出相应消融分析，如表 3.8 所示。

表3.8 在 IEMOCAP 数据集上使用不同语谱图的语音情感识别结果

Table 3.8 SER Results Using Different Spectrogram Features on the IEMOCAP dataset

特征	模型算法	IEMOCAP(SI)	IEMOCAP(SD)
语谱图 (Static)	ARCRNN 模型	63.52%	67.45%
+Delta[2D]		63.84%	68.31%
++Delta-deltas[3D]		64.36%	68.23%

从表 3.8 可以看出，本章所使用的三通道语谱图与单独使用原始对数语谱图（static）或使用 2D 语谱图相比，在独立说话人实验中最终的平均召回率中分别提升了 0.84%、0.52%，在依赖说话人实验中也呈现出相同的提升趋势，即表明了三通道语谱图可以更好的在输入端捕捉原始信号中相邻时刻间的动态信息，加强特征中的时域信息来帮助模型更好实现情感识别，证明了三通道语谱图有效性。由于独立说话人情感识别更具有应用意义，因此本章选择三通道语谱图作为模型的输入特征。

(2) 空洞卷积与普通卷积层融合的影响

针对空洞卷积层与普通卷积层的拼接，是在卷积模块的浅层构建的，即第一层采用空洞卷积层与普通卷积层分别处理语谱图并将两者输出相融合以构成新的特征，而普通卷积结构为两层卷积层的堆叠。本小节将两种不同的卷积结构处理语谱图进行实验对比，如表 3.9 所示。

表3.9 在 IEMOCAP 数据集上使用不同卷积结构的语音情感识别结果

Table 3.9 SER Results Using Different Convolutional Structures on the IEMOCAP Dataset

模型	参数配置['()'内为输入、输出通道数]	IEMOCAP(SI)	IEMOCAP(SD)
普通卷积 (单独)	Conv(3,32)+Conv(32,32)	63.82%	67.38%
空洞卷积+ 普通卷积	Conv(3,16)+Dilated Conv(3,16)	64.36%	68.23%

从表 3.9 可以看出，在模型浅层通过将空洞卷积与普通卷积相结合方式可以最大限度的扩大模型对语谱图的感受野，保留更多时域与频域之间的多尺度联系，在两类实验中最终平均召回率提升分别有 0.54%和 0.85%。值得注意的是，本小节仅在模型浅层

使用空洞卷积，这是因为随着卷积层不断叠加以提取高维特征的过程中，应用空洞卷积所获得的提升不大，并且因为受其计算过程的影响，容易造成过拟合现象。

（3）残差网络的影响

本章在所提出的卷积神经网络结构中引入残差网络，将第一个卷积区域与最后一个卷积区域构成残差连接，与不引入残差结构进行实验对比，如表 3.10 所示。

表3.10 在 IEMOCAP 数据集上是否使用残差网络结构的语音情感识别结果

Table 3.10 SER Results with or without Residual Network Structure on the IEMOCAP

模型	配置说明（有无残差结构）	IEMOCAP(SI)	IEMOCAP(SD)
ADCRN	无	63.27%	67.18%
ARCRNN	有	64.36%	68.23%

从表 3.10 可以看出，通过引入残差结构，模型在提取高维特征表征的同时对低维特征有所保留，增强了梯度传播的能力以及最重要的模型泛化能力，在两类说话人实验中分别提升了大约 1% 平均召回率。

（4）双向门控单元神经网络的影响

本章利用 BiGRUs 结构来从卷积模块输出的高维特征中进一步提取与时序相关的情感特征，本小节将 BiGRUs 结构与 BiLSTM 的结构进行对比，其中参数量指的是循环网络结构的可学习参数量，如表 3.11 所示。

表3.11 在 IEMOCAP 数据集上使用不同循环神经网络结构的语音情感识别结果

Table 3.11 SER Results Using Different RNN Structures on the IEMOCAP Dataset

模型(ARCRNN)	参数量	IEMOCAP(SI)	IEMOCAP(SD)
BiLSTM	787456	64.28%	68.30%
BiGRUs	590592	64.36%	68.23%

从表 3.11 可以看出，两种神经网络对分类准确率的影响相差无几，在独立说话人实验中 BiGRUs 平均召回率结果相对而言稍微好一些，而在依赖说话人实验中 BiLSTM 相比则显得稍优。因此在实际应用中，根据具体任务选择合适的循环神经网络结构则显得尤为重要，相比于 BiLSTM 模型结构，BiGRUs 的优势在于所使用的参数更少而较为快速的收敛。

（5）自适应时频域注意力机制模块的影响

本章所提出模型结构的最后利用注意力机制将更大的权重分配给有利于情感分类的特征区域，并实现降维以生成类别的概率分布，本小节将其与一维全局均值池化层

(GlobalAveragePooling1D) 应用在 BiGRUs 的输出之后做出对比, 此外, 在保证卷积网络以及循环网络结构提取语谱图生成高维特征不变的条件下, 添加第 2 章所提出的一维卷积自适应采样注意力机制作为对比实验, 实验结果如表 3.12 所示。

表3.12 自适应时频注意力机制模块对实验结果的影响

Table 3.12 The Influence of Temporal-Frequency Attention Mechanism Block on the Results

模型	注意力机制	IEMOCAP(SI)	IEMOCAP(SD)
RCRNN	无注意力	63.12%	66.05%
第 2 章	一维卷积自适应采样注意力	63.84%	67.48%
本章	自适应时频注意力	64.36%	68.23%

从表 3.12 可以看出, 通过引入自适应时频注意力机制模块, 模型对情感显著性特征区域的关注度更高, 分配更高权重的同时可以拉开正样本与负样本之间的概率差异, 帮助模型快速收敛的同时, 增强模型对较难分辨情感样本的敏感度, 提升模型对情感识别的准确率, 相比于仅用一维全局平均池化层来获取特征分布, 平均召回率分别在独立说人实验和依赖说话人实验中提升了 1.24%和 2.18%的平均召回率。此外, 在与第 2 章所设计的一维卷积自适应采样注意力机制结构的对比实验中, 两种实验类型结果分别提升了 0.52%和 0.75%的平均召回率, 这是因为本章提出的自适应时频注意力机制不仅仅关注高维特征中的显著性频域特征, 与时域相关的显著性特征同样也提取出来, 生成的情感特征分布包含更多的与时序相关的特征, 进而提升了实验结果, 证明了所提出自适应时频注意力机制结构的有效性。

3.5 本章小结

本章针对语音情感识别中声学特征提取以及注意力机制结构设计方面存在的问题, 提出了基于自适应时频注意力残差神经网络算法用以提升语音情感识别精度, 首先提取了将时频域局部信息结合在一起的三通道语谱图作为模型输入特征, 然后利用包含空洞卷积层和残差网络结构在内的卷积模块, 有效压缩与情感分类无关的信息并提取到有价值多尺度高维特征, 接着循环模块进一步提取与时序相关联的情感特征, 最后将特征输入到所设计的自适应时频注意力机制模块分别在时频域内生成专注于情感识别的显著性特征分布, 联合中心损失与交叉熵损失函数完成语音情感识别研究, 实验验证了所提出算法的有效性以及泛化性, 在两个公开可用的数据集 IEMOCAP 和 EMODB 上的独立说话人实验和依赖说话人实验中分别获得了 64.36%平均召回率和

85.42%准确率，在情感类别样本均衡的自设计数据集 CID 中，平均召回率和准确率均在依赖说话人实验获得了 66.56%的语音情感识别结果。

第4章 基于动态自适应空间注意力网络的语音情感识别

上一章基于语谱图提出了残差空洞卷积模块，联合循环网络模块，并设计了自适应时频注意力机制，用于获取在时频域内有利于情感识别的显著性特征分布。然而上述方法采用先后顺序分别对高维特征中的频域维度和时域维度进行显著性特征提取，忽略了在语音情感识别过程中高维特征中时频域内局部特征空间的联系，导致损失了局部空间情感信息，进而限制了识别精度的提升。此外，类别不均衡的样本特征分布，也导致部分情感类别分类困难。为了解决上述问题，进一步提升识别进度，本章提出了基于动态自适应空间注意力网络模型，利用卷积模块将语谱图映射为高维特征后，提出的动态自适应注意力网络模块对高维特征进行再提取，以生成更具判别力的显著性情感特征分布，最终在焦点损失函数的帮助下实现语音情感识别。所提出算法在三个数据集中分别进行实验，并将新冠咳嗽声检测作为扩展应用研究，增加模块消融实验，全面验证模型性能。

本章研究内容的结构安排如下：4.1节是引言；4.2节是基于动态自适应空间注意力网络的语音情感识别整体框架；4.3节对所提出方法的具体细节进行详细介绍；4.4节是实验以及结果分析；4.5节是本章小结。

4.1 引言

人们在说话过程中常常伴随着情感，情感语音信号的发声机理，是由喉咙、声门以及声道根据当时的场景或者自身情况表现不同的变化，而这些变化足以影响音频的声学效果^[115, 137]，如何有效捕捉由情感引发的声学变化，提取出更有价值的情感特征，对提升语音情感识别精度有重大研究意义。在特征提取阶段，将从原始信号中提取的语谱图作为深度学习模型的输入特征已被研究证实是可以收获良好的识别结果，并显示出非常好的应用前景^[138, 139]，这不仅仅得益于语谱图中包含大量与情感语音信号特性相关的信息，如共振峰、能量等频域参数随时间变化等特征，同时也因具有时域波形与频谱图特点的优势，作为二维特征可以被卷积神经网络进行提取以生成高维特征，在卷积网络提取特征的过程中，具体表现在通过压缩浅层特征中与情感分类无关的低级信息，并将大量情感相关信息映射到深层特征中，取得了良好的实验效果^[74, 78, 97]。由于语音存在时间连续性，有相当一部分情感特征对时间序列较为依赖，卷积层结构并不能有效捕捉情感样本中与时序信息相关的特征，而循环神经网络的出现弥补了这一缺点，配合注意力机制结构可有效提取时频域内显著性特征以获得有价值的情感特

征分布,然而这种注意力循环神经网络结构是对时域或频域单一维度特征进行加强,这一过程忽视了卷积模块所输出高维特征的二维空间属性,导致依赖于该属性的显著性情感特征丢失并对识别结果产生消极影响。这损失掉信息的物理意义可称为听觉偏差,和视觉显著性分析一样,人耳听觉同样具有显著性,比如当说话人在表达情感的时候,听众在第一次聆听的状态下无法及时捕获情感特征突出的区域,而同样一句话,观众在聆听第二次甚至多次的感受就明显与首次聆听大不相同,这种差异性通过现有注意力机制结构很难捕捉到。

针对上述问题,本章提出了一种基于动态自适应空间注意力网络模型(Dynamic Spatial Adaptive Attentive ConvLSTM Recurrent Neural Networks, DSACRNN)。首先对情感语音信号提取三通道语谱图并进行数据加强,然后利用卷积模块对语谱图提取到高维特征后,输入到动态自适应注意力机制结构中,该结构包含两个部分:1)由循环神经网络与注意力机制结构相互拼接组成,以获取对时频域沿单一维度加强后的情感特征分布(需改变高维特征形状以适应该模块);2)为高维特征扩展动态空间维度,将注意力机制嵌入到循环神经网络中对高维特征进行深度提取(不需要改变高维特征形状),以弥补听觉偏差信息从而获取基于时频二维局部空间信息的情感特征分布,最终将两部分输出的特征分布联合在一起,利用焦点损失函数实现语音情感识别。此外,本章将新冠肺炎咳嗽声检测实验作为扩展研究,以验证所提出算法的有效性和通用性。

4.2 基于动态自适应空间注意力网络的语音情感识别整体框架

图 4.1 是本章提出基于动态自适应空间注意力网络(DSACRNN)的语音情感识别框架图。首先从情感信号中提取三通道语谱图作为整体模型的输入,使用带残差结构的卷积神经网络模块处理语谱图以获得情感高维特征,然后输入到动态自适应空间注意力机制结构中,该结构包含两个部分:1)时频注意力循环模块(Temporal-Frequency Attentive LSTM, TFAL),用于捕获情感语音样本中与时序相关的高维特征并生成包含全局特征信息的显著性情感特征分布;2)空间注意力循环模块(Spatial Attentive Convolutional LSTM, SACL),用于捕获时频二维空间局部情感信息并生成包含局部空间信息的显著性情感特征分布。与 TFAL 模块不同的是, SACL 模块利用长短时记忆网络直接处理高维特征,而非处理时间序列特征,在卷积模块输出的高维特征中扩展一维空间,并在不改变高维特征形状的条件下将注意力机制嵌入到循环网络中,以构建基于空间维度的注意力机制循环网络,空间维度值表示需要更新 SACL 模块内部参数的迭代次数,通过迭代注意力机制循环网络,最终生成带有时频局部空间情感

信息的显著性特征分布，与 TFAL 结构输出的特征分布相联合，利用焦点损失函数实现语音情感识别。




图4.1 基于动态空间自适应注意力神经网络的语音情感识别模型框架图

Figure 4.1 SER Framework of the Dynamic Spatial Adaptive Attentive ConvLSTM Recurrent Neural Networks

基于动态空间自适应注意力网络模型进行语音情感识别的整体步骤如下：

- (1) 对情感语音信号提取三通道语谱图，形状大小设定：时域长度为 300 帧；滤波器数量为 40，然后对语谱图进行 SpecAugment 算法的数据增强；
- (2) 利用带残差结构的卷积神经网络对数据进行特征提取以获取高维特征；
- (3) 将步骤 (2) 输出的高维特征分别输入到时频注意力循环模块 (TFAL) 以及空间注意力循环模块 (SACL) 中获取不同类型的情感特征分布；
- (4) 将步骤 (3) 中两个模块得到的特征分布相联合，利用焦点损失函数反向传播迭代更新模型参数，实现语音情感识别。

4.3 基于动态自适应空间注意力神经网络

4.3.1 时频注意力循环模块

首先对情感语音信号提取能反映动态时间信息的三通道语谱图作为整个模型的输入特征，样本的采样频率被设置为 16kHz，滤波器数量为 40，在对语音信号进行预处理时，窗函数选择汉明窗，窗长为 30ms，帧移为 15ms，由于情感数据集在录制过程中平均时长在 3 秒左右，因此本小节将时域长度控制在 300 帧，然后在语谱图中的频域维度上进行正则化操作，以保证信息的整体分布服从正态分布，有利于模型在训练过程中学习权重以及防止梯度消失，接着利用 SpecAugment 数据增强算法对其进行增强，在加强的过程中，由于选择 3 秒的样本作为输入，因此本小节选用数据增强的尺

寸为“{40, 4, 2, 2}”，其中“{”从左到右依次是时间掩蔽宽度、频率掩蔽宽度、时间掩蔽数量和频率掩蔽数量，数据增强如图 4.2 所示。




图4.2 基于情感语音的语谱图数据增强

Figure 4.2 Data Augmentation based on Emotional Spectrogram Features

在进行完所有数据预处理后，将语谱图输入到卷积模块中，该模块包含三个卷积区域并设计了残差结构以防止网络退化，避免梯度消失，每个卷积区域中包含两层卷积层、一层批归一化层以及一层二维最大池化层以降低特征的尺寸，增大感受野，将情感信息集中在深度维度中，激活函数选择 ReLU，值得注意的是，本小节在第三层最大池化层的步幅设置时，设置为“1*2”，因为卷积模块在提取高维特征后输入到循环网络中，时域维度上时间步越长，从中提取与时序相关有价值的局部特征会增多，因此在时域上不再降维，避免损失部分与时序相关的情感信息，最大限度的保留时域信息，整个卷积模块框架图如图 4.3 所示。




图4.3 残差卷积模块框架图

Figure 4.3 Frame Diagram of Convolution Module with Residual Structure

语谱图是由 3 秒的语音信号在短时傅里叶分析中利用 40 个滤波器生成的，特征尺寸为“(300, 40)”，分别代表时域与频域。从中可以看出语谱图在时域维度上值的范围较大，远大于频域维度上的值，因此在利用卷积模块进行特征提取的过程中，在模块浅层采用“5*3”卷积核尺寸的卷积层，目的是为了提取到较大时域范围内相关的局

部特征，并将相关情感特征信息集中在深度维度上，即通道维度。随着特征深度不断增加，特征尺寸随着二维最大池化层的运用也随之变小，感受野增大，特征中所包含全局信息增多，为了避免丢失重要特征，所以在后续卷积区域中，包括残差卷积结构，均采用“3*3”卷积核尺寸，进而完成高维特征提取，卷积模块参数配置如表 4.1 所示。

表4.1 动态自适应空间注意力网络模型中卷积模块参数配置

Figure 4.1 Parameter Configuration of Convolution Module in DSACRNN Model

层	输入通道	输出通道	卷积核	步幅	填充
Conv11	3	32	(5,3)	(1,1)	(2,1)
Conv12	32	32	(5,3)	(1,1)	(2,1)
MaxP1	32	32	-	(2,2)	(0,0)
Conv21	32	64	(3,3)	(1,1)	(1,1)
Conv22	64	64	(3,3)	(1,1)	(1,1)
MaxP2	64	64	-	(2,2)	(0,0)
Conv31	64	128	(3,3)	(1,1)	(1,1)
Conv32	128	128	(3,3)	(1,1)	(1,1)
MaxP3	128	128	-	(1,2)	(0,0)
Conv-Skip11	32	128	(3,3)	(1,1)	(1,1)
Conv-Skip12	128	128	(3,3)	(1,1)	(1,1)
MaxP-Skip	128	128	-	(2,4)	(0,0)

在利用卷积模块提取高维特征之后，为了进一步从高维特征中提取与时序相关的特征并从中获取有利于情感分类的显著性特征分布，设计了一个时频注意力循环模块（TFAL）来完成上述特征提取，该模块由两部分组成：1）由 BiLSTM 网络构成的循环模块；2）注意力机制模块。特征提取的具体过程如下：首先改变卷积模块输出高维特征的形状，在保留时域维度的同时，将频域维度与深度维度相乘得到特征维度，以适应 BiLSTM 网络的输入，特征形状为“[Batch_size, Time, Fea_dim]”，其中“Time”指的是时间维度；“Fea_dim”指的是特征维度，利用 BiLSTM 网络从中提取与时序相关的情感特征信息，并将其集中在特征维度中，然后注意力机制模块利用 Softmax 函数从 BiLSTM 网络的输出特征中计算特征维度的重要性权重 α_t ，进而获取情感特征分布 d ，如公式(4-1)与公式(4-2)所示。

$$\alpha_t = \frac{\exp(W_t \cdot h_t)}{\sum_{t=1}^T \exp(W_t \cdot h_t)} \quad (4-1)$$

$$d = \sum_{t=1}^T \alpha_t \cdot h_t \quad (4-2)$$

其中 h_t 表示 BiLSTM 网络的输出特征, w_t 表示针对输出特征的可学习权重, 通过注意力机制结构对具有判别力的情感识别特征区域给予更大的权重, 有利于最终获取显著性情感特征分布, 时频注意力循环模块 (TFAL) 参数如表 4.2 所示。

表4.2 时频注意力循环模块参数配置

Table 4.2 TFAL Block Parameter Configuration

层及参数配置	输入维度	输出维度	内置参数
重塑	$T/2 * N/4 * 128$	$T/2 * [N/4 * 128]$	-
BiLSTM	$T_S * T/2 * N/4 * 128$	$T/2 * 256$	Hidden_state = 128
注意力机制	$T/2 * 256$	256	-
Dense(Dropout)	256	32	-

4.3.2 空间注意力循环模块

长短时记忆网络在一些有关时序特征提取任务中取得了良好的表现^[67], 其中时间依赖性是一个关键的因素^[140], 人耳听觉神经对所感知到的语音信号, 受信号刺激一次与多次感受存在不同, 之间的差异称之为听觉偏差, 因此尽可能多次感受情感语音信号, 有利于从中找出更有利于情感识别的显著性特征区域, 而这些显著性情感特征对于提升语音情感识别精度尤为重要。

针对上述问题, 设计并提出了空间注意力循环神经网络模块 (SACL), 该模块通过从卷积模块输出的高维特征中提取二维局部空间特征信息来消除听觉偏差, 进而获取局部空间显著性情感特征区域。具体过程如下: 首先在卷积模块输出的高维特征中扩展一维时间轴 “T_S” 以构建空间维度, 其中 “T_S” 表示空间注意力循环模块对高维特征做进一步提取的次数, 属于超参数, 本小节设置为 4; 然后输入到该模块中, 其中循环网络部分由长短时记忆网络 (LSTM) 构成, 然而这里 LSTM 结构不是用于提取与时序相关的特征, 而是在时频域用于对高维特征提取二维局部空间特征信息, 由于引入空间维度属性, 因此 LSTM 结构使用卷积层代替全连接层来更新各个 “门” 的权重参数, 并在更新之前, 引入注意力机制对高维特征进行显著性特征提取; 接着再送入到 LSTM 结构中, 循环迭代 “T_S” 次后以获得输出结果, 空间注意力循环模块结构如图 4.4 所示。




图4.4 空间注意力循环模块（SACL）细节图

Figure 4.4 Details of the SACL Block

如上所述，在卷积模块的输出维度上扩展一维长度为 4 的时间轴，构成一个四维的输入形状如 “[Batch_size, T_S, Channels, Time, Frequency]” 的张量，由图 4.4 可以看出，每次迭代 LSTM 层的输入 X_t 是通过注意力机制计算的，分别对隐藏状态 H_{t-1} 和高维特征输入 X 进行卷积，并将结果反馈给 Tanh 激活函数，然后用深度为 1 的卷积核进行卷积操作而生成的注意力机制特征 Z_t ，如公式(4-3)所示。

$$Z_t = R_a * \text{Tanh}(W_a * X + U_a * H_{t-1} + b_a) \quad (4-3)$$

其中 R_a 是深度（通道数）为 1 的内置卷积层， W_a 和 U_a 分别代表 X 和 H_{t-1} 的卷积内核（权重），然后通过 Softmax 操作计算一个归一化的注意力机制特征，如公式(4-4)所示。

$$A_t^{ij} = p(X, H_{t-1}) = \frac{\exp(Z_t^{ij})}{\sum_i \sum_j \exp(Z_t^{ij})} \quad (4-4)$$

其中 A_t^{ij} 表示注意力机制特征中位置 (i, j) 的元素，将注意力机制特征与输入 X 进行逐元素乘积，如公式(4-5)所示。

$$X_t^{new} = A_t \odot X \quad (4-5)$$

其中 X_t^{new} 是利用空间注意力机制结构新获得的特征；“ $\odot$ ”表示逐元素乘积，然后输入到 LSTM 层并获得参数更新，LSTM 层内各个“门”更新如公式(4-6)到公式(4-11)所示。

$$I_t = \sigma(W_i * X_t^{new} + U_i * H_{t-1} + b_i) \quad (4-6)$$

$$F_t = \sigma(W_f * X_t^{new} + U_f * H_{t-1} + b_f) \quad (4-7)$$

$$O_t = \sigma(W_o * X_t^{new} + U_o * H_{t-1} + b_o) \quad (4-8)$$

$$G_t = \text{Tanh}(W_c * X_t^{new} + U_c * H_{t-1} + b_c) \quad (4-9)$$

$$C_t = F_t \odot C_{t-1} + I_t \odot G_t \quad (4-10)$$

$$H_t = O_t \odot \tanh(C_t) \quad (4-11)$$

其中 I_t 、 F_t 、 O_t 、分别为三个门， G_t 属于缓存单元； C_{t-1} 和 C_t 是记忆单元； H_{t-1} 和 H_t 是隐藏状态； U 和 W 都是二维卷积核，并且所有偏差 b 都是可学习的，空间注意力循环模块（SACL）参数如表 4.3 所示。

表4.3 空间注意力循环模块参数配置

Table 4.3 SACL Block Parameter Configuration

层及参数配置	输入维度	输出维度	卷积核
重塑	$T/2 * N/4 * 64$	$T_S * T/2 * N/4 * 64$	-
AttConvLSTM	$T_S * T/2 * N/4 * 64$	$T/2 * N/4 * 64$	Kernel_size: 3*3
全局均值池化	$T/2 * N/4 * 64$	640	-
Dense(Dropout)	640	32	-

在空间注意力循环模块获取局部空间显著性特征区域之后，再连接一个全局均值池化层，消除时频维度的同时将时频信息集中在特征维度中，进而获取局部空间显著性情感特征分布，然后将该特征分布与由时频注意力循环模块（TFAL）获取的特征分布联合，最终得到包含全局特征信息以及局部空间特征信息的显著性情感特征分布，利用下面介绍的焦点损失函数完成语音情感识别。

4.3.3 损失函数

由于情感数据集样本在收集的过程中，各类情感样本数量不同，可能导致类别不平衡问题，即某一类样本数量大于其他类别样本，常用的交叉熵损失函数（Cross Entropy Loss）在处理数据类别不平衡数据集时出现了一些问题，这导致在利用损失函数训练模型时容易对类别少的样本产生偏见，而类别多的样本将主导损失函数和梯度下降，导致权重更新趋向于类别多的样本，进而产生对类别多的样本识别更有信心，而对类别少的样本则重视程度较低，导致平均召回率降低的问题。一般解决的方法是采用平衡交叉熵损失（Balanced Cross Entropy Loss），即为每个类增加一个权重因子，由 α 表示，属于超参数，如公式(4-12)所示。

$$BCE = -\sum_i (\alpha * p(x_i) \log q(x_i) + (1 - p(x_i)) \log(1 - q(x_i))) \quad (4-12)$$

其中 $\alpha \in [0,1]$ ，虽然平衡交叉熵损失在一定程度上改善了类别不平衡问题，但是并不能很好的区分难分样本和易分样本，导致总损失依然很高，而焦点损失（Focal Loss, FL）是基于交叉熵损失函数的改进^[141]，主要思想是将高置信度样本的损失降低，如公式(4-13)所示。

$$FL(p_i) = -\alpha_i (1 - p_i)^\gamma \log(p_i) - (1 - \alpha_i) (p_i)^\gamma \log(1 - p_i) \quad (4-13)$$

其中 α_i 和 γ 属于超参数，用来控制对损失函数的影响，一般在使用过程中， $\gamma = 2$ ；

$\alpha_i = 0.2$ ，这样对于正类样本而言，预测结果为 0.95 肯定是易分样本，所以“(1- 0.95)”的 γ^2 就会很小，损失函数就会变小，反之预测结果为 0.1 肯定是难分样本，所以“(1- 0.1)”的 γ^2 就会很大，损失函数值就会变大，而对于负类样本来说，预测 0.1 的结果应该远比预测 0.7 的样本损失值要小得多。综上，焦点损失函数更加关注这种难以区分的样本，减少了类别多的样本所带来的影响，并提升了收敛速度。

4.4 实验描述及结果分析

本章在两个公开可用的数据集 IEMOCAP 和 EMODB 上以及在第二章设计的 CID 数据集上进行基于动态自适应空间注意力网络模型的语音情感识别综合实验，以验证所提出模型的有效性与泛化性。在训练阶段，实验采用从样本中随机截取 3 秒片段提取三通语谱图，作为输入用以训练网络模型；而在测试阶段，将测试集数据样本分成若干个 3 秒的子段，针对每个句子中子段的后验概率应用最大池化来评估整个句子样本，当后验概率最高的那个子段标签与整个句子标签一致时，则认为所提出的模型对该句子样本识别成功。实验结果均通过双尾 T 检验证明其有效性。

4.4.1 实验准备

在 IEMOCAP 数据集上，使用 5531 个样本和包含 960 个情感样本的 CID 数据集进行相同的四分类语音情感识别实验，使用包含 535 个情感样本的 EMODB 数据集则进行七分类语音情感识别实验，并利用留一十折交叉验证算法来进行三个数据集上的实验，受数据集样本数量的限制，在 EMODB 和 CID 数据集上采用预训练模型算法，利用预训练好的模型在 EMODB 和 CID 数据集上进行全局微调，使模型参数更适合于两个数据集样本特征分布进而提升情感识别精度，各个数据集所选择的评价指标与前两章保持一致。

IEMOCAP 数据集在做独立说话人实验和依赖说话人实验时均是从零开始训练模型参数的，使用 Adam 算法作为优化器，初始学习率设置为 $1e-4$ ，然后当有 20 个 Epoch 在验证集中没有获得识别率提升时，使用余弦退火降低学习率，最小学习率设置为 $3e-6$ ，目的是在训练初期学习率大一些使网络模型收敛迅速，在训练后期学习率小一些而使网络收敛到最优解；用于计算梯度及其平方的平均值系数 betas 设置为 (0.9, 0.999)，权重衰减设置为 0，数值稳定性参数设置为 $1e-8$ ，batch_size 大小设置为 64，在训练阶段 Epoch 设置为 200。本章的模型依然使用 Pytorch 开源深度学习框架实现，所有实验均在 NVIDIA GTX 3090 单卡上运行。

4.4.2 实验结果与分析

(1) IEMOCAP 数据集的实验结果

本章所提出的算法动态自适应空间注意力网络在独立说话人实验中与其他研究方法在 IEMOCAP 数据集上的比较结果如表 4.4 所示。

表4.4 动态自适应空间注意力网络模型在 IEMOCAP 数据集上与其它方法的比较

Table 4.4 Comparison of the DSACRNN Model with Other Methods on the IEMOCAP

研究	特征	算法	平均召回率
Ghosh et.al ^[130]	语谱图	DAE+BiLSTM	51.86%
Latif et.al ^[74]		CNN+LSTM	60.23%
Bhosale et.al ^[75]		ACNN	63.15%
Yao et.al ^[131]		DNN	61.8%
Neumann et.al ^[132]		ACNN	59.54%
Latif et.al ^[142]		VAE+LSTM	62.81%
ARCRNN(第3章)	3D 语谱图	ARCRNN 模型	64.36%
本章		DSACRNN 模型	65.28%

从表 4.4 可以看出，本章所提出的算法相比于其他实验研究结果取得了最优平均召回率为 65.28%，与第三章提出的基于时频域注意力残差网络算法相比较，平均召回率提升了约 1%，与其他使用语谱图的深度学习网络模型研究相比，提升了约 2%~10%的平均召回率，证明了基于动态自适应空间注意力网络算法的优越性和有效性。相应的独立说话人实验混淆矩阵如图 4.5 所示。




图4.5 IEMOCAP 数据集独立说话人实验混淆矩阵

Figure 4.5 Confusion Matrix of Speaker-independent Experiment on IEMOCAP

从图 4.5 可以看出,本章所提出结构在高兴情感状态下获得了明显的优势,获得了比上一章高出 1%的 56.72%平均召回率,相对比与其他研究在高兴情感识别平均召回率要好^[75],并且在愤怒和悲伤情感上有一定程度的提升,分别取得 68.72%和 73.34%的实验表现,这是因为网络模型能够捕捉到包含局部空间情感信息的特征,从而在高兴、愤怒、悲伤情感识别中提升了平均召回率,为了进一步验证模型的有效性,也做了依赖说话人实验。

IEMOCAP 数据集中依赖说话人实验在上述实验条件下获得了 69.10%平均召回率的情感识别结果,其中愤怒情感的识别结果为 74.83%,与其他研究^[133]对比有较大幅度的提升,然后悲伤、高兴和中性情绪分别为 76.62%、59.53%和 65.45%的平均召回率。综上,无论是独立说话人实验还是依赖说话人实验,高兴情感的识别精度依然较低,归其原因:1) 高兴情感的特征分布与中性情感的特征分布近似;2) 数据集标注者对于样本的误判导致识别率较低;3) 数据集样本之间时间长度不统一,给并行训练造成困难,在训练阶段截取句子的子段标签和句子标签并不匹配,导致模型在训练过程中存在偏差。

(2) EMODB 数据集的实验结果

受 EMODB 数据集中样本数量的限制,大多数研究更关注依赖说话人实验以验证算法的有效性,并将准确率作为主要的评价指标用以评估模型,所提出的算法模型在依赖说话人实验中与其他方法在 EMODB 数据集上的比较结果如表 4.5 所示。

表4.5 动态自适应空间注意力网络模型在 EMODB 数据集上与其它方法的比较

Table 4.5 Comparison of the DSACRNN Model with Other Methods on the EMODB

研究	特征	算法	准确率
Kerkeni et.al ^[60]	谱特征和 MFCC	RNN	83%
Tiwari et.al ^[134]	HLDs 特征和 LLDs 特征	DNN	82.73%
Badshah et.al ^[124]	语谱图	CNN	85.5%
Chauhan et.al ^[135]		CNN	84.61%
ARCRNN (第 3 章)	3D 语谱图	ARCRNN 模型	85.68%
本章		DSACRNN 模型	86.96%

从表 4.5 可以看出,本章在 EMODB 数据集上实现了 86.96%的最佳识别准确率,实验结果验证了模型的有效性和泛化性,与上一章相比稳定提升了 1.3%,而与领域内其他使用深度学习网络模型的研究相比,提升精度在 1%~5%,这得益于所提出动态自适应空间注意力网络算法加强了模型对于高维特征中局部空间情感信息的提取;另一

个原因是在利用 EMODB 数据训练网络之前，模型已经拥有有利于情感分类的初始特征分布了，因此在后续微调过程中更容易获取符合 EMODB 数据集的语音情感特征分布进而提升识别精度，从混淆矩阵上也能看出，该网络模型在低准确率的那类情感上有一定程度提升，相应的依赖说话人实验混淆矩阵如图 4.6 所示。




图4.6 EMODB 数据集依赖说话人实验混淆矩阵

Figure 4.6 Confusion Matrix of Speaker-dependent Experiment on EMODB

从图 4.6 中可以看出，在依赖说话人实验中各个情感均具备较高的准确率，分析原因主要有：1）数据集中的样本量较少，且无背景噪声（即无情景交互），而且表演者在录制过程中刻意模仿该情绪从而产生较好的识别率；2）所提出算法能够在捕捉全局情感特征信息的同时获取高维特征中遗漏的局部空间信息，消除听觉偏差，帮助模型对低准确率情感类别获得提升，如在高兴情感中取得 76.06%准确率，与其他研究相比高兴情感准确率提升了约 29%^[108]；与上一章提出的模型结构比较，高兴情感有所提升，但与其他情感相比，高兴情感识别准确率依然是比较低的，与 IEMOCAP 数据集在高兴情感的预测趋势保持一致，这可能是由于每个人听觉生理结构的差异导致对同一句中中性或者略微高兴的句子情感差异不敏感，进而导致数据集的样本标注问题也是影响识别准确率的主要原因之一。

（3）CID 数据集的实验结果

受 CID 数据集中样本数量的限制以及多人录制条件，因此本章将重点关注该数据集下依赖说话人实验，已验证所提出方法的有效性，并将平均召回率作为主要评价指标用以评估模型，所提出的方法 DSACRNN 模型在依赖说话人实验中与其他方法在 CID 数据集上的比较结果如表 4.6 所示。

表4.6 动态自适应空间注意力网络模型在 CID 数据集上与其它方法的比较

Table 4.6 Comparison of the DSACRNN Model with Other Methods on the CID

研究	特征	算法	平均召回率
Badshah et.al ^[124]	语谱图	CNN	59.36%
Chen et.al ^[108]	3D 语谱图	ACRNN	61.42%
AWPRNN (第2章)	小波包帧级特征	AWPRNN 模型	61.30%
ARCRNN (第3章)	3D 语谱图	ARCRNN 模型	66.56%
本章		DSACRNN 模型	68.75%

从表 4.6 所示结果可以看出, 本章在 CID 数据集上实现了 68.75% 的最佳平均召回率, 与上一章相比识别精度提升了约 2%, 而与其他利用深度学习网络的研究相比识别平均召回率提升了 4%~9%, 实验结果进一步验证所提出算法的有效性与泛化性, 和 EMODB 数据集上的全局微调一样, 在 CID 数据上使用 IEMOCAP 的预训练模型, 所以在 CID 训练网络之前, 网络已经存在初始情感特征分布, 并且所提出网络模型能够进一步获取有利于情感分类的特征, 是产生识别结果精度提升的主要原因, 从混淆矩阵上也能看出, 动态自适应空间注意力网络在低召回率那类情感上有一定程度提升, 相应的依赖说话人实验混淆矩阵如图 4.7 所示。




图4.7 CID 数据集依赖说话人实验混淆矩阵

Figure 4.7 Confusion Matrix of Speaker-dependent Experiment on CID

从图 4.7 中可以看出, 在 CID 数据集依赖说话人实验中除高兴情感外均具备较高的平均召回率, 和 IEMOCAP 数据集的整体识别趋势类似, 平均召回率提升的原因主要在于所提出模型在获取全局特征信息的同时提取局部空间情感信息的优势; 另一个原因是由于数据集中的样本量较少且为四分类情感识别, 而且样本多数为表演性质的样本。愤怒情感、悲伤情感、高兴情感、中性情感等分别达到了 78.75%、81.25%、

47.92%、67.08%的平均召回率，造成高兴情感识别精度没有进一步提升的原因可能情感语音样本的音频录制环境为非专业录音设备而存在噪音、音质较差以及演员在表演过程中情绪没有控制好以及中文语言对于语音的影响较拉丁语系更大。

(4) 性能分析

相比于前两章，本章在时频注意力机制的基础上，扩展了空间注意力机制来构成动态自适应注意力网络，适当增加了可学习参数，包含未使用空间注意力循环模块的参数量，如表 4.7 所示。

表4.7 不同模型结构的可学习参数数量

Table 4.7 Number of Learnable Parameters for Different Model Structures

模型结构	可学习参数量
AWPRNN (第 2 章)	19687
ARCRNN (第 3 章)	1588351
DSACRNN (仅使用 TFAL)	1933173
DSACRNN (本章)	2319478

从表 4.7 所示，本章提出的 DSACRNN 模型占用的可学习参数最大，这是因为该结构中的空间注意力循环模块中，利用卷积层代替全连接层作为循环结构的‘门’，并设计了一个嵌入的空间注意力机制来从高维特征中提取显著性情感特征，这一过程需要使用一大部分可学习参数。尽管如此，牺牲一部分资源换取了在 IEMOCAP 情感识别任务上约 1%的平均召回率的提升（详见 4.4.3 消融实验），在其他有关语谱图的研究任务中同样表现良好，从侧面证明了所提出算法结构的有效性。值得注意的是，空间注意力循环模块的设计依赖于具体任务，当数据集过小时，容易因参数量相对过大而导致过拟合，因此在实际应用中，相比于前 2 章的注意力机制，需要更加在模型参数和识别精度上进行有效协调，可在中型存储设备上采用此算法进行语音情感识别。

4.4.3 消融实验

本小节将利用消融分析进一步验证所提出算法的有效性，采用控制变量法的方式，基线（Baseline）为本章提出的 DSACRNN 模型。模型性能主要由以下两点决定：卷积模块的层数结构以及空间注意力循环模块的应用，依次分析上述模块并做出分析对比，所有实验均在 IEMOCAP 数据集上进行：独立说话人实验（SI: Speaker-independent）；依赖说话人实验（SD: Speaker-dependent）。

(1) 卷积模块的区域数

本章在卷积模块中采用三个卷积区域，在残差结构部分采用一个卷积区域，其中每个卷积区域包括两层卷积层、一个批归一化层和一个二维最大池化层，本小节分别在残差结构不变的情况下，对卷积模块中区域数的选择分别做出相应消融分析，如表4.8所示。

表4.8 在 IEMOCAP 数据集上使用不同数量卷积区域的语音情感识别结果

Table 4.8 SER Results Using Different Convolutional Area on the IEMOCAP Dataset

区域数（通道数）	模型算法	IEMOCAP(SI)	IEMOCAP(SD)
2（64）	DSACRNN 模型	63.36%	67.84%
3（128）[本章]		65.28%	69.10%
4（256）		64.65%	68.45%

从表 4.8 可以看出，当使用较低的卷积模块区域数时，通道深度不够且只有 64，意味着有很多情感特征信息没有被很好的挖掘出来，造成全局特征信息遗漏；而在受到数据集样本数量限制的条件下，以及动态自适应空间注意力网络结构提取情感特征能力足够，当使用 4 个的卷积区域且通道数量 256 时，容易因参数量增多导致过拟合进而限制了模型对情感特征信息提取能力，因此平均召回率会有所下降。综上所述可以看出，当使用 3 层卷积模块（通道数量为 128）达到的效果最合适。

(2) 空间注意力循环模块的影响

本章提出的空间注意力循环模块结构（SACL），是从卷积模块提取的高维特征中进一步提取二维局部空间情感特征信息。本小节分别对直接单独使用 SACL 结构或时频注意力循环模块结构（TFAL），以及包含两个模块的动态自适应空间注意力机制网络三种情况进行情感识别实验对比，其中模型内卷积模块不变，如表 4.9 所示。

表4.9 在 IEMOCAP 数据集上使用不同注意力结构的语音情感识别结果

Table 4.9 SER Results Using Different Attentional Structures on the IEMOCAP Dataset

模型	结构配置	IEMOCAP(SI)	IEMOCAP(SD)
DSACRNN 模型	TFAL（单独）	64.04%	67.82%
	SACL（单独）	62.83%	66.94%
	SACL+TFAL	65.28%	69.10%

从表 4.9 可以看出，当单独使用 TFAL 结构以及 SACL 结构时，发现在 IEMOCAP 数据集独立说话人实验中结果均稍差，在两类实验中分别为 64.04%和 62.83%，这是因为当 TFAL 单独使用时，模型无法从卷积模块提取的高维特征中捕获局部空间情感信息，SACL 结构则恰好弥补了这一缺陷；而当单独使用 SACL 结构时，因为语音具有时

间连续性，导致模型忽略了高维特征中有关时序特征信息的部分，而 TFAL 结构对该遗漏部分提供良好的补充。综上，当联合使用两个结构时达到最优结果为 65.28%，这说明模型不仅有效捕捉到了全局情感特征信息，同时也提取到了时频二维局部空间情感信息，消除了听觉偏差，使模型获取到更有利于情感分类的特征分布，实验结果证明了所提出动态自适应空间注意力网络模型的有效性。

（3）卷积结构的影响

为了与第 3 章在算法结构上的对比，本小节增加了针对卷积结构影响的消融实验，使用上一章的空洞残差卷积结构，与本章所设计的动态自适应空间注意力网络相结合，对语音情感识别进行测试，如表 4.10 所示。

表4.10 在 IEMOCAP 数据集上使用不同的卷积结构的语音情感识别结果

Table 4.10 SER Results Using Different Convolutional Structures on the IEMOCAP Dataset

注意力机制	结构配置	IEMOCAP(SI)	IEMOCAP(SD)
动态自适应空间注	空洞残差卷积（第 3 章）	64.78%	68.46%
意力机制	残差卷积（本章）	65.28%	69.10%

从表 4.10 可以看出，当使用第 3 章空洞残差卷积结构时，在 IEMOCAP 数据集上的两类实验结果相较本章的残差卷积结构稍差，分别为 0.5%和 0.64%，这是因为第 3 章的卷积结构在提取语谱图底层特征时采用空洞卷积与普通卷积拼接的方式来完成提取，并扩展了一层卷积层加强特征学习，卷积结构与本章相比较为复杂，同时所提出的动态自适应空间注意力机制中可学习参数也比上一章注意力机制结构多，导致在训练过程中出现了一定程度的过拟合现象，最终导致实验结果略有下降。将第 3 章的卷积结构适当进行调整成本章的卷积结构，优化了部分可学习参数，所提出的注意力模块也能够从高维特征中进一步获取显著性信息以生成情感特征分布，并取得了良好的实验结果，从侧面也证明所提出动态自适应空间注意力模型的有效性。

（4）动态自适应空间注意力机制迭代次数

本章提出的动态自适应空间注意力结构如 4.3.2 小节 SACL 结构所述，它是通过循环迭代次数(T_S 的值)不断通过注意力机制在高维空间特征图中更新循环神经网络中卷积层的权重参数，本小节分别对不同迭代次数 T_S 的设置值做出相应的消融分析，如表 4.11 所示：

表4.11 在 IEMOCAP 数据集上使用不同 T_S 参数的动态自适应空间注意力的识别结果

Table 4.11 SER Results Using Different T_S Parameters of SACL on the IEMOCAP Dataset

迭代次数 (T_S)	模型结构	IEMOCAP(SI)	IEMOCAP(SD)
2	SACL 结构	64.53%	68.14%
3		64.82%	68.75%
4		65.28%	69.10%
5		65.16%	69.02%

从表 4.11 可以看出,随着 T_S 参数的小幅增加,在 IEMOCAP 数据集上的平均召回率有小幅提升,在 T_S 设置为 4 时,分别提升了 0.75%和 0.96%,这是因为当迭代次数较低时,SACL 结构对高维特征中与情感相关的偏差进行有效捕捉的能力较弱,在空间上没有将注意力有效集中在相对有利于情感分类的特征区域上。而随着逐步增加迭代次数(超过 4),平均召回率有所降低,因为每次迭代 SACL 结构中的权重卷积层(门)都要更新一次参数,增加了参数量,导致模型存在一定的过拟合现象,造成实验结果精度降低。该参数的设置依赖于具体任务,本章在权衡模型参数与实验结果后将 T_S 设置为 4。

4.4.4 基于空间注意力循环模块的扩展研究

新冠咳嗽声检测(Covid-19 Cough Recognition, CCR)的成功与否很大程度上取决于咳嗽声信号的特征表示,咳嗽是 Covid-19 的主要症状之一,该病毒主要攻击人体的肺部,可导致气道受限或阻塞,咳嗽声与情感语音信号的发声机理类似,都是由喉咙、声门以及声道根据当时的场景或者自身情况表现不同的变化,而这些变化足以影响音频的声学效果,情感语音信号与咳嗽声都属于音频信号,因此利用在语音情感识别上的模型算法,完全可以在新冠肺炎咳嗽声检测上得到应用。本章额外做了一个扩展研究利用本章所提出的模型算法在新冠咳嗽声检测上进行测试,以验证算法的实用性和有效性,如图 4.8 所示。




图4.8 基于动态自适应空间注意力网络的新冠检测框架图

Figure 4.8 Framework of the Spatial Attentive ConvLSTM Recurrent Neural Networks

(1) 数据集及预处理

本章扩展研究实验数据集选择公共数据集剑桥新冠数据集 Cambridge COVID-19 Sound Database (CCSD) [143]和俄罗斯新冠肺炎咳嗽声数据集 Russian Covid19-Cough Dataset (RCCD) [144]来通过实验验证所提出模型的有效性, 其中 CCSD 数据集包含 725 个样本, 有明确的训练集、验证集和测试集, 样本数量分别为 286、231、208。而 RCCD 数据集包含 1325 个样本, 包含 682 个新冠肺炎阳性病例, 采用留一十折交叉验证的方式进行实验。所有实验均为从零开始训练模型, 批量大小 (batch_size) 被设置为 32, 训练次数 (Epoch) 被设置为 100, 采用 Adam 优化器。学习率为 $3e-5$, 损失函数选择焦点损失, 使用 Pytorch 开源深度学习框架实现, 所有实验均在 NVIDIA GTX 3090 GPU 单卡上运行。

针对评价指标的选择, 不仅选择本章节使用的未加权平均召回 (UAR), 还使用准确率 (Accuracy), 此外, 针对新冠肺炎咳嗽声检测的二分类问题, 又考虑了特异性 (Specificity)、灵敏度 (Sensitivity) 及置信区间 (Confidence Intervals) 共五个评价指标, 下面逐一介绍新加的评价指标, 如下混淆矩阵 4.12 所示。

表4.12 混淆矩阵简单示意图

Table 4.12 Simple Diagram of Confusion Matrix

	真实正例	真实负例
预测正例	TP	FP
预测负例	FN	TN

特异性 (Specificity), 又叫真反例率或真阴性率 (True negative rate, TNR), 意义是描述识别出的负例占有所有负例的比例, 由 $TNR = TN / (FP + TN)$ 表示, 在临床时

描述为例如真正未感染新冠的人中，即核酸呈阴性，被医院判断为未感染新冠患者的比例，这也意味着当特异度高的时候，表示低误诊率（医院没有冤枉一个没病的人）。

灵敏度（Sensitivity），又叫真正例率或真阳性率（True positive rate, TPR），意义是描述识别出的所有正例占有所有正例的比例，由 $TPR = TP / (TP + FN)$ 表示，在临床时描述为例如真正确诊新冠的病人中，被医院判断为确诊感染新冠患者的比例。这也意味着当灵敏度高的时候，表示低漏诊率（医院没有放过一个患病的人）。

理想情况下，希望特异性和灵敏度指标都很高，然而在实际应用中一般根据情况在特异性和灵敏度中寻找一个平衡点，权衡利弊。因此，本章选用以上评价指标全面衡量所提出模型的有效性，实验结果将在下一节进行详细介绍和分析。

（2）CCSD 数据集的实验结果

由于 CCSD 数据集明确划分了训练集与测试集，所以本小节实验结果将以在测试集的表现与其他研究方法进行比较，包括本章提出的基于动态空间自适应注意力网络模型实验结果如表 4.13 所示。

从表 4.13 可以看出，本章提出的 DSACRNN 模型在 CCSD 数据集中取得高于基线大约 8% 平均召回率，分别为 73.2% 的平均召回率，证明本章所提出结构的有效性，但是由于新冠阳性样本较少，导致模型对该类样本的敏感程度有一定损失，造成实验结果中灵敏度不高。

表4.13 在 CCSD 数据集中本章模型与其他研究的对比

Table 4.13 Comparison of the Model with Other Studies in the CCSD Dataset

算法	平均召回率	准确率	特异性	灵敏度	置信区间
ComParE+SVM ^[143]	65.6%	-	-	-	-
DeepSpectrum+SVM ^[143]	63.3%	-	-	-	-
S2SAE+SVM ^[143]	67.6%	-	-	-	-
CNN+LSTM	64.7%	-	-	-	-
CNN+Transformer	72.0%	-	-	-	-
DSACRNN(本章)	73.2%	83.65%	89.94%	56.41%	±15.10%

（3）RCCD 数据集的实验结果

RCCD 数据集没有进行明确划分，因此本章采用留一十折交叉验证的方式与其他研究方法进行比较，包括本章提出两类模型结构，实验结果如表 4.14 所示。

表4.14 在 RCCD 数据集上本章所提出的模型与其他研究比较

Table 4.14 Comparison of the Proposed Model with Other Studies on the RCCD Dataset

算法	平均召回率	特异性	灵敏度	置信区间
CovidEnvelope ^[145]	67%	63%	70%	-
DSACRNN(本章)	75.77%	70.42%	81.13%	7.26%

从表 4.14 可以看出，本章提出的 DSACRNN 模型在 RCCD 数据集中均取得高于基线大约 9%，平均召回率为 75.77%，证明了本章所提出模型有效性及通用性。

(4) 消融实验分析

本小节分别针对两类模型的结构进行消融实验，以评估内部结构对模型整体性能的影响，所有实验均在 CCSD 数据集上进行，在消融分析中，以 CNN+LSTM 结构^[143]为基线进行对比分析，它是由三层普通卷积层提取高维特征后结合 LSTM 网络对咳嗽声信号进行检测识别，对比结果如表 4.15 所示。

表4.15 基于动态自适应空间注意力网络模型的消融分析

Table 4.15 Ablation Analysis based on DSACRNN Model

算法	平均召回率	准确率	特异性	灵敏度	置信区间
CNN+LSTM	64.7%	-	-	-	-
SACL(单独)	64.2%	83.45%	98.82%	29.68%	$\pm 12.38\%$
TFAL(单独)	70.91%	83.17%	90.53%	51.28%	$\pm 16.22\%$
DSACRNN(融合)	73.20%	83.65%	89.94%	56.41%	$\pm 15.01\%$

从表 4.15 可以看出，基于动态空间自适应注意力网络取得了最好的结果，高于基线 8.5%，而单独使用 SACL 模块的平均召回率和灵敏度较低：分别为 64.2%和 29.68%，这表明单独的 SACL 层对模型整体产生的影响在识别咳嗽声方面漏诊率较高。然而，从特异性可以看出，单独使用 SACL 层在新冠咳嗽声信号的误诊率中接近 0%，这体现 SACL 结构对未患有新冠的患者有较为准确的判断，这是由于 SACL 模块在提取局部时频空间特征信息方面显示出的优势，消除了听觉偏差，然而咳嗽声信号具有时间连续性，单独 SACL 模块忽略了与时序相关特征信息的提取，这是导致灵敏度较低的主要原因；与此同时，当单独使用 TFAL 模块时，情况有所改善（平均召回率和灵敏度分别为 70.91%和 51.28%），这从侧面证实了提取与时序相关全局特征信息的重要性，正如预期的那样，新冠咳嗽声的漏诊率较少。然而单独使用 TFAL 层时缺少对局部时频空间信息的特征提取，导致较低的特异性（90.53%）；融合两类模块所构建的动态自适应空间注意力网络结构（DSACRNN）则呈现出最好的性能，并且其灵敏度和特异性结

果（分别为 56.41%和 89.94%）显示出了低漏诊率和低误诊率。综上，通过该扩展实验验证了所提出的基于动态自适应空间注意力网络模型的有效性和实用性。

4.5 本章小结

本章针对语音情感识别模型在特征提取过程中，注意力机制结构从高维特征中无法获取时频二维局部空间情感特征而造成信息遗漏问题，提出了基于动态自适应空间注意力网络用以进一步提升语音情感识别精度。该算法中的空间注意力循环模块结构是将注意力机制嵌入到长短时记忆网络（LSTM）中，通过 LSTM 迭代关注相关局部空间信息来细化显著性情感特征，其中 LSTM 是针对高维特征的直接提取，而不是改变形状后用来处理时间序列，该空间注意力循环模块可有效提取特征中遗漏的局部空间信息，完善情感特征分布并结合时频注意力模块丰富情感特征表达能力，进一步提升情感识别精度。通过实验验证了本章模型的有效性与泛化性，公开可用的数据集 IEMOCAP、EMODB 分别在独立说话人实验和依赖说话人实验中分别获得 65.28%平均召回率和 86.96%准确率，在情感类别样本均衡的自设计数据集 CID 中，平均召回率和准确率均在依赖说话人实验获得 68.75%的语音情感识别结果。此外，基于新冠咳嗽声检测的扩展研究进一步证明所提出的动态自适应空间注意力网络的实用性。

第5章 基于残差多尺度卷积 Transformer 网络的语音情感识别

前三章提出的语音情感识别算法主要从离散情感标签中获取与情感相关的显著性特征信息，提升了识别精度。然而由于情感的主观性和连续性，单纯的离散标签无法准确衡量出情感在句子中的变化，限制了语音情感识别性能。为了加强显著性特征表征情感能力，更好的提升语音情感识别精度，本章研究了维度语音情感识别，提出了基于残差多尺度卷积 Transformer 神经网络（Residual Multi-Scale Convolutional Transformer, RMSCTx）的维度语音情感识别算法，提出的动态帧移算法解决了训练过程中样本片段标签与句子标签不匹配问题，设计了残差多尺度卷积模块以及自适应位置编码 Transformer 模块有效加强模型对于情感显著性特征的提取。所提出算法在三个数据集中分别进行实验，提出将新冠咳嗽声检测作为扩展应用研究，并增加模块消融实验，全面验证模型性能。

本章研究内容的结构安排如下：5.1 节是引言；5.2 节是基于残差多尺度卷积 Transformer 网络的语音情感识别框架；5.3 节对所提出方法的具体细节进行详细介绍；5.4 节是实验以及结果分析；5.5 节是本章小结。

5.1 引言

人类情绪的表达是一个复杂的过程，由特定的大脑区域控制。情绪可以通过各种渠道表达，如语言、面部表情或身体语言等。与其他表达方式相比，声音表达已被证明是最直观和准确的^[146]，在语音情感识别的发展过程中，语音情感识别总共分为两大类：离散语音情感识别和维度语音情感识别^[26]。离散情感理论是基于六类基本情感，这些情感类别的标签方案是可直观观测的，因此一部分语音情感识别模型是基于离散标签实现分类，然而离散语音情感识别模型虽然简洁但对情感的描述能力有限，很难准确地描述日常交流中一些自发情感状态。连续语音情感识别，也称为维度语音情感识别，它是由三个标签激活度、愉悦度、支配度（Arousal、Valence、Dominance），即三个值来量化进而表达情感状态，人在说话过程中，情感状态是处在起伏波动状态下的，所以单纯的离散标签无法准确衡量出情感在话语中的变化，制约了语音情感识别算法的发展。因此，为有效提升情感识别精度，可以着重于维度语音情感识别模型的相关研究，实现语音情感识别精度提升。

目前现有的维度语音情感识别算法为了方便于模型并行训练,对不同时长的原始信号进行预处理方法主要是通过截取信号或者对信号进行零填充的方式进行数据对齐^[147, 148],但是使用这种策略的问题是,数据集提供的标签通常是对整个句子样本打上固定且单一的标签。然而情感信息具有很强的主观性和时间连续性,单一标签不能准确捕捉到整段语音中的情感痕迹,例如一个真实标签为“快乐”的长语音话语中可能包含部分中性的情感成分,在对信号进行截取的过程中,有很大概率获取中性情感的那部分语音序列,这在一定程度上误导了模型对情感的分类,从而导致识别率降低。在卷积模块提取语谱图的过程中,高维特征是在低维特征上滑动卷积核并执行一定运算映射而成,而卷积核的尺度大小决定了卷积层对局部信息感知能力,这也意味着模型感受野的范围较为固定,无法很好地捕捉不同尺度下丰富的情感特征和重要的全局信息。另一方面,由于语谱图本身具有时序性,所以循环神经网络可以更好的提取高维特征中与时间序列有关的情感特征,然而在提取高维特征的过程中,当前时刻的特征较为依赖包括上一时刻在内之前的特征信息,无法并行化处理特征而导致很难捕捉到全局情感信息。此外,注意力机制结构的作用是对高维特征进行显著性提取,获得更有利于情感分类的特征分布,然而如何更有效的在语音情感识别过程中从高维特征中找到显著性情感特征所在位置区域已成为注意力机制结构需要面临的问题。

针对上述问题,本章提出了一个基于残差多尺度卷积 Transformer 神经网络(Residual Multi-Scale Convolutional Transformer, RMSCTx)。首先利用动态帧移算法对原始信号进行分块并提取三通道语谱图,然后保持块级片段顺序的同时输入到残差多尺度卷积模块中以提取高维特征,由于 Transformer 结构^[149]可在不依赖 RNN 顺序结构情况下使模型可以并行训练并且拥有全局特征信息,因此利用该结构进一步获取更有利于情感识别的块级高维特征。值得注意的是,在输入 Transformer 结构之前,设计了一个自适应位置编码算法,通过设置嵌入层使高维特征中时频域的位置信息处于可学习状态,并将学习好的位置信息融入到高维特征中,然后输入到 Transformer 结构中进一步提取有利于情感识别的显著性块级特征,最终利用时间聚合策略将块级特征生成句子级情感特征分布,在均方误差损失函数的帮助下实现维度语音情感识别。

5.2 基于残差多尺度卷积 Transformer 网络的语音情感识别框架

图 5.1 (a) 是基于残差多尺度卷积 Transformer 网络的语音情感识别模型整体框架图。该框架将利用动态帧移算法来处理原始语音信号得到块级三通道(3D)语谱图作为模型输入,之后再进行数据增强后送入网络模型中的卷积模块提取块级高维特征,

接着利用自适应位置编码算法对高维特征中时频域的位置信息进行编码，并将学习到的位置信息融入到高维特征中，使 Transformer 模块更好的对全局情感特征进行提取，最后利用一个均值池化层将块级特征生成句子级情感特征分布，通过均方损失函数完成维度语音情感识别。本章所提出算法能够对整个时间序列上的高维特征进行全面建模，有利于识别精度的提升，通过在三个公共数据集 MSP-Podcast 1.9 版本、IEMOCAP 和 MSP-IMPROVE 数据集上进行实验论证，证明了所提出方法的有效性与泛化性。




图5.1 基于残差多尺度卷积 Transformer 网络的语音情感识别模型

Figure 5.1 Residual Multi-Scale Convolutional Transformer Network for Speech Emotion Recognition

基于残差多尺度卷积 Transformer 网络的语音情感识别的整体步骤为:

(1) 利用动态帧移算法对原始语音信号进行处理, 从不同长度的语音样本中提取相同数量的块级片段并保留片段在句子中的顺序;

(2) 对每个提取到的块级片段提取三通道语谱图, 特征归一化后进行 SpecAugment 数据增强;

(3) 在保持块级片段时序的条件下, 为模型输入扩展一维度以表示块级片段的数量, 然后并行输入到网络中残差多尺度卷积模块提取块级高维特征;

(4) 利用自适应位置编码算法对高维特征中的时频域位置信息进行编码, 将位置信息融入到高维特征后, 输入到 Transformer 模块中进行块级情感特征提取;

(5) 利用均值池化的时间聚合策略使块级特征生成句子级情感特征分布, 使用均方误差损失函数实现维度语音情感识别。

5.3 基于残差多尺度卷积 Transformer 神经网络

图 5.1 (b) 显示了所提出的基于残差多尺度卷积 Transformer 神经网络的细节图, 本节将详细介绍网络模型中的各个组成部分。

5.3.1 块级片段的语音信号预处理

语音情感识别任务中的数据样本之间存在时间长度不等是在语音信号处理时的一个常见问题, 为了方便深度学习网络并行训练, 需要输入数据的尺寸相同, 因此在处理过程中往往选择对语音句子进行截取或者补零, 以统一输入时长, 但是现有的公共数据集中给出的样本标签表示这句话的情感类别, 而情感具有主观性与连续性, 它在一个句子中的分布不是固定的, 往往会产生被截取的片段与句子级标签不匹配问题, 影响模型的整体训练。因此如何处理不同长度序列的情感样本在不丢失信息的条件下可以并行训练, 且截取的片段标签能够与句子真实标签相同, 成为本小节需要解决的问题。受 Lin 等人^[53]的启发, 在信号处理过程中使用动态帧移的数据预处理算法, 该方法可以根据不同时长的样本, 动态调整帧移来从每个语音句子中获得相同数量的片段, 称之为块级 (chunk-level) 片段, 这种方法能够有效保留句子中全部的情感信息。在输入模型之前, 对输入特征扩展一维来表示所截取块的数量, 为网络并行训练提供方便的同时, 解决了输入样本与真实标签间的不匹配问题。图 5.2 展示了如何将不同长度的语音划分为固定的 N_c 的块, 每个块的长度为 Δc_i (会随着不同时长的样本而动态改变)。

已有研究表明,短至 0.5 秒的片段就可以在 SER 任务中得到利用^[150],在本小节使用 1 秒长度的片段作为数据预处理的一部分是一个合适的折中方案,由于所使用的数据集中样本数据的长度分布有很大的差异,在预处理块级片段时,对于短于 2 秒的样本进行帧复制操作,即短于 2 秒的语音样本按时间顺序用其自身的部分帧进行补充至 2 秒,通过这种方式,简化了对短时长样本的处理,块级窗口的持续时间被设定为 1 秒,这是确定动态帧移时必须指定的两个最重要的超参数之一。




图5.2 不同时长的语谱图分割成相同数量的块级语谱图

Figure 5.2 Spectrograms of Different Durations Divided into the Same Number of Chunk-level Spectrogram Features

另一方面,需要着重考虑的是数据集中最大句子的长度,为了有效防止超过预取长度而引起的问题,如公式(5-1)和(5-2)所示。

$$N_c = \frac{T_{max}}{L_c} \quad (5-1)$$

$$\Delta c_i = \frac{T_{sample} - L_c}{N_c - 1} \quad (5-2)$$

其中, L_c 是每个句子的块级长度; N_c 是块的数量; T_{sample} 是单个数据样本的持续时间; Δc_i 表示帧之间重叠的部分,可以根据不同时长的句子进行调整; T_{max} 表示数据集样本中最长样本的持续时间,通过动态改变重叠的帧长,得到了每个句子所设定的块数量, N_c 是由数据集中持续时间最长样本 T_{max} 决定的,由动态帧移算法从每个不同时长样本中截取相同数量的块级片段,这些块级片段具有表征句子级样本的能力,由相同数量块级片段组成的信号称之为块级语音信号。

在得到块级语音信号之后，需要对包含的每个块提取三通道语谱图，由于在训练过程中，要保持块级片段的顺序，所以在输入网络之前，需要重塑输入块级特征的形状以便网络模型进行并行训练，如公式(5-3)所示。

$$M_{conv} = f^{conv}(M) \in R^{(b_s, N_c, c, t, f)} \Rightarrow R^{(b_s * N_c, c, t, f)} \quad (5-3)$$

其中 b_s 指的是训练批量； N_c 如上同样指块的数量； c 指的是三通道的语谱图； t 指的是信号在时域上的长度； f 指的所使用的滤波器的数量。利用这种方式，使块级片段与句子标签相匹配。在提取完特征之后，对每一个块级片段语谱图都使用 SpecAugment 数据增强算法，以提高模型的泛化能力，最后将得到增强的块级特征输入到所提出网络模型中做进一步的特征提取，整个过程如图 5.3 所示。




图5.3 提取块级语谱图的语音信号预处理过程

Figure 5.3 Speech Signal Preprocessing Process for Extracting Chunk-level Spectrogram Features

5.3.2 残差多尺度卷积模块

获得三通道语谱图后，将特征输入到网络结构中的残差多尺度卷积模块，具体过程如下：首先在卷积模块浅层设计了两个不同的卷积核为“3*1”和“1*3”的时域卷积层和频域卷积层，目的是在时频域内有针对性的从不同尺度提取局部时域和频域特征，随后连接一个批量归一化层（BN）和激活函数 ReLU，以防止梯度消失，并加快模型收敛速度并删除对网络贡献不大或没有贡献的神经元，同时保留有用的情感信息。然后将时域卷积层和频域卷积层的输出在时域维度上连接起来，因为在浅层特征提取过程中，是将提取好的局部特征信息集中在深度维度中。由于语音具有时间连续性，沿时域维度连接，意味着包含更多与时域相关的信息，可从中提取到更多的情感局部特征。然后将在时域维度上连接得到特征输入到残差多尺度卷积区域中做进一步特征提取，卷积模块模型参数如表 5.1 所示。

表5.1 残差多尺度卷积模块模型参数配置

Table 5.1 RMSCNN Block Parameter Configuration

层	通道数	卷积核	步幅	维度	填充
输入	3	N/A	N/A	(T,F)	N/A
Conv-T	16	(3,1)	(1,1)	(T,F)	(1,0)
Conv-F	16	(1,3)	(1,1)	(T,F)	(0,1)
RMSC1-1	16	(3,3)	(1,1)	(2T,F)	(1,1)
RMSC1-2	16	(5,5)	(1,1)	(2T,F)	(2,2)
Pool-1	16	(2,2)	(2,2)	(T,F/2)	N/A
RMSC2-1	32	(3,3)	(1,1)	(T,F/2)	(1,1)
RMSC2-2	32	(5,5)	(1,1)	(T,F/2)	(2,2)
Pool-2	32	(2,2)	(2,2)	(T/2,F/4)	N/A
RMSC3-1	64	(3,3)	(1,1)	(T/2,F/4)	(1,1)
RMSC3-2	64	(5,5)	(1,1)	(T/2,F/4)	(2,2)
Conv	128	(5,5)	(1,1)	(T/2,F/4)	(2,2)

从表 5.1 可以看出，其中残差多尺度卷积区域的组成部分包括：两个卷积核分别为“3*3”和“5*5”的卷积层、一个批归一化层以及一个二维最大池化层，激活函数选择 ReLU。残差卷积区域提取特征过程：首先通过两个不同尺度下的卷积层，以捕获不同感受野下的局部情感信息，分别在两个卷积层上设置了跳层连接，通过这种方式在两个卷积层的输出后创建一个残差网络，防止网络退化并增强模型鲁棒性；然后在深度（通道）维度上进行连接，输入到批归一化层和二维最大池化层，完成特征提取，残差多尺度卷积区域结构如图 5.4 所示，并与普通卷积层进行了对比，如图 5.5 所示。

为了增强网络结构对全局情感特征的提取，本小节使用三个的残差卷积区域来增加模型的深度，使提取到的情感信息集中在深度维度上，最后，当模型深度达到 128 时，对残差卷积区域所输出的特征再使用一个较大“5*5”卷积核的卷积层来进行特征提取，因为残差多尺度卷积区域的输出特征尺寸在提取过程中逐渐变小，抽象程度逐渐变高，感受野增大，此时利用一个带有较大卷积核的卷积层进行再提取，有利于进一步加强模型对全局情感信息的提取，避免有价值的特征遗漏，以获取有利于情感识别的高维特征并输入到后续网络结构之中。




图5.4残差多尺度卷积模块

Figure 5.4 RMSCNN Block




图5.5普通卷积模块

Figure 5.5 CNN Block

5.3.3 自适应位置编码 Transformer 网络模块

在从残差多尺度卷积模块中获取高维特征，本小节设计了自适应位置编码 Transformer 模块做进一步特征提取，以获取与时序相关的全局情感信息进而生成特征分布，一个标准的 Transformer 由一个编码器和解码器以堆叠的方式组成，由于本章研究语音情感识别任务，属于回归任务，所以只使用 Transformer 中的编码器的部分来进行特征提取。语音信号具有时间连续性，在特征提取时较为依赖时间顺序，而高维特征则包含时频域的位置信息，因此在使用 Transformer 模块提取特征之前，对高维特征进行位置编码并将位置信息映射到高维特征中，有助于该模块提取显著性情感特征进而提升识别结果。传统位置编码如公式(5-4)和公式(5-5)所示。

$$p_t^{(i)} = \begin{cases} \sin(w_n \cdot t) & \text{if } i = 2n \\ \cos(w_n \cdot t) & \text{if } i = 2n + 1 \end{cases} \quad (5-4)$$

$$w_n = \frac{1}{10000^{2n/d}} \quad (5-5)$$

t 指的是当前时刻在整个语音中的位置； p_t 属于 R^d ，表示信号的位置编码； d 表示编码器的维度，由于 Transformer 模块接收的是特征输入的形状表示为 “[Batch_size, Time_steps, Feature_dim]”，其中 “Feature_dim” 是由卷积模块输出的高维特征中将通道深度与频域维度相乘得到的，也称 “D_model”，同时也是为了使 Transformer 层能够根据其内部的自注意力机制结构选择最重要的情感信息，在不损失时间信息的情况下尽可能多地保留全局情感特征。为了能够使 Transformer 结构更稳定的从高维特征中获取有利于情感识别的显著性特征区域，本小节提出了自适应位置编码算法 (Adaptive

Position Encoding, APE), 对卷积模块输出的高维特征利用两个嵌入层分别在时域和频域的位置上进行映射, 使位置信息可根据高维特征中的显著性特征位置区域进行自学习, 然后将学到的位置信息融入到高维特征中。与传统位置编码只在时域位置上进行固定数值编码相比, 自适应位置编码不仅可以对时域和频域位置同时进行编码, 而且还使位置信息具有学习能力, 自适应位置编码结构如图 5.6 所示。




图5.6 基于自适应特征位置编码算法流程图

Figure 5.6 Flow Chart of Adaptive Position Embedding Algorithm

从图 5.6 可以看出, 具体过程为: 首先从卷积层模块输出得到的高维特征为 “[Batch_size, Channels, Time, N_mels]”, 其中 “[]” 内依次表示批量大小、深度 (通道数)、时域 (时间步长) 以及频域; 然后对时域和频域分别按照其数值进行自适应编码, 例如如果时间维度上的数量为 150, 在编码后获得 0, 1, 2 ..., 149 的位置信息, 同样的情况也适用于 “N_mels”。接着利用两个嵌入层将时域和频域位置信息分别映射为二维向量, 并将两个嵌入层的输出分别设置成高维特征深度的一半, 最后根据时频位置信息的重要程度分配不同的权重进行学习之后, 利用扩展层 (Unsqueeze Layer) 将获得的位置信息特征图重塑为与高维特征相同的形状后, 将位置信息融入到高维特征中。值得注意的是, 在设置嵌入层的时候, 需要对其权重进行初始化, 使其符合高斯分布, 以使 Transformer 模块能够更好地找到有利于情感识别的全局特征信息, 学习后的位置信息特征比按固定公式执行扁平化处理的传统位置信息更具灵活性以及更强捕捉有价值信息区域的能力, 两种位置编码算法对比如图 5.7 和图 5.8 所示。




图5.7 传统位置编码热度图

Figure 5.7 Heatmap of Traditional Position Encoding




图5.8 自适应位置嵌入编码算法热度图

Figure 5.8 Heatmap of Adaptive Position Embedding Encoding Algorithm

在将自适应位置特征信息融入到卷积模块输出的高维特征之后，改变输出形状为“[Batch_size, Time, Channel * N_mel]”以适应 Transformer 模块的输入，利用 Transformer 模块对高维特征进一步提取全局显著性特征进而生成情感特征分布，Transformer 主要由一个多头注意力机制^[151]，一个前馈神经网络层和一个 Add & Norm 层组成，其中 Add 表示残差连接，目的是防止网络退化；Norm，代表层归一化（Layer Normalization），用于规范各层的激活值，Transformer 模块的具体结构如图 5.9 所示。




图5.9 Transformer 中编码器的详细结构

Figure 5.9 Detailed Structure of the Encoder in Transformer

Transformer 模块进行特征提取的具体过程为：首先利用自注意力机制计算三个不同的变换矩阵与高维特征 Q 、 K 、 V 做内积获得注意力输出矩阵，这三个不同的变换矩阵分别为 W_q 、 W_k 和 W_v ，并通过线性投影从特征维度“D_model”中得到 Q (Queries)、 K (Keys)、 V (Values)，并通过公式(5-6)获得注意力输出矩阵。

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5-6)$$

由公式 5-6 可以看出，由矩阵转置后相乘获得注意力机制特征，其中 Q 和 K 的转置做内积， d_k 表示 Q 和 K 的维度。由于在计算过程中，“ $Q * K$ ”的值会随着维度的增加而增加，梯度迭代容易因为方差的积累而产生梯度爆炸，导致模型不收敛，因此，除以维度的平方根相当于做归一化的效果。为了获得必要的输出，需要包含多个头的 Transformer，其中“多头”指的是由多个自注意力机制组成，在特征提取过程中需要将每个头的注意力输出矩阵按维度乘以输出加权矩阵，如公式(5-7)和公式(5-8)所示。

$$MultiHead(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_n)W^o \quad (5-7)$$

$$\text{head}_n = \text{Attention}(QW_n^Q, KW_n^K, VW_n^V) \quad (5-8)$$

值得注意的是，利用自适应位置编码算法学习到的位置信息只提供给 Q 和 K ，而不提供给 V ，这有助于提高 Transformer 模块定位情感特征区域的效率。此外，前馈网络层的操作也是必需的，它引入 ReLU 激活函数以加强注意力机制输出的特征分布，为提高模型的表现力做出贡献，Transformer 模块内部结构参数配置如表 5.2 所示。

表5.2 Transformer 内部结构参数配置

Table 5.2 Transformer Internal Structure Parameter Configuration

参数名称	参数值
Dim_features	1280
Heads (头数)	8
Dim_feed_forward	256
Dropout	0.2
Dim_fc_in (内置全连接层输入)	1280
Dim_fc_out (内置全连接层输出)	256

本章所提出模型中 Transformer 模块内包含两层自适应位置编码的 Transformer 结构, Transformer 模块使用了自注意力机制, 不采用循环网络顺序结构, 使得模型可以并行化训练, 可以从高维特征中进一步提取全局情感特征信息, 进而生成有利于情感识别的块级特征分布, 在下一小节将得到的块级情感特征分布转化成句子级特征分布, 以完成语音情感识别。

5.3.4 句子级特征分布的生成

残差多尺度卷积模块以及 Transformer 模块已经为每个块级片段提取特征并生成了特征分布, 汇总各个块级片段的特征分布以生成句子级分布的具体过程为: 首先对网络结构输出的形状如 “[Batch_size * Chunk_num, Time_steps, D_model]” 的高维特征使用一维均值池化层和一维最大值池化层来消除时间维度, 并将两类池化层的输出进行融合, 得到形状如 “[Batch_size, Chunk_num, D_model]” 的句子级高维特征, 其中 “Chunk_num” 表示块级片段的数量, “D_model” 表示模型提取到的句子级情感特征, 然后为了获取句子级特征分布, 需要对上述句子级高维特征进行时间聚合以消除 “Chunk_num” 维度。本小节设计了三种基于时间聚合策略模块, 使用 N_c 个块级特征向量 $\{h_1, h_2, \dots, h_{N_c}\}$ 来生成的句子级特征分布 z , 如下所示。

(1) 无注意力结构 (NonAttention): 为了获得句子级特征分布 z , 直接对块级特征向量进行求平均操作, 如公式 (5-9) 所示。

$$z = \frac{1}{N_c} \sum_{t=1}^{N_c} h_t \quad (5-9)$$

其中 N_c 代表块级片段的数量, 这种方法等同于在块级特征分布中做一维均值池化层以生成句子级特征分布。

(2) 长短时记忆注意力结构 (LSTM-Attention): 在这个方法中使用了注意力机制模型, 首先对 Transformer 模块的输出进行处理, 方式为使用两个方向含 128 个隐藏单元的 BiLSTM 网络, 然后利用注意力机制对块级特征进行选择, 将更大的权重分配给含情感信息更多的块级片段, 得到了一系列含 256 个神经元的高维特征句子级分布 z , 如公式(5-10)和(5-11)所示。

$$\alpha_t = \frac{\exp(W \cdot h_t)}{\sum_{t=1}^{N_c} \exp(W \cdot h_t)} \quad (5-10)$$

$$z = \sum_{t=1}^{N_c} \alpha_t \cdot h_t \quad (5-11)$$

该模块的目标是将权重集中在与情感相关的部分, 其中 α_t 表示注意力权重。

(3) 自注意力结构 (Self-Attention): 在应用自注意力结构获得句子级特征分布时, 所考虑的结构与 Transformer 内部的注意力机制结构相同, 不同的是, Transformer 模块处理块级片段时相应的时间维度 (时间步长, Time_steps) 表示的是块级片段的时域长度, 而在进行句子级时间聚合时, 相应的时间维度则是由代表块级片段数量的维度替代, 在整个过程中严格控制块级片段的时间顺序, 由于时间聚合策略是通过消除块级片段来生成句子级情感特征分布, 因此只使用一层的双头 Transformer 结构且不使用自适应位置编码来获得句子级特征分布。

5.3.5 损失函数

最后, 在获得句子级情感特征分布之后, 使用损失函数实现对 Arousal、Valence、Dominance 值的预测, 以完成维度语音情感识别。在识别过程中选用均方误差损失作为损失函数, 均方误差损失 (Mean Square Error, MSE) 又称为二次损失、L2 损失, 它通过计算预测值和实际值之间的距离 (即误差) 的平方来衡量模型优劣, 即预测值和真实值越接近, 两者的均方差就越小, 因此通过将模型的输出与真实标签共同送入到 MSE 中, 对三类标签进行预测, 计算方式如公式 (5-12)。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - y'_i)^2 \quad (5-12)$$

其中训练数据的真实输出为 y_i ; 模型对数据的预测值为 y'_i ; n 为训练数据的个数。MSE 损失的范围为 0 到 ∞ , 维度情感识别综合实验将在下一节详细介绍。

5.4 实验描述及结果分析

本章在三个公开可用的数据集 MSP-Podcast 1.9、IEMOCAP 以及 MSP-IMPROV 上进行了基于残差多尺度卷积 Transformer 神经网络 (RMSCTx) 的维度语音情感识别综

合实验，通过使用动态帧移算法，从句子样本中获取等量的块级片段并提取三通道语谱图，然后利用所提出网络结构提取全局情感高维特征，最终使用时间聚合策略生成句子级特征分布并完成进行语音情感识别，通过大量实验证明所提出模型的有效性和泛化性。

5.4.1 实验准备

在使用数据集的过程中，采用 1 秒的块级片段并提取三通道语谱图输入到 RMSCTx 模型中。以 MSP-Podcast 数据集为例，该数据集的句子长度从 2.75 秒到 11 秒不等，所以最大时长 T_{max} 是 11 秒。首先通过动态帧移算法都将从每个样本中获取 11 个时长为 1 秒的块级片段，然后提取语谱图并得到模型输入 X_c ，形状为 “[11, 3, 62, 40]”，其中块级片段的数量为 11；对数语谱图的 static、delta 和 delta-deltas 的组合用 3 来表示；62 则表示短时分析后信号在时域上的长度；代表频域的滤波器数量被设置为 40。然后对块级特征利用 SpecAugment 数据增强算法，其中时域掩蔽长度设置为 20，频域掩蔽长度设置为 8，归一化处理之后输入到残差多尺度卷积模块以提取高维特征，接着输入到两层自适应位置编码 Transformer 模块中进一步提取全局情感特征，其中每层 Transformer 结构之前都对高维特征使用自适应位置编码算法。最后利用均值池化的时间聚合策略生成句子级特征分布以完成语音情感识别。批量大小 (batch_size) 被设置为 64、训练次数 (Epoch) 被设置为 100、采用 Adam 优化器、学习率为 $3e-5$ 、损失函数选择均方误差损失 (Mean-squared error, MSE)、统计学的相关一致性系数 (CCC) 和置信区间 (CI) 作为评价指标来评估实验的可靠性和准确性，使用 Pytorch 开源深度学习框架进行实验，所有实验均在 NVIDIA RTX 3090 GPU 单卡上运行，相关一致性计算公式如公式(5-13)所示。

$$CCC = \frac{2\rho\sigma_x\sigma_y}{\sigma_x^2 + \sigma_y^2 + (\mu_x - \mu_y)^2} \quad (5-13)$$

由(5-13)可知，预测标签 x 和真实标签 y 之间的相关系数用 ρ 来表示；平均值使用 μ 来表示；方差则用 σ 的平方表示；标准差用 σ 表示。CCC 分数越高，表示识别结果越好，关联性越强。此外为了确保结果的可靠性，还报告了每个实验的置信区间如公式(5-14)所示。

$$CI = \frac{Upper_bound - Lower_bound}{2} \quad (5-14)$$

在测试集中随机抽取 1000 个数据点，并计算每个样本的相关一致系数，随后计算出 2.5% 的四分位数，用 *Lower_bound* 表示，以及 97.5% 的四分位数，用 *Upper_bound* 表示，最后，估计这两个界限之间的总体置信区间。

本章使用的数据集为 MSP-Podcast 1.9、IEMOCAP 以及 MSP-IMPROV 数据集，对于 MSP-Podcast 数据集，其中训练集为 55283 个样本，验证集为 9546 个样本，测试集为 21560 个样本；对于 IEMOCAP 和 MSP-IMPROV 数据集，由于没有分类标签的限制（取决于几分类任务），每个情感样本均提供了 Arousal、Valence 和 Dominance 标签，所以在本章使用两个数据集的全部样本，两个数据集均包括表演戏剧脚本和充满感情场景而诱发的对话记录，但是由于两个数据集并没有对句子施加严格的持续时间范围，而且时间跨度很大，因此，本小节放弃短于 1 秒和长于 17 秒的句子（这些与平均时长差距非常大的样本仅占总数据集的 3%），因此在两个数据集中定义 $T_{max} = 17$ 秒，即在一个句子级样本中包含 17 个持续时间为 1 秒的块级片段，对于 IEMOCAP 数据集使用留一十折交叉验证；对于 MSP-IMPROV 数据集，它包含和 IEMOCAP 数据集类似的 6 个对话（Session），每个对话中包含 2 个说话人，因此在 MSP-IMPROV 中使用留一十二折交叉验证，此外该数据集有 52 个样本的 Dominance 没有被标记，在本章不参与任何训练与测试。

5.4.2 实验结果与分析

（1）MSP-Podcast 数据集的实验结果

为了证明本章所提出算法的有效性，本小节将用该模型得到的结果与目前最先进的端到端有监督学习模型训练的结果进行比较。CRNN 模型^[53]主要由一个传统的 CNN 和 BiLSTM 组成，在 CNN 获得的高维特征后输入到 BiLSTM 做进一步特征提取，最后通过全连接网络层（FCN）获得识别结果；在此基础上，Attentive ConvLSTM^[108]额外提供了一个注意力机制，增强了模型的识别能力；Convolutional Transformer（CTx）^[152]模型由一组卷积模块和 Transformer 模块相连接而组成；值得注意的是，为了突出本章在结构创新上的优越性，在对比实验 CRNN 和 CTx 模型结构中，所使用的卷积模块结构与第 4 章的卷积结构保持一致；GLAM 模型^[153]在一个残差多尺度卷积网络的基础上添加两个线性层和一个 GeLU 激活函数层，用于改善跨尺度的特征关系。除了本章提出的 RMSCTx 模型结构外，还在此基础上设计一个基线对比模型，该模型将完整 Transformer 结构替换成 Attentive BiLSTM 构成 Attentive Residual Multi-Scale ConvBiLSTM（ARMSCRNN）模型，实验对比结果如表 5.3 所示。

表5.3 在 MSP-Podcast 数据集上使用不同模型的实验结果对比

Table 5.3 Comparison of Results Using Different Models on the MSP-Podcast Dataset

模型	Arousal(CI)	Valence(CI)	Dominance(CI)
ConvBiLSTM(CRNN) ^[53]	0.4994(0.0038)	0.1330(0.0026)	0.3835(0.0069)
Attentive ConvBiLSTM(ACRNN) ^[108]	0.5171(0.0011)	0.1403(0.0032)	0.3876(0.0055)
Convolutional Transformer(CTx) ^[152]	0.5254(0.0064)	0.1583(0.0040)	0.4032(0.0053)
GLAM CNN(GLAM) ^[153]	0.5121(0.0089)	0.1483(0.0031)	0.4135(0.0058)
Attentive RMSConvBiLSTM(ARMSCRNN) [本章]	0.5282(0.0114)	0.1424(0.0037)	0.4027(0.0076)
RMSConvolutional Transformer(RMSCTx) [本章]	0.5459(0.0082)	0.1615(0.0037)	0.4200(0.0137)

从表 5.3 可以看出, 本章所设计的模型在所有对比的实验中取得了最好的成绩, 其中 Arousal: CCC = 0.5459, Valence: CCC = 0.1615, Dominance: CCC = 0.4200, 而对应的置信区间的数值进一步证实了实验结果的有效性, 验证了所提出算法的准确性和有效性, 尽管模型依然在 Valence 维度取得当前研究领域内的最佳结果, 但是与其他维度标签相比, 在 Valence 维度的结果欠佳, 这是因为一方面是数据集录制的音频质量的原因, 另一方面也是因为 Valence 反映了语音信号中的消极或积极程度, 有监督学习模型对 Valence 的敏感程度不高也会导致结果偏低。

(2) IEMOCAP 和 MSP-IMPROV 数据集上的结果

由于两个数据集都是交互式动态情感数据集, 均在真实场景下的演员们的双人互动录制的, 两个数据集在本章算法的实验结果如图 5.10 和图 5.11 所示。

由图 5.10 和图 5.11 得知, ARMSCRNN 和 RMSCTx 在所有维度标签上都超过了其他模型, CCC 的趋势也与表 5.3 所呈现的一致, 即本章所提出的模型在 Arousal 和 Dominance 维度上取得了最佳性能。值得注意的是, 通过实验结果观察到, ARMSCRNN 模型在 MSP-IMPROV 数据集上的 Arousal 和 Valence 维度以及在 IEMOCAP 数据集上的 Valence 维度的实验结果比 RMSCTx 的结果略好, 这是由于在针对 MSP-Podcast 数据集的实验中, 设计模型的层数和超参数适合大数据集训练, 而 MSP-IMPROV 数据集中用来训练和测试的数据比 MSP-Podcast 少得多(分别少于 8 倍和 12 倍), 所以使得 RMSCTx 模型结构与其他结构相比存在过拟合现象, 因此导致了

相对较差的结果。综上，本章提出的模型与最先进的模型相比，在维度语音情感识别方面有明显优势，实验结果验证了所提出的网络模型的泛化性和有效性。




图5.10 在 IEMOCAP 数据集上使用不同模型的实验结果对比

Figure 5.10 Comparison of Results Using Different Models on the IEMOCAP Dataset




图5.11 在 MSP-IMPROV 数据集上使用不同模型的实验结果对比

Figure 5.11 Comparison of Results Using Different Models on the MSP-IMPROV Dataset

(3) 性能分析

本章着重使用以自注意力机制为主要结构的 Transformer 模型（2 层）来进行情感显著性特征的提取，不同模型结构的可学习参数如图 5.4 所示。

表5.4 不同模型结构的可学习参数数量

模型结构	可学习参数量
CTx	15265553
GLAM	10666789
RMSCTx	15282673

从表 5.4 可以看出,相比于前 3 章,以自注意力机制为主要结构的模型可学习参数明显增多,这是因为自注意力机制通过 Query、Key 和 Value 的值来在高维特征中搜索与情感相关的显著性特征,每个值都需要通过线性层来学习参数,这相当于增加了多组的可学习参数,然而这并不意味着参数增多就不好,相反随着可训练数据样本的明显增多,模型学到的有利于情感识别的特征也随之增多,上述实验结果很好的证明了这一点。此外,在同为自注意力机制模型中,以 MSP-Podcast 数据集为例,本章算法在训练过程中拥有较优的收敛速度,如图 5.12 所示。




图5.12 不同模型结构在 MSP-Podcast 数据集中的收敛时间

Figure 5.12 Convergence time of different model structures in the MSP-Podcast dataset

从图 5.12 可以看出,对比三种自注意力机制的结构,本章所提出的 RMSCTx 模型具有较快的收敛时间,在针对激活度 (Arousal) 和支配度 (Dominance) 的识别中速度最快,而在愉悦度 (Valence) 中略低于 CTx,这可能是由于 CTx 模型在进行愉悦度识别过程,存在过拟合现象,而导致收敛速度稍快。实验结果可以看出,本章提出的算法在三个维度中均取得了最佳效果,且拥有较快的收敛速度,在实际应用中,该算法模型可根据具体任务进行部署,对硬件设备的容量有一定的要求,适用于拥有较大数据量任务的应用场景。

5.4.3 消融实验

为了更详细地说明本章所提出模型的有效性,本小节将对其进行消融分析并将基准 (Baseline) 设定为 RMSCTx 模型,数据集为 MSP-Podcast 1.9 版本。

(1) 块级片段窗口尺寸的影响

由于情感在一个句子中的分布并不是均匀的^[154],在训练阶段就保持块与块之间的时间顺序,而不是打乱各个块级片段的时序以进行混合训练。为了保留足够的情感变

化，确定块级片段的时间长度对整个模型训练来说十分重要，本小节分析了不同块级窗口大小对于模型性能的影响，块级片段的时间长度对实验结果的影响如表 5.5 所示。

表5.5 块级片段的时间长度对实验结果的影响

Table 5.5 The Influence of the Time Length of Chunk-level Segments on the Results

L_c 长度	Arousal(CI)	Valence(CI)	Dominance(CI)
1 秒	0.5459 (0.0082)	0.1615 (0.0037)	0.4200 (0.0137)
2 秒	0.5159(0.0071)	0.1451(0.0041)	0.3882(0.0061)
3 秒	0.5206(0.0083)	0.1485(0.0047)	0.4112(0.0078)

从表 5.5 可以看出不同块级片段长度 L_c （1 秒、2 秒和 3 秒）所产生的结果，提高 L_c 会有更多信息被包含在块级片段中，反而降低了时间聚合策略对生成句子级特征分布的重要性，导致结果有所降低，当 L_c 设置为 1 秒时，三个维度标签的 CCC 是最高的，表明 1 秒的块级片段有足够能力来表达句子级特征分布。

（2）三通道语谱图的影响

为了评估 delta 和 delta-deltas 的使用在多大程度上促进了模型的性能，本小节逐渐将这些语谱图添加到模型输入中，随后对实验结果进行评估，如表 5.6 所示。

表5.6 3D 语谱图选择对实验结果的影响

Table 5.6 The Influence of 3D Spectrogram Feature Selection on the Results

特征选择(语谱图)	Arousal(CI)	Valence(CI)	Dominance(CI)
Static	0.5297(0.0066)	0.1656 (0.0036)	0.3955(0.0060)
+Delta	0.5269(0.0063)	0.1641(0.0040)	0.3967(0.0059)
+Delta-deltas	0.5459 (0.0082)	0.1615(0.0037)	0.4200 (0.0137)

从表 5.6 可以看出，使用 delta 和 delta-deltas 构成的三通道语谱图在识别 Arousal 和 Dominance 维度标签更有效，这是因为 Arousal 反映了从“平静”到“活跃”的趋势变化，而 Dominance 代表了从“弱”到“强”的趋势变化，本小节认为语谱图的 delta 和 delta-deltas 对 Arousal 和 Dominance 更加敏感，可以更好的帮助模型捕捉这些改变，而在 Valence 维度标签的识别时，仅使用 static 语谱图取得了最佳结果，CCC 为 0.1656，这是因为高兴情绪和中性情绪在某些样本中的 Valence 非常接近，导致在做差分运算时，样本空间中相邻时刻的差分结果较为接近，进而导致在 Valence 维度上产生误差。综上，本章使用三通道语谱图作为模型输入。

(3) 数据增强的影响

有研究表明^[170]，与其他传统数据增强技术相比（如音量调整和音速调整），SpecAugment 方法对模型的识别能力最为有利，在输入模型之前，对块级的片段的语谱图进行数据增强，由于不同的增强效果会与模型识别能力产生影响，因此本小节评估了在不同参数规格下的数据增强，如表 5.7 所示。

表5.7 不同 SpecAugment 数据增强的参数对实验结果的影响

Table 5.7 The Influence of Different SpecAugment Parameters on the Results

掩蔽参数	Arousal(CI)	Valence(CI)	Dominance(CI)
{10, 4, 1, 1}	0.5113(0.0066)	0.1574(0.0042)	0.3990(0.0057)
{20, 8, 1, 1}	0.5459 (0.0082)	0.1615 (0.0037)	0.4200(0.0137)
{30, 12, 1, 1}	0.5285(0.0113)	0.1610(0.0035)	0.4081(0.0093)
{10, 4, 2, 2}	0.5347(0.0070)	0.1531(0.0038)	0.4250 (0.0085)
{20, 8, 2, 2}	0.5249(0.0055)	0.1522(0.0034)	0.4018(0.0072)

从表 5.7 可以看出，当 SpecAugment 算法的参数设置为“{20, 8, 1, 1}”，其中“{ }”内依次为时域掩蔽数量、频域掩蔽数量、时域掩蔽次数以及频域掩蔽次数，在 Arousal 和 Valence 上维度获得了良好的性能。从消融分析中可以看出，较小的参数规格没有增强模型的识别能力，这会导致模型的泛化性降低，相反，更大尺寸的掩蔽（Mask）会造成特征中情感信息的丢失，从而产生负面影响，得到的结果还表明，在保持总的掩蔽区域不变的情况下，适当增加掩蔽的数量可以加强模型的对 Dominance 维度的敏感性，提高模型对该标签的识别，因此设置合适大小的 SpecAugment 参数可以提升模型的鲁棒性和有效性。

(4) 自适应位置编码算法的影响

在使用 Transformer 模块之前，给高维特征提供位置信息可有效提升模型识别精度，在本节中针对所提出的自适应位置编码算法与传统位置编码获得的结果进行消融分析，分析了不同位置编码技术的使用情况以及层数对实验结果的影响，其中传统位置编码用“T”表示；自适应位置编码用“A”表示；“（1）”表示位置编码在传入到 Transformer 结构之前只使用一次；“（2）”表示在每层 Transformer 结构前均使用位置编码（本章只使用两层该结构）。实验结果如表 5.8 所示。

表5.8 自适应位置编码算法对实验结果的影响

Table 5.8 The Influence of Adaptive Position Encoding Algorithm on the Results

位置编码	Arousal(CI)	Valence(CI)	Dominance(CI)
T (1)	0.5269(0.0090)	0.1392(0.0037)	0.3969(0.0070)
A (1)	0.5348(0.0103)	0.1577(0.0040)	0.4159(0.0134)
T (2)	0.5313(0.0091)	0.1532(0.0034)	0.3973(0.0095)
A (2)	0.5459(0.0082)	0.1615(0.0037)	0.4200(0.0137)

从表 5.8 可以看出,本章所提出的自适应位置编码算法在各个维度识别上均取得了最佳结果,其中针对每一层的 Transformer 结构(本章使用两层 Transformer 提取显著性情感特征),在输入结构之前均进行一次自适应位置编码算法,所以一共使用两次位置编码算法,相较于仅使用一次传统位置编码相比,在三个维度上分别提升了 0.019、0.0223、0.0231。这是由于所提出的自适应位置编码算法可以自学习高维特征上显著性情感特征区域的具体位置,进而帮助 Transformer 结构提升对全局情感特征的提取能力,实验结果证明了所提出结构的有效性。

(4) Transformer 模块层数的影响

有研究证明在 Transformer 模块的每一层前加入位置信息是很有必要的^[155],然而应该选择多少层 Transformer 结构是影响模型整体识别能力的一个关键因素,因为较少的层数可能会影响模型捕捉情感信息的能力,而较多的层数可能会导致模型参数的增多进而产生过拟合现象。因此,本小节对 Transformer 结构层数的选择做出实验评估,如表 5.9 所示。

表5.9 不同 Transformer 结构的层数对实验结果的影响

Table 5.9 The Number of Layers of Different Transformer Structures on the Results

Transformer 层数	Arousal(CI)	Valence(CI)	Dominance(CI)
1	0.5260(0.0066)	0.1602(0.0037)	0.4083(0.0078)
2	0.5459(0.0082)	0.1615(0.0036)	0.4200(0.0137)
3	0.5101(0.0084)	0.1549(0.0035)	0.4024(0.0059)

从表 5.9 可以看出,当 Transformer 的层数设置为两层时,获得了最佳的实验结果,相比于使用一层 Transformer 结构在三个维度上分别提升了 0.0199、0.0013、0.0117。这与实验前分析情况保持一致,合理层数的 Transformer 结构可以更好的从残差多尺度卷积模块输出的高维特征中提取到有利于情感识别的全局情感特征。因此,在本章模型中,使用两层 Transformer 结构来提取情感显著性特征。

(5) 时间聚合策略对句子级特征分布的影响

通过所提出网络模型得到块级片段特征分布后，由于每个句子级样本都对应一个标签，使用时间聚合策略来获取句子级情感特征分布，不同时间聚合策略对实验结果会产生不同影响，本小节将对三种块级片段生成句子级特征分布的时间聚合策略做出评估，其中“None”指的是使用均值池化作为时间聚合策略，如表 5.10 所示。

表5.10 时间聚合策略对实验结果的影响

Table 5.10 The Influence of Temporal Aggregation Strategy on the Results

Attention 类别	Arousal(CI)	Valence(CI)	Dominance(CI)
None	0.5459 (0.0082)	0.1615(0.0036)	0.4200 (0.0137)
RNN-Attention	0.5268(0.0011)	0.1654(0.0040)	0.4102(0.0093)
Self-Attention	0.5310(0.0085)	0.1693 (0.0041)	0.4056(0.0128)

从表 5.10 可以看出，在使用均值池化时间聚合策略时，在 Arousal 维度以及 Dominance 维度上分别取得了最好的结果 CCC: 0.5459 和 0.4200，这表明基于 1 秒的块级片段在残差多尺度卷积 Transformer 网络模型的帮助下有能力识别出平静（Calm）/活跃（Active）以及弱（Weak）/强（Strong）的表现程度。LSTM-Attention 和 Self-Attention 的设置并不像一维均值池化那样直接有效，很大原因是因为两个维度对块级片段的时间顺序相对不那么敏感，导致在 Arousal 和 Dominance 的识别效果相对较低，但是实验表明，基于 LSTM-Attention 和 Self-Attention 的时间聚合策略对 Valence 维度有着积极的影响，这是因为利用时间聚合策略在生成句子级特征分布的过程中，两种注意力机制策略可以帮助块级片段进一步提取其特征分布中少量的与时序相关的信息，而这些信息与积极（Positive）/消极（Negative）有相关联系，导致在 Valence 维度的结果上，基于注意力机制的时间聚合策略表现更好，分别为 CCC: 0.1654 和 0.1693。综上，本章在一维均值池化的帮助下，在 Arousal 和 Dominance 维度上取得最佳结果，而 Valence 的最好结果在 Self-Attention 注意力机制的时间聚合策略上获得。

5.4.4 基于自适应位置编码算法的扩展研究

本章将新冠肺炎咳嗽声检测作为扩展研究验证所提出的自适应位置编码算法的有效性和实用性，提出了基于二维卷积自适应位置编码 Transformer 神经网络（Adaptive Position Encoding Convolutional Transformer, APECTx），网络模型的具体结构由两部分构成：卷积模块以及自适应位置编码 Transformer 模块，在卷积模块中使用带残差结构的两个卷积区域，其中每个卷积区域包含两层卷积层，一层批归一化层以及一层二维

最大池化层，激活函数使用 ReLU；在 Transformer 模块中，只使用一层该结构，新冠肺炎咳嗽声检测任务结构框架图如图 5.13 所示。




图5.13 基于自适应位置嵌入的卷积 Transformer 神经网络模型框架

Figure 5.13 Convolutional Transformer Neural Network Model Based on Adaptive Position Embedding

(1) 实验准备与实验结果

本小节所使用的数据集以及评价标准均和 4.4.4 章节所设置的一样，使用公共数据集剑桥新冠数据集（CCSD）和俄罗斯新冠肺炎咳嗽声数据集（RCCD）来通过实验验证所提出模型结构的有效性和通用性，评价指标采用平均召回率，准确率，特异性、灵敏度及置信区间 5 个指标全面验证所提出算法，其中 CCSD 数据集的实验结果及其对比实验如表 5.11 所示。

表5.11 在 CCSD 数据集中本章模型与其他研究的对比

Table 5.11 Comparison of the Model with Other Studies in the CCSD Dataset

算法	平均召回率	准确率	特异性	灵敏度	置信区间
ComParE+SVM ^[143]	65.6%	-	-	-	-
DeepSpectrum+SVM ^[143]	63.3%	-	-	-	-
CNN+Transformer	72.0%	-	-	-	-
DSACRNN(第4章)	73.2%	83.65%	89.94%	56.41%	±15.10%
APECTx(本章)	72.6%	87.50%	96.45%	48.72%	±15.01%

从表 5.11 可以看出，与上一章相比，尽管两类模型在平均召回率指标上相差无几，但通过对比其他指标上的表现，可以发现在上一章提出的 DSACRNN 模型中灵敏度指标要略高于 APECTx 模型，为 56.41%。但是却在特异性指标方面又略低于 APECTx 模型，后者为 96.45%，这意味 DSACRNN 模型在新冠肺炎检测上的漏诊率较低，而 APECTx 模型在新冠肺炎误诊率方面有一定程度的加强。APECTx 模型使用了 Self-Attention 机制，从结构上来说，不采用 RNN 的顺序结构，使模型可以并行化训练，而

且能够掌控全局信息，加快模型收敛速度的同时获取有效的显著性特征分布，在 RCCD 数据集上的实验如表 5.12 所示。

表5.12 在 RCCD 数据集上本章所提出的模型与其他研究比较

Table 5.12 Comparison of the Proposed Model with Other Studies on the RCCD Dataset

算法	平均召回率	特异性	灵敏度	置信区间
CovidEnvelope ^[145]	67%	63%	70%	-
DSACRNN(第 4 章)	75.77%	70.42%	81.13%	7.26%
APECTx(本章)	78.47%	68.61%	89.06%	7.88%

从表 5.12 可以看出，本章提出的自适应位置编码 Transformer 模型结构在 RCCD 数据集中取得高于基线（Baseline）大约 10%的平均召回率，为 78.47%，证明了所提出结构的有效性。由上述评价指标内容可知，在 RCCD 数据集的实验结果呈现出与 CCSD 数据集近似的趋势，高灵敏度意味着低漏诊率，所提出模型结构在这一指标上达到 89.06%。综上，所提出自适应位置编码算法在两个新冠咳嗽声公共数据集中均取得了最佳的实验结果，同时也证明了该算法的泛化性与通用性。

（2）APECTx 模型结构消融分析

本小节将针对 APECTx 模型进行逐级消融分析，基线选择 CNN+LSTM 模型，然后逐渐添加和更改所提出模型的部分内部结构，其中 ACRNN 模型是在基线模型的基础上添加注意力机制结构，对比结果如表 5.13 所示。

表5.13 基于 APECTx 模型的消融分析

Table 5.13 Ablation Analysis based on APECTx Model

算法	平均召回率	准确率	特异性	灵敏度	置信区间
CNN+LSTM	64.7%	-	-	-	-
ACRNN	66.8%	86.86%	97.63%	35.90%	±15.67%
CTx(无位置编码)	68.6%	87.50%	98.82%	38.46%	±14.71%
CTx(传统位置编码)	70.4%	85.57%	94.67%	46.15%	±16.55%
APECTx	72.6%	87.50%	96.45%	48.72%	±15.01%

从表 5.13 可以看出，APECTx 模型取得了最佳结果，高于基线 7.9%，证明了所提出算法的有效性，与其他结构相比，ACRNN 模型在内部卷积模块（带有残差结构）不变的情况下，BiLSTM 和传统注意力机制的经典组合只获得了 66.8%的平均召回率；同样地，在特征提取过程中对高维特征没有添加位置信息的 Transformer 结构的实验结果平均召回率仍然低于 70.0%（参照 CTx 的 68.6%）；相比之下，在 Transformer 结构中加入传统位置编码明显提高了模型的性能，达到 70.4%的平均召回率。然而最好的

结果是由本小节所提出的 APECTx 模型，分别达到了 72.6 % 的平均召回率、96.45 % 的特异性以及 48.72% 的灵敏度。综上，通过对比分析实验结果，验证了所提出的自适应位置编码算法的有效性和实用性。

5.5 本章小结

本章针对维度语音情感识别模型在训练过程中所截取样本片段标签与句子标签不匹配问题；模型在特征提取过程中，获取的显著性特征表征情感能力弱的问题，提出了基于残差多尺度卷积 Transformer 神经网络的维度语音情感识别算法，用以提升识别精度。首先通过动态帧移算法调整语音片段之间帧重叠部分使每个句子级样本拥有相同数量的块级片段，然后将块级片段提取语谱图作为模型输入，利用提出的残差多尺度卷积模块对其提取高维特征，扩大特征区域感受野，捕获更多情感特征信息。设计自适应位置编码算法对时频域内显著性特征区域位置进行自学习，然后融入位置信息至 Transformer 模块，进而获取全局显著性块级特征。最后利用基于均值池化的时间聚合策略生成句子级情感特征分布，完成维度语音情感识别。本章在三个公共数据集上进行了大量的实验，其中 MSP-Podcast 数据集在激活度、愉悦度和支配度三个维度上分别获得 0.5459、0.1615 和 0.4200 的相关一致性系数，在 IEMOCAP 和 MSP-IMPROV 数据集上同样取得了良好的实验结果，表明所提出算法在维度语音情感识别中优势明显，有足够能力进行维度数值预测。此外，本章将新冠咳嗽声检测作为扩展研究以对所提出的自适应位置编码算法进行实验，结果证明了该算法的有效性与实用性。

结 论

随着人工智能研究取得了巨大进展与成就，语音情感识别作为人机交互的重要分支也取得了长足的进步，然而由于语音情感的复杂性、主观性和可变性，现有的基于深度学习的语音情感识别模型在性能和识别精度上与人脑识别仍然存在差距，归其原因主要是由于缺乏对更具有判别力的语音情感特征的获取。本文研究了离散情感识别和维度情感识别算法，分别从语音情感信号处理、特征提取、注意力机制结构设计三个方面进行研究，提升语音情感识别精度。

本文的主要研究工作为以下四个方面：

1. 基于小波包重构特征自适应注意力网络的语音情感识别

由于短时傅里叶变换无法根据信号高、低频率自适应调整窗口宽度，导致特征提取过程中，表征信号局部特征能力较弱，能够捕获的显著性情感特征较少。因此，本文提出了基于小波包重构特征注意力神经网络算法。首先利用小波包重构算法对原始信号进行分解并重构成一组新的信号，提取帧级声学特征。其次循环网络模块和自适应特征采样注意力模型进一步从特征中获得有利于情感识别的显著性帧级特征分布。最后与原始信号中所获取的句子级特征分布相融合，并使用交叉熵损失函数完成语音情感识别。该语音情感识别算法利用重构后小波信号较强的局部特征表征能力，使获取的帧级特征拥有更多时频分辨率情感信息，同时提出的自适应特征采样注意力模块则加强了对情感显著性特征的捕捉。实验在两个公开可用的数据集 IEMOCAP 和 EMODB 上的独立说话人实验和依赖说话人实验上分别获得了 62.15% 平均召回率和 82.63% 准确率，在情感类别样本均衡的自设计数据集 CID 中，召回率和准确率均在依赖说话人实验获得 61.3% 的实验结果，表明所提出方法可有效提升情感识别精度。

2. 基于自适应时频注意力残差网络的语音情感识别

语谱图在普通卷积神经网络提取特征过程中获取全局信息能力不足而导致情感特征遗漏，以及注意力机制在时域维度中获取相关显著性情感信息能力较弱。因此，本文提出了基于自适应时频注意力残差网络算法，进一步提升情感识别精度。首先从原始语音信号提取三通道语谱图，然后提出在卷积模块中使用空洞卷积和残差卷积结构相拼接的方式，扩大感受野以捕获浅层次和深层次情感特征。其次提出使用由双向门控循环单元网络构成的循环模块进一步提取与时序信息相关的特征，输入至提出的自适应时频注意力机制模块，分别用于在时频维度提取有利于情感识别的显著性特征以

生成情感特征分布。最后利用可兼顾类内聚合和类间分离的中心损失函数，联合中心损失函数和交叉熵损失函数实现语音情感识别。实验较第 2 章在三个数据集 IEMOCAP、EMODB 和 CID 分别获得了 2.21% 平均召回率、2.79% 准确率和 5.26% 平均召回率的提升，结果表明在不依赖传统声学特征的情况下，所提出算法可进一步提升语音情感识别精度。

3. 基于动态空间自适应注意力网络的语音情感识别

自适应时频注意力残差网络采用先后顺序分别对高维特征中的频域维度和时域维度进行显著性特征提取，忽略了时频二维局部特征空间的联系，导致损失了局部空间情感特征信息，限制了识别精度的提升。因此，本文提出了基于动态自适应空间注意力神经网络算法，从原始信号提取三通道语谱图，并提出时频注意力循环模块和空间注意力循环模块构建的动态自适应空间注意力网络，用于获取时频域延单一维度加强后的特征分布，同时弥补缺失的二维局部空间情感信息。然后联合两个模块输出的特征分布利用焦点损失函数完成语音情感识别，提升情感识别精度。实验在两个公开可用的数据集 IEMOCAP 和 EMODB 上的独立说话人实验和依赖说话人实验上分别获得了 65.28% 平均召回率和 86.96% 准确率以及在 CID 数据集的依赖说话人实验中获得了 68.75% 的实验结果，较第 3 章在三个数据集 IEMOCAP、EMODB 和 CID 分别获得了 0.92%、1.54% 和 2.19% 的提升，结果证明了所提出算法的有效性、泛化性和实用性。

4. 基于残差多尺度卷积 Transformer 网络的语音情感识别

情感的主观性和连续性使得离散情感标签无法准确衡量情感在话语中的变化，导致特征提取过程中模型对于情感显著性特征提取能力较弱，同时在语音信号处理时所截取片段标签与句子标签也不匹配。因此，本文提出基于残差多尺度卷积 Transformer 网络的维度语音情感识别算法，从三个情感维度预测样本中激活度、愉悦度、支配度的值，提升情感识别精度。首先根据所使用数据集中最大时长，利用动态帧移算法对每个情感样本生成等量的块级信号，并对其提取三通道语谱图，保持块级时间顺序下输入到提出的残差多尺度自适应位置编码 Transformer 模块中，以获取高维特征中全局显著性情感块级特征。其次利用时间聚合策略将情感块级特征生成句子级情感特征分布，利用均方误差损失函数实现维度语音情感识别。实验在三个公开可用的数据集 MSP-Podcast 1.9、IEMOCAP 和 MSP-IMPROV 上实现，在 MSP-Podcast 数据集中三个标签上取得了较好的实验结果，在三个维度识别中分别获得 0.5459、0.1615 和 0.4200 的相关一致系数结果，IEMOCAP 和 MSP-IMPROV 数据集在与其他研究的对比实验中，均取得良好结果，证明了所提出方法可有效提升模型在三个维度下的识别精度。

本文的主要创新点如下:

1. 提出了一种基于小波包重构特征自适应注意力网络的语音情感识别算法。首先提出利用小波包重构方法解析声学语音信号, 突显帧级声学特征中时频分辨率情感信息的表征能力。其次提出自适应注意力网络用于获取显著性声学特征并生成帧级特征分布, 联合原始信号中获取的句子级声学特征完成语音情感识别。该算法解决了在语音情感识别过程中, 传统声学语音特征在时频域内表征信号局部特征能力较弱和在特征提取过程中显著性情感信息特征捕捉能力不足的问题。

2. 提出了基于自适应时频注意力残差网络的语音情感识别算法。首先在三通道语谱图的特征提取过程中, 提出构建空洞卷积和残差结构的卷积模块, 并使用双向门控循环模块获取与时序相关的特征。其次提出自适应时频注意力机制模块, 捕捉时序特征内显著性语音情感信息, 生成更具判别力的特征分布来完成语音情感识别。该算法解决了语音情感识别过程中, 普通卷积神经网络因获取全局信息能力不足而导致部分情感特征丢失, 以及在时域维度中相关特征信息表征情感能力较弱的问题。

3. 提出了基于动态自适应空间注意力网络的语音情感识别算法。首先通过卷积模块对语谱图进行特征提取以获得高维特征, 然后提出时频注意力循环模块用于从高维特征中捕获与时序相关特征, 并生成包含全局信息的显著性特征分布。其次提出空间注意力循环模块用于提取高维特征中时频二维局部空间的情感特征, 生成包含局部空间信息的显著性特征分布, 然后联合两类特征分布完成语音情感识别。该算法解决了在语音情感识别特征提取过程中高维特征内时频二维局部空间情感相关信息遗漏问题。

4. 提出了基于残差多尺度卷积 Transformer 网络的语音情感识别算法。首先提出动态帧移算法使语音信号生成相同数量的块级片段并提取语谱图, 实现块级片段与句子标签匹配下的模型并行训练。其次提出构建自适应特征位置编码结构的多尺度卷积模块, 使 Transformer 能够获取块级片段情感显著性特征。最后提出均值池化时间聚合策略生成句子级情感特征分布完成语音情感识别。该算法解决了离散情感识别算法因无法准确衡量出情感在话语中的变化而存在的局限性, 语音信号处理过程中所截取的语音片段标签与句子标签不匹配, 以及语音情感识别特征提取过程中情感显著性特征提取能力较弱的问题。

本文重点研究了基于深度学习算法的语音情感识别, 并取得了一些进展, 但目前仍存在一些问题, 值得在未来进一步研究与探索。就目前本文的研究进展而言, 未来可继续对以下问题进行深入研究:

(1) 本文用来验证实验算法的数据集来自于公共数据集和自设计数据集, 这些数据集中的大部分情感语音样本不是自发的对话交流状态, 而是在采集者的引导下捕捉到的。如果在未来应用推广到现实生活中, 难免会存在偏差, 而且情感具有主观性, 有一些样本的标签并不准确, 因此, 未来将对自发情感语音进行进一步探索。

(2) 本文提出的方法都是致力于通过注意力机制结构帮助加强模型整体对情感语音的特征提取从而提升识别精度, 但是模型计算量大, 超参数略多, 除了提升准确率之外, 如何减少模型计算参数是语音情感识别方法的又一个改进方向, 因此, 未来研究需要使模型更加轻量化。

(3) 本文提出算法所使用的情感语音样本都是基于单一样本, 没有与上下文对话建立联系, 在情感特征提取过程中会造成一定的信息损失, 因此如何合理建立基于上下文对话的语音情感识别模型在未来将进行进一步研究。

参考文献

- [1] Shin B R, Lee S P. A Comparison of Effective Feature Vectors for Speech Emotion Recognition[J]. The transactions of The Korean Institute of Electrical Engineers, 2018, 67(10): 1364-1369.
- [2] Liu M, Chen H, Li Y, et al. Emotional tone-based audio continuous emotion recognition[C]. MultiMedia Modeling: 21st International Conference, MMM 2015, Sydney, NSW, Australia, January 5-7, 2015, Proceedings, Part II 21. Springer International Publishing, 2015: 470-480.
- [3] Rázuri J G, Sundgren D, Rahmani R, et al. Speech emotion recognition in emotional feedback for human-robot interaction[J]. International Journal of Advanced Research in Artificial Intelligence (IJARAI), 2015, 4(2): 20-27.
- [4] Ingale A B, Chaudhari D S. Speech emotion recognition[J]. International Journal of Soft Computing and Engineering (IJSCE), 2012, 2(1): 235-238.
- [5] Fahad M S, Ranjan A, Yadav J, et al. A survey of speech emotion recognition in natural environment[J]. Digital signal processing, 2021, 110: 102951.
- [6] 高利军, 薛雷. 语音情感识别综述 [J]. 工业控制计算机, 2022, 35(10): 115-6+20.
- [7] Kerkeni L, Serrestou Y, Mbarki M, et al. A review on speech emotion recognition: Case of pedagogical interaction in classroom[C]. 2017 International Conference on Advanced Technologies for Signal and Image Processing (ATSIP). IEEE, 2017: 1-7.
- [8] Tickle A, Raghu S, Elshaw M. Emotional recognition from the speech signal for a virtual education agent[C]. Journal of Physics: Conference Series. IOP Publishing, 2013, 450(1): 012053.
- [9] Tanko D, Dogan S, Demir F B, et al. Shoelace pattern-based speech emotion recognition of the lecturers in distance education: ShoePat23[J]. Applied Acoustics, 2022, 190: 108637.
- [10] 卢建朋. 语音情感识别在教学中的应用研究与分析 [J]. 科技传播, 2022, 14(15): 103-5+9.
- [11] Tan L, Yu K, Lin L, et al. Speech emotion recognition enhanced traffic efficiency solution for autonomous vehicles in a 5G-enabled space-air-ground integrated

- intelligent transportation system[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(3): 2830-2842.
- [12] Braun M, Chadowitz R, Alt F. User experience of driver state visualizations: A look at demographics and personalities[C]. Human-Computer Interaction–INTERACT 2019: 17th IFIP TC 13 International Conference, Paphos, Cyprus, September 2–6, 2019, Proceedings, Part IV 17. Springer International Publishing, 2019: 158-176.
- [13] Li W, Cui Y, Ma Y, et al. A spontaneous driver emotion facial expression (defe) dataset for intelligent vehicles: Emotions triggered by video-audio clips in driving scenarios[J]. IEEE Transactions on Affective Computing, 2021.
- [14] Tan H, Zhang H, Shi J, et al. Speech-Based Driver Emotion Recognition[C]. Green Transportation and Low Carbon Mobility Safety: Proceedings of the 12th International Conference on Green Intelligent Transportation Systems and Safety. Singapore: Springer Nature Singapore, 2022: 577-587.
- [15] Cummins N, Vlasenko B, Sagha H, et al. Enhancing speech-based depression detection through gender dependent vowel-level formant features[C]. Artificial Intelligence in Medicine: 16th Conference on Artificial Intelligence in Medicine, AIME 2017, Vienna, Austria, June 21-24, 2017, Proceedings 16. Springer International Publishing, 2017: 209-214.
- [16] Deschamps-Berger T, Lamel L, Devillers L. End-to-end speech emotion recognition: challenges of real-life emergency call centers data recordings[C]. 2021 9th International Conference on Affective Computing and Intelligent Interaction (ACII). IEEE, 2021: 1-8.
- [17] 史国燕, 樊思滢, 王乐. 语音情感识别技术在心理辅导中的研究和应用 [J]. 长江信息通信, 2022, 35(09): 19-22.
- [18] Dong Y, Yang X. A hierarchical depression detection model based on vocal and emotional cues[J]. Neurocomputing, 2021, 441: 279-290.
- [19] Adyapady R R, Annappa B. A comprehensive review of facial expression recognition techniques[J]. Multimedia Systems, 2023, 29(1): 73-103.
- [20] Hossain S, Umer S, Rout R K, et al. Fine-grained image analysis for facial expression recognition using deep convolutional neural networks with bilinear pooling[J]. Applied Soft Computing, 2023: 109997.

- [21] Kumar P, Raman B. A BERT based dual-channel explainable text emotion recognition system[J]. *Neural Networks*, 2022, 150: 392-407.
- [22] Deng J, Ren F. A survey of textual emotion recognition and its challenges[J]. *IEEE Transactions on Affective Computing*, 2021.
- [23] Wang Z, Ren J, Zhang D, et al. A deep-learning based feature hybrid framework for spatiotemporal saliency detection inside videos[J]. *Neurocomputing*, 2018, 287: 68-83.
- [24] Starner T, Mann S, Rhodes B, et al. Augmented reality through wearable computing[J]. *Presence: Teleoperators & Virtual Environments*, 1997, 6(4): 386-398.
- [25] Plutchik R. The nature of emotions: Human emotions have deep evolutionary roots, a fact that may explain their complexity and provide tools for clinical practice[J]. *American scientist*, 2001, 89(4): 344-350.
- [26] Akçay M B, Oğuz K. Speech emotion recognition: Emotional models, databases, features, preprocessing methods, supporting modalities, and classifiers[J]. *Speech Communication*, 2020, 116: 56-76.
- [27] Ekman P, Friesen W V, Ellsworth P. Emotion in the human face: Guidelines for research and an integration of findings[M]. Elsevier, 2013.
- [28] Shamsi M, Tahon M. Training speech emotion classifier without categorical annotations[J]. *arXiv preprint arXiv:2210.07642*, 2022.
- [29] Chen P, Zou B, Belkacem A N, et al. An improved multi-input deep convolutional neural network for automatic emotion recognition[J]. *Frontiers in Neuroscience*, 2022, 16: 965871.
- [30] Grimm M, Kroschel K, Mower E, et al. Primitives-based evaluation and estimation of emotions in speech[J]. *Speech communication*, 2007, 49(10-11): 787-800.
- [31] 李永伟, 陶建华, 李凯. 基于声门波和声道特征的语音情感识别 [J]. *信号处理*, 2023, 39(04): 632-8.
- [32] 赵鑫. 基于深度学习的语音情感识别方法研究 [J]. *山西电子技术*, 2022, (06): 83-5.
- [33] 张霞, 杨勇, 赵力. 基于复数帧段特征的语音情感识别方法 [J]. *电子器件*, 2022, 45(02): 479-82.
- [34] Yeh S L, Lin Y S, Lee C C. A dialogical emotion decoder for speech emotion recognition in spoken dialog[C]. *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2020: 6479-6483.

- [35] Busso C, Bulut M, Lee C C, et al. IEMOCAP: Interactive emotional dyadic motion capture database[J]. *Language resources and evaluation*, 2008, 42: 335-359.
- [36] Busso C, Parthasarathy S, Burmania A, et al. MSP-IMPROV: An acted corpus of dyadic interactions to study emotion perception[J]. *IEEE Transactions on Affective Computing*, 2016, 8(1): 67-80.
- [37] Lotfian R, Busso C. Building naturalistic emotionally balanced speech corpus by retrieving emotional speech from existing podcast recordings[J]. *IEEE Transactions on Affective Computing*, 2017, 10(4): 471-483.
- [38] Mariooryad S, Lotfian R, Busso C. Building a naturalistic emotional speech corpus by retrieving expressive behaviors from existing speech corpora[C]. *Fifteenth Annual Conference of the International Speech Communication Association*. 2014.
- [39] Burmania A, Parthasarathy S, Busso C. Increasing the reliability of crowdsourcing evaluations using online quality assessment[J]. *IEEE Transactions on Affective Computing*, 2015, 7(4): 374-388.
- [40] Burkhardt F, Paeschke A, Rolfes M, et al. A database of German emotional speech[C]. *Interspeech*. 2005, 5: 1517-1520.
- [41] Liu S, Liu S, Cai W, et al. Multimodal neuroimaging feature learning for multiclass diagnosis of Alzheimer's disease[J]. *IEEE transactions on biomedical engineering*, 2014, 62(4): 1132-1140.
- [42] Lee C M, Narayanan S S, Pieraccini R. Combining acoustic and language information for emotion recognition[C]. *INTERSPEECH*. 2002.
- [43] Schuller B, Rigoll G, Lang M. Speech emotion recognition combining acoustic features and linguistic information in a hybrid support vector machine-belief network architecture[C]. *2004 IEEE international conference on acoustics, speech, and signal processing*. IEEE, 2004, 1: I-577.
- [44] Lee C C, Mower E, Busso C, et al. Emotion recognition using a hierarchical binary decision tree approach[J]. *Speech Communication*, 2011, 53(9-10): 1162-1171.
- [45] Lanjewar R B, Mathurkar S, Patel N. Implementation and comparison of speech emotion recognition system using Gaussian Mixture Model (GMM) and K-Nearest Neighbor (K-NN) techniques[J]. *Procedia computer science*, 2015, 49: 50-57.

- [46] Tzinis E, Potamianos A. Segment-based speech emotion recognition using recurrent neural networks[C]. 2017 Seventh International Conference on Affective Computing and Intelligent Interaction (ACII). IEEE, 2017: 190-195.
- [47] Mirsamadi S, Barsoum E, Zhang C. Automatic speech emotion recognition using recurrent neural networks with local attention[C]. 2017 IEEE International conference on acoustics, speech and signal processing (ICASSP). IEEE, 2017: 2227-2231.
- [48] Chernykh V, Prihodko P. Emotion recognition from speech with recurrent neural networks[J]. arXiv preprint arXiv:1701.08071, 2017.
- [49] Sarma M, Ghahremani P, Povey D, et al. Emotion Identification from Raw Speech Signals Using DNNs[C]. Interspeech. 2018: 3097-3101.
- [50] Xie Y, Liang R, Liang Z, et al. Attention-based dense LSTM for speech emotion recognition[J]. IEICE TRANSACTIONS on Information and Systems, 2019, 102(7): 1426-1429.
- [51] Atmaja B T, Akagi M. Dimensional speech emotion recognition from speech features and word embeddings by using multitask learning[J]. APSIPA Transactions on Signal and Information Processing, 2020, 9: e17.
- [52] Fahad M S, Deepak A, Pradhan G, et al. DNN-HMM-based speaker-adaptive emotion recognition using MFCC and epoch-based features[J]. Circuits, Systems, and Signal Processing, 2021, 40: 466-489.
- [53] Lin W C, Busso C. Chunk-level speech emotion recognition: A general framework of sequence-to-one dynamic temporal modeling[J]. IEEE Transactions on Affective Computing, 2021.
- [54] Rao K S, Koolagudi S G, Vempada R R. Emotion recognition from speech using global and local prosodic features[J]. International journal of speech technology, 2013, 16: 143-160.
- [55] Lugger M, Yang B. The relevance of voice quality features in speaker independent emotion recognition[C]. 2007 IEEE International Conference on Acoustics, Speech and Signal Processing-ICASSP'07. IEEE, 2007, 4: IV-17-IV-20.
- [56] Li X, Tao J, Johnson M T, et al. Stress and emotion classification using jitter and shimmer features[C]. 2007 IEEE International Conference on Acoustics, Speech and Signal Processing-ICASSP'07. IEEE, 2007, 4: IV-1081-IV-1084.

- [57] Sato N, Obuchi Y. Emotion recognition using mel-frequency cepstral coefficients[J]. Information and Media Technologies, 2007, 2(3): 835-848.
- [58] Bitouk D, Verma R, Nenkova A. Class-level spectral features for emotion recognition[J]. Speech communication, 2010, 52(7-8): 613-625.
- [59] Zhou G, Hansen J H L, Kaiser J F. Nonlinear feature based classification of speech under stress[J]. IEEE Transactions on speech and audio processing, 2001, 9(3): 201-216.
- [60] Kerkeni L, Serrestou Y, Mbarki M, et al. Automatic speech emotion recognition using machine learning[J]. 2019.
- [61] Anusha R, Subhashini P, Jyothi D, et al. Speech emotion recognition using machine learning[C]. 2021 5th International Conference on Trends in Electronics and Informatics (ICOEI). IEEE, 2021: 1608-1612.
- [62] Jain M, Narayan S, Balaji P, et al. Speech emotion recognition using support vector machine[J]. arXiv preprint arXiv:2002.07590, 2020.
- [63] 蒯红权, 吴建华, 吴亮. 基于注意力机制的深度循环神经网络的语音情感识别 [J]. 电子器件, 2022, 45(01): 139-42.
- [64] Prakash P R, Anuradha D, Iqbal J, et al. A novel convolutional neural network with gated recurrent unit for automated speech emotion recognition and classification[J]. Journal of Control and Decision, 2023, 10(1): 54-63.
- [65] 陈港, 张石清, 赵小明. 结合数据平衡和注意力机制的 CNN+LSTM 的自然语音情感识别 [J]. 计算机系统应用, 2021, 30(05): 269-75.
- [66] Baruah M, Banerjee B. Speech emotion recognition via generation using an attention-based variational recurrent neural network[J]. Proc. Interspeech 2022, 2022: 4710-4714.
- [67] Shahin I, Hindawi N, Nassif A B, et al. Novel dual-channel long short-term memory compressed capsule networks for emotion recognition[J]. Expert Systems with Applications, 2022, 188: 116080.
- [68] 张会云, 黄鹤鸣, 李伟, et al. 基于 AA-LSTM 网络的语音情感识别研究 [J]. 计算机仿真, 2021, 38(03): 211-6.
- [69] Cairong Z, Xinran Z, Cheng Z, et al. A novel DBN feature fusion model for cross-corpus speech emotion recognition[J]. Journal of Electrical and Computer Engineering, 2016, 2016.

- [70] Schuller B, Arsic D, Rigoll G, et al. Audiovisual behavior modeling by combined feature spaces; proceedings of the 2007 IEEE International Conference on Acoustics, Speech and Signal Processing-ICASSP'07, F, 2007 [C]. IEEE.
- [71] Kim E, Shin J W. Dnn-based emotion recognition based on bottleneck acoustic features and lexical features[C]. ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 6720-6724.
- [72] Aldeneh Z, Provost E M. Using regional saliency for speech emotion recognition[C]. 2017 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2017: 2741-2745.
- [73] Lee J, Tashev I. High-level feature representation using recurrent neural network for speech emotion recognition[C]. Interspeech 2015. 2015.
- [74] Latif S, Rana R, Khalifa S, et al. Direct modelling of speech emotion from raw speech[J]. arXiv preprint arXiv:1904.03833, 2019.
- [75] Bhosale S, Chakraborty R, Kopparapu S K. Deep encoded linguistic and acoustic cues for attention based end to end speech emotion recognition[C]. ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 7189-7193.
- [76] Sajjad M, Kwon S. Clustering-based speech emotion recognition by incorporating learned features and deep BiLSTM[J]. IEEE access, 2020, 8: 79861-79875.
- [77] 耿磊, 傅洪亮, 陶华伟, et al. 基于动态卷积递归神经网络的语音情感识别 [J]. 计算机工程, 2023, 49(04): 125-30+37.
- [78] Trigeorgis G, Ringeval F, Brueckner R, et al. Adieu features? end-to-end speech emotion recognition using a deep convolutional recurrent network[C]. 2016 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2016: 5200-5204.
- [79] Lim W, Jang D, Lee T. Speech emotion recognition using convolutional and recurrent neural networks[C]. 2016 Asia-Pacific signal and information processing association annual summit and conference (APSIPA). IEEE, 2016: 1-4.
- [80] 李瑞航, 吴红兰, 孙有朝, et al. 基于深度残差收缩网络多特征融合语音情感识别 [J]. 数据采集与处理, 2022, 37(03): 542-54.

- [81] 夏玉果, 杜静, 赵力. 基于 3D 倒谱特征和注意力机制的 CNN-BiLSTM 语音情感识别 [J]. 电子器件, 2022, 45(06): 1434-40.
- [82] Wu X, Liu S, Cao Y, et al. Speech emotion recognition using capsule networks[C]. ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 6695-6699.
- [83] 甘宏. 一种基于注意力机制的语音情感识别算法研究 [J]. 江西科学, 2022, 40(04): 758-61.
- [84] Tao F, Liu G. Advanced LSTM: A study about better time dependency modeling in emotion recognition[C]. 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2018: 2906-2910.
- [85] 高利军, 薛雷. 基于 Transformer 架构的语音情感识别研究 [J]. 工业控制计算机, 2023, 36(01): 82-3+6.
- [86] Yoon S, Byun S, Dey S, et al. Speech emotion recognition using multi-hop attention mechanism[C]. ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 2822-2826.
- [87] Nediyanath A, Paramasivam P, Yenigalla P. Multi-head attention for speech emotion recognition with auxiliary learning of gender recognition[C]. ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 7179-7183.
- [88] Yeh S L, Lin Y S, Lee C C. An interaction-aware attention network for speech emotion recognition in spoken dialogs[C]. ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 6685-6689.
- [89] 徐华南, 周晓彦, 姜万, et al. 基于自身注意力时空特征的语音情感识别算法 [J]. 声学技术, 2021, 40(06): 807-14.
- [90] Li Y, Zhao T, Kawahara T. Improved End-to-End Speech Emotion Recognition Using Self Attention Mechanism and Multitask Learning[C]. Interspeech. 2019: 2803-2807.
- [91] Xie Y, Liang R, Liang Z, et al. Speech emotion classification using attention-based LSTM[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2019, 27(11): 1675-1685.

- [92] Liu C L, Yin F, Wang D H, et al. CASIA online and offline Chinese handwriting databases[C]. 2011 international conference on document analysis and recognition. IEEE, 2011: 37-41.
- [93] Tarantino L, Garner P N, Lazaridis A. Self-Attention for Speech Emotion Recognition[C]. Interspeech. 2019: 2578-2582.
- [94] Xu H, Zhang H, Han K, et al. Learning alignment for multimodal emotion recognition from speech [J]. arXiv preprint arXiv:190905645, 2019.
- [95] Li D, Liu J, Yang Z, et al. Speech emotion recognition using recurrent neural networks with directional self-attention[J]. Expert Systems with Applications, 2021, 173: 114683.
- [96] Schuller B, Batliner A, Steidl S, et al. Recognising realistic emotions and affect in speech: State of the art and lessons learnt from the first challenge[J]. Speech communication, 2011, 53(9-10): 1062-1087.
- [97] Tzirakis P, Zhang J, Schuller B W. End-to-end speech emotion recognition using deep neural networks[C]. 2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 5089-5093.
- [98] Parthasarathy S, Busso C. Semi-supervised speech emotion recognition with ladder networks[J]. IEEE/ACM transactions on audio, speech, and language processing, 2020, 28: 2697-2709.
- [99] Atmaja B T, Akagi M. Improving valence prediction in dimensional speech emotion recognition using linguistic information[C]. 2020 23rd Conference of the Oriental COCOSDA International Committee for the Co-ordination and Standardisation of Speech Databases and Assessment Techniques (O-COCOSDA). IEEE, 2020: 166-171.
- [100] Sridhar K, Busso C. Ensemble of Students Taught by Probabilistic Teachers to Improve Speech Emotion Recognition[C]. INTERSPEECH. 2020: 516-520.
- [101] Li M, Yang B, Levy J, et al. Contrastive unsupervised learning for speech emotion recognition[C]. ICASSP 2021-2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2021: 6329-6333.
- [102] Wagner J, Triantafyllopoulos A, Wierstorf H, et al. Dawn of the transformer era in speech emotion recognition: closing the valence gap[J]. arXiv preprint arXiv:2203.07378, 2022.

- [103] Seo J, Lee B. Multi-Task Conformer with Multi-Feature Combination for Speech Emotion Recognition[J]. Symmetry, 2022, 14(7): 1428.
- [104] Mariooryad S, Lotfian R, Busso C. Building a naturalistic emotional speech corpus by retrieving expressive behaviors from existing speech corpora[C]. Fifteenth Annual Conference of the International Speech Communication Association. 2014.
- [105] Kawade R, Bhalke D G. Speech Emotion Recognition Based on Wavelet Packet Coefficients[C]//ICCCE 2021: Proceedings of the 4th International Conference on Communications and Cyber Physical Engineering. Singapore: Springer Nature Singapore, 2022: 823-828.
- [106] 程适, 骆晓宁, 李冬城, et al. 一种基于双向 LSTM 的语音情感识别模型 [J]. 长江信息通信, 2022, 35(07): 19-22.
- [107] Huang C W, Narayanan S S. Deep convolutional recurrent neural network with attention mechanism for robust speech emotion recognition[C]. 2017 IEEE international conference on multimedia and expo (ICME). IEEE, 2017: 583-588.
- [108] Chen M, He X, Yang J, et al. 3-D convolutional recurrent neural networks with attention model for speech emotion recognition[J]. IEEE Signal Processing Letters, 2018, 25(10): 1440-1444.
- [109] Eyben F, Wöllmer M, Schuller B. Opensmile: the munich versatile and fast open-source audio feature extractor[C]. Proceedings of the 18th ACM international conference on Multimedia. 2010: 1459-1462.
- [110] Han K, Yu D, Tashev I. Speech emotion recognition using deep neural network and extreme learning machine[C]. Interspeech 2014. 2014.
- [111] Sebastian J, Pierucci P. Fusion Techniques for Utterance-Level Emotion Recognition Combining Speech and Transcripts[C]. Interspeech. 2019: 51-55.
- [112] Huang Y, Wu A, Zhang G, et al. Speech emotion recognition based on deep belief networks and wavelet packet cepstral coefficients[J]. International Journal of Simulation: Systems, Science and Technology, 2016, 17(28): 28.1-28.5.
- [113] Albornoz E M, Milone D H, Rufiner H L. Spoken emotion recognition using hierarchical classifiers[J]. Computer Speech & Language, 2011, 25(3): 556-570.

- [114] Deng J, Zhang Z, Marchi E, et al. Sparse autoencoder-based feature transfer learning for speech emotion recognition[C]. 2013 humane association conference on affective computing and intelligent interaction. IEEE, 2013: 511-516.
- [115] Mao Q, Dong M, Huang Z, et al. Learning salient features for speech emotion recognition using convolutional neural networks[J]. IEEE transactions on multimedia, 2014, 16(8): 2203-2213.
- [116] Bai S, Kolter J Z, Koltun V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. arXiv preprint arXiv:1803.01271, 2018.
- [117] Zheng W Q, Yu J S, Zou Y X. An experimental study of speech emotion recognition based on deep convolutional neural networks[C]. 2015 international conference on affective computing and intelligent interaction (ACII). IEEE, 2015: 827-831.
- [118] Han W, Ruan H, Chen X, et al. Towards temporal modelling of categorical speech emotion recognition[C]. Interspeech. 2018, 2018: 932-936.
- [119] Kim J, Engleblenne G, Truong K P, et al. Deep temporal models using identity skip-connections for speech emotion recognition[C]. Proceedings of the 25th ACM international conference on Multimedia. 2017: 1006-1013.
- [120] Kong Q, Cao Y, Iqbal T, et al. Panns: Large-scale pretrained audio neural networks for audio pattern recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020, 28: 2880-2894.
- [121] Gauy M M, Finger M. Pretrained audio neural networks for Speech emotion recognition in Portuguese[J]. arXiv preprint arXiv:2210.14716, 2022.
- [122] Bautista J L, Lee Y K, Shin H S. Speech Emotion Recognition Based on Parallel CNN-Attention Networks with Multi-Fold Data Augmentation[J]. Electronics, 2022, 11(23): 3935.
- [123] Park D S, Chan W, Zhang Y, et al. Specaugment: A simple data augmentation method for automatic speech recognition[J]. arXiv preprint arXiv:1904.08779, 2019.
- [124] Badshah A M, Rahim N, Ullah N, et al. Deep features-based speech emotion recognition for smart affective services[J]. Multimedia Tools and Applications, 2019, 78: 5571-5589.
- [125] 董炳辰, 汤鲲. 基于深度学习网络的语音情感识别方法研究 [J]. 计算机与数字工程, 2022, 50(08): 1771-5.

- [126] Wen Y, Zhang K, Li Z, et al. A discriminative feature learning approach for deep face recognition[C]. Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part VII 14. Springer International Publishing, 2016: 499-515.
- [127] 宋鹏, 李绍凯, 张雯婧, et al. 基于迁移判别回归的跨域语音情感识别 [J]. 信号处理, 2023, 39(04): 649-57.
- [128] Han Z, Zhao H, Wang R. Transfer learning for speech emotion recognition[C]//2019 IEEE 5th Intl Conference on Big Data Security on Cloud (BigDataSecurity), IEEE Intl Conference on High Performance and Smart Computing,(HPSC) and IEEE Intl Conference on Intelligent Data and Security (IDS). IEEE, 2019: 96-99.
- [129] 李晓坤, 李洪亮. 基于深度迁移学习的跨库语音情感识别 [J]. 通信技术, 2021, 54(04): 848-52.
- [130] Ghosh S, Laksana E, Morency L P, et al. Representation learning for speech emotion recognition[C]. Interspeech. 2016: 3603-3607.
- [131] Yao Z, Wang Z, Liu W, et al. Speech emotion recognition using fusion of three multi-task learning-based classifiers: HSF-DNN, MS-CNN and LLD-RNN[J]. Speech Communication, 2020, 120: 11-19.
- [132] Neumann M, Vu N T. Improving speech emotion recognition with unsupervised representation learning on unlabeled speech[C]. ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 7390-7394.
- [133] Yenigalla P, Kumar A, Tripathi S, et al. Speech Emotion Recognition Using Spectrogram & Phoneme Embedding[C]. Interspeech. 2018, 2018: 3688-3692.
- [134] Tiwari U, Soni M, Chakraborty R, et al. Multi-conditioning and data augmentation using generative noise model for speech emotion recognition in noisy conditions[C]. ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 7194-7198.
- [135] Chauhan K, Sharma K K, Varma T. Speech emotion recognition using convolution neural networks[C]. 2021 international conference on artificial intelligence and smart systems (ICAIS). IEEE, 2021: 1176-1181.

- [136] Huang Y, Wu A, Zhang G, et al. Extraction of adaptive wavelet packet filter - bank - based acoustic feature for speech emotion recognition[J]. IET Signal Processing, 2015, 9(4): 341-348.
- [137] Badshah A M, Ahmad J, Rahim N, et al. Speech emotion recognition from spectrograms with deep convolutional neural network[C]. 2017 international conference on platform technology and service (PlatCon). IEEE, 2017: 1-5.
- [138] Zhu L, Deng R, Maire M, et al. Sparsely aggregated convolutional networks[C]. Proceedings of the European Conference on Computer Vision (ECCV). 2018: 186-201.
- [139] Guo M, Yang Y, Xu R, et al. When nas meets robustness: In search of robust architectures against adversarial attacks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 631-640.
- [140] Cornia M, Baraldi L, Serra G, et al. Predicting human eye fixations via an lstm-based saliency attentive model[J]. IEEE Transactions on Image Processing, 2018, 27(10): 5142-5154.
- [141] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]. Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [142] Latif S, Rana R, Qadir J, et al. Variational autoencoders for learning latent representations of speech emotion: A preliminary study[J]. arXiv preprint arXiv:1712.08708, 2017.
- [143] Schuller B W, Batliner A, Bergler C, et al. The INTERSPEECH 2021 computational paralinguistics challenge: COVID-19 cough, COVID-19 speech, escalation & primates[J]. arXiv preprint arXiv:2102.13468, 2021.
- [144] Ponomarchuk A, Burenko I, Malkin E, et al. Project Achoo: a practical model and application for COVID-19 detection from recordings of breath, voice, and cough[J]. IEEE Journal of Selected Topics in Signal Processing, 2022, 16(2): 175-187.
- [145] Hossain M Z, Uddin M B, Ahmed K A. Covidenvelope: A fast automated approach to diagnose Covid-19 from cough signals[J]. medRxiv, 2021: 2021.04. 16.21255630.
- [146] Atmaja B T, Hamada Y, Akagi M. Predicting valence and arousal by aggregating acoustic features for acoustic-linguistic information fusion[C]. 2020 IEEE REGION 10 CONFERENCE (TENCON). IEEE, 2020: 1081-1085.

- [147] Gerczuk M, Amiriparian S, Ottl S, et al. Emonet: A transfer learning framework for multi-corpus speech emotion recognition[J]. IEEE Transactions on Affective Computing, 2021, 1-16.
- [148] Guo L, Wang L, Dang J, et al. Learning affective representations based on magnitude and dynamic relative phase information for speech emotion recognition[J]. Speech Communication, 2022, 136: 118-127.
- [149] Zhang Y, Du J, Wang Z, et al. Attention based fully convolutional network for speech emotion recognition[C]. 2018 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC). IEEE, 2018: 1771-1775.
- [150] Arias J P, Busso C, Yoma N B. Shape-based modeling of the fundamental frequency contour for emotion detection in speech[J]. Computer Speech & Language, 2014, 28(1): 278-294.
- [151] 杨磊, 赵红东, 于快快. 基于多头注意力机制的端到端语音情感识别 [J]. 计算机应用, 2022, 42(06): 1869-75.
- [152] Liu S, Mallol-Ragolta A, Yan T, et al. Capturing Time Dynamics From Speech Using Neural Networks for Surgical Mask Detection[J]. IEEE Journal of Biomedical and Health Informatics, 2022, 26(8): 4291-4302.
- [153] Zhu W, Li X. Speech Emotion Recognition with Global-Aware Fusion on Multi-Scale Feature Representation[C]. ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 6437-6441.
- [154] Van Boven L, White K, Huber M. Immediacy bias in emotion perception: Current emotions seem more intense than previous emotions[J]. Journal of Experimental Psychology: General, 2009, 138(3): 368.
- [155] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]. Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part I 16. Springer International Publishing, 2020: 213-229.