

学校代码: 10285

学 号: 20215227066



# 硕士学位论文

(专业学位)



基于深度学习的音频时频谱分类方法研究

Deep Learning Based Audio Spectrogram Classification

|        |            |
|--------|------------|
| 研究生姓名  | 王萌威        |
| 指导教师姓名 | 杨哲         |
| 专业名称   | 计算机技术      |
| 研究方向   | 音频信号处理     |
| 所在院部   | 计算机科学与技术学院 |
| 论文提交日期 | 2024年6月    |

# 基于深度学习的音频时频谱分类方法研究

## 摘 要

对音频内容的分类是音频信号处理的一项基础任务，它可以帮助语音识别、语音合成等上层应用的组织、分析和理解音频信号。时频谱作为深度学习模型在处理音频内容分类任务时广泛采用的一种音频特征，具有许多其他特征所不具备的独特属性，比如频率维模式分布的局部性、时间维和频率维代表物理意义的差异性以及频率维特征的非平移不变性，然而现有模型往往缺少对这些特点的发掘和利用，使得模型的性能任然存在提升的空间。为了更有效地利用时频谱的特性，对三个面向不同应用场景的音频内容分类任务中常用的深度学习模型，进行了针对时频谱特性的改进。

为了使时延神经网络（Time Delay Neural Network，简称 TDNN）更好地利用时频谱频率维中的局部特征，提出了一种设置在 TDNN 主干模型前的基于子频带划分的前端模型。前端模型将时频谱划分为多个子频带，并逐层扩大子频带的频率范围。前端模型包含局部频率信息的输出特征作为主干模型的输入，使 TDNN 能够在局部频率特征的基础上进行建模。在说话人识别数据集中的实验表明，提出的模型相较于基线模型错误率最高相对降低了 14%，而参数量只为基线模型的 52%。

为了使卷积神经网络（Convolutional Neural Network，简称 CNN）利用时频谱频率维特征的非平移不变性，提出一种新的 CNN 模型称为时频增强卷积神经网络（Time-Frequency Enhanced Convolutional Neural Network，简称 TFECN）。TFECN 通过对卷积核大小的设计避免卷积核在频率维的参数共享，进而避免 CNN 将位于频率维不同位置的相同时频模式识别为相同的语义。此外，为了避免改进后卷积方法缺失对局部特征的建模，还提出一种将预训练小卷积核权重迁移至大卷积核中的方法。在声音事件分类数据集中的实验表明，提出的模型相较于传统的 CNN 方法，精度相对提升了 6%。

为了使 Transformer 更好地建模时频谱频率维的局部特征，同时考虑到时频谱两个维度不同的属性，提出一种新的双分支 Transformer 模型。模型中的第一个分支以类似 TDNN 的方式处理时频谱，该分支虽然能够考虑到时频谱时间维和频率维的差异，但缺少对局部频率特征的建模。第二个分支引入分块化过程处理时频谱，该分支虽然能够建模局部频率特征，但无法对时间维和频率维进行区分。通过在模型中同时

引入这两个分支，来利用两个分支的优点去缓解彼此的缺点。在语音情感识别数据集  
中的实验表明，提出的模型取得了超越目前先进模型的准确率。

**关键词：**音频内容分类，时频谱特征，时延神经网络，卷积神经网络，Transformer

作 者：王萌威

指导老师：杨 哲

# Deep Learning Based Audio Spectrogram Classification

## Abstract

Classification of audio content is a fundamental task in audio signal processing, which can help the organization, analysis and understanding of audio signals for upper layer applications such as speech recognition and speech synthesis. The spectrogram, as an audio feature widely used by deep learning models for audio content classification tasks, has many unique properties that other features do not have, such as the localization of the distribution of frequency dimension, the discrepancy between time and frequency dimensions, and the non-shift invariance of frequency-dimensional features, yet existing models often lack the exploration and utilization of these features, allowing any improvement in the performance of the model. In order to utilize the spectrogram more effectively, three deep learning models commonly used in audio content classification tasks facing different application scenarios are improved for the spectrogram feature.

In order to make the time-delay neural network (TDNN) better utilize the local features in the frequency dimension of the spectrogram, proposes a front-end model based on sub-band segmentation set in front of the backbone model of the TDNN. The front-end model divides the spectrogram into multiple sub-bands and expands the frequency range of the sub-bands layer by layer. The front-end model contains output features with local frequency information as inputs to the backbone model, enabling TDNN to be modeled on the basis of local frequency features. Experiments on a speaker recognition dataset show that the proposed model has the highest relative reduction of 14% in error rate compared to the baseline model, while the number of parameters is only 52% of the baseline model.

In order to make the convolutional neural network (CNN) utilize the non-shift invariance of the frequency-dimensional features of the spectrogram, proposes a new CNN model called TFECN. TFECN avoids the parameter sharing of convolutional kernels in the frequency dimension by designing the size of the convolutional kernel, which in turn avoids the CNN to recognize the same temporal-frequency patterns located in different positions of the frequency dimension as the same semantics. In addition, in order to avoid the lack of

modeling local features in the improved convolutional method, also proposes a method to migrate the weights of the pre-trained small convolutional kernel into the large convolutional kernel. Experiments on the sound event classification dataset show that the proposed model achieves a relative accuracy improvement of 6% compared to the traditional CNN method.

In order for the Transformer to better model the local features in the frequency dimension of the spectrogram, and taking into account the different attributes of the two dimensions of the spectrogram, a new two-branch Transformer model is proposed. The first branch in the model handles the spectrogram in a way similar to TDNN, which lacks the modeling of local frequency features although it can take into account the differences between the time and frequency dimensions of the spectrogram. The second branch introduces a chunking process to deal with the spectrogram, which is able to model the local frequency features but is unable to differentiate the time and frequency dimensions. Utilizing the advantages of these two branches to mitigate each other's disadvantages by introducing them into the model at the same time. Experiments on a speech emotion recognition dataset show that the proposed model achieves an accuracy rate that exceeds the current models.

**Key words:** Audio Content Classification, Spectrogram Features, Time Delay Neural Networks, Convolution Neural Networks, Transformer

Written by Wangmengwei

Supervised by Yangzhe

# 目 录

|                           |    |
|---------------------------|----|
| 第一章 绪论.....               | 1  |
| 1.1 研究背景和意义.....          | 1  |
| 1.2 国内外研究现状.....          | 3  |
| 1.2.1 时延神经网络.....         | 3  |
| 1.2.2 卷积神经网络.....         | 4  |
| 1.2.3 Transformer.....    | 5  |
| 1.2.4 时频谱特性优化.....        | 6  |
| 1.3 论文研究内容.....           | 6  |
| 1.4 论文结构.....             | 8  |
| 第二章 相关概念与技术 .....         | 9  |
| 2.1 音频时频谱分类.....          | 9  |
| 2.2 时频谱特征.....            | 10 |
| 2.3 研究使用的基本模型.....        | 12 |
| 2.3.1 时延神经网络.....         | 12 |
| 2.3.2 卷积神经网络.....         | 13 |
| 2.3.3 Transformer.....    | 15 |
| 2.4 本章小结.....             | 17 |
| 第三章 基于时延神经网络的音频分类模型 ..... | 18 |
| 3.1 引言.....               | 18 |
| 3.2 方法介绍.....             | 19 |
| 3.2.1 子频带前端模型.....        | 20 |
| 3.2.2 主干模型改进以及反向特征融合..... | 22 |
| 3.2.3 模型细节.....           | 24 |
| 3.3 实验.....               | 25 |
| 3.3.1 数据集.....            | 25 |
| 3.3.2 评价指标.....           | 26 |
| 3.3.3 实验设置.....           | 27 |
| 3.3.4 实验结果.....           | 29 |
| 3.4 本章小结.....             | 32 |
| 第四章 基于卷积神经网络的音频分类模型 ..... | 33 |
| 4.1 引言.....               | 33 |
| 4.2 时频增强卷积神经网络.....       | 34 |
| 4.2.1 模型架构.....           | 34 |
| 4.2.2 时频增强卷积.....         | 36 |

|                                  |    |
|----------------------------------|----|
| 4.2.3 预训练.....                   | 38 |
| 4.3 实验.....                      | 39 |
| 4.3.1 数据集.....                   | 39 |
| 4.3.2 评价指标.....                  | 40 |
| 4.3.3 实验设置.....                  | 41 |
| 4.3.4 实验结果.....                  | 43 |
| 4.4 本章小结.....                    | 46 |
| 第五章 基于 Transformer 的音频分类模型 ..... | 48 |
| 5.1 引言.....                      | 48 |
| 5.2 双分支 Transformer.....         | 50 |
| 5.2.1 时延神经网络分支.....              | 51 |
| 5.2.2 卷积神经网络分支.....              | 52 |
| 5.2.3 模型细节.....                  | 54 |
| 5.3 实验.....                      | 55 |
| 5.3.1 数据集.....                   | 55 |
| 5.3.2 评价指标.....                  | 56 |
| 5.3.3 实验设置.....                  | 56 |
| 5.3.4 实验结果.....                  | 58 |
| 5.4 本章小结.....                    | 61 |
| 第六章 总结与展望 .....                  | 62 |
| 6.1 工作总结.....                    | 62 |
| 6.2 工作展望.....                    | 63 |
| 参考文献.....                        | 64 |

# 第一章 绪论

本章首先介绍音频时频谱分类方法的研究背景与意义，之后介绍相关的国内外研究，最后介绍本文的研究内容与全文组织结构。

## 1.1 研究背景和意义

随着信息技术的发展，对音频信号内容的分析已经渗透到生活的方方面面，从智能手机到智能家居，从车载系统到个人娱乐设备，极大地丰富了人们的生活体验。苹果的 Siri 语音助手通过先进的语音识别和自然语言处理技术，能够理解用户的指令并作出相应的反应。亚马逊的 Alexa 智能音箱不仅能够响应语音指令，还能够控制与之兼容的智能家居设备。除了这些知名的消费电子产品，对音频信号内容的分析还在许多其他领域发挥着重要作用。例如，在娱乐领域，通过分析音乐的流派使得用户能够更有效地搜索、访问和使用音乐资源<sup>[1]</sup>；在教育领域，语音评测技术可以帮助语言学习者提高发音准确性<sup>[2]</sup>；在安全监控领域，声音识别系统可以用于检测异常声音，提前预警潜在的安全威胁。这一切都离不开对音频信号内容的分析和处理。

音频内容分类指的是根据一段音频表达的内容不同将其归类到不同的类别。它是音频信号处理的一个重要工具，有助于组织、分析和理解音频信号。根据音频信号的内容或者应用场景的不同，音频内容分类又可以分为不同的子任务，比如判断一段语音信号属于哪个说话人的说话人识别、识别语音信号中所包含情感的语音情感识别以及识别音频信号中包含声音事件的声音事件分类等。通过对音频信号进行分类，可以更好地理解信号的本质、结构和内容，能够为语音识别、语音合成等上层应用提供更好的支持。

在深度学习方法流行之前，高斯混合模型 (Gaussian Mixture Model, 简称 GMM)<sup>[3]</sup>等传统机器学习方法是音频内容分类中的主流方法。受限于计算性能，为了减少模型参数量，通常将音频的原始波形特征转换为梅尔频率倒谱系数 (Mel Frequency Cepstral Coefficients, 简称 MFCC) 之后，再用来训练模型并进行预测。MFCC 特征是由梅尔频谱 (Mel Spectrogram) 进行离散余弦变换后，取较低的几个频率分量，添加一阶差分和二阶差分后得到的。相较于梅尔频谱，MFCC 各频率维相互独立，此时可以假设 GMM 中每个正态分布的协方差矩阵为对角矩阵，减少了模型的参数量。得益于计算

设备的性能提升,深度学习开始逐渐流行并被用于音频内容分类任务,相较于 MFCC 包含更多信息量的声谱图 (Spectrogram) 以及梅尔频谱更多地被研究者们使用。不管是 MFCC、梅尔频率还是声谱图,它们都是一种二维特征,一个维度代表时间维,另一个维度代表频率维,因此本文将这些特征统称为时频谱。由于时频谱与自然图像都是二维特征,使得一些研究将时频谱作为图像进行处理,但时频谱也有许多特殊的属性<sup>[4]</sup>。首先,时频谱两个维度分别表示不同的属性,而图像的横纵坐标都对对应着空间位置。其次,时频谱中沿频率维分布的特征不满足平移不变性。图像中的特征沿着两个轴滑动时,其代表的语义一般不会发生改变,只是在图像中的空间位置发生了变化,这种性质被称为特征的平移不变性。如果模型在提取特征时能够满足特征的平移不变性,则称这个模型是平移等变的。在时频谱中,一种特征模式沿着时间轴移动时,该模式满足平移不变性,所代表的语义只是在音频中的时间位置发生了改变。另一方面,考虑到频率是声音的三要素,当一种特征模式沿着时频谱频率维进行移动时,其代表的语义很有可能发生了变化。最后,在图像中属于同一种类的像素点一般都在图像中相邻,并且这些像素点也仅属于一个种类。而在时频谱中,组成周期信号的谐波在谱图中是不相邻的,导致一种声音的特征模式可能离散地出现在频率维的不同位置,同时频谱中每个像素点也可能从属于多种声音。

在本文中,将使用时频谱作为输入特征的音频内容分类任务称为音频时频谱分类任务。目前较为常见的用于音频时频谱分类的深度学习模型有循环神经网络,时延神经网络,卷积神经网络以及 Transformer。循环神经网络和时延神经网络 (Time Delay Neural Network, 简称 TDNN) 将时频谱的频率维作为输入特征的通道维,在模型每层中对特征的所有通道进行加权求和。这导致模型缺少对频率维局部特征的建模,可能会对模型的分类性能产生不利的影响。由于时频谱和图像形式上的相近,很多研究方法<sup>[5,6]</sup> 都直接将时频谱当作图像并利用卷积神经网络 (Convolutional Neural Network, 简称 CNN) 进行分类。由于 CNN 的卷积核大小通常远小于输入的特征图,考虑到了时频谱的局部特征,但由于卷积核在同一层中共享参数,这导致了 CNN 是平移等变的。CNN 的平移等变性对于识别图像中的目标是有利的,因为图像中的目标一般不会随着位置的改变而发生语义的改变。但对于时频谱的频率维来说却是不利的,时频谱中的模式可能会随着频率位置的改变而发生语义的改变<sup>[7]</sup>。Transformer 作为一种热门的深度学习模型也经常用来进行音频内容分类<sup>[8,9]</sup>,它在处理时频谱输入时通常有两种方式。一种方式类似 TDNN,直接将频率维作为特征通道维进行处理;另一种则先使用分块化 (Patchify) 对时频谱进行预处理,之后再再将分块化后的

时频谱作为 Transformer 的输入特征。第一种方式与 TDNN 类似, 同样都面临着缺少对局部特征建模的问题。第二种方式由于在分块化过程中使用了 CNN, 因此也同样面临着 CNN 平移等变性带来的问题。此外, 由于分块化实际上是将两个不同的维度压缩为同一维度, 对于图像来说, 由于两个维度拥有相同的属性, 因此不会产生不利的影响, 但时频谱中两个维度代表不同的属性, 因此简单的压缩可能会对模型的性能产生不利的影响。总的来说, 目前的深度学习模型在对音频的时频谱特征进行分类时并没有完全考虑到时频谱的特性。如何更好地利用时频谱的特性, 使模型更好地对音频进行分类, 更好地服务于上层应用是一个亟待解决的问题。

## 1.2 国内外研究现状

本节首先介绍时延神经网络、卷积神经网络以及 Transformer 这三种常用的音频分类模型在国内外的研究现状。考虑到本文的研究内容, 下文介绍的所有方法都使用时频谱作为模型输入特征。最后, 本节对目前音频内容分类任务中针对时频谱特性进行优化的一些方法进行了介绍。

### 1.2.1 时延神经网络

时延神经网络 (Temporal Delay Neural Network, 简称 TDNN) 是一种用于处理序列数据的深度学习模型, 最初被用于语音识别。目前常用于在音频分类子任务之一的说话人识别任务中提取帧级特征<sup>[10,11]</sup>。ECAPA-TDNN<sup>[11]</sup> 在 TDNN 提取器中引入了 Res2Net<sup>[12]</sup> 的模块设计并使用 SE 模块<sup>[13]</sup> 对每一层输出特征进行缩放, 将每一层输出的特征拼接后使用一个全连接层进行特征融合, 之后使用强调通道的注意力机制对融合后的特征进行注意力统计值池化 (Attention Static Pooling, ASP)<sup>[10]</sup> 得到话语级特征。

TDNN 可以理解为一维的 CNN, 同循环神经网络一样<sup>[14]</sup>, 输入特征通道维对应时频谱频率维, 模型每一层都拥有覆盖全部频率范围的感受野, 缺少针对频率局部特征的建模。为了在 TDNN 中引入针对局部频率特征的建模过程, 常用的方法是在 TDNN 前添加一个 CNN 作为前端模型, 将前端模型的输出特征作为 TDNN 输入。然而这种方法没有考虑到一维卷积和二维卷积结构上的差异, 只是简单的将二维卷积的输出展平作为一维卷积的输入, 可能会使主干模型无法高效地提取帧级特征。

### 1.2.2 卷积神经网络

卷积神经网络（Convolutional Neural Network，简称 CNN）最早在计算机视觉领域提出，用于识别手写数字。由于其合理的模型设计，现在也经常用于音频分类任务。在说话人识别任务中 CNN 主要用于提取帧级特征<sup>[15,16]</sup>。ResNetSE34<sup>[15]</sup> 使用一个四阶段的 34 层 ResNet 作为帧级特征提取器，使用 SE 模块对每个阶段的输出特征图进行缩放。由于 ResNet 属于 CNN，模型将提取的三维特征展平成二维之后使用 ASP 得到话语级特征。对于声音事件分类任务，在过去的很长一段时间里，CNN 一直是这个问题的主流模型。PANN<sup>[5]</sup> 提出了一个十四层的 CNN 模型 CNN14，首先利用一组一维卷积从音频的波形特征中提取不同于梅尔频谱的时频特征，之后将其与梅尔频谱进行拼接作为模型的输入。最后将 CNN14 输出特征经过平均池化和最大值池化后的结果相加得到音频嵌入，使用全连接层根据音频嵌入来计算音频中声音事件的类别。PSLA<sup>[6]</sup> 使用基于深度可分离卷积（Depthwise Separable Convolution）的 CNN，每个卷积操作被拆解为一个逐点卷积（Pointwise Convolution）和一个逐层卷积（Depthwise Convolution）。训练时，模型首先在自然图像数据集 ImageNet<sup>[17]</sup> 中进行预训练，之后再声音事件数据集中进行微调。此外，PSLA 通过多头注意力机制对各帧特征进行加权平均得到用于分类的音频嵌入。在语音情感识别任务中，LightSERNet<sup>[18]</sup> 基于 CNN，模型分为两个部分，第一部分为多条并行的路径，每条路径中的卷积模块拥有不同形状的卷积核，分别用来建模不同尺度的特征，在最后将所有路径的输出特征进行拼接作为第二部分的输入，模型第二部分为单路径的五层 CNN，用来融合不同尺度的特征信息以进行更准确的分类。TIMNet<sup>[19]</sup> 同样是基于 CNN 的模型，考虑到情感是一种非语言信息，模型中新设置一条路径将沿时间维反转后的时频谱特征作为输入。对于模型中的每一层，首先将两条路径的输出特征相加后沿时间维进行平均池化，之后将各层池化后的特征拼接到一起使用一个全连接层将各层的特征进行融合得到音频嵌入，最后使用一个全连接层对音频嵌入进行分类。

虽然大量的研究使用 CNN 来进行音频分类，但 CNN 的平移等变性在处理时频谱时会将不同频率位置的相同模式识别为相同的语义，不符合频率维特征的非平移不变性。此外，CNN 作为一个经典的模型往往拥有比 Transformer 更少的参数量以及计算量，虽然已有很多研究证明 Transformer 模型的设计结构可以被用在其他模型中以提升性能<sup>[20,21]</sup>，但在音频分类问题中很少有研究利用这些方法去改进传统 CNN 模型。

### 1.2.3 Transformer

Transformer 是一个基于多头自注意力的序列到序列模型，最初在自然语言处理领域中提出，用于机器翻译任务<sup>[22]</sup>。由于 Transformer 在建模长距离依赖上的出色表现，最近也出现了许多研究使用 Transformer 进行音频分类任务。对于说话人识别任务，MFA-Conformer<sup>[23]</sup> 使用 Conformer 模块在 Transformer 提取器中引入局部特征信息以提升提取器的性能。此外 MFA-Conformer 还效仿 ECAPA-TDNN 将模型每一层的输出进行特征融合，之后通过 ASP 计算话语级特征。对于声音事件分类任务，以 AST<sup>[8]</sup> 为开端，出现了越来越多用于声音事件分类的 Transformer。AST 简单地采用了机器视觉中的视觉 Transformer (Vision Transformer, 简称 ViT)<sup>[24]</sup> 结构，将梅尔频谱看作是自然图像，首先对梅尔频谱进行分块化，将二维时频谱压缩为一维序列，之后利用 Transformer 进行特征提取。训练时同 PSLA 一样，首先将模型在 ImageNet 数据集中进行预训练，之后在音频事件数据集上进行微调。HTS-AT<sup>[9]</sup> 则是基于 SwinTransformer<sup>[25]</sup> 的声音事件分类模型，SwinTransformer 在 ViT 的基础上引入了窗口注意力机制，仅计算相同窗口中各个分块之间的注意力分数。为了保证不同窗口之间的信息交流，通过移位特征的方式来将两个相邻窗口中的分块移入同一窗口。此外，HTS-AT 将分块化后的梅尔频谱按照时间，频率，窗口的顺序排列，以将相同时间帧不同频率分量的分块集中到一个注意力窗口中。对于语音情感识别任务，Speechformer<sup>[26]</sup> 是一个基于 Transformer 的模型，该方法考虑到语音的层次特性，将模型设置为四个阶段，分别处理帧、音素、字、话语四个不同的基本单元。模型根据每个阶段处理的基本单元不同设置不同长度的注意力窗口，仅计算相同基本单元中各帧之间的注意力分数。此外，每个阶段之间设置合并块，合并块根据前后两个阶段要处理的基本单元，将上一阶段一定长度的特征帧进行平均池化，近似为下一阶段的基本单元。DWformer<sup>[27]</sup> 同样基于 Transformer，模型每一层由动态局部窗口 Transformer 和动态全局窗口 Transformer 组成。考虑到语音中不同时间段包含的情感信息不同，动态局部窗口 Transformer 根据之前模块计算的情感重要性分数将特征沿时间维划分为多个不等长的窗口分别进行处理，动态全局窗口 Transformer 则根据之前模块的输出特征重新计算情感重要性分数。

Transformer 作为音频分类的另一种常用模型，它的两种处理时频谱输入方式一种类似于 TDNN，缺少针对局部频率特征的建模；另一种使用 CNN，没有考虑到 CNN 的平移等变性对时频谱中平移不变特征产生的不利影响。此外，Transformer 模型通

常会使用分块化方法将时频谱的时间和频率维度压缩为一个维度，这使得模型无法很好地利用两个维度不同的信息。

### 1.2.4 时频谱特性优化

由于时频谱特征在深度学习模型中的广泛使用，出现了许多针对时频谱特性进行优化的方法。对于 CNN 来说常见的优化方式有三类，使用自适应卷积、引入注意力机制以及划分子频带。自适应卷积根据输入的不同来生成不同的卷积核，ACNN<sup>[28]</sup> 根据时间维和频率维不同的统计值生成卷积核两个方向的权重以区分时频谱两个不同的维度，而 FDC<sup>[7]</sup> 则是根据频率维不同位置处的值生成不同的卷积核来避免像识别图像中目标那样沿频率维识别模式。注意力机制从卷积后的结果选出重要的部分并赋予较大的权重，FRL<sup>[29]</sup> 只根据频率维不同位置的值生成不同的权重，CTFALite<sup>[30]</sup> 则分别根据时间维和频率维的特征生成不同的权重。子频带划分方法则是将输入时频谱的频率维划分为多个子频带，并对这些子频带分别使用不同的卷积核进行卷积。OFD<sup>[31]</sup> 设置多条路径分别处理未经划分的时频谱和划分后各个子频带，在模型的最后将各条路径的输出特征拼接到一起形成音频嵌入并使用全连接层进行分类。

由于 Transformer 中一部分方法将时频谱视为图像，因此需要对输入时频谱进行分块化处理。分块化需要使用 CNN 来完成分块，因此需要避免 CNN 平移等变性产生的不利影响。CAT<sup>[32]</sup> 将用来分块化的 CNN 换为全连接层，并且将每个时间帧的所有频率分量分为一个块。此外，分块化将时频谱的两个维度转换压缩为一个维度，因此需要妥善处理两个维度的不同。SepTr<sup>[33]</sup> 在模型中设置两种 Transformer 模块，一种模块将同一时间帧的所有频率分量分为一个块，另一种模块将同一频率分量的所有时间帧分为一个块，以此来区分两个维度不同的信息。

## 1.3 论文研究内容

现有的音频内容分类模型在处理时频谱特性时，由于缺少针对时频谱特性进行优化，导致分类性能仍有一定的提升空间。针对这一问题，本文在不同的应用场景中的音频内容分类任务，包括说话人识别、声音事件分类和语音情感识别中分别对这三种模型 TDNN、CNN 和 Transformer 引入针对时频谱特性的改进，以提升模型在这些任务中的分类性能。如图1-1所示，总的来说，本文研究内容围绕现有音频分类模型缺少针对时频谱特性的优化的不足，提出了对三种常用音频分类模型的优化。本文的

主要研究内容如下：




图 1-1 研究内容示意图

(1) 对于 TDNN 模型，考虑到其在音频内容分类任务的子任务之一，说话人识别任务中的流行，并且也是目前该任务中性能最好的模型，因此本文选择对说话人识别任务中的 TDNN 模型进行改进。TDNN 模型除了缺少针对时频谱特性的优化外，现有方法还存在多层特征融合方式无法对高层和低层特征之间的复杂关系进行有效建模的问题。针对这两个问题，本文提出一种新的前端模型以及一种新的多层特征融合方式。在前端模型中通过将输入特征图划分为多个子频带，并逐层扩大子频带的频率范围，使 TDNN 可以渐进地对局部频率特征进行建模。通过使 TDNN 模型能够针对局部频率特征进行建模，进而提升 TDNN 模型在说话人识别任务中的性能。

(2) 对于 CNN 模型，其为声音事件分类这一音频内容分类子任务中非常流行的一类模型。虽然最近随着 Transformer 模型的涌现，CNN 正在逐渐被其取代，但其参数量及计算量上仍然存在着优势。因此本文选择对声音事件分类任务中的 CNN 模型进行改进，进一步探索其在声音事件分类任务中的潜能。为了在用于声音事件分类的 CNN 模型中引入针对时频谱特性的优化，本文提出了一种新的 CNN 模型称为 TFECN。TFECN 包含两个分支，一个分支专注于较长时间上下文特征的提取，另一个分支则通过对卷积核大小的设计避免卷积核在频率维的参数共享，进而破坏 CNN 在频率维的平移等变性。通过避免 CNN 的平移等变性对识别时频谱中频率维平移不变特征产生的不利影响，提升 CNN 模型在声音事件分类任务中的性能。

(3) 随着 Transformer 模型在多模态任务中的流行, 出现了大量研究专注于提升其在仅依靠单一模态数据时的性能, 语音情感识别正是其中的一个重点研究方向, 因此本文选择对该任务中的 Transformer 进行改进。为了在用于语音情感识别任务的 Transformer 中引入针对时频谱特性的优化, 本文提出了一种新的双分支 Transformer。模型中第一个分支使用类似 TDNN 的方式处理时频谱, 第二个分支利用分块化的方式处理输入时频谱。第一个分支能够缓解第二个分支分块化过程将时间和频率两个不同的维度压缩为同一维度造成的信息损失, 第二个分支能够补充第一个分支缺失的局部频率特征建模。通过双分支的设计同时考虑时频谱特征中时间维和频率维的差异以及针对局部特征的建模, 进而提升 Transformer 模型在语音情感识别任务中的识别性能。

虽然三个研究内容针对不同的下游任务, 但如前文所述, 这些下游任务同属音频内容分类问题。本文的研究目标是利用时频谱的特性提升现有深度学习模型在音频内容分类问题中的性能, 它们之间的任务特性差异不在本文的研究范围内。

## 1.4 论文结构

全文共六个章节, 整体内容组织结构如下:

第一章为绪论, 首先介绍音频时频谱分类方法的研究背景与意义, 之后介绍相关的国内外研究, 最后介绍本文的研究内容与组织结构。

第二章为相关概念和技术, 首先介绍音频时频谱分类任务的概念, 之后介绍时频谱特征的概念及提取方法, 最后介绍目前主流的音频时频谱分类模型 TDNN、CNN、Transformer 的概念及原理。

第三章介绍了在说话人识别任务中针对 TDNN 的改进。

第四章介绍了在声音事件分类任务中针对 CNN 的改进。

第五章介绍了在语音情感识别任务中针对 Transformer 的改进。

第六章为总结与展望, 首先对全文工作进行总结, 之后对基于本文内容的未来工作和研究进行展望。

## 第二章 相关概念与技术

本章首先介绍音频时频谱分类任务的概念，之后介绍时频谱特征的概念及提取方法，最后介绍目前主流的音频时频谱分类模型 TDNN、CNN、Transformer 的概念及原理。

### 2.1 音频时频谱分类

本文所称的音频时频谱分类即以时频谱作为模型的输入特征的音频内容分类。基于深度学习的音频时频谱分类任务的整体流程大致可以分为三步，第一步从音频的时域波形信号中提取时频谱特征，第二步利用深度学习模型从时频谱特征中提取音频嵌入，第三步使用分类器（通常看作深度学习模型的一部分）对音频嵌入进行分类，整体的流程如图2-1所示，从图中可以看出，本文设计的三个不同子任务实际上只存在音频内容以及标签文本的不同，不同任务之间的差异及其各自的特性并不在本文的研究内容中。




图 2-1 音频时频谱分类示意图

音频内容分类根据应用场景的不同可以分为不同的任务，目前研究的几个任务包括说话人识别、声音事件分类、语音情感分析。说话人识别指的是判断一段给

定语音属于哪个说话人，由于说话人识别系统分类准确率高通常意味着深度学习模型提取的音频嵌入较好的建模了特定说话人的属性，因此说话人识别任务经常被用来为其他上层应用提供支持，比如说话人确认、语音合成<sup>[34]</sup>。声音事件分类指的是判断一段给定音频中包含哪些声音事件，其中声音事件指的是不限于语音的自然发生的或人为产生的声音，通常在环境声音监控、智能家居等领域有着重要应用<sup>[35]</sup>。语音情感识别指的是判断一段语音属于哪一类情绪，其目标是使计算机能够像人类一样，通过分析语音信号中的声学特征，来感知和解释说话人的情绪，对于提高计算机系统的用户体验、促进人机交互的自然性和智能性有着重要意义<sup>[36]</sup>。不同于帧级分类任务，比如说话人日志以及声音事件检测，本文所研究的问题都是片段级的分类任务，即对整段音频进行分类，而不是对音频的每一帧进行分类。

## 2.2 时频谱特征

本文所称的时频谱特征泛指音频信号在输入深度学习模型之前由一维时域波形信号经过变换得到的二维特征，包含但不限于声谱图（Spectrogram）、梅尔频谱（Mel Spectrogram）又称梅尔滤波器组（Mel Filterbank，简称 Fbank）特征、梅尔频率倒谱系数（Mel Frequency Cepstral Coefficients，简称 MFCC）。本节下面逐一介绍这些特征的提取方法。

声谱图是由音频的时域波形信号经过短时傅里叶变换（Short Time Fourier Transform，简称 STFT）计算得到，STFT 分为三步，分帧、加窗及离散傅里叶变换。由于语音的短时平稳特性，可以通过选取合适的帧长，将这一帧中的信号视为平稳的。为了使不同帧之间平稳过渡，通常会在帧与帧之间设置小于帧长的间隔称为帧移。由于分帧相当于对原始信号进行截断，直接对分帧后的语音信号进行离散傅里叶变换会在信号截断处产生高频分量，这种现象被称为吉布斯现象（Gibbs phenomenon）。为了避免吉布斯现象对计算频谱特征产生的不利影响，需要对分帧后的信号进行加窗操作，加窗相当于对一帧信号进行加权。常用的窗函数有汉宁窗（Hanning window）、汉明窗（Hamming window），对于长度为  $N$  的离散信号  $x[n]$ ， $0 \leq n \leq N-1$ ，两种窗函数对应的权重可以表示为：

$$w[n] = (1 - \alpha) - \alpha \cos \frac{2\pi n}{N-1} \quad (2.1)$$

对于汉宁窗  $\alpha = 0.5$ ，对于汉明窗  $\alpha = 0.46$ 。之后对加窗后的每一帧信号进行离散傅里

叶变换（Discrete Fourier Transform，简称 DFT）得到该帧的频谱，DFT 的计算如下：

$$X[k] = \sum_{n=0}^{N-1} x[n] \left( \cos\left(\frac{2\pi kn}{N}\right) - j \sin\left(\frac{2\pi kn}{N}\right) \right) \quad 0 \leq k \leq N-1 \quad (2.2)$$

其中， $j$  是虚数单位， $X$  为变换后的频谱， $X[k]$  为频谱中第  $k$  个频率分量的值。最后将所有帧的频谱沿时间堆叠得到声谱图特征，提取声谱图的流程如图2-2。




图 2-2 声谱图提取过程示意图

声源经过声腔的调制，组成语音信号的谐波振幅有的加强，有的减弱，形成有起伏的新的包络曲线。曲线中出现峰值的频率对应着声腔的共鸣频率，这些峰值称为共振峰。因此频谱的包络曲线反映了声腔的物理特性，而 MFCC 就是一种描述频谱包络的特征。在将音频由时域波形信号转换为声谱图特征后，对声谱图中的幅值进行平方得到功率谱，或者直接对幅值取绝对值。之后为了使特征更加符合人耳的听觉感知特性，将声谱图的每一帧频谱通过一组按照梅尔刻度设计好的三角形滤波器组得到带通滤波后的结果，最后使用对数函数矫正人耳对于声强的非线性，此时得到的特征即 Fbank 特征。为了得到 MFCC 特征，需要在 Fbank 特征的基础上进行离散余弦变换（Discrete Cosine Transform，简称 DCT）计算倒谱，计算如下：

$$X[k] = \sqrt{\frac{2}{N}} \sum_{n=0}^N x[n] \cos\left(\frac{(n + \frac{1}{2})\pi k}{N}\right) \quad (2.3)$$

每一帧取倒谱中前 12 个倒谱系数，加上该帧的能量得到 13 维的特征，最后通过计算特征在相邻帧之间的一阶差分和二阶差分并与 13 维的特征进行堆叠得到最终 39 维

的 MFCC 特征。此外，在提取 MFCC 和 Fbank 特征的最开始，可以对音频时域信号进行预加重操作来补偿音频在录制和传输过程中产生的高频分量损失，预加重后的信号  $y$  通过下式计算得到：

$$y[n] = x[n] - \alpha x[n-1] \quad 0.9 \leq \alpha \leq 1.0 \quad (2.4)$$

音频时频谱的整个提取流程可以通过图2-3来总结。




图 2-3 时频谱提取过程示意图

## 2.3 研究使用的基本模型

本节主要介绍音频时频谱分类任务中常用深度学习模型的概念及原理，这些模型包括时延神经网络、卷积神经网络、Transformer。

### 2.3.1 时延神经网络

时延神经网络（Temporal Delay Neural Network，简称 TDNN）是一种用于处理序列数据的深度学习模型，最初被用于语音识别，常规的 TDNN 有以下几个特征：

（1）模型本身是一个多层结构，在每一层中，输出特征中的单个通道与输入特征中所有通道之间都存在连接，输出特征每个通道中的单帧都是由输入特征所有通道中部分帧加权求和并经过一个非线性激活函数得到的。这种设计确保了模型能够学习到复杂的非线性决策面。

（2）为了建模一定的时间上下文信息，模型引入了时延单元，时延单元决定了每个输出帧对每个通道中多少个输入帧加权求和。模型第一层的一个输出帧对应的音频时间上下文与时延单元长度等长，随着模型层级的堆叠，一个输出帧对应音频时间

上下文也不断变长,在足够深的模型中,模型高层对应的时间上下文可以达到整条音频的长度。

(3) 为了满足音频特征在时间维的平移不变性,输出特征中相同通道中每一帧对应的输入特征权值都是固定,即每个输入通道时延单元的值是相同的,可以理解为每个通道对应一个沿时间方向滑动的滑动窗口。这个特性避免了模型的参数量随着音频长度的增长而增加,使得模型可以处理不定长音频,也降低了模型过拟合的风险。

TDNN 的计算原理如图2-4所示,图中输入特征共包含 5 个时间帧和 8 个通道,输出特征共包含 3 个时间帧和 4 个通道,时延单元的长度为 3。图2-4左侧为输出特征中相同通道中不同帧的计算方法,每个输出帧对应输入特征所有的 8 个通道,每个通道对应时延单元中的 3 个帧。在这 24 个值使用可学习的权重参数加权求和后,通过非线性激活函数计算加权求和的活性值,这个活性值即输出特征中的一个输出帧。输出特征中相同通道的输出帧对应的权值相同。图2-4右侧为相同时间不同通道的输出帧计算方法,每个输出通道对应一组不同的权值。




图 2-4 时延神经网络原理示意图

### 2.3.2 卷积神经网络

卷积神经网络 (Convolutional Neural Network, 简称 CNN) 最早在计算机视觉领域提出,用于识别手写数字。早期全连接神经网络由于权重参数非常多,导致训练的效率非常低。CNN 中的局部连接和权值共享特性使得模型的参数量相较于全连接神经网络大幅减少,计算效率得到了显著提升。局部连接指的是输出特征中的每一个神

神经元都只和输入特征图（输入特征中的一个通道）中某个局部窗口内的神经元相连，这一方面大幅减少了模型的参数量，另一方面也符合生物视觉皮层中高阶神经元基于相邻低阶神经元输出的观察。一个局部窗口的连接权重组成一个卷积核（Kernel），权值共享指的是同一输入特征图内卷积核都是相同的。由于权值共享机制，同一输入特征图的卷积核只能建模一种局部特征，为了增强 CNN 的表达能力，一个输出特征图往往对应多个卷积核，这些卷积核对应输入特征中全部或部分通道（分组卷积），一个输出特征图对应的权重不同的卷积核组成了一个滤波器（Filter），同一输出特征图使用相同的滤波器。

CNN 的计算原理如图2-5（a）所示，输入特征有 3 个通道，输出特征有 2 个通道，对应 2 个输出特征图，卷积核的长宽都为 3。输出特征图中神经元  $y_{ij}$  的计算如下：

$$y_{ij} = \sum_{\mathbf{W}} \sum_{u=1}^U \sum_{v=1}^V w_{uv} x_{i-u+1, j-v+1} \quad (2.5)$$

其中  $x_{ij}$  为输入特征图位置  $i, j$  处的神经元， $w_{uv}$  为卷积核  $\mathbf{W} \in \mathbb{R}^{U \times V}$  中位置  $u, v$  处的权值， $\mathbf{F}$  为由  $y_{ij}$  所在输出特征图对应的三个卷积核组成的滤波器，不同的输入特征图对应着不同的卷积核  $\mathbf{W}$ 。对于分组卷积，一个滤波器包含的卷积核数量不一定等于输入特征图的数量，如图2-5（b）所示，图中为一个分组数为 4 的分组卷积，每个滤波器包含的卷积核只对应输入特征中 1/4 的输入通道。




图 2-5 卷积神经网络原理示意图

由于时频谱和图像都为二维特征，因此 CNN 也可以直接使用时频谱作为输入，

不同于 TDNN 中时频谱频率维为初始输入特征的通道维, CNN 中时频谱的频率维相当于图像中的一边, 独立于特征的通道维。由于局部连接和权值共享机制, CNN 中的卷积核类似于 TDNN 中沿时间滑动的时延单元, 不同的是 CNN 中的卷积核沿着时间和频率两个方向滑动。因此, CNN 可以简单地理解为二维的 TDNN。

### 2.3.3 Transformer

Transformer 是一个基于多头自注意力的序列到序列模型, 最初在自然语言处理领域中提出, 用于机器翻译任务<sup>[22]</sup>。原始的 Transformer 包含两部分, 编码器 (Encoder) 和解码器 (Decoder), 大多数研究将使用多头自注意力机制的模型统称为 Transformer, 即使模型仅包含编码器部分。由于用在分类任务中的 Transformer 几乎都仅包含编码器, 因此本文中的 Transformer 特指仅包含编码器部分的 Transformer。

Transformer 的核心为自注意力机制, 自注意力机制可以根据输入内容的不同动态地生成连接各个神经元的权重。自注意力机制通常采用查询 (Query)、键 (Key)、值 (Value) 注意力形式, 首先使用三个线性变换矩阵从输入特征中计算得到查询矩阵、键矩阵和值矩阵, 之后通过查询矩阵和键矩阵求得注意力分数并利用注意力分数对值矩阵进行帧与帧间的加权求和得到输出特征, 整个过程如图2-6所示。具体来说, 长度为  $N$ , 通道数为  $D_x$  的输入特征  $\mathbf{X} \in \mathbb{R}^{D_x \times N}$  经过三个线性映射矩阵  $\mathbf{W}_q$ ,  $\mathbf{W}_k$  和  $\mathbf{W}_v$  计算得到查询矩阵  $\mathbf{Q}$ 、键矩阵  $\mathbf{K}$  和值矩阵  $\mathbf{V}$ , 计算如下:

$$\begin{cases} \mathbf{Q} = \mathbf{W}_q \mathbf{X} \in \mathbb{R}^{D_k \times N} \\ \mathbf{K} = \mathbf{W}_k \mathbf{X} \in \mathbb{R}^{D_k \times N} \\ \mathbf{V} = \mathbf{W}_v \mathbf{X} \in \mathbb{R}^{D_v \times N} \end{cases} \quad (2.6)$$

其中  $\mathbf{W}_q \in \mathbb{R}^{D_k \times D_x}$ ,  $\mathbf{W}_k \in \mathbb{R}^{D_k \times D_x}$ ,  $\mathbf{W}_v \in \mathbb{R}^{D_v \times D_x}$ ,  $D_k$  为  $\mathbf{Q}$  和  $\mathbf{K}$  的通道数,  $D_v$  为  $\mathbf{V}$  的通道数。之后使用键值对注意力机制根据  $\mathbf{Q}$ ,  $\mathbf{K}$  计算得到注意力分数矩阵  $\mathbf{A} \in \mathbb{R}^{N \times N}$ , 计算如下:

$$\mathbf{A} = \text{softmax}\left(\frac{\mathbf{K}^T \mathbf{Q}}{\sqrt{D_k}}\right) \quad (2.7)$$

$$\text{softmax}(m_{ij}) = \frac{\exp(m_{ij})}{\sum_{j'}^N \exp(m_{ij'})} \quad (2.8)$$

其中,  $m_{ij}$  为矩阵中第  $i$  行第  $j$  列的值。最后利用注意力分数  $\mathbf{A}$  对  $\mathbf{V}$  加权求和得到输

出特征，计算如下：

$$Y = VA \quad (2.9)$$

多头自注意力即将输入特征映射到多个特征空间中分别进行自注意力计算，在实现上一般将生成的  $Q$ 、 $K$ 、 $V$  矩阵沿通道维进行切分作为多个头，多头可以使模型在多个不同的特征空间中捕捉不同的交互信息。Transformer 的另一个重要的机制为位置编码。由自注意力机制的计算方式可以看出如果只是改变音频特征中帧的顺序，这些不同排列的特征产生的输出也只会存在排列顺序的不同，因此需要为音频特征添加位置信息以表示每一帧的时间先后。原始 Transformer 中通过正弦位置编码引入位置信息，不同位置的位置编码计算如下：

$$\begin{cases} PE(p, 2i) = \sin(\frac{p}{10000^{2i/D_x}}) \\ PE(p, 2i + 1) = \cos(\frac{p}{10000^{2i/D_x}}) \end{cases} \quad (2.10)$$

其中  $PE(p, i)$  表示特征第  $i$  个通道位置  $p$  处的位置编码， $2i$  表示特征通道中的偶数维， $2i + 1$  表示特征通道中的奇数维，即对特征中的偶数维通道使用正弦函数计算位置编码，奇数维通道使用余弦函数计算位置编码。正弦位置编码中每个确定的位置都对应一个确定的位置编码，该位置编码表示该位置的绝对位置信息，因此正弦位置编码是一种绝对位置编码。




图 2-6 自注意力机制原理示意图

通过对比图2-6和图2-4，可以看到 Transformer 输入特征的形式与 TDNN 的输入特征类似，因此使用 Transformer 处理时频谱特征的一种方式就是直接将时频谱频率维作为输入特征的通道维。此外，由于 Transformer 在计算机视觉中的流行，出现了

许多使用图像作为 Transformer 输入特征的方法,为了使 Transformer 能够处理图像输入,一种常见的方法是使用分块化 (Patchify)<sup>[24]</sup> 对图像进行预处理。不同于时频谱中的每一帧都包含了一定时间间隔的完整信息,单独选取图像中的一列往往没有任何意义。分块化过程即将图像中一定二维窗口大小的信息压缩为一维序列中的一帧并映射到多个特征空间的过程。分块化过程中常用的模型为 CNN, 整个过程如图2-7所示。首先将 CNN 从图像中提取的输出特征中每一个通道的特征图沿一个方向展平,之后沿通道维重新堆叠到一起,形成可以被 Transformer 处理的特征。虽然时频谱特征可以直接使用 Transformer 进行处理,但相当一部分研究<sup>[8,9]</sup> 仍然将时频谱当作图像进行处理,即将时频谱先进行分块化之后再输入到 Transformer 中。




图 2-7 分块化过程示意图

## 2.4 本章小结

本章首先介绍了本文所研究的音频时频谱分类问题的含义,之后介绍了时频谱特征的含义,以及常用的几种时频谱特征,最后介绍了音频内容分类问题的几种常用深度学习模型,包括时延神经网络、卷积神经网络和 Transformer。

## 第三章 基于时延神经网络的音频分类模型

### 3.1 引言

对于 TDNN 模型,考虑到其在音频分类任务的子任务之一,说话人识别任务中的流行,并且也是目前该任务中性能最好的模型,因此本章选择对说话人识别任务中的 TDNN 模型进行改进。说话人识别指的是判断一段给定语音属于数据集中哪一个说话人,在生物识别、智能家居等领域有着众多的应用。自从深度学习在说话人识别任务中应用后,深度学习模型凭借强大的性能,逐渐成为研究的主流模型。一个典型的基于深度学习的说话人识别方法分为三部分:帧级特征提取器,池化层和前馈网络<sup>[34,37]</sup>。帧级特征提取器负责从输入音频中提取帧级特征,池化层负责将不定长的帧级特征映射为定长的话语级特征,前馈网络负责将话语级特征映射为说话人嵌入并根据说话人嵌入对音频进行分类。帧级特征提取是整个方法中的第一步,提取的特征好坏直接影响整个方法的性能,因此针对帧级特征提取器的改进是目前的一个主要研究方向。

目前,TDNN 和 CNN 是两类常见的帧级特征提取器,CNN 可以理解为二维的 TDNN,TDNN 同时也可以理解为一维的 CNN,TDNN 中的时延单元也可以看作是一维卷积的卷积核,在本章中以一维卷积指代 TDNN,二维卷积指代 CNN。对于 TDNN,输入特征通道维对应时频谱频率维,模型每一层都拥有覆盖全部频率范围的感受野。对于二维卷积模型,通道维独立于时频谱,随着模型由浅入深,每一层的频率维感受野逐渐增大,渐进地建模局部频率特征。为了在 TDNN 中引入针对局部频率特征的建模过程,常用的方法是在 TDNN 前添加一个二维卷积作为前端模型,将前端模型的输出特征作为 TDNN 输入。本章将帧级特征提取器中这个接收前端模型输出的模型称为主干模型。Thienpondt 等人<sup>[38]</sup>为了使基于 TDNN 的提取器能够像二维卷积那样渐进地建模局部频率特征,在 TDNN 主干模型前添加一个四层 ResNet<sup>[39]</sup>作为前端模型,并表现出不错的性能提升。在此基础上,Liu 等人<sup>[40]</sup>在 ResNet 前端模型中使用 Res2Block<sup>[12]</sup>模块设计,同时引入注意力机制来强调重要的频率成分,进一步提升了提取器的性能。然而这些方法没有考虑到一维卷积和二维卷积结构上的差异,只是简单的将二维卷积的输出展平作为一维卷积的输入,可能会使主干模型无法高效地提取帧级特征。

在早期的方法中,考虑到帧级特征提取器(以下简称为提取器)的深层特征会与说话人的辨识信息有着较强的相关性,因此只使用提取器最后一层的输出特征计算说话人嵌入。然而,越来越多的研究表明,结合不同层的特征能够提高说话人嵌入的鲁棒性,许多研究开始关注如何将不同层的特征更好的融合。常见的特征融合方法可以分为两类:帧级特征融合<sup>[23]</sup>和话语级特征融合<sup>[41]</sup>。Yang 等人<sup>[23]</sup>将模型后三层的帧级特征沿通道维拼接起来经过一个全连接层得到融合后的特征。Kim 等人<sup>[41]</sup>将提取器各层的帧级特征统计值池化后得到的话语级特征进行拼接再经过一个全连接层得到融合后的特征。考虑到高层特征和低层特征之间较大的语义差距,使用全连接层直接融合高层和低层特征可能会造成较大的信息损失。此外,这些融合方式中全连接层的参数量与参与融合的特征层数直接相关,为了减少提取器的参数量,往往只取有限层数(比如三层)的特征进行融合,这限制了融合特征的尺度多样性。

为了解决上述问题,本章在 TDNN 中引入了两点改进。首先,在基于 TDNN 的提取器中引入基于子频带划分的 TDNN 作为前端模型,模拟二维卷积中渐进地对局部频率特征进行建模,同时避免由于 TDNN 和二维卷积结构上的差异导致的特征提取低效问题。其次,提出了一种基于反向路径逐层融合的多层特征融合方法,既避免了直接对高层和低层特征进行融合,又减少了融合特征增加的参数量。此外,本章在主干模型部分采用逆瓶颈层的设计来进一步提升模型的建模能力。实验表明改进后的方法相较于基线方法提升了性能,并且以较少的参数量取得了优于主流的说话人识别方法的性能。

## 3.2 方法介绍

整个说话人识别方法如图3-1左侧所示提出的前端模型以及改进后的主干模型共同组成帧级特征提取器,帧级特征提取器提取的帧级特征经过池化层得到话语级特征,话语级特征经过前馈网络中的第一个全连接层得到用来进行分类的说话人嵌入,第二个全连接层计算得到说话人嵌入的类别分数,分类损失函数计算类别分数与样本标签之间的损失,并反向传播至整个模型的各个模块。在本节中,首先介绍在帧级特征提取器中引入的改进。3.2.1节介绍为在基于 TDNN 的提取器中引入渐进建模局部频率特征过程而提出的前端模型。3.2.2节介绍主干模型中进行的改进以及提出的多层特征融合方法。最后在3.2.3节介绍引入改进后的说话人识别方法的实现细节。




图 3-1 提出的 TDNN 模型结构示意图

### 3.2.1 子频带前端模型

在二维卷积模型中，模型的低层主要对神经元周围局部区域特征进行建模，高层则通过覆盖整个特征图的感受野来学习更抽象的特征表示。而在 TDNN 中模型一开始便拥有覆盖整个频率维的感受野，不存在二维卷积中对频率维特征循序渐进的建模过程。为了在 TDNN 中引入这一过程，Thienpondt 等人<sup>[38]</sup>在 TDNN 主干模型前设置一个基于二维卷积的前端模型，前端模型展平后的输出作为主干模型的输入。假设前端模型的输出特征形状为  $(B, C, F, T)$ ，其中  $B$  为一个小批次中的样本个数， $C$  为二维卷积的输出通道数， $F$  和  $T$  分别为特征图频率维和时间维的长度。主干模型首先将特征的形状展平为  $(B, C \times F, T)$ ，之后作为一维卷积的输入。考虑到二维卷积中通道维独立于特征图，若直接将二维卷积的通道维和特征图的频率维合并，会导致展平后特征通道维的信息既有可能位于同一特征空间（二维卷积特征图中的同一通道的值），又有可能位于不同的特征空间（不同通道的值），进而使得主干模型无法很好的建模展平后特征通道之间的关系。

为了避免前端模型和主干模型结构上的差异，本章使用一个三层的 TDNN 作为前端模型，并参考 Zhao 等人<sup>[42]</sup>研究中主干模型的设计，在前端模型的每一层进行子频带划分，用不同的 TDNN 分别对子频带的特征建模，模型层次越深，子频带数

量越少, TDNN 的频率感受野就越大。通过这种方式来模拟二维卷积中渐进建模局部频率特征的过程。具体来说, 假设输入的时频谱特征频率维长度为  $f$ , 前端模型每一层的输出特征通道维长度为  $c$ 。前端模型的第一层为分组数为  $g_1$ , 卷积核大小为  $k_1$  的分组一维卷积, 每一组的卷积核负责将输入时频谱特征中频率范围为  $f/g_1$  的子频带映射为输出特征中的  $c/g_1$  个通道。第二层和第三层采用 Res2Block<sup>[12]</sup> 的模块设计。Res2Block 如图3-2右下角所示。图中的 Res2Conv1d 含有多组卷积核, 在图中使用




图 3-2 前端模型结构示意图

Conv1d 表示, 每一组卷积核对应输入特征中一部分通道。此外, 在这些卷积核之间设置一条层内路径, 第  $n-1$  组卷积的输出除了传递给下一层外也会传递给第  $n$  组, 这样路径开头的卷积时间维感受野较小, 路径末尾的卷积时间维感受野较大, 使得模型在同一层内能够考虑不同时间尺度的信息。Res2Block 前后两个一维卷积为分组数为  $g_i$ , 卷积核大小  $k_i = 1$  的分组卷积。Res2Conv1d 同样也分为  $g_i$  组, 不同于 Res2Conv1d 内部划分  $n$  组用于建模不同时间尺度的特征, 这里的  $g_i$  组分别对应着不同的子频带。 $g_i$  满足  $g_1 > g_2 > g_3$ , 在第  $i$  层第一个一维卷积中, 由于  $c/g_i > c/g_{i-1}$ , 使得第  $i$  层中的一组的卷积核覆盖第  $i-1$  层输出特征中的  $g_{i-1}/g_i$  个子频带, 即第  $i$  层的频率维感受野相较于第  $i-1$  层增大  $g_{i-1}/g_i$ , 如图3-2右上角所示, 其中  $\odot$  表示卷积操作, 图中输入

特征的四个子频带经过两组不同的卷积核的卷积操作后子频带数量缩减为 2 个。在模型中每一个卷积操作之后都接着一个批量归一化（Batch Normalization，简称 BN）和一个 ReLU 非线性激活函数。

### 3.2.2 主干模型改进以及反向特征融合

使用 ECAPA-TDNN<sup>[11]</sup> 中的提取器作为本章方法提取器中的主干模型。ECAPA-TDNN 的提取器为一个四层结构，前三层均为 SE-Res2Block 模块，使用 SE 模块<sup>[13]</sup> 重新缩放 Res2Block 提取的帧级特征。假设 Res2Block 的输出特征形状为  $(B, C, T)$ ，SE 模块首先使用挤压（Squeeze）操作得到时间维的全局特征  $\mathbf{z}$ ：

$$\mathbf{z} = \frac{1}{T} \sum_t \mathbf{h}_t \quad (3.1)$$

其中  $\mathbf{h}_t$  为每一帧的输入特征。之后对  $\mathbf{z}$  使用激励（Excitation）操作来得到输出特征中每个通道的缩放分数  $\mathbf{s}$ ：

$$\mathbf{s} = \sigma(\mathbf{W}_2 f(\mathbf{W}_1 \mathbf{z} + \mathbf{b}_1) + \mathbf{b}_2) \quad (3.2)$$

其中  $\mathbf{W}_1$  和  $\mathbf{W}_2$  分别为 SE 模块中第一和第二个全连接层的权重参数， $\mathbf{b}_1$  和  $\mathbf{b}_2$  分别为第一和第二个全连接层的偏置项。 $f(\cdot)$  为 ReLU 非线性激活函数， $\sigma(\cdot)$  为 sigmoid 非线性激活函数。最后使用  $\mathbf{s}$  对输出特征进行缩放：

$$\tilde{\mathbf{h}}_c = \mathbf{s}_c \mathbf{h}_c \quad (3.3)$$

其中  $\tilde{\mathbf{h}}_c$  为特征图中经过缩放后的第  $c$  个通道。提取器最后一层为一个用于特征融合的全连接层。该层将前面三层输出特征沿通道维拼接后作为输入，输出融合后的特征。此外，为了更有效利用浅层的特征，每一层都将之前所有层的输出特征逐元素相加作为输入。在 ECAPA-TDNN 的 SE-Res2Block 中，Res2Conv1d 前后有两个卷积核大小  $k = 1$  的一维卷积，用来学习通道间的信息。假设第一个一维卷积输出通道与输入通道之比和第二个一维卷积输入通道与输出通道之比为  $r$ ，考虑到逆瓶颈层在 MobileNetV2<sup>[43]</sup> 和 ConvNeXt<sup>[20]</sup> 中都有着良好的性能表现，本章设置  $r > 1$  使主干模型的每一层都为逆瓶颈层结构。

本章借鉴特征金字塔网络 (Feature Pyramids Networks, 简称 FPN)<sup>[44]</sup>, 提出了一种新的多层特征融合机制, 通过一条自顶向下的路径, 向低层逐层传递高层的特征。FPN 最初被用于机器视觉中使用二维卷积的目标检测任务, 通过逐元素相加来进行特征融合, 而基于二维卷积的模型通常会在不同层之间添加下采样和增加通道数的操作, 因此高层的特征需要经过上采样操作, 低层特征需要通过二维卷积提升通道数, 之后才能够进行融合。Jung 等人<sup>[45]</sup> 使用基于二维卷积的提取器, 因此直接沿用 FPN 结构中融合特征的方法, 如图3-3所示, 假设提取器共  $L$  层, 方便起见图中仅展示单通道的特征图。由于二维卷积中随着模型层数的加深, 特征通道维会逐渐增大, 因此首先每一层的特征图经过二维卷积提升通道维。此外, 由于二维卷积中随着模型层数的加深, 模型输出的特征图尺寸会减小, 因此上一层传递过来的融合后特征需要经过上采样提升图像分辨率。将两者进行逐元素相加便得到该层的融合特征, 最后将所有层的融合后特征沿通道维拼接得到模型输出的融合后特征。 $\oplus$  表示逐元素相加,  $\otimes$  表示沿通道维拼接。不同于原始 FPN, 本章选择将低层特征与高层融合特征逐元素




图 3-3 FPN 中的特征融合方法示意图

相加后再通过全连接层 (Fully Connected Layer, 简称 FC) 进行特征融合, 如图3-4所示, 方便起见图中仅展示单通道的特征图。将反向路径中第  $L$  层传递过来的特征和第  $L-1$  层的输出特征逐元素相加后, 使用 FC 进行特征融合, 之后经过 BN 和 ReLU 得到反向路径中第  $L-1$  层的特征, 并将其传递给第  $L-2$  层。最后将反向路径中各层的特征拼接起来作为融合后的帧级特征。另外, 由于本章提取器采用了前端模型和主干模型两部分设计, 而前端模型和主干模型分别建模不同层次的频率特征, 因此本章只对提取器中主干模型的特征进行融合。本章主干模型层与层之间不设其他操作, 因此在进行特征融合时, 不需要对高层特征和低层特征进行额外操作。假设主干模型中共有  $L$  层参与特征融合, 每一层输出特征的通道数为  $C_1$ , 融合后特征的通道数为  $C_2$ 。使用全连接层融合拼接后的多层特征为模型新增的参数量为  $L \cdot C_1 \cdot C_2$ 。而本章

提出的多层特征融合方法新增的参数量为  $L \cdot C1 \cdot (C2/L) = C1 \cdot C2$ ，与参与融合的特征层数无关。此外反向路径中每层只考虑当前层和反向路径中特征的融合，避免了直接对高层和低层特征进行融合。




图 3-4 提出的特征融合方法示意图

### 3.2.3 模型细节

同其它基于深度学习的说话人识别方法一样，本章提出的方法分为帧级特征提取器、池化层、前馈网络三部分。帧级特征提取器由3.2.1节中的多频带前端模型和3.2.2节中的改进后主干模型构成。使用强调通道的注意力统计值池化（Attention Statistics Pooling，简称 ASP）<sup>[10]</sup> 来从帧级特征中计算话语级特征，计算如下：

$$\mathbf{e}_t = \mathbf{W}_4 f(\mathbf{W}_3 \mathbf{h}_t + \mathbf{b}_3) + \mathbf{b}_4 \quad (3.4)$$

其中  $\mathbf{e}_t$  为每帧特征  $\mathbf{h}_t$  的分数，由两个全连接层计算得到。 $\mathbf{W}_3$  和  $\mathbf{W}_4$  为 ASP 中第一和第二个全连接层的权重， $\mathbf{b}_3$  和  $\mathbf{b}_4$  为第一和第二个全连接层的偏置项。之后沿时间维使用 Softmax 函数得到每一帧特征的注意力权重  $\alpha_t$ ：

$$\alpha_t = \frac{\exp(\mathbf{e}_t)}{\sum_{t'}^T \exp(\mathbf{e}_{t'})} \quad (3.5)$$

使用  $\alpha_t$  计算帧级特征的加权平均值以及标准差：

$$\tilde{\mu} = \sum_t^T \alpha_t \mathbf{h}_t \quad (3.6)$$

$$\tilde{\sigma} = \sqrt{\sum_t^T \alpha_t \mathbf{h}_t^2 - \tilde{\mu}^2} \quad (3.7)$$

将  $\tilde{\mu}$  和  $\tilde{\sigma}$  沿通道维拼接作为话语级特征。最后使用前馈网络中的第一层 FC 从话语级特征提取最终的说话人嵌入，使用第二层 FC 根据说话人嵌入计算各个说话人的分类分数。

说话人识别方法提取的嵌入经常被用来作为说话人确认方法中的说话人嵌入，说话人确认任务需要在不重新训练模型的情况下根据模型提取的说话人嵌入判断两段音频是否属于同一说话人，而这两段音频对应的说话人可能并没有出现在训练集中。在实际应用中需要区分的说话人数量可能非常多，这就要求模型的特征空间能够在容纳足够多不同说话人特征的同时保证各个说话人特征的判别性，因此希望在训练时方法提取嵌入的说话人判别性尽可能大，即每个类别的说话人嵌入之间的距离尽可能远，同类别的说话人嵌入之间的距离尽可能近。

为了使得说话人识别模型能够提取类内紧凑、类间分离的说话人嵌入，目前主流的方法是对分类损失进行改进，提升分类器从说话人嵌入中识别说话人的难度，进而使得模型提取的说话人嵌入满足说话人确认任务的要求。本章使用在其他研究中表现较好的 AAM-Softmax<sup>[46]</sup> 作为分类损失。AAM-Softmax 为了减小同类说话人嵌入之间的距离引入了加性角间隔  $m$ ：

$$L = -\frac{1}{N} \sum_{i=1}^N \log\left(\frac{\exp(s \cdot \cos(\theta_{y_i} + m))}{\exp(s \cdot \cos(\theta_{y_i} + m)) + \sum_{j=1, j \neq y_i}^N \exp(s \cdot \cos \theta_j)}\right) \quad (3.8)$$

其中  $N$  为训练集中不同说话人的个数， $\theta_j$  为归一化后的说话人嵌入与分类器中  $j$  节点归一化后的权重之间的余弦距离， $s$  为防止训练无法收敛的缩放因子。

### 3.3 实验

#### 3.3.1 数据集

本章实验使用的数据集是目前说话人识别领域中最常用的两个英文数据集 VoxCeleb1<sup>[47]</sup> 和 VoxCeleb2<sup>[48]</sup>。两个数据集中的音频均采集自 YouTube 视频网站，VoxCeleb1 包含来自 1251 名说话人的 15 万条音频，平均每个说话人包含 116 条音频，每条音频平均长约 8.2 秒。VoxCeleb2 包含来自 6112 个说话人的 110 万条音频，平均每个说话人包含 185 条音频，每段音频平均长约 7.8 秒。

本章使用 VoxCeleb2 的训练集来进行训练，训练集包含来自 5994 名说话人的

1092009 条音频。在官方划分的三个评估集 VoxCeleb1-O、VoxCeleb1-E、VoxCeleb1-H 中测试训练好的模型。其中 VoxCeleb1-O 为 VoxCeleb1 的原始测试集，包含由 40 个说话人的 4874 条音频组成的 37611 个音频对。VoxCeleb1-E 包含从整个 VoxCeleb1 数据集中随机采样的 579818 个音频对。VoxCeleb1-H 包含从整个 VoxCeleb1 数据集中采样的 550894 个音频对，每对音频都来自相同国家，相同性别的说话人。

### 3.3.2 评价指标

考虑到 VoxCeleb 测试集的组织方式，以及方便与其他进行模型比较，本章实验使用说话人确认任务中常用的等错误率（Equal Error Rate，简称 EER），最小检测代价函数（Minimum Cost Detection Function，简称 minDCF）指标来衡量模型的性能，而不是分类任务中常见的准确率（Accuracy）指标。由于两个指标主要用来评价模型是否能够判断两段音频是否属于同一说话人，因此也可以间接反映模型的分类性能。

EER 为检测误差权衡（Detection Error Tradeoff）曲线中错误接受率（False Accept Rate，简称 FAR）和错误拒绝率（False Reject Rate，简称 FRR）相等时的错误率。错误接受率和错误拒绝率计算如下：

$$\begin{cases} \text{FAR} = \frac{\text{FP}}{\text{TN} + \text{FP}} \\ \text{FRR} = \frac{\text{FN}}{\text{TP} + \text{FN}} \end{cases} \quad (3.9)$$

其中 FP 为预测结果中假正类数量，TN 为真负类数量，FN 为假负类数量，TP 为真正类数量。在一个数据集中，对于一个给定类别，将数据集中属于该类别的样本称为正类（Positive），不属于该类别的样本称为负类（Negative）。给定一个分类系统在该数据集上的分类结果，其中系统预测中正类属于给定类别的结果称为真正类 TP（True Positive），正类不属于给定类别的结果称为假正类 FP（False Positive），负类不属于给定类别的结果称为真负类 TN（True Negative），负类属于给定类别的结果称为假负类 FN（False Negative）。minDCF 计算如下：

$$\text{minDCF} = C_{\text{FR}} \cdot \text{FRR} \cdot P_{\text{T}} + C_{\text{FA}} \cdot \text{FAR} \cdot P_{\text{I}} \quad (3.10)$$

其中  $C_{\text{FR}}$  和  $C_{\text{FA}}$  分别为错误拒绝和错误接受的代价系数， $P_{\text{T}}$  和  $P_{\text{I}}$  分别表示真实说话人和冒名顶替者出现的先验概率。在本章的实验中，将  $C_{\text{FR}}$  和  $C_{\text{FA}}$  设置为 1，将  $P_{\text{T}}$  和

$P_1$  分别设置为 0.01 和 0.99。

### 3.3.3 实验设置

本章实验使用的操作系统为 RedHat 4.8.5-39, 开发语言为 Python 3.7.9, 模型训练框架为 Pytorch 1.12+cuda 11.3, CPU 为 Intel(R) Xeon(R) Gold 6248R CPU @ 3.00GHz, GPU 为 NVIDIA A100(40GB), 内存大小为 64GB。

本章实验使用 80 维 Fbank 特征作为输入时频谱特征。首先将所有音频重采样为 16kHz, 并从每段音频中随机截取 3 秒的片段, 如果音频总长度小于 3 秒则将其循环填充至 3 秒。使用 0.97 的预加重系数对音频进行预加重以补偿高频分量的损失。之后使用汉宁窗以 25 毫秒的窗长和 10 毫秒的帧移对片段进行分帧、加窗, 并对每个窗进行 512 点的 STFT。最后将得到的声谱图使用 80 个梅尔滤波器计算得到 80 维的 Fbank 特征, 并将得到的特征沿着频率维使用均值方差归一化。对于每一段音频, 最后提取的特征形状为 (80, 300)。

由于使用数据增强能够显著提升方法在测试时的鲁棒性, 本章参照 Chung 等人<sup>[15]</sup>的方法对训练集进行数据增强。在提取 Fbank 特征之前, 对训练集中每条音频随机选择一种噪声或者混响进行加噪处理。其中加性噪声选取自 MUSAN<sup>[49]</sup> 数据集中的语音、噪声、音乐类别, 混响随机选取自 RIR<sup>[50]</sup> 数据集中的中型和小型房间的冲激响应。在提取 Fbank 特征之后, 对每条音频都应用 SpecAugment 数据增强, 随机从频率维选择 0-20 个分量, 从时间维选择 0-100 帧进行掩蔽。

本文方法中的提取器使用 512 的通道数。对于形状为 (80, 300) 的输入特征, 在前端模型的第一层将其划分为 8 个独立的子频带, 每个子频带包含 10 个频率分量, 即将  $g_1$  设置为 8。为了在前端模型中完成渐进建模局部特征的过程, 使得主干模型能够平滑地对全局频率特征进行建模, 将前端模型中第二和第三层的  $g_2$  和  $g_3$  分别设置为 4、2。在第二层中将 8 个子频带缩减为 4 个, 在第三层将 4 个子频带缩减为 2 个。这样在主干模型第一层中第一个一维卷积将两个子频带合并为完整的频率维后, 主干模型中的所有 SE-Res2Block 块都能够专注于建模全局频率特征。在整个模型的第一层使用较大的卷积核, 在后续层级中使用较小的卷积核, 即在前端模型的第一层设置  $k_1 = 5$ , 在后续的所有层级 (包括主干模型) 设置  $k = 3$ 。为了在保证模型整体参数量较少的同时增加主干模型每一层建模特征的时间上下文长度, 在主干模型三层 SE-Res2Block 中使用膨胀卷积并将膨胀率  $d$  分别设置为 2、3、4。在每一层中设置

$r = 2$  以实现逆瓶颈层设计。使用提出的方法对主干模型所有层的特征进行融合，融合后的特征通道数为 1536。最后，将前馈网络中第一个全连接层的输出通道数设置为 192，以提取 192 维的说话人嵌入。模型各层的具体超参数设置如表3-1所示。

表 3-1 提出模型的网络结构

| 模型层  |                | k g d r | 输出尺寸<br>通道 × 时间   |
|------|----------------|---------|-------------------|
| 前端模型 | Conv1d-BN-ReLU | 5 8 1 - | $512 \times 300$  |
|      | Res2Block      | 3 4 1 1 | $512 \times 300$  |
|      | Res2Block      | 3 2 1 1 | $512 \times 300$  |
| 主干模型 | SE-Res2Block   | 3 1 2 2 | $512 \times 300$  |
|      | SE-Res2Block   | 3 1 3 2 | $512 \times 300$  |
|      | SE-Res2Block   | 3 1 4 2 | $512 \times 300$  |
| 特征融合 | FC-BN-ReLU     | N/A     | $512 \times 300$  |
|      | FC-BN-ReLU     | N/A     | $512 \times 300$  |
|      | FC-BN-ReLU     | N/A     | $512 \times 300$  |
|      | 拼接融合特征         | N/A     | $1536 \times 300$ |
| 池化层  | ASP            | N/A     | $3072 \times 1$   |
| 前馈网络 | FC             | N/A     | $192 \times 1$    |
|      | FC             | N/A     | $5994 \times 1$   |

在训练过程中，采取了一系列精心设计的策略以优化训练效果。具体来说，在每个训练批次中，选择了 400 个样本作为一个批次的容量，这一选择是基于实验结果和计算资源的可用性进行的权衡。为了有效地更新模型的参数，采用了广泛认可的 Adam 优化器，它结合了自适应估计方法和动量方法的优点，从而在多种任务中表现出色。进一步地，对优化器的超参数进行了细致的调整，将权重衰减系数设定为  $2 \times 10^{-5}$ ，这一系数有助于防止训练过程中的过拟合现象，通过在损失函数中添加一个与权重大小成比例的惩罚项来实现。此外，采用了一种先进的学习率调度策略，即带有预热阶段的余弦衰减学习率调度器。这种调度器首先允许学习率从 0 开始预热，在前 3 轮训练中逐渐增加至  $1 \times 10^{-3}$ ，以确保模型参数能够平稳地开始其优化过程。随后，在接下来的 77 轮训练中，学习率将按照余弦函数的形式平滑地衰减至  $1 \times 10^{-7}$ ，这有助于在训练的后期细致地调整参数，从而获得更好的收敛性能。在损失函数的选

择上, 本研究采用了 AAM-Softmax 损失函数, 将其中的参数  $m$  和  $s$  分别设置为 0.2 和 30, 这样的参数配置旨在增强模型对不同类别特征的区分能力, 并促进模型在特征空间中进行有效的特征对齐。在测试阶段, 对于长度小于 3 秒的音频样本, 为了避免信息的丢失, 采用循环填充的方法, 将其长度补充至 3 秒, 以保持与长音频样本相同的处理标准。所有参与本研究的方法都是在配备了 2 张 NVIDIA A100 GPU 的系统上进行训练和测试的, 每张 GPU 拥有 40GB 的大容量显存。

### 3.3.4 实验结果

#### 1. 对比试验

在这部分实验中, 使用本章模型与目前主流的说话人识别方法进行对比, 这些方法包括 ECAPA-TDNN<sup>[11]</sup>、ResNetSE34<sup>[15]</sup> 以及 MFA-Conformer<sup>[23]</sup>。ECAPA-TDNN 结构如 3.2.2 节中所介绍, 这里将特征的通道数设置为 1024。ResNet 作为一种流行的二维卷积提取器在 CNN 的基础上通过残差连接 (Residual Connections) 将模型每一层的输入特征直接相加到该层的输出特征中, 缓解了 CNN 在训练过程中出现的梯度消失问题。ResNetSE34 使用一个 4 阶段的 34 层 ResNet 作为提取器, 使用 SE 模块对每个阶段的输出特征图进行缩放, 使用 ASP 来从提取器最后一层输出的帧级特征中计算得到话语级特征。MFA-Conformer 是一种流行的基于 Transformer 的说话人识别方法, 其提取器的初始层为步长为 2 跨步卷积, 负责对特征进行下采样, 提取器主干使用 Conformer<sup>[51]</sup> 模块, Conformer 在 Transformer 每一层中添加一个二维卷积来建模局部特征, 最后提取器将不同层的特征拼接后通过一个全连接层进行特征融合, 并使用 ASP 从融合后的帧级特征中计算得到话语级特征。总的来说, 所有方法只存在提取器上的区别。

表 3-2 展示了本章方法与目前流行的几种方法的对比实验结果。可以看出在对比的三种方法中, ECAPA-TDNN 有着最好的性能表现。这说明 TDNN 模型的结构设计相较于 CNN 和 Transformer 可能更加适合说话人识别任务。另一方面, 本章方法在三个测试集上的性能都要优于 ECAPA-TDNN, 其中在 VoxCeleb1-E 中 EER 相对降低了 9%, 在 VoxCeleb1-O 中 minDCF 相对降低了 14%, 而参数量仅为 ECAPA-TDNN 的 52%。这说明本章方法能够更高效地提取更有效的说话人嵌入。

表 3-2 VoxCeleb 中的对比实验结果

| 模型            | 参数量          | VoxCeleb1-O  |              | VoxCeleb1-E  |              | VoxCeleb1-H  |              |
|---------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
|               |              | EER          | minDCF       | EER          | minDCF       | EER          | minDCF       |
| ResNetSE34    | 22.06M       | 1.35%        | 0.127        | 1.72%        | 0.191        | 3.11%        | 0.281        |
| MFA-Conformer | 19.76M       | 1.07%        | 0.112        | 1.35%        | 0.153        | 2.59%        | 0.247        |
| ECAPA-TDNN    | 15.05M       | 0.96%        | 0.106        | 1.30%        | 0.143        | 2.58%        | 0.249        |
| 本章模型          | <b>7.85M</b> | <b>0.95%</b> | <b>0.091</b> | <b>1.18%</b> | <b>0.130</b> | <b>2.36%</b> | <b>0.234</b> |

## 2. 前端模型有效性实验

为了证明前端模型的有效性，本节基于 512 维的 ECAPA-TDNN（基线模型）设计了五种提取器用来进行实验。首先根据 Thienpondt 等人<sup>[38]</sup>的研究，设计一个通道数为 128 的四层  $k=3$  的 ResNet 作为前端模型，将基线模型的提取器作为主干模型与其组合称为 Conv2d(128)-ECAPA。ResNet 中第一层和最后一层在频率维使用步长为 2 的跨步卷积来降低计算量，中间两层的输入通过快捷连接相加到输出中，每个卷积层后都有一个 ReLU 和 BN。最终前端模型输出的特征形状为 (400, 128, 20, 300)，为了将特征传递到主干模型中，需要先将其展平为 (400, 2560, 300)，2560 的通道数量使得主干模型的第一层拥有较大的参数量。为了进行公平的比较，另外设计了一个通道数为 32 的 4 层 ResNet 前端模型，将其与基线模型的提取器组合称为 Conv2d(32)-ECAPA，除了通道数减少外，其余结构与 Conv2d(128)-ECAPA 相同。最后使用与 3.3.3 节中相同的前端模型结构与基线模型的提取器进行组合称该模型为 Subband-ECAPA。另外由于提出前端模型的结构与主干模型相似，因此设计一个由一层  $k=5$  的一维卷积初始层和两层与基线模型的提取器相同设置的 SE-Res2Block 组成的前端模型，与基线模型的提取器组成一个七层的 ECAPA-TDNN，称为 ECAPA-TDNN-D，用以验证提出的前端模型并不是简单的加深主干模型深度。所有实验只在提取器中的前端模型上的存在区别。

表3-3展示了前端模型有效性实验的结果。基线模型和 Conv2d(128)-ECAPA 结果的比较说明通过直接添加二维卷积来引入频率维的局部信息并不是高效的，虽然 Conv2d(128)-ECAPA 相较于基线模型有一定的提升，但是却引入了大量的参数，而与本章模型参数量接近的 Conv2d(32)-ECAPA，实际上却降低了模型的性能。另一方面，ECAPA-TDNN-D 的 EER 相较于基线模型错误率降低了 5%，说明了直接加深模型深

度确实能够带来一定的性能提升。而本节模型的 EER 相较于基线模型降低了 9%，这说明提出前端模型带来的性能提升不仅仅是因为加深了模型的深度，更重要的是引入了模拟二维卷积渐进地建模局部频率特征的过程。

表 3-3 VoxCeleb-O 中前端模型有效性实验结果

| 模型                | 参数量    | 浮点运算量 | VoxCeleb1-O<br>EER |
|-------------------|--------|-------|--------------------|
| 基线模型              | 6.19M  | 1.04G | 1.17%              |
| Conv2d(128)-ECAPA | 10.36M | 4.76G | 1.10%              |
| Conv2d(32)-ECAPA  | 7.00M  | 1.39G | 1.19%              |
| ECAPA-TDNN-D      | 7.42M  | 1.29G | 1.11%              |
| Subband-ECAPA     | 7.06M  | 1.22G | 1.06%              |

### 3. 主干模型及反向特征融合有效性实验

为了证明本章对主干模型改进以及提出的反向特征融合方法的有效性，本节基于 512 通道数的 ECAPA-TDNN 设计了四种只包含主干模型的提取器进行对比实验。第一种提取器的 SE-Res2Block 块中不改变通道数，始终保持 512 的通道数，即  $r = 1$ ，将该模型作为基线模型。第二种提取器为  $r = 2$  的逆瓶颈层设计，称该模型为 IBECAPA。此外，另设一个  $r = 0.5$  的瓶颈层提取器，称该模型为 BECAPA。为了保证瓶颈层和逆瓶颈层的计算量和参数量相近，在 BECAPA 中将通道数设置为 1024。最后，本节模型将 IBECAPA 结构中拼接所有层特征并使用全连接层进行融合的多层特征融合方法替换为 3.2.2 节中提出的多层特征融合方法，称该模型为 IFF-IBECAPA。

表 3-4 展示了为证明对主干模型改进的有效性而进行的实验的结果。其中瓶颈层 (BECAPA) 与基线模型的 EER 相近，但是参数量和计算量却高于基线模型，这可能是由于瓶颈层 Res2Block 中的一维卷积压缩了特征通道数，导致了一定的信息损失，进而导致 Res2Conv1d 无法得到足以建模不同时间尺度的特征。相反，逆瓶颈层中一维卷积增加了特征的通道数，使得 Res2Conv1d 得到信息更加充分，进而更加有效的建模不同时间尺度的特征，逆瓶颈层 (IBECAPA) 与基线模型实验结果的对比也印证了这一点。另一方面，比较本章提出的特征融合方法 (IFF-ECAPA) 和原始的特征融合方法 (IBECAPA)，本节模型在进一步降低 EER 的同时还降低了模型整体的参数量，这足以说明本章提出的多层特征融合方法能够更高效的融合不同层的特征。

表 3-4 VoxCeleb-O 中改进后主干模型有效性实验结果

| 模型          | 参数量    | 浮点运算量 | VoxCeleb1-O<br>EER |
|-------------|--------|-------|--------------------|
| 基线模型        | 6.19M  | 1.04G | 1.17%              |
| BECAPA      | 10.73M | 1.87G | 1.16%              |
| IBECAPA     | 8.55M  | 1.51G | 1.11%              |
| IFF-IBECAPA | 6.98M  | 1.20G | 1.05%              |

#### 4. 模型超参数搜索实验

为了进一步增加实验的可信性,表3-5中展示了本章模型超参数搜索过程中不同学习率(Learning Rate,简称lr)以及批次大小(Batch Size,简称bs)设置时在VoxCeleb1-O中的EER结果。从表中可以看出当初始学习率lr为 $1 \times 10^{-3}$ ,并且批次大小bs为400时,模型的性能最好,因此本文将lr设置为 $1 \times 10^{-3}$ ,bs设置为400。

表 3-5 VoxCeleb 中模型超参数搜索实验结果

|                | lr= $1 \times 10^{-4}$ | lr= $1 \times 10^{-3}$ | lr= $3 \times 10^{-3}$ |
|----------------|------------------------|------------------------|------------------------|
| <b>bs=200</b>  | 1.02%                  | 0.97%                  | 1.21%                  |
| <b>bs=400</b>  | 0.96%                  | 0.95%                  | 1.17%                  |
| <b>bs=1000</b> | 1.03%                  | 1.02%                  | 1.25%                  |

### 3.4 本章小结

本章针对现有说话人识别方法中基于TDNN的帧级特征提取器存在的问题提出了两点优化。第一点优化针对TDNN无法有效对局部频率特征进行建模问题,提出了一种新的前端模型,利用子频带划分并逐层减少子频带数量使模型渐进地建模局部频率特征。第二点优化针对TDNN现有的多层特征融合方法无法高效地建模高层特征和低层特征之间的复杂关系,提出了一种新的特征融合方式,在主干模型中设置一条反向路径,反向路径中每一层只专注于当前层特征和反向路径中上层传递来的特征之间的关系。实验表明,改进后的方法能够以更少的参数量取得超过目前主流方法的性能。

## 第四章 基于卷积神经网络的音频分类模型

### 4.1 引言

对于 CNN 模型, 其为声音事件分类这一音频分类子任务中非常流行的一类模型。虽然最近随着 Transformer 模型的涌现, CNN 正在逐渐被其取代, 但其参数量及计算量上仍然存在着优势。因此本章选择对声音事件分类任务中的 CNN 模型进行改进, 进一步探索其在声音事件分类任务中的潜能。声音事件分类指的是将一段音频样本映射为声音事件标签, 在过去的很长一段时间里, CNN 一直是这个任务的主流模型<sup>[5,6,52]</sup>。时频谱作为一种 CNN 常用的音频输入特征, 拥有不同属性的两个维度, 一个维度代表频率维, 另一个维度代表时间维。沿时间维分布的时频模式与图像中的目标类似, 都是平移不变的, 这意味着某种时频模式沿着时间维移动可以看作是图像中物体的空间位置发生了改变, 并不会改变模式所代表的语义。相反, 沿频率维分布的时频模式则是非平移不变的, 这意味着一个声音事件种类的时频模式如果沿着频率维移动, 该模式代表语义很可能发生了改变<sup>[7]</sup>。CNN 中沿两个维度移动的卷积核, 在适配时频谱时间维特征平移不变性的同时, 也与时频谱频率维中非平移等变的特征相冲突。

最近, 随着 Transformer 的流行, 出现了许多基于 Transformer 的声音事件分类模型。Transformer 最初是被用于自然语言处理<sup>[22]</sup>, 后来的一些研究将其应用到计算机视觉领域<sup>[24]</sup>, 并很快成为了研究热点。以 AST<sup>[8]</sup> 为开端, 越来越多 Transformer 被用于声音事件分类, 并不断更新各个声音事件数据集中深度学习模型的最佳性能。随着对 Transformer 架构理解的逐步加深, 众多研究开始探索其强大性能背后的原因。这些研究尝试将 Transformer 的特性或结构设计适配到其他模型中, 通过实验揭示 Transformer 成功的关键因素, 并将其优势应用到更多的深度学习模型中。受启发于 Transformer 中自注意力机制的全局感受野, RepLKNet<sup>[21]</sup> 通过引入超大的卷积核来增大传统 CNN 的感受野。Mlp-Mixer<sup>[53]</sup> 和 Metaformer<sup>[54]</sup> 借鉴 Transformer 的标记混合器 (Token Mixer) 和通道混合器 (Channel Mixer) 设计, 将其中使用自注意力机制的标记混合器替换为多层感知机甚至极其简单的池化层, 经验性地证明了 Transformer 结构对其性能起着重要作用。ConvNeXt<sup>[20]</sup> 详细分析了 Transformers 的设计空间, 逐步将这些设计引入到传统 CNN 中, 使其性能逐渐接近并超过 Transformer。虽然这些

工作总结了大量利用 Transformer 设计技巧来提升其他模型性能的方法,然而目前还没有工作尝试使用这些方法来改进一个用于声音事件分类的 CNN,尽管 CNN 相较于 Transformer 往往有着更少的参数量、计算量以及更加简单的结构设计。

上述问题启发本文提出一种新的 CNN 模型,它既能避免 CNN 的平移等变性对识别频率维非平移不变的模式产生不利影响,又能像 Transformer 的自注意力机制那样在频率维提供全局感受野。对于声音事件分类,目前最优秀的模型几乎全为基于 Transformer 的模型。为了证明一个 CNN 依然可以实现领先的性能,本章针对时频谱的特性对 CNN 进行优化并结合 Transformer 中的结构设计,提出了时频增强卷积神经网络(Time-Frequency Enhanced Convolutional Neural Network,简称 TFECN)。TFECN 不仅可以释放 CNN 在频率维的平移等变性,同时也提供了像 Transformer 一样的频率维全局感受野,以一种简单的方式实现了 Transformers 中的复杂的设计。此外,为了使用之前工作提供的预训练权重,本章提出了一种将小尺寸卷积核中权重迁移至更大卷积核的方法。这种方法使得一些使用大卷积核的模型能够利用与其结构类似的但使用更小卷积核的模型来进行迁移学习。实验结果表明,TFECN 在三个常用于声音事件分类任务的数据集 AudioSet<sup>[55]</sup>、FSD50K<sup>[56]</sup>、ESC50<sup>[57]</sup>中,皆优于以相同方式训练的模型,并在 FSD50K 中实现了最先进的性能,证明了 CNN 依然可以在声音事件分类任务中实现先进的性能。

## 4.2 时频增强卷积神经网络

在本节中,首先介绍 TFECN 的整体模型结构,之后介绍为了规避 CNN 频率维平移等变形而提出的时频增强卷积,最后介绍为了使用之前工作提供的预训练权重而提出的将小尺寸卷积核中权重迁移至更大卷积核的方法。

### 4.2.1 模型架构

TFECN 参照 Transformer 中常见的四阶段设计,并采用 3 : 3 : 9 : 3 的阶段计算比。为了在增加特征表达能力的同时避免模型计算量过大,在 TFECN 不同阶段之间设置过渡层。过渡层中使用卷积核大小为  $3 \times 3$  的卷积来增加特征的通道数以将特征映射到更多的特征空间中,使用步长为  $2 \times 2$  的跨步卷积来沿着特征时间维和频率维进行下采样以减少模型的计算量。在模型的最开始,使用卷积核大小为  $7 \times 7$ ,步长为  $4 \times 4$  的跨步卷积来对时频谱进行下采样。在组成一个阶段的基本块中,首先是一个扩

展率 (Expand Ratio) 为 2 的逆瓶颈块。在逆瓶颈块中, 首先对输入特征使用卷积核大小为  $1 \times 1$  的卷积即逐点卷积 (Pointwise Convolution) 来将特征映射到更多的特征空间 (通道), 扩展率为 2 意味着通道数量为原来的两倍, 之后使用分组数等于通道数的分组卷积即逐层卷积 (Depthwise Convolution) 来捕获每个特征空间中的特征, 最后再使用另外一个逐点卷积将特征映射回原来的通道数。在由逐点卷积和逐层卷积组成的深度可分离卷积 (Depthwise Separable Convolution) 中, 逐点卷积负责捕获特征空间之间的交互特征。而在逆瓶颈块中, 逐点卷积更多的是负责将特征映射到更多更复杂的特征空间中, 与 Transformer 的自注意力机制中查询、键和值的线性映射矩阵的作用一致。因此, 模型捕获通道间特征的能力可能会有所下降。Transformer 为了解决这个问题, 在自注意力层之后添加了由全连接层组成的多层感知机作为补充, 受此启发, TFECN 在逆瓶颈块后额外添加一个多层感知机来增加模型在不同特征空间的信息交流。TFECN 的整个模型结构如图4-1所示, 阶段一与其他阶段的不同在于将过渡层替换为下采样层, 即阶段一仅对输入特征进行下采样而不进行通道增维。考虑到 ConvNeXt 在实验中证明使用 Transformer 中常用的层归一化 (Layer Normalization, 简称 LN) 替换传统 CNN 中使用的批量归一化 (Batch Normalization, 简称 BN) 能够带来一定的性能提升, 因此 TFECN 中的归一化采用 LN。LN 计算如下:

$$\begin{aligned}\tilde{X} &= \frac{X - \mu}{\sqrt{\sigma^2 + \epsilon}} \\ \mu &= \frac{1}{H \times W} \sum_i^H \sum_j^W x_{ij} \\ \sigma^2 &= \frac{1}{H \times W} \sum_i^H \sum_j^W (x_{ij} - \mu)^2\end{aligned}\quad (4.1)$$

其中  $\tilde{X}$  为特征  $X \in \mathbb{R}^{H \times W}$  层归一化后的结果,  $x_{ij}$  为  $X$  中位置  $i, j$  处的值,  $\mu$  为特征图的均值,  $\sigma$  为特征图的标准差。为了更好的迁移预训练模型中的知识, 同预训练模型 Convformer<sup>[54]</sup> 一样, 本章使用 Squared ReLU 作为激活函数, 计算如下:

$$f(x) = \text{ReLU}^2(x) = \begin{cases} x^2, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (4.2)$$

此外, 模型还参照 Metaformer<sup>[54]</sup>, 在激活函数后设置可学习的缩放和偏差, 并对第 3 和第 4 阶段中对来自快捷链接的输入进行缩放, 以进行更有效地训练。




图 4-1 TFECN 模型结构图

### 4.2.2 时频增强卷积

由于时频谱中沿频率轴分布的模式不具有平移不变性，一个小于特征图尺寸的卷积核在特征图内滑动会对模型的识别能力产生干扰，尤其是对识别高层语义特征的模型顶层。为解决这个问题，本章提出了一种新的卷积方式称为时频增强卷积（Time-Frequency Enhanced Convolution，简称 TFEConv），TFEConv 的原理如图4-2所示，方便起见图中假设输入特征图中被卷积核覆盖区域的神经元拥有相同的值，即不同位置的卷积核覆盖的时频模式相同，并将输出特征图表示为仅保留频率维的一维形式，图中虚线框表示为了保证输入和输出特征图尺寸一致而对输入特征图进行的 0 填充。

在图4-2（a）中，输入特征图中相同的模式  $\mathbf{x}$  经过相同的权重  $\mathbf{w}$  与输出特征图中神经元相连，最终产生相同的输出：

$$\mathbf{w} \odot \mathbf{x} = \mathbf{w} \odot \mathbf{x} \quad (4.3)$$

其中  $\mathbf{w}$  表示卷积核的所有列， $\odot$  表示逐元素相乘， $\mathbf{x}$  表示输出特征图中与神经元相连的区域。这意味着在不同位置的相同模式有着相同的语义。这种现象符合图像中目标的分布事实，比如图像中一个物品从左侧移动到了右侧，该物品的种类并没有发生变化。但是当一种模式在时频谱频率维的位置发生改变，比如从高频位置移动到低频位置，这种模式代表的语义很可能发生了变化，比如说由笑声变为了哭声。此外，由公式 (4.3) 可以看出，导致 CNN 将频率维不同位置的相同模式识别为相同的语义的主要原因是 CNN 的参数共享机制。参数共享机制使得卷积核在特征图中的不同位置都

拥有相同的权重，进而与不同位置相同的时频模式作用产生相同的输出。

为了规避 CNN 在频率维的参数共享机制，TFECN 首先将卷积核沿频率方向扩大，使其覆盖整个频率维度，这样在卷积核沿着频率维移动时，输出特征图中每个神经元与输入特征图连接的权重总是不相同的。如图4-2（b）所示，即使是两个相同的时频模式，经过不同的权重与输出神经元相连，最终也将产生不同的输出：

$$\mathbf{w}_{p:q} \odot \mathbf{x} \neq \mathbf{w} \odot \mathbf{x} \quad (4.4)$$

其中  $\mathbf{w}_{p:q}$  表示卷积核中第  $p$  到  $q$  列的权重。此时不同频率位置处的相同模式也拥有着不同的语义。最后，为了保证输出特征图中每个神经元都能够覆盖整个频率维，继续沿频率维扩大卷积核，使其满足下式：

$$K_f - \lfloor \frac{K_f}{2} \rfloor = F \quad (4.5)$$

对于输入特征图  $\mathbf{X} \in \mathbb{R}^{T \times F}$ ， $F$  代表其频率维的长度。 $K_f$  代表卷积核沿频率方向的长度。这样，在保证输出特征图和输入特征图尺寸保持一致的前提下，输出特征图中最左端与最右端的神经元都能够覆盖经过填充后输入特征图的整个频率维，如图4-2（c）所示。本章称使用满足公式（4.5）的卷积核的逐层卷积为频率增强卷积（Frequency Enhanced Convolution，简称 FEConv）。

另一方面，考虑到时间线索对识别一些声音事件种类也起着重要作用，TFEConv 中引入了另一个卷积核，并将其沿时间方向进行扩展，增加卷积核和时间维的感受野以建模更长时间上下文的特征，并称使用这个卷积核的逐层卷积为时间增强卷积（Time Enhanced Convolution，简称 TEConv）。最后，使用由 TEConv 和 FEConv 共同组成 TFEConv 来替换逆瓶颈块中的逐层卷积。在 TFEConv 中，使用两个可学习的权重参数  $w_t$  和  $w_f$  将 TEConv 和 FEConv 的输出加权求和：

$$\text{TFEConv}(\mathbf{X}) = w_t \cdot \text{TEConv}(\mathbf{X}) + w_f \cdot \text{FEConv}(\mathbf{X}) \quad (4.6)$$




图 4-2 时频增强卷积示意图

### 4.2.3 预训练

与之前的许多研究<sup>[6,8]</sup>相同,本章使用包含 1400 万张共 2 万个类别的人工标注大规模图像数据集 ImageNet<sup>[17]</sup>对提出的模型进行预训练。由于 Convformer<sup>[54]</sup>与 TFECN 模型结构相似,因此本章通过将该模型提供的预训练权重迁移至 TFECN 来实现预训练过程。考虑到 Convformer 的卷积核尺寸为  $7 \times 7$ ,并不能直接移植到本章模型中。受启发于结构重参数化<sup>[58]</sup>中将不同尺寸卷积核融合的方法,首先初始化两个与 TEConv 和 FEConv 中卷积核尺寸相同的大卷积核  $LK \in \mathbb{R}^{K_t \times K_f}$ ,之后使用预训练的小卷积核  $PSK \in \mathbb{R}^{K_s \times K_s}$  的权重为两个  $LK$  的中央区域赋值,如图4-3所示,并称这样形成的卷积核为  $PLK \in \mathbb{R}^{K_t \times K_f}$ 。由于卷积的可加性,使用  $PLK$  进行的卷积可以表示为:

$$X \otimes PLK = X \otimes LK + X \otimes PSK \quad (4.7)$$

其中  $X \in \mathbb{R}^{T \times F}$  表示输入特征图,  $\otimes$  表示卷积操作。为了避免对预训练学习到的知识的破坏,使用 0 初始化  $LK$ 。这样在训练的最开始,公式 (4.7) 中右侧第一项的值为 0,使用  $PLK$  进行卷积也就相当于使用  $PSK$  进行卷积:

$$X \otimes PLK = X \otimes PSK \quad (4.8)$$

由于预训练权重的存在,卷积核中初始值为 0 的权重也可以得到更新。最后,使用  $PLK$  来为 TFECN 中的卷积核进行权重初始化。

实际上,在相同尺寸的卷积核间进行权重迁移就相当于使用 0 初始化了一个与预训练卷积核尺寸相同的卷积核,之后将两者相加。从另一个角度来说,这类似于 ResNet<sup>[39]</sup> 中的残差块,残差块负责学习目标映射与恒等映射之间的残差,而 0 初始




图 4-3 权重迁移示意图

化卷积核则是学习目标映射与经过预训练的卷积核学习到的映射之间的残差。因此，本章提出的权重迁移方法，只不过是将用来学习这种残差的卷积核替换为更大的卷积核，并没有使预训练学习到的知识在不同尺寸卷积核之间的迁移过程中产生损失。

## 4.3 实验

### 4.3.1 数据集

AudioSet<sup>[55]</sup> 是目前最大声音事件数据集，它由超过 2 百万条 10 秒左右长度的音频片段组成，这些音频从视频网站 YouTube 的视频中裁剪出来，并人工标注为 527 个类别。AudioSet 中的单个样本会同时出现多个声音事件种类，每个样本会使用以一种或多种标签进行标注，因此 AudioSet 中的声音事件分类是一个多标签多类问题。整个数据集被官方划分为平衡训练集、未平衡训练集以及测试集。考虑到 YouTube 中的视频，会随着时间减少，因此为了保证实验的可比较性，本章参照 Kong 等人<sup>[5]</sup>提供的方法来获取数据集。最终成功下载未平衡训练集中的 1912137 条音频，平衡训练集中的 20550 条音频，以及测试集中的 18887 条音频。本章使用未平衡训练集与平衡训练集组成的训练集来训练模型，并在官方划分的测试集上评估模型。为了利用 GPU 并行计算的优势，通过循环填充少于 10 秒的音频，裁剪多余 10 秒的音频来将所有训练样本统一至 10 秒。由于 AudioSet 存在严重的类别不平衡问题，本章在训练时对每一个批次的采样采用了加权采样的方法，对样本数量多的种类，在采样时赋值更小的权重，对于样本数量很少的种类，在采样时赋值更大的权重，权重的计算公式如下：

$$w_c = \frac{1000}{f_c + 100} \times f_c \quad (4.9)$$

其中  $w_c$  为种类  $c$  的采样权重,  $f_c$  为种类  $c$  在训练集中出现的次数。

FSD50K<sup>[56]</sup> 是目前第二大的人工标注声音事件数据集, 它包含了从 Freesound 挑选的 5 万条平均长度为 7.6 秒的音频片段, 并且从 AudioSet 对声音事件的分类中挑选 200 个类别进行标注。同 AudioSet 一样, FSD50K 中一个样本也会同时对应多个声音事件种类, 在 FSD50K 中的分类任务也是一个多标签多类问题。本章实验采用官方的训练集、验证集、测试集划分。考虑到 FSD50K 中音频长度多变, 为了充分利用数据集中较长的音频, 本章按照一定的重叠对于长于 10 秒的音频进行 10 秒的分段。具体来说, 对于训练集中的音频使用 3 秒的重叠, 而验证集和测试集则不使用重叠。另外, 由于 FSD50K 中的评估集 (包括验证集和测试集) 经过精细的人工标注, 能够降低标注错误等噪声对反应模型性能的指标产生的影响, 更准确地反映出不同模型之间的差异。因此本章选择在 FSD50K 中进行消融实验, 以更好地反应提出的方法对模型性能的影响。

ESC50<sup>[57]</sup> 包含了 2000 条长度为 5 秒的音频, 并使用 50 种类别进行标注。与其他两个数据集不同, ESC50 中每条音频只包含一个类别, 是一个多分类任务。本章使用官方划分的 5 个折来进行 5 折交叉验证。此外, 将单条音频重复两遍以与其他数据集中 10 秒的训练样本长度保持一致。

### 4.3.2 评价指标

本节主要介绍本章实验中使用的评价指标, 包括准确率 (Accuracy, 简称 Acc) 和均值平均精度 (Mean Average Precision, 简称 mAP)。

准确率指的是预测正确的结果在所有预测结果中的占比, 计算如下:

$$\text{Acc} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \quad (4.10)$$

其中 TP 为预测结果中真正类的数量, FP 为假正类的数量, TN 为真负类的数量, FN 为假负类的数量。

精度 (Precision) 定义为真正类在系统预测中属于给定类别的结果中的占比, 计算如下:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (4.11)$$

召回率 (Recall) 定义为真正类在数据集中所有正类中的占比, 计算如下:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (4.12)$$

对于一个特定类别, 给定一个具体的召回率值, 计算在不低于给定召回率下能达到的最高精度, 选取多个召回率值分别计算最高精度后取平均, 得到的结果称为平均精度 (Average precision, 简称 AP)。之后对于数据中所有类别的平均精度取平均即为均值平均精度 (Mean Average precision, 简称 mAP)。在常见实现中, 一般将 AP 定义为精度召回率曲线下面积, 此时 mAP 计算如下:

$$\text{mAP} = \frac{1}{C} \sum_c \sum_n^N (R_n^c - R_{n-1}^c) P_n^c \quad (4.13)$$

其中  $C$  为数据集中类别数量,  $N$  为选择的召回率值数量,  $R_n^c$  为类别  $c$  中第  $n$  个召回率值,  $P_n^c$  为类别  $c$  中召回率不低于  $R_n^c$  时能达到的最大精度。

为了方便与其他方法进行比较, 本章中 AudioSet 和 FSD50K 两个数据集中的实验使用 mAP 作为评价指标, ESC50 中的实验使用 Acc 作为评价指标。

### 4.3.3 实验设置

本章实验的软硬件配置同第 3 章。对于每个数据集, 首先将其中的每个样本转换成单声道, 重采样至 32kHz, 并使用与数据集对应的方法将样本长度统一至 10 秒。之后使用大小为 1024 的汉宁窗以及大小为 320 的帧移来对音频进行 STFT, 并将频率限制在 50Hz 到 14000Hz 之间。最后使用 128 个滤波器组成的梅尔滤波器组来计算梅尔频谱。最终产生形状为 (1000, 128) 的时频谱特征。

使用  $(K_t, K_f, K_s)$  来表示一个阶段中 TFEConv 的卷积核尺寸, 其中  $K_t$  表示 TEConv 中卷积核时间维的尺寸,  $K_f$  表示 FEConv 中卷积核频率维的尺寸,  $K_s$  则表示两个卷积核中剩余方向上的尺寸。经过分块化和下采样, 特征的频率维度在四个阶段的尺寸分别为 32, 16, 8, 4。参照公式 (4.5), 将后三个阶段的 TFEConv 中  $K_f$  分别设置为 31, 15, 7。由于在第一阶段中卷积的主要建模底层特征, 拥有较大的特征图尺寸, 因此将  $K_f$  设置为 31, 使其几乎覆盖整个频率维, 以在降低计算量的同时, 释放卷积的平移不变性。最终四个阶段卷积核大小分别设置为 (15, 31, 7), (15, 31, 7), (15, 15, 7), (15, 7, 7)。训练时采用 RepLKNet 中大核逐层卷积的高效 CUDA 实现, 以加快训练速

度。另外，为了避免在使用预训练权重时破坏预训练学习到的知识，将四个阶段中 TFEConv 中的  $w_f$  和  $w_t$  的初始值都设置为 0.5。

由于数据增强能够显著提升模型的泛化能力，在本章实验中使用了两种数据增强技术，Mixup<sup>[59]</sup> 和 SpecAugment。Mixup 通过线性组合两个不同的训练样本及其标签来创造新的训练样本。这种方法可以鼓励模型学习到更加平滑的决策边界，从而提高模型在面对未见过的输入数据时的表现。具体来说，Mixup 通过下式来对样本进行混合：

$$\begin{cases} x = \lambda \cdot x_A + (1 - \lambda) \cdot x_B \\ y = \lambda \cdot y_A + (1 - \lambda) \cdot y_B \end{cases} \quad (4.14)$$

其中  $x$  为样本， $y$  为标签， $\lambda$  为混合比例。 $\lambda$  从 Beta 分布中采样得到，Beta 分布的概率密度函数计算如下：

$$\begin{cases} f(x; \alpha, \beta) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} \\ B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx \end{cases} \quad (4.15)$$

本章从  $\alpha = \beta = 0.5$  的 Beta 分布中采样得到 Mixup 中的  $\lambda$ 。SpecAugment 随机从时频谱的频率维和时间维选取部分值掩蔽置零，增加数据的多样性以提升模型的泛化性能。本章将最大时间掩蔽长度设置为 256，最大频率掩蔽长度设置为 64。此外，由于 AudioSet 存在部分标注错误，本章还采用标签平滑（Label Smoothing）正则化技术，以避免模型对数据集中的标注错误产生拟合，并提升模型的泛化能力。具体来说，首先将样本标签转换为独热编码的形式，对于包含 527 个种类的 AudioSet 来说，其独热编码形式的标签为一个长度为 527 的一维向量，其中样本中出现的类别位置处值为 1，其余未出现的类别位置处值为 0。标签平滑计算如下：

$$\begin{cases} v_1 = 1 - s \\ v_0 = \frac{c_1 \times s}{c_0} \end{cases} \quad (4.16)$$

其中  $v_1$  为标签平滑后，标签中 1 位置处的值， $v_0$  为标签平滑后，标签中 0 位置处的值， $c_1$  为标签中 1 的数量， $c_0$  为标签中 0 的数量， $s$  为人为指定的超参数，本章中  $s = 0.1$ 。

在所有数据集中的模型都使用 AdamW 优化器进行训练，并使用带预热的余弦衰减学习率调度将学习率首先从 0 经过十轮的预热线性增长到  $4 \times 10^{-4}$ ，并在第 50

轮衰减至  $1 \times 10^{-7}$ 。对于 ESC50，在进行到 50 轮时，继续保持  $1 \times 10^{-7}$  的学习率训练总共 100 轮，对于其余两个数据集则在 50 轮停止训练。此还使用指数移动平均 (Exponential Moving Average, 简称 EMA) 技术使用历史均值为模型参数赋值，以提高模型的泛化能力，参数  $p$  在时刻  $t$  的实际更新值  $p_t$  计算如下：

$$p_t = \gamma \cdot p_{t-1} + (1 - \gamma) \cdot \theta_t \quad (4.17)$$

其中  $\gamma$  为衰减率， $\theta_t$  为 AdamW 优化器经过梯度下降更新的参数值。对于 AudioSet 和 FSD50K，将  $\gamma$  设置为 0.9999，而对于 ESC50 则设置为 0.9998。针对不同的分类问题，为了实现方便，使用二元交叉熵作为 AudioSet 和 FSD50K 多标签多分类任务的损失函数，使用交叉熵作为 ESC50 多分类任务的损失函数。对于 AudioSet，使用 4.3.1 节中介绍的加权采样方法，在每一轮训练中，从训练集中采样 20 万个样本作为该轮的训练集，并采用 128 的批次大小在 4 张 NVIDIA A100 GPU 上进行训练。对于 FSD50K 和 ESC50 则采用全部训练数据作为每一轮的训练集，并分别使用 64 和 16 的批量大小在 2 张 NVIDIA A100 GPU 上进行训练。

#### 4.3.4 实验结果

##### 1. 消融实验

消融实验以一个类似 MobileNetV2<sup>[43]</sup> 的模型作为基线模型，它相较于 TFECN 有两点简化，移除 TFECN 中的多层感知机，并使用卷积核大小为  $7 \times 7$  的逐层卷积替换 TFEConv，称这个模型为 MobileNetV2-like。之后在 MobileNetV2-like 的基础上重新引入多层感知机。由于多层感知机相当于深度可分离卷积中的逐点卷积，逆瓶颈块相当于逐层卷积，因此称这个模型为深度可分离卷积神经网络 (Depthwise Separable Convolution Neural Network, 简称 DSCN)。最后，使用 TFEConv 替换 DSCN 逆瓶颈块中的逐层卷积形成最终的 TFECN。此外，为了验证提出的卷积核权重迁移方法的有效性，使用 ImageNet 中的预训练权重，分别在相同尺寸的卷积核之间进行权重迁移 (DSCN\_ImgP)，以及使用 4.2.3 节中提出的方法在不同尺寸卷积核之间进行权重迁移 (TFECN\_ImgP)。

如表 4-1 所示，引入多层感知机的 DSCN 性能相较于 MobileNetV2-like 获得了提升，但是在引入 TFEConv 后却出现了过拟合的情况。这可能是由于大卷积核在单独

训练时, 会丧失一定的局部性先验, 导致模型在小数据集上优化困难, 并造成泛化性的损失。类似 RepLKNet<sup>[21]</sup> 在训练大卷积核网络时, 使用的用来辅助训练的小卷积核, 在大卷积核中引入的小卷积核的预训练权重, 同样也起着重新引入局部性先验的作用。因此, 在引入 ImageNet 的先验知识后, 这种过拟合现象得到缓解, 并最终使得 TFECN\_ImgP 优于 DSCN\_ImgP。总之, 虽然 TFEConv 最终能够为模型的性能带来提升, 但是却对预训练有着较大的依赖。

表 4-1 FSD50K 中的消融实验结果

|                  | 参数量   | 浮点运算量 | 验证集 mAP | 测试集 mAP |
|------------------|-------|-------|---------|---------|
| MobileNetV2-like | 11.0M | 4.0G  | 0.529   | 0.497   |
| DSCN             | 25.1M | 10.1G | 0.549   | 0.519   |
| TFECN            | 26.7M | 11.9G | 0.557   | 0.515   |
| DSCN-ImgP        | 25.1M | 10.1G | 0.622   | 0.598   |
| TFECN-ImgP       | 26.7M | 11.9G | 0.625   | 0.601   |

## 2. 对比试验

表4-2展示了 TFECN 与最新的几种声音事件分类方法的对比实验结果。对比的方法包括:

- PANN<sup>[5]</sup>: 本章使用 PANN 中的 14 层 CNN 结构 CNN14 用作对比模型。CNN14 结合了梅尔频谱和时域波形作为输入特征, 以提高识别声音事件类别的性能。
- PSLA<sup>[6]</sup>: 此方法使用的模型基于 EfficientNet, 是一种 CNN 模型。模型在 CNN 中使用了多头注意力机制以在不同特征空间中捕捉音频数据的复杂特征。
- ERANN<sup>[60]</sup>: 此方法提出了一种新的 CNN 模型, 该模型通过调整卷积核的大小、步长以及填充来优化参数量和浮点运算量, 在保持较小模型大小以及较快推理速度的同时, 实现了接近最先进方法的性能。
- AST<sup>[8]</sup>: 此方法采用计算机视觉中常用的视觉 Transformer (Vision Transformer, 简称 ViT) 设计, 在原始 Transformer 中引入了分块化过程。
- HTS-AT<sup>[9]</sup>: 此方法采用了层次化的 Transformer 结构, 在每个 Transformer 块内部采用了窗口注意力 (Window Attention) 机制, 只计算每个窗口内的注意力矩阵。此外, 模型引入了 Token-Semantic 模块, 该模块能够将最终输出的标记

(Token) 映射到类别上。

- PaSST<sup>[61]</sup>: 此方法提出了一种名为 Patchout 的技术, 用于在音频时频谱上高效训练 Transformer。Patchout 通过在训练过程中随机丢弃输入部分序列, 减少计算和内存复杂度, 同时作为一种正则化手段, 提高训练 Transformer 的泛化能力。

对比方法中除了 PANN 和 ERANN 没有经过预训练, 其余的模型都使用了在 ImageNet 中预训练得到的预训练权重, 其中 HTS-AT 和 PaSST 是目前这种训练方式下 mAP 最高的模型。从表4-2中的结果可以看出, 本章提出的 TFECN 大幅超越之前的 CNN 模型, 并且以更少的参数量优于最新的 Transformer, 说明了一个 CNN 模型仍旧可以在声音事件分类中取得先进的性能。

表 4-2 AudioSet 中的对比实验结果

| 模型结构   |             | 参数量   | 预训练数据集   | mAP          |
|--------|-------------|-------|----------|--------------|
| PANN   | CNN         | 81M   | -        | 0.431        |
| PSLA   | CNN         | 13.6M | ImageNet | 0.444        |
| ERANN  | CNN         | 55M   | -        | 0.450        |
| AST    | Transformer | 86M   | ImageNet | 0.459        |
| HTS-AT | Transformer | 31M   | ImageNet | 0.471        |
| PaSST  | Transformer | 86M   | ImageNet | 0.471        |
| TFECN  | CNN         | 27M   | ImageNet | <b>0.477</b> |

最后, 与之前的工作<sup>[5,8]</sup> 相同, 本章使用之前在 AudioSet 中训练过的 TFECN, 重新在其他两个样本数量较少的数据集上进行微调, 并对微调后的模型在测试集上进行评估, 实验结果如表4-3所示。

在 FSD50K 数据集中 TFECN 实现了最先进的效果, 超越当前最好的 Transformer, mAP 提升了 2 个百分点。在 FSD50K 中, 相较于过去传统的 CNN 模型, TFECN 的由于引入了针对时频谱的改进, mAP 提升了超过 10 个百分点。

同样的, 在 ESC50 中, TFECN 也要优于以相同方式训练的模型, 这里相同方式指的是使用 ImageNet 的预训练模型在 AudioSet 中进行监督训练, 最后使用 AudioSet 中训练的模型在下游任务中进行微调。相较于最先进的 Transformer 模型, TFECN 的 mAP 提升了 0.7 个百分点, 相较于最先进的 CNN 模型, mAP 则提升了接近 2 个百分点。由于 ESC50 中模型性能接近饱和, 因此提升幅度未及 TFECN 在 FSD50K 中的表

现也在情理之中。

表 4-3 FSD50K 和 ESC50 中的对比实验结果

| 预训练数据  |           | FSD50K mAP   | ESC50 Acc    |
|--------|-----------|--------------|--------------|
| PANN   | Audio     | -            | 0.947        |
| PSLA   | Img+Audio | 0.567        | -            |
| ERANN  | -         | -            | 0.961        |
| AST    | Img+Audio | -            | 0.957        |
| HTS-AT | Img+Audio | -            | 0.970        |
| PaSST  | Img+Audio | 0.656        | -            |
| TFECN  | Img+Audio | <b>0.673</b> | <b>0.977</b> |

### 3. 模型超参数搜索实验

为了进一步增加实验的可信性，表4-4中展示了本章模型 TFECN 超参数搜索过程中不同学习率（Learning Rate，简称 lr）以及批次大小（Batch Size，简称 bs）设置时在 FSD50K 测试集中的 MAP 结果。在超参数搜索过程中，未使用预训练权重。从表中可以看出，当学习率 lr 为  $4 \times 10^{-4}$ ，bs 为 32；lr 为  $1 \times 10^{-4}$ ，bs 为 64；lr 为  $4 \times 10^{-4}$ ，bs 为 64 时，模型的性能达到最优，为了更好地利用 GPU 的并行计算，本文选择将 lr 设置为  $4 \times 10^{-4}$ ，bs 设置为 64。

表 4-4 FSD50K 中模型超参数搜索实验结果

|               | lr= $1 \times 10^{-4}$ | lr= $4 \times 10^{-4}$ | lr= $1 \times 10^{-3}$ |
|---------------|------------------------|------------------------|------------------------|
| <b>bs=32</b>  | 0.511                  | 0.515                  | 0.497                  |
| <b>bs=64</b>  | 0.515                  | 0.515                  | 0.503                  |
| <b>bs=128</b> | 0.507                  | 0.513                  | 0.507                  |

## 4.4 本章小结

本章主要介绍了提出的用于声音事件分类任务的 CNN 模型。声音事件分类是音频内容分类任务中非常重要的一类任务，虽然最近 Transformer 在该问题上表现出一定的优势，但其结构复杂度，参数量、和计算量都要高于 CNN 模型。本章针对传统

CNN 模型由于平移等变性对识别频率维特征产生不利影响的问题，提出了一个通过频率维大卷积核来释放卷积平移等变性的 TFEConv。为了将已有工作的预训练权重无损迁移至 TFECN，还提出了一种在不同尺寸卷积核之间迁移权重的方法。最后在 AudioSet、FSD50K 以及 ESC50 三个数据集上的实验结果证明了提出方法的有效性。

## 第五章 基于 Transformer 的音频分类模型

### 5.1 引言

随着 Transformer 模型在多模态任务中的流行,出现了大量研究专注于提升其在仅依靠单一模态数据时的性能,语音情感识别正是其中的一个重点研究方向,因此本章选择对音频分类子任务,语音情感识别任务中的 Transformer 进行改进。语音情感识别指的是利用计算机分析并识别语音中的情感类别,被广泛应用于客户服务、心理健康分析、人机交互系统等领域,是语音信号处理的一个研究热点。鉴于 Transformer 在捕捉长距离依赖关系方面的卓越性能以及其出色的可扩展性,众多研究开始探索将这一模型应用于语音情感识别领域。时频谱作为常见的输入音频特征,也同样被作为用于语音情感识别的 Transformer 的输入特征。为了更加合理地从时频谱中提取到对语音情感识别有用的信息,Transformer 存在两种不同的方式处理时频谱输入:第一种方式将时频谱直接作为 Transformer 的输入,在模型的第一层中将时频谱的频率维映射为特征的通道维;第二种方式将时频谱作为自然图像并经过分块化(Patchify)<sup>[24]</sup>处理后作为 Transforemr 的输入,使用分块化生成的独立于时频谱时间维和频率维的通道维作为输入特征的通道维。

处理时频谱特征的第一种方式类似 TDNN,模型中每一层都拥有覆盖时频谱频率维所有频率分量的感受野,缺少对局部频率特征的建模。为了 TDNN 中引入对局部频率的建模,除了在 TDNN 前添加基于 CNN 的前端模型<sup>[38,40]</sup>之外,另一种常见的作法是将时频谱划分为多个不同的子频带,相对独立地处理各个子频带。PCF<sup>[42]</sup>提出了一种渐进融合时频谱频率维的 TDNN 模型,首先将时频谱划分为多个不同的子频带,对于每个子频带使用不同的 TDNN 进行特征提取,随着模型层级的加深,子频带的数量逐渐减少,使得模型平滑地由对局部特征的建模过渡到对全局特征的建模。OFD<sup>[31]</sup>则将时频谱按照一定地窗口大小和重叠将其沿频率方向划分为多个子频带,每个子频带对应模型的一个分支,在每个分支的终点对应一个子频带分类器,该分类器只通过部分频率分量来进行分类。除了这些子分类器外,模型还将送入子分类器前的特征沿频率维进行拼接并使用一个全局分类器进行分类。子分类器和全局分类器一同训练,两者的分类损失通过一定的权重缩放求和后反向传递到模型的各个层级。

处理时频谱特征的第二种方式中需要使用 CNN 在分块化过程中对时频谱进行分块。考虑到 CNN 的平移等变性,模型可能将位于不同频率位置的相同模式识别为相同语义的分块。虽然 Transformer 的位置编码能够为不同频率位置处的分块添加不同的位置信息,但这种一维的位置信息可能无法很好地表达不同频率分块语义信息的不同。为了区分不同频率位置处语义信息的不同,一种方法是直接破坏 CNN 的平移等变性。FDC<sup>[7]</sup>提出了一种在时频谱频率维使用自适应卷积的 CNN 模型,模型首先随机初始化一定数量不同权重的基核(Basis Kernel),之后使用注意力机制根据时频谱特征中不同的频率位置生成每个基核的注意力系数,最后利用注意力系数对所有基核进行加权求和得到最终的自适应卷积核,使得不同频率位置处的卷积核拥有不同的权重。另一种方法则是通过注意力机制对 CNN 的输出特征中不同频率位置进行注意力加权,CTFALite<sup>[30]</sup>提出了一种针对时频谱特征的注意力机制,首先将时频谱分别沿时间维和频率维进行平均池化并生成不同的注意力分数,之后使用相应的注意力分数对输出特征的时间维和频率维分别进行加权以区分不同的时间位置以及频率位置。

在类似 TDNN 的方式中,频率维作为特征的通道维独立于时间维,能够很好地利用时频谱中时间维和频率维不同的属性,但无法很好地建模频率维的局部特征。在使用 CNN 进行分块化的方式中,虽然 CNN 能够更好地建模时频谱中的局部特征,但由于分块化过程将时频谱中时间和频率两个不同的维度压缩为一个维度,不利于模型区分时频谱中的时间和频率信息。为了结合两种方式的优点,并弥补各自的缺点,本章提出一种新的用于语音情感识别的 Transformer,模型包含两个分支,第一个分支采用类似 TDNN 的方式处理时频谱特征,第二个分支采用分块化处理时频谱特征。将模型每一层中两个分支的输出特征沿通道维进行拼接并使用一个全连接层进行融合,对融合后的特征沿时间维进行平均池化作为模型的中间输出特征,最后将所有层的中间输出进行加权求和得到用于分类的音频嵌入。除了利用双分支的结构来结合两个分支的优点并避免两个分支的缺点外,本章还使用上文中提到的方法分别对两个分支进行优化,在第一个分支中使用子频带划分的方法增强模型对局部特征的建模,在第二个分支中使用自适应卷积核避免 CNN 的平移等变性。实验结果证明提出方法的有效性,并表明提出的方法相较于目前最新的语音情感识别方法提升了性能。




图 5-1 双分支 Transformer 模型结构示意图

## 5.2 双分支 Transformer

本节介绍本章提出的双分支 Transformer 的具体结构，模型的整体框架如图 5-1 所示，图中 TDNN 分支将时频谱的频率维作为特征的通道维进行处理，而 CNN 分支则先将时频谱经过分块化过程处理之后输入到分支中。TDNN 分支中通道维（频率维）独立于时间维，能够很好地考虑到时频谱两个维度的不同，但是将时频谱特征的频率维作为通道维同时处理所有通道使得该分支缺少针对局部频率的建模；CNN 分支分块化过程中使用的二维卷积增能够针对局部频率特征进行建模，但是分块化过程中将时频谱特征的频率维和时间维压缩为一个维度使得该分支无法很好地考虑到时频谱时间和频率两个维度的差异性。

同原始 Transformer<sup>[22]</sup> 一致，本章模型在每一层中的多头自注意力（Multi-Head Self-Attention, 简称 MHSA）后添加一个前馈网络（Feed Forward Network, 简称 FFN），并将 MHSA 和 FFN 各自的输入通过快捷连接与各自的输出相加再进行层归一化。

本节首先介绍了两个分支各自的结构,以及针对各个分支存在的问题的优化方法。下文将采用类似 TDNN 的方式处理时频谱特征的分支称为 TDNN 分支,将采用分块化过程的分支称为 CNN 分支。最后在 5.2.3 节介绍了基于改进后 Transformer 的语音情感识别方法的实现细节。

### 5.2.1 时延神经网络分支

如前文所述,TDNN 分支中无法很好地提取时频谱频率维的局部特征,为了在 Transformer 中引入对局部特征的建模,本章效仿 TDNN 中的子频带划分,将时频谱划分为多个不同的子频带。考虑到 Transformer 中的 MHSA 机制,本章将不同的子频带划分到 MHSA 中不同头中分别进行特征提取。对于本章提出的 6 层 Transformer 结构,在前三层分别采用 8、4、2 的子频带划分,后三层则不进行子频带划分。与其他 Transformer 中常见的设置一样,本章将模型中每一层头的数量设置为 8。在模型的第一层,一个子频带对应 MHSA 中的 1 个头;在模型第二层,一个子频带对应 MHSA 中的 2 个头;以此类推。子频带对应 MHSA 头逐渐增加的过程,可以看作层与层之间的过渡层,过渡层对每一层的输出特征进行下采样(子频带数量的减少),同时增加每一层输出特征的通道数量(每个子频带对应的头数增加)。

对于 MHSA 中用于求得  $Q$ 、 $K$  和  $V$  的三个线性映射矩阵,以及将多个头映射到同一特征空间的线性映射矩阵,本章采用卷积核大小为 1 的一维分组逐点卷积替代传统 Transformer 中的全连接层作为映射矩阵,将卷积输出特征的每个分组作为一个子频带的特征划分到 MHSA 中的不同头中。在本节中将  $Q$ 、 $K$  和  $V$  对应的三个分组卷积统称为 Conv1d1,将负责多头映射的分组卷积称为 Conv1d2,如图 5-2 所示,图中 4 个输入子频带经过 Conv1d1 后,每个子频带对应两个不同的自注意力头,在对不同的自注意力头完成自注意力运算后,8 个自注意力头分为两组经过 Conv1d2 生成两个不同的子频带。在模型的第一层 Conv1d1 由三个分组数  $g_1 = 8$  逐点分组卷积组成,卷积的每个分组对应一个子频带;Conv1d2 由一个分组数  $g_2 = 4$  的逐点分组卷积组成,负责将两个相邻的子频带合并为一个子频带,经过第一层的特征子频带数量由 8 降至 4。模型第二层的 Conv1d1 由三个分组数为  $g_1 = 4$  的逐点分组卷积组成,每个分组对应 MHSA 中的两个头;Conv1d2 由一个分组数  $g_2 = 2$  的分组卷积组成,经过第二层的特征子频带数量由 4 降至 2。第三层与第二层相似,Conv1d1 和 Conv1d2 分别由  $g_1 = 2$  和  $g_2 = 1$  的逐点分组卷积组成。从模型第四层开始,Conv1d1 和 Conv1d2 为不再进行分组的普通逐点卷积。




图 5-2 TDNN 分支示意图

为了避免 MHSA 后的 FFN 将各个独立的子频带进行融合，不同于传统 Transformer 中使用两个全连接层并在两个全连接层中间设置一个激活函数的 FFN 结构，TDNN 分支的前三层与 MHSA 相同，同样使用分组逐点卷积替换 FFN 中全连接层。每层的 FFN 根据前一个 MHSA 块中 Conv1d2 的分组数来对其中的逐点卷积进行分组。具体来说，在模型的第一层，由于 Conv1d2 的  $g_2 = 4$ ，因此 FFN 中的逐点卷积的分组数设置为 4。同理对于模型第二层和第三层中的 FFN，分别将其中的逐点卷积分组数设置为 2 和 1。对于后面的三层则不对 FFN 中逐点卷积进行分组。本章使用 ReLU 激活函数作为每个 FFN 中的激活函数。

### 5.2.2 卷积神经网络分支

在 CNN 分支中，模型将时频谱当作图像进行分块化处理，首先将单通道的时频谱特征经过 CNN 映射为多通道特征，之后将每个通道中的特征图展平为一维，最后将展平后的特征重新沿通道维拼接起来作为 Transformer 的输入特征。由于 CNN 中相同层的卷积核共享参数，因此当卷积核沿着频率维滑动时会将不同频率位置处的相同模式识别为相同的语义，这不满足时频谱频率维特征的非平移不变性。为了解决这个问题，一种直观的方式是使卷积核沿着频率维滑动时，每个位置处的卷积核参数都是不同的。根据特征图中不同位置的内容生成参数不同的卷积核的方法也被称为自适应卷积（Adaptive Convolution）或动态卷积（Dynamic Convolution）技术。由于

时频谱中的特征仅在频率维是非平移等不变的, 因此本章在分块化过程中使用频率动态卷积 (Frequency Dynamic Convolution, 简称 FDC)<sup>[7]</sup> 来避免 CNN 的平移等变性的对提取沿频率维分布的特征产生不利影响, 而在时间维保留 CNN 的平移等变性以更加合理地提取沿时间维分布特征。

FDC 使用频率自适应卷积核, 首先初始化  $n$  个不同权重的基核, 这些基核的权重参数是可训练的, 之后使用注意力机制在输入特征图频率维的每个位置处生成不同的自适应注意力权重, 使用这些不同的权重来对初始化的  $n$  个不同的基核进行加权求和, 以在不同位置处生成权重参数不同的自适应卷积核。自适应卷积核的具体计算过程如图 5-3 所示, 图中  $W_1 \cdots W_n$  代表不同基核对应的自适应注意力权重,  $K_1 \cdots K_n$  代表不同的基核,  $\oplus$  代表逐元素相加,  $\odot$  代表卷积操作。具体来说, 首先将时频谱特征沿着时间维进行平均池化得到只保留频率维的一维特征。由于本章模型仅在第一层的分块化过程中使用 CNN, 因此初始输入特征的通道数为 1, 为了得到代表不同基核权重的不同通道特征图, 将池化后的一维特征复制 3 次并沿一个新的维度进行拼接, 然后使用两个一维卷积从拼接后的三通道特征提取  $n$  个通道的自适应注意力权重。在两个一维卷积之间使用层归一化和 ReLU 激活函数, 在最后一维卷积后沿通道维应用 Softmax 归一化确保相同频率位置不同基核的注意力权重之和为 1。最后, 通过频率自适应注意力权重对基核进行加权求和, 得到用于频率动态卷积的频率自适应卷积核, 在卷积过程中自适应卷积核只沿时间方向滑动。




图 5-3 频率动态卷积示意图

### 5.2.3 模型细节

本章提出的语音情感识别方法利用由 TDNN 分支和 CNN 分支组成的六层 Transformer 提取音频嵌入，之后使用由两个全连接层组成的分类器将音频嵌入映射为情感标签。音频嵌入的提取过程如图5-1所示，对于两个分支各自的输出特征，首先将其沿通道维堆叠并使用一个全连接层将堆叠后特征的通道数压缩为原先的二分之一，以此来融合两个分支的特征。假设每一层的输出特征形状为  $(T, F)$ ，堆叠后特征的形状为  $(T, 2 \times F)$ ，融合后的特征形状为  $(T, F)$ ，其中  $T$  表示特征时间维的长度， $F$  表示特征通道维的长度。使用模型每一层融合后特征沿时间维的平均值作为表征语音情感的中间特征，为了结合不同尺度的信息，对每一层输出的中间特征进行融合以得到最终的音频嵌入。具体来说，将每一层融合后的特征沿时间维进行全局平均池化后沿新的维度重新拼接，最后使用一个全连接层，将拼接特征形成的新的维度作为全连接层的通道维，对各层的输出特征进行加权求和，最终得到用于分类的音频嵌入。池化后的特征形状为  $(1, F)$ ，拼接后的特征形状为  $(6, F)$ ，经过输入通道数为 6 输出通道数为 1 的全连接层后形成的音频嵌入的形状为  $(1, F)$ 。分类器中第一个全连接层将嵌入通道维增加，之后经过 ReLU 激活函数以及层归一化操作再由第二个全连接层将嵌入的通道维降至数据集中情感类别的数量。经过第一个全连接层后的嵌入形状为  $(1, H)$ ，经过第二个全连接层后的嵌入形状为  $(1, C)$ ，其中  $H$  为人为指定的超参数， $C$  为数据集中情感类别的数量。

为了表示音频中不同帧的相对位置关系，本章采用相对位置编码<sup>[62]</sup>作为 Transformer 的位置编码。绝对位置编码中序列第  $i$  帧和第  $j$  帧的注意力分数计算如下：

$$A_{i,j}^{abs} = (W_q(E_{x_i} + U_i))^T (W_k(E_{x_j} + U_j)) \quad (5.1)$$

其中  $W$  为线性层权重， $E_{x_i}$  为特征中第  $i$  帧， $U_i$  为第  $i$  帧的绝对位置编码， $W_q$  和  $W_k$  分别为键和查询的映射矩阵，进一步展开公式 (5.1) 得到：

$$\begin{aligned} A_{i,j}^{abs} = & \underbrace{E_{x_i}^T W_q^T W_k E_{x_j}}_{(a)} + \underbrace{E_{x_i}^T W_q^T W_k U_j}_{(b)} \\ & + \underbrace{U_i^T W_q^T W_k E_{x_j}}_{(c)} + \underbrace{U_i^T W_q^T W_k U_j}_{(d)} \end{aligned} \quad (5.2)$$

可以看出公式 (5.2) 中 (a) 与位置编码没有关系，(b) 和 (c) 只包含一个位置编码，也

不存在相对位置关系, 只有 (d) 中包含两个位置编码, 可能编码有相对位置关系。Wu 等人<sup>[62]</sup> 的研究表明 (d) 中可能包含的相对位置关系经过  $W_q^T$  和  $W_k$  线性变换后会发生损失。为了重新在位置编码中引入相对位置关系, 将公式 (5.2) 改写为:

$$\begin{aligned}
 A_{i,j}^{rel} &= \underbrace{E_{x_i}^T W_q^T W_k E_{x_j}}_{(a)} + \underbrace{E_{x_i}^T W_q^T W_R R_{i-j}}_{(b)} \\
 &\quad + \underbrace{u^T W_k E_{x_j}}_{(c)} + \underbrace{v^T W_R R_{i-j}}_{(d)} \\
 &= \underbrace{(q_i + u^T) k_j}_{(ac)} + \underbrace{(q_i + v^T) W_R R_{i-j}}_{(bd)}
 \end{aligned} \tag{5.3}$$

其中使用  $R_{i-j}$  替换公式 (5.2) 中的  $U_j$ , 表示将键的绝对位置编码换为键和查询的相对位置编码。同时使用一个新的线性变换  $W_R$  替换公式 (5.2) 中对  $U_j$  进行的线性变换  $W_k$ 。最后将  $W_q U_i$  替换为两个可学习的参数  $u, v$ 。因为  $W_q$  是可学习的, 因此  $u, v$  也应该是可学习的。

## 5.3 实验

### 5.3.1 数据集

IEMOCAP<sup>[63]</sup> 是一个由南加州大学 SAIL 实验室发布的多模态对话数据集, 共包含了 12 个小时的音视频数据以及相应的文本转录。数据集共包含 5 段会话, 每段会话有一名男性和一名女性在即兴或剧本化场景中表演。在本章实验中, 将兴奋情绪归为快乐情绪, 并从愤怒、快乐、中性、悲伤 4 种情感种类中选择总共 5531 个音频数据用于实验。

CREMA-D<sup>[64]</sup> 是一个包含 7442 条音频片段的语音情感数据集, 这些音频来源于 48 名男性和 43 名女性共 91 名演员。这些演员年龄在 20 至 74 岁之间, 并来自多个种族。每名演员从 12 个句子中选择发言, 使用 6 种不同的情感以 4 中不同的情感强度进行发音。6 中情感包括愤怒、厌恶、恐惧、快乐、中性和悲伤, 4 种不同的情感强度包括低、中、高、未指定。考虑到演员的专业性, 可以假设 CREMA-D 相较于 IEMOCAP 更加清晰且存在较少的歧义。

由于本章使用的数据集样本数量较少, 因此在本章的实验中采用 10 折交叉验证的方法评估模型。将每个数据集随机划分为 10 个折, 每次使用其中的 1 个折进行测

试,剩下的 9 个折用于训练模型,取模型在 10 个折中测试的指标平均值作为模型最终的评价指标值。

### 5.3.2 评价指标

本章所有实验均使用准确率 (Accuracy, 简称 Acc) 作为评价指标,由于语音情感识别数据集各个情感类别的样本数量有较大差异,为了更加全面地反映模型的性能,本章同其他研究一样将准确率分为加权准确率 (Weighted Accuracy, 简称 WA) 和非加权准确率 (Unweighted Accuracy, 简称 UA)。WA 中的加权可以理解为数据集中每个情感类别使用该类别的样本数量作为权重,使用各个类别准确率的加权平均作为模型在数据集上的评价指标,具体计算如下:

$$\begin{aligned} \text{WA} &= \frac{\sum_c^C (\text{TP}_c + \text{TN}_c)}{\sum_c^C (\text{TP}_c + \text{TN}_c + \text{FP}_c + \text{FN}_c)} \\ &= \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \end{aligned} \quad (5.4)$$

其中  $C$  为数据中的类别数量,  $\text{TP}_c$  为第  $c$  个类别的真正类数量,  $\text{TP}$  为整个测试集中真正类数量,这种根据样本个数加权平均的方法也被称为微平均 (Micro Average)。UA 则是先单独计算每个类别的准确率,之后将各个类别的准确率直接进行平均,计算如下:

$$\begin{aligned} \text{UA} &= \frac{1}{C} \sum_c^C \text{Acc}_c \\ &= \frac{1}{C} \sum_c^C \frac{\text{TP}_c + \text{TN}_c}{\text{TP}_c + \text{TN}_c + \text{FP}_c + \text{FN}_c} \end{aligned} \quad (5.5)$$

其中  $\text{Acc}_c$  为类别  $c$  的准确率,这种在类别水平上进行平均的方法也被称为宏平均 (Macro Average)。

### 5.3.3 实验设置

本章实验的软硬件配置同第 3 章。对于所有数据集中的每条语音,首先将其重采样至 16kHz,之后将每条语音切分成多个 3 秒长的片段,每个片段单独作为一个样本。对于每个样本使用窗长为 25 毫秒的汉宁窗,以及长度为 10 毫秒的帧移进行 STFT。之后使用 80 个梅尔滤波器组成的滤波器组提取 80 维的梅尔频谱。最后将提取的时频谱特征形状为 (300, 80)。

对于模型两个分支中的每一层，将输入和输出特征的通道维设置为 256，自注意力头数量设置为 8。对于 CNN 分支，设置频率动态卷积中的基核个数为  $n = 4$ ，基核的尺寸为  $7 \times 7$ ，卷积的步长设置为 7，即每个分块之间不存在重叠，最后将输出通道数设置为 128。TDNN 分支的第一层中的 Conv1d1 输入通道数为 80，输出通道数为 256。CNN 分支的第一层中的线性映射矩阵输入通道数为 128，输出通道数为 256。设置 FFN 和分类器中的隐层特征通道维数  $H = 1024$ 。

考虑到语音情感识别数据集中样本数量相对较少，本章同样使用数据增强方法增加数据集中样本的多样性，以提升模型的泛化性。本章采用的数据增强方法包括 SpecAugment 以及 EMix<sup>[65]</sup>。使用 SpecAugment 对样本频率维和时间维分别进行 0-20 和 0-100 的随机掩蔽。EMix 是一种针对语音情感识别任务的 Mixup<sup>[59]</sup> 数据增强方法变体。考虑到情感在语音中并不是连续分布的，当混合两个样本时，两个样本中情感强度较高的部分可能在时间上不存在重叠，因此混合后的样本能够完整的表达两种不同的情感，此时 Mixup 使用不同比例对两个标签进行凸组合（Convex Combination）的做法可能会对模型的训练产生干扰。为了解决上述问题，EMix 只对样本进行凸组合，并且只对数据中指定情感类别的样本进行混合。本章采用 Emix 中的中性情绪及同类情绪混合方法。中性情绪混合计算如下：

$$\begin{cases} \hat{x} &= \lambda_1 x^e + (1 - \lambda_1) x^n \\ \hat{y} &= y^e \end{cases} \quad (5.6)$$

其中  $\hat{x}$  和  $\hat{y}$  分别表示混合后的样本和标签， $x^e$  和  $y^e$  分别表示非中性情感  $e$  的样本和标签， $x^n$  表示中性情感的样本， $\lambda_1$  从 (0.5, 1) 中随机采样。同类情绪混合计算如下：

$$\begin{cases} \hat{x} &= \lambda_2 x_i^e + (1 - \lambda_2) x_j^e \\ \hat{y} &= y^e \end{cases} \quad (5.7)$$

其中  $x_i^e$  和  $x_j^e$  表示非中性情感类别  $e$  中的样本  $i$  和样本  $j$ ， $\lambda_2$  从 (0, 1) 中随机采样。

本章模型使用 Adam 优化器进行训练，每个批次的样本数量为 32，使用交叉熵作为损失函数。在训练过程中，学习率首先经过 10 轮预热线性增长到  $3 \times 10^{-4}$ ，再经过 90 轮训练余弦衰减为  $1 \times 10^{-7}$ 。所有方法均使用 1 张 40GB 显存的 NVIDIA A100 进行训练和测试。

### 5.3.4 实验结果

#### 1. 对比试验

在这部分的实验中，使用本章提出的模型与最新的几种语音情感识别模型在 IEMOCAP 和 CASIA 数据集中进行对比，其中在 IEMOCAP 中对比的模型包括：

- **Speechformer<sup>[26]</sup>**：此方法使用模型的不同层分别建模音频中不同层级的特征，根据不同的层级使用不同的注意力窗口大小。在每个阶段之间设置合并块，合并块根据前后两个阶段要处理的基本单元，将上一阶段一定长度的特征帧进行平均池化，近似为下一层要建模的层级特征。
- **DST<sup>[66]</sup>**：此方法将 Transformer 中的多头注意力模块替换为可变形语音注意力模块。可变形语音注意力模块通过一个由全连接层和激活函数组成的决策网络根据输入语音动态确定注意力窗口的大小和位置，使得模型能够自适应地发现并关注音频中情绪显著的部分。
- **DWformer<sup>[27]</sup>**：模型通过动态局部窗口 Transformer 在不同的注意力窗口中捕捉音频中细粒度的语音情绪相关信息，通过动态全局窗口 Transformer 重新衡量注意力窗口间的重要性关系，并重新划分窗口。
- **Speech SwinTransformer<sup>[67]</sup>**：此方法使用计算机视觉领域中的 SwinTransformer 作为基础模型，采用固定大小的注意力窗口来捕捉局部的情绪特征，并通过特征图移位的操作增强模型对位于窗口边界特征的捕捉能力。

在 CREMA-D 中对比的模型包括：

- **ResNet-18+SPEL<sup>[68]</sup>**：此方法使用 SPEL（Self-paced Ensemble Learning）算法对多个 ResNet-18 模型进行集成。
- **SepTr<sup>[33]</sup>**：此方法提出了一种串联两种 Transformer 模块组成的模型，第一种模块沿着时间维进行自注意力操作，第二种模块沿着频率维进行自注意力操作。
- **TRILL<sup>[69]</sup>**：此方法基于 ResNet-50，使用三元损失将模型在 AudioSet 上进行预训练，之后在 CREMA-D 数据集上使用音高相关特征（恒定 Q 变换谱图）和音色相关特征（MFCC、梅尔频谱）进行微调。
- **EMix-NS<sup>[65]</sup>**：此方法为在常规的 6 层 Transformer 中使用 EMix-NS 数据增强方式来训练模型。

表5-1展示了对比实验的结果。在 IEMOCAP 中，本章模型超越所有对比模型取得了最好的 UA，但是 WA 要劣于 Emix-NS 和 Speech SwinTransformer。这说明本章模型能够在保证数据集整体准确率的较好的同时，确保每个类别都有较高的准确率，即模型能够正确建模区分不同情感的音频嵌入，而不是只建模了在部分情感中有强判别力的音频嵌入。在 CREMA-D 中的所有测试模型中本章模型取得了最好的 UA 和 WA，优于使用相同数据增强方法的 EMix-NS，这说明本章模型中对 Transformer 的改进是有效的。

表 5-1 IEMOCAP 和 CASIA 中的对比实验结果

| 模型                | IEMOCAP      |              | CREMA-D      |              |
|-------------------|--------------|--------------|--------------|--------------|
|                   | WA           | UA           | WA           | UA           |
| Speechformer      | 0.629        | 0.645        | -            | -            |
| DST               | 0.718        | 0.736        | -            | -            |
| DWformer          | 0.723        | 0.739        | -            | -            |
| Speech SwinTrans. | 0.752        | 0.659        | -            | -            |
| ResNet-18+SPEL    | -            | -            | -            | 0.681        |
| SepTr             | -            | -            | 0.704        | -            |
| TRILL             | -            | -            | -            | 0.751        |
| EMix-NS           | <b>0.776</b> | 0.719        | 0.773        | 0.773        |
| 本章模型              | 0.738        | <b>0.747</b> | <b>0.781</b> | <b>0.782</b> |

## 2. 消融实验

在这部分的实验中，以一个 6 层的原始 Transformer 为基线模型。将时频谱视为图像并在基线模型前添加分块化过程，称这个模型为视觉 Transformer，记为 ViT。在基线模型中引入 TDNN 分支中的子频带划分改进，称该模型为多频带 Transformer，记为 MBTransformer。在 ViT 中使用 CNN 分支中的频率动态卷积来进行分块化，称该模型为频率动态卷积 Transformer，记为 FDCTransformer。另外，本节实验中的音频嵌入都是由模型每层输出特征沿时间维平均池化后再经过全连接层加权求和得到的。

表5-2展示了消融实验的结果。通过对比 MBTransformer 和基线模型的结果可以看出，MBTransformer 的 WA 和 UA 相对于基线模型分别提升了 0.008 和 0.1，说明在时频谱中进行子频带划分能够提升模型的性能，这在一定程度上印证了本文关于原

始 Transformer 由于缺少对局部频率特征的建模而导致分类性能欠佳的猜想。

通过对比 FDCTransformer 和 ViT 的结果可以看出,在分块化过程中使用动态频率卷积能够提升模型的性能。此外注意 ViT 的 WA 和 UA 相较于基线模型的结果分别降低了 0.013 和 0.008,这说明将时频谱作为图像进行分块化处理可能会影响模型从时频谱中提取到有效的特征。而 FDCTransformer 的 WA 和 UA 则都要高于基线模型,仅比 MBTransformer 分别降低了 0.001 和 0.003,这说明 ViT 劣于基线模型的很大一部分原因是分块化过程中使用的 CNN 无法正确识别频率维非平移不变特征造成的,并且由于在分块化过程中引入了对局部频率特征的建模使得解决了上述问题的 FDCTransformer 取得了与改进后基线模型,即 MBTransformer 相近的结果。

最后,对比本章模型与其他单分支模型的结果,结合两个分支后的本章模型相较于单个分支性能最好性能的模型 MBTransformer 和 FDCTransformer 性能分别提升了 0.016 和 0.017 (WA), 0.016 和 0.019 (UA),说明本章模型双分支的结构可以有效结合两个分支各自的特点,从更多样的特征中提取到更有效的音频嵌入。

表 5-2 IEMOCAP 中的消融实验结果

| 模型             | IEMOCAP      |              |
|----------------|--------------|--------------|
|                | WA           | UA           |
| 基线模型           | 0.714        | 0.721        |
| ViT            | 0.701        | 0.713        |
| MBTransformer  | 0.722        | 0.731        |
| FDCTransformer | 0.721        | 0.728        |
| 本章模型           | <b>0.738</b> | <b>0.747</b> |

### 3. 模型超参数搜索实验

为了进一步增加实验的可信性,表5-3中展示了本章模型超参数搜索过程中不同学习率 (Learning Rate, 简称 lr) 以及批次大小 (Batch Size, 简称 bs) 设置时在 CREMA-D 数据集中 10 折交叉验证的 WA 结果。从表中可以看出,当初始学习率 lr 为  $3 \times 10^{-4}$ , 批次大小 bs 为 32 时; 初始学习率 lr 为  $1 \times 10^{-3}$ , 批次大小 bs 为 200 时,模型的性能最优。考虑到语音情感数据集的数量样本较少,为了增加训练的稳定性,选择将初始学习率设置为  $3 \times 10^{-4}$ , 批量大小设置为 32。

表 5-3 CREMA-D 中模型超参数搜索实验结果

|               | $lr=1 \times 10^{-4}$ | $lr=3 \times 10^{-4}$ | $lr=1 \times 10^{-3}$ |
|---------------|-----------------------|-----------------------|-----------------------|
| <b>bs=32</b>  | 0.775                 | 0.781                 | 0.774                 |
| <b>bs=64</b>  | 0.780                 | 0.775                 | 0.778                 |
| <b>bs=200</b> | 0.772                 | 0.778                 | 0.781                 |

## 5.4 本章小结

本章主要介绍针对语音情感识别任务的双分支 Transformer。本章分别针对 Transformer 处理时频谱使用的两种方法各自存在的问题进行改进，在类似 TDNN 的方式中通过子频带划分引入模型对局部频率的建模，在类似 CNN 的方式中通过引入动态频率卷积，释放分块化过程中使用的 CNN 的频率维平移等变性。最后为了结合两个分支各自的优点，本章模型提出了一种双分支 Transformer，通过全连接层来融合两个分支中每一层的输出特征。在 IEMOCAP 和 CREMA-D 上的实验结果证明了提出方法的先进性，在 IEMOCAP 上的消融实验则证明了提出方法中引入的各种改进的有效性。

## 第六章 总结与展望

### 6.1 工作总结

对音频内容的分类是分析音频信号的一个重要工具,可以帮助语音识别、语音合成等上层应用组织、分析和理解音频信号。说话人识别、声音事件分类、语音情感识别是常见的三种面向不同应用场景的音频内容分类任务,随着深度学习的发展,基于深度学习的模型已经在这些任务中取得了超过传统机器学习模型的性能。时频谱作为这些任务中的深度学习模型常用的一种输入音频特征,拥有许多不同于其他特征的特点,比如频率维特征的非平移不变性以及两个维度不同的属性,然而现有模型往往缺少对这些特点的发掘和利用。为了更好地利用时频谱特点以进一步提升深度学习模型在音频内容分类任务中的表现,本文在前述三个任务中常用的深度学习模型上进行针对时频谱特性的改进。本文的主要研究内容如下:

(1) 为了在用于说话人识别的 TDNN 模型中引入对时频谱频率维局部特征的建模,本文提出了一种基于子频带划分的前端模型。在前端模型中通过将输入特征图划分为多个子频带,并逐层扩大子频带的频率范围,使 TDNN 可以渐进地对局部频率特征进行建模。在说话人识别数据集中的实验表明,提出的模型相较于基线模型错误率最高相对降低了 14%,而参数量只为基线模型的 52%。

(2) 为了在用于声音事件分类任务的 CNN 模型中利用时频谱频率维特征的非平移不变性,本文提出了一种新的 CNN 模型称为 TFECN。TFECN 包含两个分支,一个分支专注于较长时间上下文特征的提取,另一个分支则通过对卷积核大小的设计避免卷积核在频率维的参数共享,进而破坏 CNN 在频率维的平移等变性。为了避免改进后卷积方法缺少对局部特征的建模,本文还提出了一种将小卷积核权重迁移至大卷积核的方法。在声音事件分类数据集中的实验表明,提出的模型相较于传统的 CNN 方法,精度相对提升了 6%。

(3) 为了在用于语音情感识别任务的 Transformer 模型中引入对时频谱局部频率特征的建模以及利用时频谱频率维特征的非平移不变性,本文提出了一种双分支结构的 Transformer 模型。模型中第一个分支使用类似 TDNN 的方式处理时频谱,第二个分支利用分块化的方式处理输入时频谱。在语音情感识别数据集中的实验表明,提出的模型取得了超越目前最先进模型的准确率。

## 6.2 工作展望

本文针对说话人识别中的 TDNN 模型、声音事件分类中的 CNN 模型以及语音情感识别中的 Transformer 模型在处理时频谱特征时存在的问题，引入了针对时频谱特性的优化，并通过实验证明了相应改进的有效性。但是这些模型仍然存在进一步的改进空间：

(1) 在针对用于说话人识别的 TDNN 改进中，由于前端模型每一层子频带的划分都是独立的，只有在下一层中才会对不同子频带之间的信息进行交互，这限制了层内特征的多样性。可以考虑引入类似 SwinTransformer 中对特征图进行位移的方法在层内进行不同子频带之间的信息交互。

(2) 在针对用于声音事件分类任务的 CNN 改进中，由于引入了超大卷积核，造成 CNN 由于缺少对局部频率特征建模而出现的过拟合现象。虽然本文通过迁移在大规模数据集上的预训练的小卷积核权重缓解出了问题，但对于缺少大规模数据集的应用场景，通过增大卷积核避免 CNN 平移等变性的方法仍然受到限制。

(3) 在针对用于语音情感识别的 Transformer 改进中，本文使用了两个相对独立的分支，两个分支的每一层之间不存在直接的交互。可以考虑通过可学习参数对各分支每一层的输出加权求和，将加权求和后的特征作为各分支下一层的输入特征，以此来引入不同分支之间的交互。

## 参考文献

- [1] Castellon R, Donahue C, Liang P. Codified audio language modeling learns useful representations for music information retrieval [C]//Proceedings of the 22nd International Society for Music Information Retrieval Conference. ISMIR, 2021: 88-96.
- [2] Zhang J, Zhang Z, Wang Y, et al. speechocean762: An Open-Source Non-Native English Speech Corpus for Pronunciation Assessment [C]//Proc. Interspeech 2021. 2021: 3710-3714.
- [3] Zhuang X, Huang J, Potamianos G, et al. Acoustic fall detection using gaussian mixture models and gmm supervectors [C]//2009 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2009: 69-72.
- [4] Dörfler M, Bammer R, Grill T. Inside the spectrogram: Convolutional neural networks in audio processing [C]//2017 International Conference on Sampling Theory and Applications (SampTA). 2017: 152-155.
- [5] Kong Q, Cao Y, Iqbal T, et al. Panns: Large-scale pretrained audio neural networks for audio pattern recognition [J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020, 28: 2880-2894.
- [6] Gong Y, Chung Y A, Glass J. Psla: Improving audio tagging with pretraining, sampling, labeling, and aggregation [J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 3292-3306.
- [7] Nam H, Kim S H, Ko B Y, et al. Frequency Dynamic Convolution: Frequency-Adaptive Pattern Recognition for Sound Event Detection [C]//Proc. Interspeech 2022. 2022: 2763-2767.
- [8] Gong Y, Chung Y A, Glass J. AST: Audio Spectrogram Transformer [C]//Proc. Interspeech 2021. 2021: 571-575.
- [9] Chen K, Du X, Zhu B, et al. Hts-at: A hierarchical token-semantic audio transformer for sound classification and detection [C]//ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 646-650.
- [10] Snyder D, Garcia-Romero D, Sell G, et al. X-vectors: Robust dnn embeddings for speaker recognition [C]//2018 IEEE international conference on acoustics, speech and

- signal processing (ICASSP). IEEE, 2018: 5329-5333.
- [11] Desplanques B, Thienpondt J, Demuynck K. ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification [C]//Proc. Interspeech 2020. 2020: 3830-3834.
- [12] Li X, Li N, Weng C, et al. Replay and synthetic speech detection with res2net architecture [C]//ICASSP 2021-2021 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2021: 6354-6358.
- [13] Jin X, Xie Y, Wei X S, et al. Delving deep into spatial pooling for squeeze-and-excitation networks [J]. Pattern Recognition, 2022, 121: 108159.
- [14] Dua M, Jain C, Kumar S. Lstm and cnn based ensemble approach for spoof detection task in automatic speaker verification systems [J]. Journal of Ambient Intelligence and Humanized Computing, 2022, 13(4): 1985-2000.
- [15] Chung J S, Huh J, Mun S, et al. In Defence of Metric Learning for Speaker Recognition [C]//Proc. Interspeech 2020. 2020: 2977-2981.
- [16] Liu B, Chen Z, Wang S, et al. Df-resnet: Boosting speaker verification performance with depth-first design. [C]//INTERSPEECH. 2022: 296-300.
- [17] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database [C]//2009 IEEE conference on computer vision and pattern recognition. IEEE, 2009: 248-255.
- [18] Aftab A, Morsali A, Ghaemmaghami S, et al. Light-serenet: A lightweight fully convolutional neural network for speech emotion recognition [C]//ICASSP 2022-2022 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2022: 6912-6916.
- [19] Ye J, Wen X C, Wei Y, et al. Temporal modeling matters: A novel temporal emotional modeling approach for speech emotion recognition [C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [20] Liu Z, Mao H, Wu C Y, et al. A convnet for the 2020s [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 11976-11986.
- [21] Ding X, Zhang X, Han J, et al. Scaling up your kernels to 31x31: Revisiting large kernel design in cnns [C]//Proceedings of the IEEE/CVF conference on computer vision and

- pattern recognition. 2022: 11963-11975.
- [22] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems: volume 30. Curran Associates, Inc., 2017.
- [23] Zhang Y, Lv Z, Wu H, et al. MFA-Conformer: Multi-scale Feature Aggregation Conformer for Automatic Speaker Verification [C]//Proc. Interspeech 2022. 2022: 306-310.
- [24] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [C]//International Conference on Learning Representations. 2021.
- [25] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows [C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [26] Chen W, Xing X, Xu X, et al. SpeechFormer: A Hierarchical Efficient Framework Incorporating the Characteristics of Speech [C]//Proc. Interspeech 2022. 2022: 346-350.
- [27] Chen S, Xing X, Zhang W, et al. Dwformer: Dynamic window transformer for speech emotion recognition [C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [28] Kim S H, Park Y H. Adaptive convolutional neural network for text-independent speaker recognition. [C]//Interspeech: volume 2021. 2021: 66-70.
- [29] Deng A, Wang S, Kang W, et al. On the importance of different frequency bins for speaker verification [C]//ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 7537-7541.
- [30] Wei Y, Du J, Liu H, et al. Ctfalite: Lightweight channel-specific temporal and frequency attention mechanism for enhancing the speaker embedding extractor. [C]//INTERSPEECH. 2022: 341-345.
- [31] Choi S, Kwak I Y, Oh S. Overlapped Frequency-Distributed Network: Frequency-Aware Voice Spoofing Countermeasure [C]//Proc. Interspeech 2022. 2022: 3558-3562.
- [32] Liu X, Lu H, Yuan J, et al. Cat: causal audio transformer for audio classification [C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [33] Ristea N C, Ionescu R T, Khan F S. SepTr: Separable Transformer for Audio Spectro-

- gram Processing [C]//Proc. Interspeech 2022. 2022: 4103-4107.
- [34] Bai Z, Zhang X L. Speaker recognition based on deep learning: An overview [J]. Neural Networks, 2021, 140: 65-99.
- [35] Mesaros A, Heittola T, Virtanen T, et al. Sound event detection: A tutorial [J]. IEEE Signal Processing Magazine, 2021, 38(5): 67-83.
- [36] Fahad M S, Ranjan A, Yadav J, et al. A survey of speech emotion recognition in natural environment [J]. Digital signal processing, 2021, 110: 102951.
- [37] 闫河, 董莺艳, 王鹏, 等. 基于 CNN-LSTM 网络的声纹识别研究 [J]. 计算机应用与软件, 2019, 36(4): 166-170.
- [38] Thienpondt J, Desplanques B, Demuynck K. Integrating Frequency Translational Invariance in TDNNs and Frequency Positional Information in 2D ResNets to Enhance Speaker Verification [C]//Proc. Interspeech 2021. 2021: 2302-2306.
- [39] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778.
- [40] Liu T, Das R K, Lee K A, et al. Mfa: Tdnn with multi-scale frequency-channel attention for text-independent speaker verification with short utterances [C]//ICASSP 2022-2022 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2022: 7517-7521.
- [41] Kim J h, Shim H j, Heo J, et al. Rawnext: Speaker verification system for variable-duration utterances with deep layer aggregation and extended dynamic scaling policies [C]//ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 7647-7651.
- [42] Zhao Z, Li Z, Wang W, et al. Pcf: Ecapa-tdnn with progressive channel fusion for speaker verification [C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [43] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [44] Zhu L, Lee F, Cai J, et al. An improved feature pyramid network for object detection [J]. Neurocomputing, 2022, 483: 127-139.

- [45] Jung Y, Kye S M, Choi Y, et al. Improving Multi-Scale Aggregation Using Feature Pyramid Module for Robust Speaker Verification of Variable-Duration Utterances [C]//Proc. Interspeech 2020. 2020: 1501-1505.
- [46] Deng J, Guo J, Xue N, et al. Arcface: Additive angular margin loss for deep face recognition [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 4690-4699.
- [47] Nagrani A, Chung J S, Zisserman A. Voxceleb: a large-scale speaker identification dataset [C]//INTERSPEECH. 2017.
- [48] Chung J S, Nagrani A, Zisserman A. Voxceleb2: Deep speaker recognition [C]//INTERSPEECH. 2018.
- [49] Snyder D, Chen G, Povey D. MUSAN: A Music, Speech, and Noise Corpus [Z]. 2015.
- [50] Ko T, Peddinti V, Povey D, et al. A study on data augmentation of reverberant speech for robust speech recognition [C]//2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2017: 5220-5224.
- [51] Gulati A, Qin J, Chiu C C, et al. Conformer: Convolution-augmented Transformer for Speech Recognition [C]//Proc. Interspeech 2020. 2020: 5036-5040.
- [52] 杨立东, 张壮壮. 改进卷积神经网络的音频场景分类研究 [J]. 现代电子技术, 2021, 44(3): 91-94.
- [53] Tolstikhin I O, Houlsby N, Kolesnikov A, et al. Mlp-mixer: An all-mlp architecture for vision [J]. Advances in neural information processing systems, 2021, 34: 24261-24272.
- [54] Yu W, Si C, Zhou P, et al. Metaformer baselines for vision [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023.
- [55] Gemmeke J F, Ellis D P, Freedman D, et al. Audio set: An ontology and human-labeled dataset for audio events [C]//2017 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2017: 776-780.
- [56] Fonseca E, Favory X, Pons J, et al. Fsd50k: an open dataset of human-labeled sound events [J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 30: 829-852.
- [57] Piczak K J. Esc: Dataset for environmental sound classification [C]//Proceedings of the 23rd ACM international conference on Multimedia. 2015: 1015-1018.
- [58] Ding X, Zhang X, Ma N, et al. Repvgg: Making vgg-style convnets great again [C]//

- Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13733-13742.
- [59] Zhang H, Cisse M, Dauphin Y N, et al. mixup: Beyond empirical risk minimization [C]//International Conference on Learning Representations. 2018.
- [60] Verbitskiy S, Berikov V, Vyshegorodtsev V. Eranns: Efficient residual audio neural networks for audio pattern recognition [J]. Pattern Recognition Letters, 2022, 161: 38-44.
- [61] Koutini K, Schlüter J, Eghbal-zadeh H, et al. Efficient Training of Audio Transformers with Patchout [C]//Proc. Interspeech 2022. 2022: 2753-2757.
- [62] Wu K, Peng H, Chen M, Fu J, Chao H. Rethinking and improving relative position encoding for vision transformer [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 10033-10041.
- [63] Busso C, Bulut M, Lee C C, et al. Iemocap: Interactive emotional dyadic motion capture database [J]. Language resources and evaluation, 2008, 42: 335-359.
- [64] Cao H, Cooper D G, Keutmann M K, et al. Crema-d: Crowd-sourced emotional multimodal actors dataset [J]. IEEE transactions on affective computing, 2014: 377-390.
- [65] Dang A, Vu T H, Wang J C, et al. Emix: a data augmentation method for speech emotion recognition [C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [66] Chen W, Xing X, Xu X, et al. Dst: Deformable speech transformer for emotion recognition [C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2023: 1-5.
- [67] Wang Y, Lu C, Lian H, et al. Speech swin-transformer: Exploring a hierarchical transformer with shifted windows for speech emotion recognition [C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2024: 11646-11650.
- [68] Ristea N C, Ionescu R T. Self-Paced Ensemble Learning for Speech and Audio Classification [C]//Proc. Interspeech 2021. 2021: 2836-2840.
- [69] Vu L, Phan R C W, Han L W, et al. Improved speech emotion recognition based on music-related audio features [C]//2022 30th European Signal Processing Conference (EUSIPCO). IEEE, 2022: 120-124.

## 插图目录

|                                     |    |
|-------------------------------------|----|
| 图 1-1 研究内容示意图 .....                 | 7  |
| 图 2-1 音频时频谱分类示意图 .....              | 9  |
| 图 2-2 声谱图提取过程示意图 .....              | 11 |
| 图 2-3 时频谱提取过程示意图 .....              | 12 |
| 图 2-4 时延神经网络原理示意图 .....             | 13 |
| 图 2-5 卷积神经网络原理示意图 .....             | 14 |
| 图 2-6 自注意力机制原理示意图 .....             | 16 |
| 图 2-7 分块化过程示意图 .....                | 17 |
| 图 3-1 提出的 TDNN 模型结构示意图 .....        | 20 |
| 图 3-2 前端模型结构示意图 .....               | 21 |
| 图 3-3 FPN 中的特征融合方法示意图 .....         | 23 |
| 图 3-4 提出的特征融合方法示意图 .....            | 24 |
| 图 4-1 TFECN 模型结构图 .....             | 36 |
| 图 4-2 时频增强卷积示意图 .....               | 38 |
| 图 4-3 权重迁移示意图 .....                 | 39 |
| 图 5-1 双分支 Transformer 模型结构示意图 ..... | 50 |
| 图 5-2 TDNN 分支示意图 .....              | 52 |
| 图 5-3 频率动态卷积示意图 .....               | 53 |

## 表格目录

|                                        |    |
|----------------------------------------|----|
| 表 3-1 提出模型的网络结构 .....                  | 28 |
| 表 3-2 VoxCeleb 中的对比实验结果 .....          | 30 |
| 表 3-3 VoxCeleb-O 中前端模型有效性实验结果 .....    | 31 |
| 表 3-4 VoxCeleb-O 中改进后主干模型有效性实验结果 ..... | 32 |
| 表 3-5 VoxCeleb 中模型超参数搜索实验结果 .....      | 32 |
| 表 4-1 FSD50K 中的消融实验结果 .....            | 44 |
| 表 4-2 AudioSet 中的对比实验结果 .....          | 45 |
| 表 4-3 FSD50K 和 ESC50 中的对比实验结果 .....    | 46 |
| 表 4-4 FSD50K 中模型超参数搜索实验结果 .....        | 46 |
| 表 5-1 IEMOCAP 和 CASIA 中的对比实验结果 .....   | 59 |
| 表 5-2 IEMOCAP 中的消融实验结果 .....           | 60 |
| 表 5-3 CREMA-D 中模型超参数搜索实验结果 .....       | 61 |

苏州大学  
硕士学位论文  
(专业学位)

苏州大学研究生院统一印制

中国知网 <https://www.cnki.net>